

Combatendo a Disseminação de Conteúdo Poluído em Redes Par-a-Par para Compartilhamento de Arquivos

Cristiano Costa, Vanessa Soares, Jussara Almeida, Virgílio Almeida

¹ Departamento de Ciência da Computação
Universidade Federal de Minas Gerais (UFMG)
Belo Horizonte, Brasil

{krusty, vanessa, jussara, virgilio}@dcc.ufmg.br

Abstract. Recent studies reported a new form of malicious behavior in file-sharing Peer-to-Peer (P2P) systems, namely, content pollution, which reduces content availability. This paper proposes Scrubber, a decentralized peer reputation system that imposes severe and quick punishment to content polluters but also promotes peer rehabilitation. We evaluate the efficiency of Scrubber in reducing pollution dissemination via simulation, comparing it against the Credence reputation system as well as a system without reputation. Two pollution mechanisms, namely, decoy insertion and identifier corruption, are considered. Our results show that, for various scenarios, Scrubber is able to quickly reduce the fraction of daily downloads to polluted content to a small percentage.

Resumo. Estudos recentes reportaram uma nova forma de comportamento malicioso em redes Par-a-Par (P2P) para compartilhamento de arquivos: a poluição de conteúdo. Este trabalho propõe Scrubber, um sistema descentralizado de reputação que impõe severa e rápida punição aos poluidores, porém também promove reabilitação. A eficiência do Scrubber em reduzir a poluição foi avaliada via simulação, comparando-o com o sistema de reputação Credence. Dois mecanismos de poluição foram considerados: inserção de cópias falsas e corrupção pelo identificador. Nossos resultados mostraram que o Scrubber reduz rapidamente a fração de downloads poluídos e comparado ao Credence apresenta uma convergência muito melhor e uma eficiência competitiva.

1. Introdução

O rápido crescimento no número de usuários, objetos compartilhados e volume de tráfego garantiram às Redes Par-a-Par (P2P) para compartilhamento de arquivos (ex.: eDonkey [eDonkey], FastTrack [Fasttrack] e BitTorrent [BitTorrent]) a posição de uma das mais importantes aplicações hoje na *Internet*. Os sistemas P2P atuais possuem uma grande quantidade de dados, dentre os quais estão *terabytes* de álbuns de música, filmes e seriados, documentos, *software* e jogos.

Este grande aumento na popularidade foi acompanhado por relatos de padrões de comportamento oportuno e malicioso, como *free-riding* [Adar and Huberman 2000] e conluio [Feldman et al. 2004], os quais impactam diretamente na escalabilidade das redes P2P. Recentemente foram apresentadas evidências de uma nova forma de comportamento malicioso: a poluição de conteúdo [Liang et al. 2005a]. Poluição consiste na disponibilização de objetos com o conteúdo corrompido, porém possuindo o metadado de um objeto

não corrompido. Como o conteúdo poluído pode ser somente detectado através de uma inspeção do áudio/vídeo, tipicamente usuários comuns acabam obtendo conteúdo poluído e desperdiçando banda e processamento com tráfego indesejado. Além disso, usuários comuns tendem a deixar os objetos poluídos obtidos em suas pastas de compartilhamento [Christin et al. 2005], de onde outros usuários podem realizar *download* e assim contribuir de forma passiva com a disseminação de conteúdo poluído na rede.

Pelo menos três mecanismos para disseminação de conteúdo poluído são conhecidos. A *Inserção de cópias falsas* consiste na inserção de versões poluídas de um determinado objeto [Liang et al. 2005a]. A *Corrupção pelo identificador* consiste em aproveitar da falha de algumas técnicas para gerar os identificadores dos objetos para inserir arquivos corrompidos [Benevenuto et al. 2006]. Finalmente, na *Poluição por Índice* o poluidor publica conteúdo que não existe na rede, reduzindo as chances de que um usuário encontre cópias válidas do objeto [Liang et al. 2006].

Relatos recentes indicam que conteúdo poluído é um problema real nas atuais redes P2P para compartilhamento de arquivos: mais de 80% de cópias de alguns arquivos populares no KaZaa [Fasttrack] estão poluídos [Liang et al. 2005a]. Todavia, os esforços na direção de reduzir a disseminação da poluição têm sido muito tímidos. Alguns trabalhos anteriores focam na modelagem e análise de diferentes mecanismos de disseminação de poluição [Costa et al. 2006, Benevenuto et al. 2006, Thommes and Coates 2006, Kumar et al. 2006]. Outros têm dado idéias gerais de como reduzir a disseminação de poluição [Liang et al. 2005a, Christin et al. 2005, Thommes and Coates 2006]. Mas somente alguns poucos propuseram e implementaram soluções práticas. Dentre eles, podemos citar os sistemas de reputação *Credence* [Walsh and Sirer 2006] e o *Eigentrust* [Kamvar et al. 2003], assim como um sistema de *lista negra* de pares [Liang et al. 2005b]. Contudo, a avaliação desses sistemas foi de certa forma limitada. Em particular, nenhuma comparação dos compromissos e desempenho relativo foi realizada.

Este trabalho propõe *Scrubber*, um sistema de reputação descentralizado e distribuído onde os pares atribuem reputação uns para os outros com a intenção de identificar e isolar os usuários maliciosos que disseminam conteúdo poluído ativamente na rede. Além disso, *Scrubber* impõe uma punição severa e rápida para os poluidores (recusando servir as suas requisições), mas também inclui incentivos para a reabilitação de pares que pararam de enviar conteúdo poluído. O *Scrubber* foi comparado com o *Credence*, uma arquitetura descentralizada onde usuários atribuem reputação para os *objetos* na rede e usam um protocolo distribuído de obtenção de votos para disseminar a reputação dos objetos. Assim sendo, estas comparações permitem destacar os principais compromissos de desempenho dessas duas abordagens.

O *Scrubber* e o *Credence* foram avaliados, assim como um sistema sem reputação no qual a poluição é reduzida somente pela escolha do par em apagar o conteúdo poluído, em um grande número de cenários. Em particular, nós consideramos dois mecanismos de disseminação de conteúdo poluído em nossa análise: A *Inserção de cópias falsas* e a *Corrupção pelo identificador*. Os resultados das simulações mostraram que ambos sistemas de reputação podem significativamente reduzir a disseminação de poluição em longo prazo. Contudo, para ambos mecanismos de poluição, o *Scrubber* converge rapidamente para um máximo de eficiência competitivo, reduzindo a fração de *downloads* diários de objetos poluídos para menos que 8%, se somente 25% dos pares reagem a punição im-

posta pelo *Scrubber* apagando seus objetos poluídos.

As demais seções deste trabalho estão organizadas da seguinte forma. A Seção 2 apresenta conceitos e trabalhos relacionados sobre a disseminação de conteúdo poluído. A Seção 3 descreve o novo sistema de reputação: *Scrubber*. A metodologia e os resultados principais da nossa avaliação de desempenho são apresentadas na Seção 4. Conclusões e trabalhos futuros são discutidos na Seção 5.

2. Trabalhos Relacionados

Esta seção, em um primeiro momento, discute evidências de comportamento malicioso e oportunista, em particular a disseminação de conteúdo poluído, nas redes P2P (Seção 2.1) e então brevemente aponta as soluções presentes na literatura (Seção 2.2). As principais características do sistema de reputação *Credence*, avaliado nesse trabalho, estão resumidas na Seção 2.3.

2.1. Comportamento Malicioso e Oportunista em Redes P2P

Um grande número de padrões de comportamento malicioso e oportunista tem sido observado nas redes P2P. Como exemplos, podemos citar *free-riding* (falta de cooperação dos usuários) [Adar and Huberman 2000], conluio de pares para tirar proveito do sistema [Feldman et al. 2004] e *sybil attack* [Cheng and Friedman 2005], onde uma entidade tenta dominar a rede instanciando um grande número de clientes.

Recentemente, uma nova forma de comportamento malicioso, conhecido como poluição de conteúdo, foi observada em redes P2P reais para compartilhamento de arquivos. Utilizando um *crawler* para procurar e obter arquivos do sistema KaZaa/fasttrack [Liang et al. 2005a], Liang *et al.* observou que a fração de cópias poluídas de arquivos populares pode ser maior que 80%. Christian *et al.* avaliou a disponibilidade e poluição do conteúdo em três grandes sistemas P2P.

Três mecanismos de disseminação de conteúdo poluído foram reportados na literatura. A *Inserção de cópias falsas* consiste na inserção de versões poluídas de um arquivo com o intuito de dificultar a localização de uma versão não poluída e fazer com que o usuário desperdice seus recursos realizando *download* de uma versão corrompida. A *Corrupção pelo identificador* consiste em explorar a fraqueza de algumas técnicas atuais de geração dos identificadores dos objetos para criar cópias poluídas de versões não poluídas. Desta forma, cada versão pode ter cópias poluídas e não poluídas tornando este um rápido mecanismo para disseminar poluição [Benevenuto et al. 2006]. Finalmente, a *poluição pelo índice* [Liang et al. 2006] consiste na publicação de arquivos e fontes inexistentes, fazendo com que a requisição de *download* de um determinado usuário nunca seja atendida.

A disseminação de conteúdo poluído para os vários mecanismos também tem sido estudada. Modelos de disseminação baseados em sistemas de equação diferencial e modelos de fluido foram propostos em [Kumar et al. 2006, Thommes and Coates 2006]. Costa *et al.* [Costa et al. 2006] analisou, via simulação, o impacto de dar incentivos para os usuários apagarem seu conteúdo poluído. Pouwelse *et al.* [Pouwelse et al. 2005] analisou o impacto da inserção de arquivos *torrents* poluídos no BitTorrent/Suprnova [BitTorrent], concluindo que os moderadores conseguem dificultar a ação dos usuários maliciosos em disseminar conteúdo poluído.

2.2. Mecanismos para Combater a Disseminação de Poluição

Algumas idéias foram propostas para reduzir a disseminação de poluição nas redes P2P [Liang et al. 2005a, Thommes and Coates 2006, Kumar et al. 2006]. Contudo, somente poucos trabalhos práticos foram realmente implementados. Em [Liang et al. 2005b], os autores propõem uma estratégia baseada em uma lista negra centralizada de pares. Esta lista negra é atualizada por *crawlers* que monitoram o tráfego P2P procurando por pares que demonstram características de comportamento malicioso (ex.: múltiplos clientes numa mesma máquina). Apesar dos resultados promissores em isolar os usuários maliciosos, a lista negra centralizada sofre potencialmente de problemas de escalabilidade, tolerância a falhas e segurança.

Temos conhecimento de dois sistemas de reputação descentralizados para reduzir a disseminação de conteúdo poluído: Eigentrust e *Credence*. O sistema de reputação Eigentrust [Kamvar et al. 2003] mantém uma reputação global para cada par i . Essa reputação é computada a partir da reputação i atribuída pelos outros pares da rede e pesada por suas reputações globais. Contudo, a necessidade de um conjunto de pares pré-confiáveis para computar a reputação global levanta algumas considerações práticas que precisam ser avaliadas. O funcionamento do *Credence* [Walsh and Sirer 2005] é apresentado na Seção 2.3.

Outros sistemas de reputação também têm sido propostos para reduzir o impacto de *free-riding* em Grades para compartilhamento de CPU [Andrade et al. 2004] e comportamento egoísta (*free-riding*) em redes sobrepostas de roteamento [Rocha et al. 2006a, Rocha et al. 2006b]. Mecanismos de incentivo para combater *free-riding* em redes P2P também foram propostos em [Feldman et al. 2004, Dutta et al. 2003].

2.3. O Sistema de Reputação Credence

O *Credence* [Walsh and Sirer 2005, Walsh and Sirer 2006] é um sistema descentralizado e distribuído, onde os usuários atribuem reputações para os *objetos* aos quais realizaram *download*. Seu funcionamento é baseado em um protocolo distribuído de obtenção de votos para disseminar a reputação dos objetos pela rede e um esquema de correlação que dá mais peso para votos vindos de pares que tendem ter a mesma opinião.

O sistema funciona da seguinte forma. Antes de um par A realizar um *download*, ele dispara uma *pesquisa de votos* na rede para coletar votos sobre o objeto desejado. Os votos coletados podem ser -1 , se o par considerar o objeto *poluído*, ou 1 , caso contrário. Os votos coletados por A são agregados em uma medida de reputação, que é usada para decidir se o *download* de determinado objeto deve ser realizado. Esta agregação é realizada pesando cada voto pelo *relacionamento* que A possui com o votante.

Este relacionamento entre dois pares, expressado pela *correlação* de seus históricos de votos, captura se eles tendem a votar identicamente (correlação positiva), inversamente (correlação negativa) ou se eles têm um histórico de votos não correlacionado. A correlação entre os pares A e B é computada da seguinte forma:

$$\theta(A, B) = \frac{(p - ab)}{\sqrt{a(1-a)b(1-b)}} \quad (1)$$

onde, a é a fração de votos positivos dados por A no passado, b a fração de votos positivos dados por B e p a fração em que ambos pares votaram positivamente.

Quando está computando a reputação de um objeto, o par A pesa o voto do par B por $r(A, B)$ e segue a seguinte expressão:

$$r_{A,B} = \begin{cases} \theta(A, B) & \text{se } |\theta(A, B)| \geq 0.5 \\ 0 & \text{caso contrário} \end{cases} \quad (2)$$

Note que o peso $r(A, B)$ é fixado em 0 sempre que A e B possuírem um histórico de votos não correlacionado, ou seja, neste caso os votos de B são desconsiderados pelo par A .

Cada par sempre armazena localmente todos os votos coletados em um *banco de dados de votos*, sem levar em consideração se o *download* foi realizado. Além disso, todas as *correlações fortes* ($|\theta(A, B)| \geq 0.5$) encontradas são armazenadas localmente em uma *tabela de correlação* que é atualizada periodicamente a partir do *banco de dados de votos*.

O *Credence* também executa um *protocolo de fofoca* para descobrir *correlações transitivas*. As correlações transitivas são correlações descobertas por outros pares na rede. Periodicamente, um par A seleciona aleatoriamente um par B e obtém os coeficientes de correlação conhecidos por B . As correlações encontradas são então computadas multiplicando os coeficientes de correlação obtidos pelo peso $r(A, B)$. Todas as correlações transitivas fortes também são armazenadas na tabela de correlação.

3. O Sistema de Reputação Scrubber

Scrubber é um novo sistema de reputação desenhado para identificar e isolar pares maliciosos que ativamente disseminam conteúdo poluído nas redes P2P para compartilhamento de arquivos. Além disso, *Scrubber* permite a reabilitação dos *poluidores passivos* (pares compartilham conteúdo poluído por descuido) atribuindo incentivo para que eles apaguem o conteúdo poluído que receberam e mantiveram em suas pastas de compartilhamento. O *Scrubber* é descentralizado e distribuído, respeitando o modo de funcionamento dos sistemas P2P atuais e facilitando assim sua implantação.

O desenho do *Scrubber* foi inspirado em um sistema de reputação proposto para combater comportamento egoísta em redes sobrepostas de roteamento [Rocha et al. 2006a, Rocha et al. 2006b]. Os principais conceitos da proposta original foram modificados e estendidos para capturar as peculiaridades da disseminação de poluição em rede P2P reais para compartilhamento de arquivos.

No *Scrubber*, os pares atribuem reputação uns para os outros. Reputações são construídas a partir de dois componentes principais: a *Experiência Individual* e o *Testemunho*.

A *experiência individual* de um par i a respeito do par j é a confiança que i tem em j baseado nos objetos obtidos dele anteriormente. Depois de cada objeto obtido de j , o par i atualiza sua *experiência individual* com j , $I_{i(j)}$, da seguinte forma:




Figura 1. Funcionamento do *Scrubber* em um Sistema com Três Pares (A, B e C).

$$I_{i(j)} = \begin{cases} \min(0, I_{i(j)} - \alpha_d n^2) & \text{se o objeto é poluído} \\ \max(1, I_{i(j)} + \alpha_i) & \text{caso contrário} \end{cases} \quad (3)$$

onde n é o número de *downloads* consecutivos de objetos poluídos de j (incluindo o último). Temos também, α_d e α_i que representam a penalidade e recompensa dados para o par j para cada objeto poluído e não poluído enviado, respectivamente. Note que a *experiência individual* diminui mais rápido do que aumenta. Visando penalizar severamente os poluidores, em particular aqueles que somente enviam ocasionalmente objetos não poluídos, o *Scrubber* pesa o parâmetro α_d com o quadrado do número de objetos poluídos enviados consecutivamente. Além disso, dado que tipicamente ocorrem poucas transferências entre dois pares, foi preciso modificar e estender [Rocha et al. 2006a, Rocha et al. 2006b] para conseguir aplicar de forma eficiente as punições no cenário das redes P2P. Foram utilizados diferentes fatores de penalidade e recompensa, e proposto $\alpha_d > \alpha_i$. A *Experiência Individual* de qualquer par i relativo a um par desconhecido j é inicialmente fixado em R_{init} .

O *Testemunho* captura a opinião da comunidade (ou seja, a rede) sobre um par j . No trabalho em [Rocha et al. 2006a, Rocha et al. 2006b] é assumido que os nós sempre têm, em todo instante, Testemunhos sobre todos os outros nós. Afim de facilitar a implantação do *Scrubber* em redes P2P de grandes proporções, foi proposto a *Pesquisa por Testemunho*. Periodicamente, cada par i envia uma *Pesquisa por Testemunho* para um par k selecionado aleatoriamente. As *experiências individuais* de todos os outros pares que k interagiu no passado é retornada para i . Esta informação é utilizada por i , antes da realização de um novo *download*, para atualizar o *Testemunho* da comunidade sobre j da seguinte maneira:

$$T_{i(j)} = \frac{\sum_{k \in N_{i(j)}} I_{k(j)} R_{i(k)}}{\sum_{k \in N_{i(j)}} R_{i(k)}} \quad (4)$$

onde $N_{i(j)}$ é a lista dos pares que enviaram para i no passado suas experiências sobre j . $R_{i(j)}$, definido abaixo, é a reputação atual do par j atribuída por i . Note que as experiências individuais obtidas na comunidade são pesadas pelas reputações locais de suas fontes para evitar difamação. Finalmente, essa opinião da comunidade ajuda aos pares identificar poluidores em potencial, assim como promover a *reabilitação* de pares que apagaram o conteúdo poluído de suas pastas de compartilhamento. Se nenhum testemunho sobre j foi coletado, $T_{i(j)} = R_{init}$.

Antes e depois de cada *download*, o par i computa a reputação local de todos os pares j , $R_{i(j)}$, da seguinte maneira:

$$R_{i(j)} = \beta T_{i(j)} + (1 - \beta) I_{i(j)} \quad (5)$$

onde β ($0 \leq \beta \leq 1$) controla os pesos dados para a *experiência individual* e o *testemunho*. O parâmetro $R_{min(i)}$ ($0 \leq R_{min(i)} \leq R_{init}$) é a reputação mínima que um par deve ter para ser considerado confiável por i . Um par i não envia objetos e nem realiza *downloads* para pares que ele não considera confiáveis. Note que, recusando enviar objetos a esses pares, *Scrubber* dá incentivo para que os *poluidores passivos* apaguem seus objetos poluídos, já que essa é a única forma dos poluidores passivos aumentarem a sua reputação na rede e ter suas futuras requisições de *download* servidas. A *reabilitação* dos poluidores passivos pode ser facilitada se os pares utilizarem diferentes valores de $R_{min(i)}$, visto que um par considerado não confiável por i pode readquirir sua confiança aumentando sua reputação com outros pares k que possuam valores $R_{min(k)}$ mais baixos, e assim tendo a sua reputação aumentada em i através dos testemunhos.

Iremos agora ilustrar a operação do *Scrubber* em uma rede hipotética com três pares, A , B e C . A Figura 1 mostra como a reputação de C atribuída pelo par A , $R_{A(C)}$, evolui com o decorrer do tempo. Os parâmetros do sistema são $R_{min(A)} = 0.35$, $\alpha_d = 0.2$, $\alpha_i = 0.4$, e $\beta = 0.5$. Inicialmente, nós fixamos $I_{A(C)} = I_{B(C)} = 0.5$, $T_{A(C)} = 0.5$, e $R_{A(B)} = 0.7$.

No instante 2, A recebe um objeto poluído de C , diminui $I_{A(C)}$ para 0.1 e $R_{A(C)}$ para 0.3. Como $R_{A(C)} < R_{min(A)}$, A considera C não confiável e recusa sua requisição de *download* recebida duas unidades de tempo depois. Motivado por esta negação de serviço, C apaga seus objetos poluídos. Durante as próximas duas unidades de tempo, B recebe um objeto não poluído de C e aumenta $I_{B(C)}$ para 0.7 (não mostrado na figura). No instante 6, A envia uma *pesquisa por testemunho* para B e obtém a sua *experiência individual* sobre C , $I_{B(C)}$. No instante 8, antes de iniciar um novo *download*, A utiliza $I_{B(C)}$ para atualizar $T_{A(C)}$ para 0.7 e $R_{A(C)}$ para 0.4. A considera C confiável novamente e inicia um *download* dele. Depois que o processo termina (instante 10), A aumenta $I_{A(C)}$ para 0.3 e $R_{A(C)}$ para 0.5.

4. Avaliação de Desempenho

Esta seção apresenta a avaliação, via simulação, do *Scrubber* e do *Credence*, comparando-os com um *sistema básico* no qual a poluição é somente reduzida se os pares apagarem o

conteúdo poluído obtido. As duas métricas principais utilizadas nesta análise é a *eficiência* e *convergência*. A primeira está relacionada com a eficácia do sistema em reduzir a disseminação de poluição e é medida a partir da fração de *downloads* poluídos ao longo do tempo. A outra métrica está relacionada com tempo necessário para que o sistema alcance a sua eficiência máxima.

A Seção 4.1 apresenta o modelo de simulação. Os principais resultados são discutidos na Seção 4.2.

4.1. Modelo de Simulação

Foi construído um simulador orientado por eventos capaz de reproduzir os principais aspectos que influenciam na análise da disseminação de conteúdo poluído nas redes P2P para compartilhamento de arquivos. As principais características desse simulador são:

A Rede: o foco principal deste estudo é a propagação de um determinado objeto na rede. Portanto, não foi modelado nenhuma rede P2P específica. Particularmente, foi assumido que a pesquisa e descoberta de pares/objetos na rede é perfeita. O *download* pode ser realizado a partir de múltiplas fontes (F) aleatoriamente selecionadas daqueles pares que estão compartilhando o objeto requisitado. É assumido que o *download* é realizado instantaneamente e todo objeto obtido é compartilhado.

Objetos: existem no sistema A arquivos únicos, cada qual com V versões únicas. Cada versão tem um número de cópias que varia com o passar do tempo. No início da simulação, os objetos compartilhados por um par são escolhidos primeiramente selecionando o *arquivo* e logo então a *versão*. Ambas seleções são realizadas seguindo uma distribuição Zipf com parâmetro $\alpha = 0.8$ [Liang et al. 2005a]. Com a simulação em andamento, a seleção de objetos para *download* é realizada primeiramente selecionando o *arquivo* com a Zipf, e então selecionando a *versão* a partir da sua popularidade atual no sistema (ex.: número de cópias).

Pares: no modelo existem duas classes de pares: *pares normais* e *poluidores ativos*. Na inicialização do simulador, *poluidores* compartilham somente objetos poluídos e os *pares normais* somente objetos não poluídos. Um *par normal* pode realizar *download* e deixar ou entrar no sistema, durante a simulação. O tempo entre *downloads* consecutivos e o tempo de atividade/inatividade dos pares são exponencialmente distribuídos.

Disseminação de Poluição: a disseminação de conteúdo poluído foi simulado utilizando os mecanismos de *inserção de cópias falsas* [Liang et al. 2005a] e *corrupção pelo identificador* [Benevenuto et al. 2006]. No início da simulação, cada *poluidor* e *pares normais* selecionam seus objetos locais de forma que a probabilidade de se escolher um objeto poluído (de uma única fonte) seja 0.5. Para a *inserção de cópias falsas*, é garantido que todas as cópias de uma versão poluída estejam poluídas.

4.2. Resultados

Os resultados discutidos se referem aos parâmetros apresentados na Tabela 1. Os parâmetros apresentados foram variados e experimentados com variadas configurações. Especialmente, experimentos variando o número de nós foram realizados com valores mais altos e consistentes com os encontrados em caracterizações, como por exemplo 1000 nós [Gummadi et al. 2003]. Os resultados encontrados nestes cenários foram semelhantes aos

PARÂMETRO	VALOR	
# arquivos únicos A	100	
# versões únicas V	500	
# múltiplas fontes F	10	
seleção de arquivo	Zipf ($\alpha = 0.8$)	
seleção de versão (início)	Zipf ($\alpha = 0.8$)	
PARÂMETRO	PARES NORMAIS	POLUIDORES
# pares	180	20
# objetos compartilhados (início)	20	90
taxa de <i>download</i>	4 objetos/dia	0
tempo ativo (μ)	12 horas	∞
tempo inativo (μ)	12 horas	-

Tabela 1. Parâmetros da Simulação

apresentados, porém o número de interações entre pares no qual o simulador foi capaz de executar foi insuficiente para realizar análises sobre a convergência dos sistemas de reputação. Outras simulações foram realizadas com diferentes configurações e resultados qualitativamente similares foram obtidos.

Para os experimentos com o *Scrubber*, foi utilizado $\alpha_d = 0.4$, $\alpha_i = 0.1$ e $R_{init} = 0.5$. Os valores da variável $R_{min(i)}$ são uniformemente distribuídos entre 0.1 e 0.4, e a *pesquisa por testemunho* é enviada uma vez a cada hora. O *Scrubber* foi experimentado para diferentes valores de α_d e α_i e em todos os experimentos, garantindo que $\alpha_d \geq \alpha_i$, o sistema se comporta de forma similar ao reportado com menor ou maior convergência refletindo punições mais ou menos severas. Para os experimentos com o *Credence*, foi assumido que a *tabela de correlação* é atualizada antes de cada *download*. Visando manter uma comparação justa com o *Scrubber*, foi ajustado para 1 hora o intervalo entre execuções do *protocolo de fofoca*. Todos os resultados são médias de 5 execuções apresentando um desvio padrão menor do que 5% da média.

Ambos *Scrubber* e *Credence* necessitam da *opinião do usuário* sobre os objetos obtidos, para assim calcular a *Experiência Individual* e o *Voto do Objeto*, respectivamente. Portanto, foram considerados diferentes cenários baseados na probabilidade de que um usuário queira dar sua opinião. Para o *sistema básico*, a *opinião do usuário* é a probabilidade de que o usuário apague o objeto poluído imediatamente após o recebimento. Para o *Scrubber*, outros cenários foram construídos variando a probabilidade de que um par apague todos os seus objetos poluídos após ter uma requisição de *download* recusada, referenciado como δ .

Primeiramente será discutido os resultados quando a poluição é disseminada via a *inserção de cópias falsas*. A Figura 2-a mostra a fração diária de *downloads* não poluídos quando a *opinião do usuário* é 1. Para o *Scrubber*, é apresentado os resultados utilizando $\beta = 1.0$ e executando-o para dois cenários extremos: quando $\delta = 1$, ou seja, pares punidos sempre apagam seu conteúdo poluído e quando $\delta = 0$, ou seja, pares punidos nunca apagam seu conteúdo poluído. Note que o *Scrubber* converge rapidamente para o máximo de eficiência em ambos cenários. Isolando os *poluidores ativos* no início da simulação,




Figura 2. Eficiência dos Sistemas de Reputação para a disseminação por Inserção de Cópias Falsas

o *Scrubber* garante que, dentro de 8 dias após a introdução do conteúdo poluído na rede, pelo menos 89% de toda a fração de *downloads* são de objetos não poluídos, mesmo se nenhum par apaga seus objetos poluídos ($\delta = 0$). Uma eficiência de 100% não é alcançada devido aos objetos poluídos armazenados, mas não constantemente enviados, pelos *poluidores passivos*. Os *poluidores passivos* são *pares normais* que realizaram *download* de objetos poluídos. Esses *poluidores passivos* enviam uma quantidade de arquivos não poluídos maior que poluídos e portanto conseguem uma reputação agregada na rede (sendo $\beta = 1.0$) alta o suficiente para escapar da punição. Se os pares punidos sempre apagarem o conteúdo poluído ($\delta = 1$), o *Scrubber* apresenta resultados ainda melhores, convergindo em 12 dias para uma fração máxima de 93% de *downloads* de objetos não poluídos.

O *Credence*, por outro lado, leva muito mais tempo para atingir a mesma eficiência máxima do *Scrubber*. Ele alcança a fração de 89% e 93% de *downloads* diários de objetos não poluídos em 32 e 44 dias após a introdução da poluição. Contudo, pelo fato de o *Credence* reputar objetos, o conteúdo poluído compartilhado pelos *poluidores passivos* é eventualmente isolado. Deste modo, o *Credence* reduz a fração de *downloads* de objetos poluídos de forma estável ao longo do tempo, ultrapassando a eficiência do *Scrubber* no final da simulação, porém em não mais do que 9%. Como esperado, ambos sistemas de reputação conseguem resultados significativamente melhores do que o *sistema básico*.




Figura 3. Eficiência dos Sistemas de Reputação para a disseminação por *Corrupção pelo Identificador*

A Figura 2-b mostra resultados similares quando a *opinião do usuário* é igual a 0.25. Todos os sistemas são penalizados pela falta de cooperação da comunidade. Contudo, as penalidades severas impostas pelo *Scrubber* aos *poluidores* fazem com que este seja mais robusto à falta de cooperação. De fato, se os pares punidos sempre apagarem seus conteúdos poluídos, o *Scrubber* alcança aproximadamente o mesmo máximo de eficiência do cenário anterior, com um pequeno aumento no tempo de convergência. Se, por outro lado, os pares punidos nunca apagarem seus conteúdos poluídos, um máximo de eficiência é alcançado em 16 dias, o qual é somente 10% menor que o máximo de eficiência alcançado pelo *Credence* em 100 dias de operação.

A Figura 2-c mostra os resultados para o *Scrubber* com $\beta = 0.25$. Comparando-os com a Figura 2-a, é possível observar que se o conteúdo poluído nunca é apagado, o aumento do β favorece a convergência e eficiência, já que a opinião da comunidade ajuda aos pares fazerem uma melhor escolha nas suas decisões de *download*. Por outro lado, se o conteúdo poluído é sempre apagado pelos pares punidos, a opinião agregada da comunidade incentiva aos *poluidores passivos* compartilharem conteúdo misto (poluído e não poluído). Neste caso, favorecer a *Experiência Individual* aumenta as chances de que os *poluidores passivos* sejam punidos. Como consequência, os objetos poluídos são apagados num espaço de tempo que, apesar de longo, é razoável e muito menor que a convergência do *Credence* para uma eficiência similar.

Para a poluição disseminada pelo mecanismo de *corrupção pelo identificador*, os resultados das Figuras 3-a, 3-b e 3-c são qualitativamente similares aos apresentados para a poluição por *inserção de cópias falsas*. Como discutido em [Benevenuto et al. 2006], esse mecanismo consegue disseminar o conteúdo poluído muito rapidamente. Todavia, ambos *Credence* e *Scrubber* são capazes de reduzir a disseminação de conteúdo poluído de forma eficiente. Em particular, se $\delta = 1$, o *Scrubber* é capaz de limpar praticamente todos os objetos poluídos da rede muito mais rapidamente que o *Credence*, mesmo quando somente 25% dos usuários cooperam. Finalmente, a Figura 3-d mostra como o *Scrubber* se comporta para diferentes valores de δ . Note que, comparado com o *Credence*, o *Scrubber* ainda provê uma melhor convergência e eficiência competitiva mesmo se somente 25% dos pares punidos apagarem seu conteúdo poluído. Resultados semelhantes foram obtidos para valores mais baixos de β e para a disseminação de poluição pelo mecanismo de *Inserção de Cópias Falsas*.

5. Conclusões e Trabalhos Futuros

Este artigo propõe *Scrubber*, uma novo sistema descentralizado e distribuído onde os pares colaboram atribuindo reputação uns para os outros como sendo fonte de conteúdo poluído. O *Scrubber* foi avaliado comparando a sua eficiência em reduzir a disseminação de conteúdo poluído com o sistema de reputação de objetos *Credence* e com um sistema que não utiliza reputação. A comparação realizada considera dois mecanismos de disseminação de poluição: *inserção de cópias falsas* e a *corrupção pelo Identificador*. O resultados mostraram que ambos *Credence* e *Scrubber* podem efetivamente reduzir a fração de *downloads* poluídos. Contudo, para ambos mecanismos de disseminação de poluição, o *Scrubber* tem uma rápida convergência e um eficiência competitiva, a não ser nos casos que a fração de pares que apagam os objetos poluídos em resposta à punição recebida seja muito pequena ($\delta < 0.25$). Neste caso, o *Credence* alcança uma fração de *downloads* de objetos não poluídos que é 9% e 10% maiores que o *Scrubber*, para a *inserção de cópias falsas* e *corrupção pelo identificador*, respectivamente.

Trabalhos Futuros incluem a avaliação do *Scrubber* quando submetido a a padrões de comportamento malicioso como por exemplo o conluio, *Whitewashing*, *Sybil* e ataques do tipo Traidor. Pretende-se também desenhar, implementar e avaliar de um sistema de reputação híbrido que combina os benefícios da reputação de par (ex.: *Scrubber*) e objeto (ex.: *Credence*).

Referências

- Adar, E. and Huberman, B. A. (2000). Free Riding on Gnutella. *First Monday*.
- Andrade, N., Brasileiro, F., Cirne, W., and Mowbray, M. (2004). Discouraging Free Riding in a Peer-to-Peer CPU-Sharing Grid. In *Proc. of 13th High Performance Distributed Computing Symposium*.
- Benevenuto, F., Costa, C., Vasconcelos, M., Almeida, V., Almeida, J., and Mowbray, M. (2006). Impact of Peer Incentives on the Dissemination of Polluted Content. In *Proc. of 21st ACM SAC*, Dijon, France.
- BitTorrent. <http://www.bittorrent.com>.
- Cheng, A. and Friedman, E. (2005). Sybilproof reputation mechanisms. In *In Proc. of P2PECON*, pages 128–132, New York, NY, USA. ACM Press.

- Christin, N., Weigend, A. S., and Chuang, J. (2005). Content Availability, Pollution and Poisoning in File Sharing Peer-to-Peer Networks. In *Proc. of ACM E-Commerce Conference*, Vancouver, Canada.
- Costa, C., Soares, V., Benevenuto, F., Vasconcelos, M., Almeida, J., Almeida, V., and Mowbray, M. (2006). Disseminação de Conteúdo Poluído em Redes P2P. In *Proc. of 24th SBRC*, Curitiba, Brazil.
- Dutta, D., Goel, A., Govindan, R., and Zhang, H. (2003). The Design of a Distributed Rating Scheme for Peer-to-Peer Systems. In *Proc. of P2Pcon*.
- eDonkey. <http://www.edonkey2000.com>.
- Fasttrack. <http://www.fasttrack.com>.
- Feldman, M., Lai, K., Stoica, I., and Chuang, J. (2004). Robust Incentive Techniques for Peer-to-Peer Networks. In *Proc. of the 5th ACM conference on Electronic commerce*, New York, NY, USA.
- Gummadi, K., Dunn, R., Saroiu, S., Gribble, S., Levy, H., and Zahorjan, J. (2003). Measurement, Modeling, and Analysis of a Peer-to-Peer File-Sharing Workload. In *Proc. of SOSp*, Bolton Landing, NY, USA.
- Kamvar, S., Schlosser, M., and Garcia-Molina, H. (2003). The Eigentrust Algorithm for Reputation Management in P2P Networks. In *Proc. of International WWW Conference*, Budapest, Hungary.
- Kumar, R., Yao, D., Bagchi, A., Ross, K., and Rubenstein, D. (2006). Fluid Modeling of Pollution Proliferation in P2P Networks. In *Proc. of ACM Sigmetrics*, Saint-Malo, France.
- Liang, J., Kumar, R., Xi, Y., and Ross, K. W. (2005a). Pollution in P2P File Sharing Systems. In *Proc. of IEEE Infocom*, Miami, FL, USA.
- Liang, J., Naoumov, N., and Ross, K. (2005b). Efficient Blacklisting and Pollution-Level Estimation in P2P File-Sharing Systems. In *Proc. of AINTEC*, Bangkok, Thailand.
- Liang, J., Naoumov, N., and Ross, K. (2006). The Index Poisoning Attack in P2P File-Sharing Systems. In *Proc. of IEEE Infocom*, Barcelona, Catalunya, Spain.
- Pouwelse, J., Garbacki, P., Epema, D., and Sips, H. (2005). The BitTorrent P2P File-sharing System: Measurements and Analysis. In *Proc. of IPTPS*, Ithaca, NY, USA.
- Rocha, B., Almeida, V., and Guedes, D. (2006a). Estratégias para Aumento de Confiabilidade em Redes de Roteamento Sobrepostas com Nós Egoístas.
- Rocha, B., Almeida, V., and Guedes, D. (2006b). Increasing the Quality of Service in Selfish Overlay Networks. *IEEE Internet Computing*.
- Thommes, R. and Coates, M. (2006). Epidemiological Modelling of Peer-to-Peer Viruses and Pollution. In *Proc. of IEEE Infocom*, Barcelona, Catalunya, Spain.
- Walsh, K. and Sirer, E. G. (2005). Fighting Peer-to-Peer SPAM and Decoys with Object Reputation. In *Proc. of P2Pcon*, Philadelphia, PA, USA.
- Walsh, K. and Sirer, E. G. (2006). Experience With a Distributed Object Reputation System for Peer-to-Peer Filesharing. In *Proc. of NSDI*, San Jose, California.

