

Localização de Dispositivos Móveis em Redes WiFi usando Variação da Potência de Transmissão e kNN

Helmer A. S. Mourão, Horácio A. B. Fernandes de Oliveira

¹Instituto de Informática – Universidade Federal do Amazonas (UFAM)
Manaus – AM – Brazil

{helmermourao, horacio}@icomp.ufam.edu.br

Abstract. *Indoor localization systems are usually based in the signal strength of packets received by a set of WiFi routers. Among the most precise solutions, are those based in trainment, that use previously recorded received signal strength indications (RSSI) to allow a classifier, such as kNN (k-Nearest Neighbor) to estimate the position. In these solutions, packets are sent by the mobile devices using the same transmission power. In this paper, we go further and propose the use of different transmission powers, so the information about the signal fading can be taken into consideration by the classifier. Our results clearly indicate significant improvement when compared to the traditional solutions. In some configuration, our solution resulted in less than 1 m error in 96% of the cases.*

Resumo. *Sistemas de localização de dispositivos móveis em ambientes internos são geralmente baseados na potência de recepção de pacotes em um conjunto de roteadores WiFi. Dentre as soluções de localização mais precisas, estão as baseadas em treinamentos, que utilizam informações previamente coletadas de potências de sinais recebidos (RSSI - Received Signal Strength Indication) para permitir que um classificador, como o kNN (k-Nearest Neighbor), estime a posição. Em tais abordagens, os pacotes são enviados pelos dispositivos móveis sempre com a mesma potência de transmissão. Neste artigo, vamos além e propomos o envio dos pacotes em diferentes potências de transmissão, para que a característica de queda do sinal possa também ser levada em consideração pelo classificador. Os resultados obtidos foram animadores e mostraram ganhos significativos quando comparado às abordagens tradicionais encontradas na literatura obtendo, em algumas configurações, erros menores que 1 m em 96% dos casos.*

1. Introdução

Nos últimos anos tem-se observado a massificação dos dispositivos móveis no mercado consumidor tais quais *notebooks*, *netbooks*, aparelhos celulares e *smartphones* [Santos et al. 2011]. Isso, aliado ao aumento da capacidade de processamento e o surgimento de novas tecnologias de comunicação, possibilitou o desenvolvimento de aplicativos orientados a contexto [Moura 2007]. Em tais aplicativos, um dos pontos essenciais é localizar o dispositivo no ambiente em que ele se encontra.

Uma das principais soluções para a localização/posicionamento é a utilização de receptores GPS (*Global Positioning System*), já disponível em muitos dos dispositivos

móveis. Entretanto, tal sistema tem uma baixa performance em ambientes internos devido à falta de visada direta aos satélites, o que impede ou gera erros de localização inaceitáveis [Ni et al. 2004]. Portanto, em tais casos, um sistema de localização local é necessário.

Um desafio para os sistemas móveis é ser o mínimo invasivo possível, através da obtenção das informações necessárias de forma imperceptível. Nesse aspecto, um sistema de localização que se aproveita da infraestrutura de rede WiFi já existente em edifícios e locais públicos torna-se algo bastante desejável. Dentre as principais soluções para localização em ambientes internos encontram-se as soluções baseadas em treinamentos [Moura 2007, Ni et al. 2004, Jan and Lee 2003], Ekahau¹, que utilizam informações previamente coletadas de potências de sinais recebidos (RSSI - *Received Signal Strength Indication*) para permitir que um classificador, como o kNN (*k-Nearest Neighbor*), estime a posição dos nós. Tais soluções têm sido consideradas ultimamente devido a dois motivos principais: (1) disponibilidade das informações de potência do sinal sem necessidade de equipamentos extras; e (2) imunidade do sistema à grande variação e imprevisibilidade do RSSI em ambientes internos.

Nos sistemas baseados em treinamento, é comum que o dispositivo móvel envie alguns pacotes com uma certa potência de transmissão e estes serão recebidos por diversos roteadores com potências de recepção diferentes dependendo do posicionamento deles. Tais informações de potência de recepção serão utilizadas para determinar a posição do nó móvel através do classificador.

Neste trabalho, vamos além e experimentamos tal técnica através da variação da potência de transmissão dos pacotes enviados pelos nós móveis. Desta forma, na nossa solução, chamada SPoT (Sistema de Posicionamento com variação da Potência de Transmissão), ao invés de enviarmos diversos pacotes com a mesma potência de transmissão, enviamos diversos pacotes cada um com uma potência de transmissão diferente. O objetivo dessa variação é que o comportamento da queda dos sinais possa servir como uma característica extra para o classificador usado como, no nosso caso, o kNN [Bahl and Padmanabhan 2000], resultando em erros menores de localização.

O restante deste trabalho está organizado como segue. Na Seção 2, apresentamos os trabalhos relacionados. A Seção 3 descreve o sistema de localização proposto, cuja avaliação de performance é mostrada na Seção 4. Finalmente, na Seção 5, apresentamos nossas conclusões e trabalhos futuros.

2. Trabalhos Relacionados

Nos algoritmos baseados em treinamento, também conhecidos como *fingerprinting*, mapas de RSSI são previamente gerados com base nos valores de RSSI obtidos nos diferentes pontos do local em que se deseja ter a localização. Em seguida, um classificador usa tais informações para estimar a posição dos nós. Um classificador muito utilizado para este fim é o kNN (*k-Nearest Neighbor* – k-Vizinho(s) mais Próximo), conforme utilizado pelo RADAR [Bahl and Padmanabhan 2000].

No RADAR [Bahl and Padmanabhan 2000], um dos primeiros sistemas de localização usando RSSI, leituras do RSSI são realizadas em diversos pontos do local

¹Ekahau, Inc. Ekahau Positioning Engine 2.0. <http://www.ekahau.com/>

em que se quer realizar a localização. Cada leitura contém os valores da potência do sinal recebido pelos diferentes roteadores que receberam o pacote enviado naquele local. Tais informações são registradas em um banco de dados. Após este treinamento, quando um usuário solicita a sua localização, os valores de RSSI da solicitação são comparados com os observados na fase de treinamento usando o classificador kNN, que irá retornar a posição mais provável em que a solicitação foi enviada, informação esta que será retornada para o usuário.

No sistema Horus [Youssef et al. 2003, Youssef and Agrawala 2004], é proposta uma técnica de agrupamento conjunta para a estimativa de localização que usa um método probabilístico. Nesse sistema, cada possível coordenada em que o candidato possa estar é considerada uma classe ou categoria. A fim de minimizar o erro de distância, a localização é escolhida enquanto a sua probabilidade é maior. Aumentando o número de amostras em cada local de amostragem permite melhorar a sua precisão, pois isso melhora a estimativa das médias e desvios-padrão da distribuição Gaussiana utilizada. Sistemas probabilísticos foram propostos também em outros trabalhos [Roos et al. 2002, Castro et al. 2001]

Em [Battiti et al. 2002], é proposto um método de determinação de localização com treinamento usando classificadores baseados em redes neurais. Em seguida, os autores em [Saha et al. 2003] compararam os diversos classificadores citados até o momento: redes neurais, kNN e métodos probabilísticos, mostrando que todas as técnicas tiveram comportamento muito bons.

Em [Hamza 2010] diversos experimentos foram realizados confirmando que as técnicas de localização para ambientes internos baseadas em treinamento (*fingerprinting*) têm desempenho melhor do que as tradicionais baseadas em trilateração/multilateração. O principal motivo apontado foi o fenômeno de *multipath*, em que o comportamento do sinal é afetado pelos diversos obstáculos encontrados em tais cenários. Entretanto, uma observação levantada neste trabalho é que as técnicas de localização baseada em treinamento sofrem degradações na precisão da localização em ambientes dinâmicos, onde as propriedades do local podem mudar com o tempo (rearranjo de armários, mesas, divisórias, etc).

Levando em consideração os problemas de *multipath* e ambientes dinâmicos, em [Fang and Lin 2010] é proposta uma abordagem com treinamento onde a posição é estimado a partir de um “estado”, ao invés do RSSI diretamente. Tal estado é reconstruído a partir de uma sequência temporal de amostras de RSSI. A partir daí, o mais preciso estado de localização é estimado porque o impacto da variação temporal devido ao *multipath* é considerado.

Como pode-se observar, as soluções propostas na literatura são baseadas sempre em pacotes que são enviados sempre com a mesma potência de transmissão. Já no SPoT, solução proposta neste trabalho, os pacotes são enviados com potências diferentes, de forma que essa diferença na queda do sinal possa ser levado em consideração pelo classificador na hora de localizar os dispositivos móveis.

3. SPoT: Sistema de Posicionamento com Variação da Potência de Transmissão

Nesta seção, explicamos o funcionamento do SPoT (Sistema de Posicionamento com variação da Potência de Transmissão), sistema de localização proposto neste trabalho.

Conforme mencionado, nos sistemas encontrados na literatura, são utilizados como informação de entrada os RSSIs recebidos nos diferentes roteadores WiFi ou mesmo uma média de uma janela de RSSIs recebidos (diversos pacotes enviados pelo nó móvel). A nossa proposta é fazer com que se tenha mais informações para o classificador fazer uma inferência de melhor qualidade sobre a localização do dispositivo móvel. Entretanto, precisamos de novas características que possam ser de fácil obtenção em uma infraestrutura WiFi. Desta forma, a ideia da nossa proposta é utilizar a comunicação entre dispositivo e roteadores com diferentes potências de transmissão, visto que isso é um recurso disponível na maioria dos *drivers* de dispositivos WiFi comercializados [Moura 2007].

Tendo essas informações extras, passamos para a segunda fase que é a escolha de um algoritmo para o tratamento dos dados. Como optamos por resolver nosso problema de maneira discreta (conforme explicado mais adiante), escolhemos um algoritmo de classificação que é simples mas que obteve bons resultados em outros trabalhos como em [Bahl and Padmanabhan 2000] e [Ni et al. 2004]. Tal classificador é o kNN (*k-nearest neighbor*).

O kNN foi escolhido por ser um algoritmo que trata bem dados muito ruidosos como é o caso do RSSI, por que diferente do SVM e das RNA's que tentam criar uma superfície de separação (que às vezes não existem) ele rotula pelas amostras pelas mais parecidas, e com pequenos valores de k ele consegue bons resultados [Wettschereck et al. 1997].

Na área de reconhecimento de padrões, o algoritmo kNN é considerado um algoritmo de aprendizado supervisionado e foi introduzido por [Cover and Hart 1967]. A ideia geral desse algoritmo “consiste em encontrar os k exemplos rotulados mais próximos do exemplo não classificado e, com base no rótulo desses exemplos mais próximos, é tomada a decisão relativa à classe do exemplo não rotulado” [Ferrero 2009].

Em nossa modelagem usando o kNN, cada indivíduo (amostra coletada ou ponto a ser localizado) é representado em um plano cartesiano onde suas coordenadas correspondem aos valores das suas características, assim uma amostra de um ponto X é representada por um ponto $(x_1, x_2, \dots, x_n)$ onde n é o número de características da amostra. Neste trabalho cada coordenada $(x_1, x_2, \dots, x_n)$ corresponde a um valor do RSSI em uma determinada potência de transmissão.

Ao utilizar o kNN, é necessário ajustar os parâmetros do classificador que, neste caso são o valor de k (que representa o número de vizinhos que serão considerados no cálculo) e como será feita o cálculo da distância entre 2 pontos.

Para definirmos a melhor configuração para nosso classificador, foram feitos experimentos preliminares para ajustar esses parâmetros, dessa forma obtemos bases preliminares para testar entre várias configurações qual a melhor considerando como métrica a taxa de acerto.

Utilizando técnicas de seleção de parâmetros, foi possível decidir no kNN com




Figura 1. Arquitetura do Sistema de Localização.

k igual a 5 e usando o calculo de distancia “Manhattan”, uma vez que configuração se mostrou melhor nos testes preliminares.

Como nas outras abordagens baseadas em treinamento, nossa proposta de localização é discreta. Isso significa que ela não diz exatamente qual a localização do nó, mas sim em que “célula” ele se encontra. Desta forma, o kNN foi treinado com amostras rotuladas pelo centro de uma área de 1 m^2 (célula), onde foram feitas as coletas que construíram a sua base de treinamento. Dessa forma, se o classificador acerta a célula em que o dispositivo se encontra é considerado que ele acertou a posição do dispositivo. Tal asserção é bem razoável visto que o erro máximo do centro para qualquer parte da célula será de 0,7 m.

A arquitetura geral do SPoT é ilustrada na Figura 1. Em nossa arquitetura, na fase de treinamento (chamada de fase *offline*), será criado um mapa de RSSI que servirá de base para o treinamento do kNN. Tal mapa é gerado levando um dispositivo móvel para uma localização conhecida da região de interesse e fazendo com que ele envie pacotes de dados em diferentes potências de transmissão. Tais pacotes serão recebidos pelos roteadores (3 ou mais) que guardarão os dados de RSSI em uma base de dados juntamente com a posição conhecida do dispositivo. Tal procedimento deverá ser realizado em cada uma das células que se deseja obter a localização dos dispositivos. Quanto maior o treinamento, maior será a precisão do sistema. Na segunda fase (*online*), um dispositivo móvel poderá requisitar a sua localização enviando dois ou mais pacotes em potencias diferentes e, com base nos RSSIs observados nos roteadores, o classificador kNN irá estimar a localização (célula) do dispositivo.

4. Avaliação de Performance

A avaliação de performance do SPoT foi realizada através de experimentos práticos em um ambiente interno (*indoor*). Em nossos experimentos, utilizamos roteadores sem fio Cisco/Linksys WRT610N com o *firmware* DD-Wrt e um software simples desenvolvido para a captura dos pacotes e obtenção dos RSSIs (baseado na *libpcap*).

Para fins de comparação, foi-se implementado um sistema de localização tradicional baseado em treinamento e usando o kNN. Conforme mencionado anteriormente, tal sistema é baseado na utilização de uma única potência de transmissão. Os experi-




Figura 2. Coleta de Informações.

mentos desse sistema tradicional foram realizados ao mesmo tempo e com os mesmos equipamentos utilizados na nossa abordagem. Desta forma, será possível ver exatamente a influência da utilização de diferentes potências de transmissão no erro de localização, uma vez que todo o restante se manteve igual nas duas abordagens.

A implementação do kNN usada foi a da ferramenta *Waikato Environment for Knowledge Analysis (WEKA)*² que é uma coleção de algoritmos de aprendizado de máquina para tarefas de mineração de dados. Escolhemos essa ferramenta por ser simples (apesar de possuir muitas funcionalidades) e ser disponibilizada gratuitamente, além de possuir muita documentação disponível.

4.1. Montando o Mapa de RSSI

Para a primeira fase do sistema (*offline*), foi necessário obter um banco de dados sobre a variação do RSSI para o treinamento do kNN.

Como ambiente de testes escolhemos uma sala fechada com área de 7x7 m², essa sala foi usada para simular um ambiente interno tendo alguns obstáculos como mesas e cadeiras.

Em cada extremidade dela foi colocado um roteador que ficou captando os pacotes que estavam sendo enviados a partir de um *notebook*. O *notebook* foi colocado em posições previamente definidas e conhecidas no *grid*, conforme mostra a Figura 2. Foram coletados 200 pacotes por posição alternando a potência de transmissão em 5 valores diferentes. Tais valores foram: 0, 5, 10, 15 e 20 dBm.

Os pacotes de treinamento foram captados pelos quatro roteadores e armazenados para a construção da base de dados, resultando em uma base contendo informações sobre as 49 posições do *grid*. Em seguida, tais informações da base foram utilizadas para o treinamento do kNN.

²<http://www.cs.waikato.ac.nz/ml/weka/>




Figura 3. Resultados obtidos usando quatro roteadores.

4.2. Análise dos Resultados usando Quatro Roteadores

Para analisarmos os resultados obtidos pelo SPoT, utilizamos como métrica o erro acumulado em metros (FDA - Função de Distribuição Acumulada). O erro de classificação para cada amostra, nas 49 células de 1 m^2 , é calculado com base na posição real da coleta e na posição estimada pelo classificador.

No gráfico da Figura 3, podemos ver o comportamento do erro acumulado para 3 configurações diferentes do SPoT comparadas a 2 variações da abordagem tradicional. A curva “SPoT-5P” mostra o comportamento do erro de localização para o SPoT utilizando as 5 potências de transmissão estudadas, ou seja, o nó móvel enviou 5 pacotes com potências de transmissão diferentes (0, 5, 10, 15 e 20 dBm). Por usar mais características, esta curva foi a que obteve melhores resultados, confirmando as nossas suposições iniciais de que as diferentes potências poderiam ser usadas para melhorar a qualidade do classificador. Como pode-se observar nessa curva, nosso sistema foi capaz de localizar os nós com um erro abaixo de 1 m em mais de 95% dos casos.

Ainda na Figura 3, a curva “SPoT-3P: 5 10 15” mostra o comportamento do SPoT utilizando apenas três potências diferentes, ou seja, o nó móvel enviou três pacotes com potências de transmissão diferentes (5, 10 e 15 dBm). Esta curva se mostrou um pouco inferior à primeira por utilizar menos informações. Entretanto, é fácil de se perceber que os resultados foram bastante próximos e que, assim como na primeira curva, ela ainda se destaca das demais, sendo uma solução aceitável para os casos em que se queira reduzir a quantidade de pacotes enviados pelo dispositivo móvel.

Para melhor entender os resultados obtidos, implementamos uma versão do SPoT que utiliza três pacotes (parecido com a variação anterior) mas que ao invés de usar pacotes com potências diferentes, esta variação utilizou pacotes diferentes mas com a mesma potência de transmissão (20 dBm). Apesar de não ser o algoritmo proposto, essa variação serviu para diferenciar mais facilmente o que é ganho relativo à variação do sinal do que não é. Como pode ser observado na curva “SPoT-3P: 20 20 20”, esta variação ficou bem abaixo das outras duas, que utilizaram a variação da potência de transmissão. Este resultado mostra claramente que os ganhos obtidos pelo SPoT devem-se basicamente à mudança da potência de transmissão.




Figura 4. Resultados obtidos usando três roteadores.

Finalmente, a curva “Tradicional” ilustra o comportamento de um sistema de localização tradicional, através de um classificador kNN que utiliza os dados de RSSIs obtidos a partir de um único pacote sempre usando a mesma potência de transmissão. Já a curva “Tradicional/Média” mostra novamente a abordagem tradicional mas com o envio de três pacotes (usando a mesma potência de transmissão) e tirando a média dos RSSIs destes três pacotes. Como pode se observar, as duas abordagens tradicionais obtiveram uma qualidade de localização bem inferior se comparado ao SPoT.

4.3. Análise dos Resultados usando Três Roteadores

Na seção anterior, mostramos os resultados obtidos pelo SPoT utilizando os quatro roteadores disponíveis. Para entender um pouco mais do seu funcionamento e comportamento em diferentes cenários, resolvemos experimentar a solução proposta utilizando apenas três roteadores, quantidade mínima necessária para obter uma solução única. Como haviam quatro roteadores disponíveis, foram realizados testes com as várias combinações de roteadores, 3 a 3, resultando em 4 possíveis combinações de roteadores. Entretanto, percebemos que todas apresentavam o mesmo comportamento e, por isso, mostramos apenas uma das combinações no gráfico da Figura 4.

Novamente, podemos observar que o SPoT foi capaz de localizar os nós com erros bem abaixo dos obtidos pelas abordagens tradicionais. Comparando este gráfico com o anterior (Figura 3), é possível observar uma queda muito pequena na qualidade da localização, mostrando que nossa abordagem mantém uma qualidade aceitável mesmo com uma quantidade menor de roteadores e mostrando ainda que ao se aumentar a quantidade de roteadores, há um ganho muito pequeno na qualidade da localização, o que pode não compensar na maioria dos casos.

4.4. Análise dos Resultados usando diferentes Combinações das Potências de Transmissão

Conforme mencionado anteriormente, e observado no gráfico da Figura 4, a utilização do SPoT com apenas três pacotes (com três potências diferentes), teve resultados próximos aos obtidos executando o SPoT com 5 pacotes e potências diferentes. Como tínhamos que




Figura 5. Resultados obtidos variando as potências 3 a 3.

escolher 3 potências de transmissão dentre as 5 disponíveis, resolvemos analisar o comportamento do erro de localização obtido por cada uma dessas possíveis combinações (e utilizando apenas três roteadores). A ideia inicial era avaliar, por exemplo, se a utilização das potências maiores de transmissão seria mais vantajoso em relação às potências menores. Entretanto, o que foi observado e que está ilustrado no gráfico da Figura 5 é que basicamente não houve mudança no desempenho do sistema. Portanto, levando-se em consideração que os pacotes enviados com potências maiores alcançam distâncias maiores, o gráfico da Figura 5 indica que podemos utilizar as maiores potências disponíveis (10, 15 e 20 dBm, neste caso) sem se preocupar com uma degradação perceptível na precisão da localização.

Ainda nessa linha de combinações das potências, e procurando aumentar ainda mais os conhecimentos sobre o comportamento do sistema, resolvemos executar o SPoT fazendo o dispositivo móvel enviar apenas dois pacotes com potências de transmissão diferentes. Assim como no resultado anterior, diversas combinações surgem a partir das 5 potências disponíveis. Dentre as combinações disponíveis, escolhemos as quatro mais relevantes e executamos o SPoT com elas. Os resultados obtidos são mostrados no gráfico da Figura 6. Novamente, como pode-se observar, não houve diferenças significativas nos resultados. Entretanto, comparando este gráfico com o anterior (que usa três potências), é possível perceber que houve uma queda na qualidade da localização. Daí, pode-se observar que o SPoT é bem dependente da quantidade de pacotes enviados em potências diferentes, motivo esse que nos levará a pesquisar ainda mais nossa solução com a utilização de ainda mais potências (trabalhos futuros).

4.5. Análise dos Resultados usando diferentes Quantidades de Potências de Transmissão

No gráfico da Figura 7, podemos observar o comparativo com várias quantidades de potência. Com o uso de apenas 2 potências, já é possível observar uma melhora considerável na qualidade de localização. Aumentando a quantidade de potências utilizadas para 3, 4 e 5 potências, é possível observar um ganho ainda maior na localização. Entretanto, é possível observar que o incremento de ganho de uma quantidade de potências para outra parece diminuir, concluindo-se que se faz necessário uma relação de compro-




Figura 6. Resultados obtidos variando potências 2 a 2.




Figura 7. Resultados obtidos variando a quantidade de potências.

misso entre o acerto do classificador e o custo em quantidade de pacotes enviados pelo dispositivo móvel, uma vez que mais potências/características significa o uso de mais pacotes.

5. Conclusão

No presente trabalho, propomos um novo sistema de localização para ambientes internos: o SPoT (Sistema de Posicionamento com variação da Potência de Transmissão). Nossa abordagem proposta é baseada nas técnicas de treinamento e classificação usando kNN, uma das técnicas mais usadas em ambientes internos por levar em consideração a variação e imprevisibilidade do RSSI. Entretanto, nossa abordagem se distingue das demais por utilizar diferentes potências de transmissão como características extras para o classificador, permitindo a este último gerar estimativas mais precisas de localização.

O sistema proposto foi avaliado através de experimentos reais em um ambiente interno utilizando diversas combinações de (1) quantidade de roteadores, (2) quais roteadores, (3) quantidade de potências de transmissão, e (4) quais potências de transmissão, tudo isso comparado com a abordagem tradicionalmente utilizada em localização interna

bem como com sua variante que usa a média do RSSI de vários pacotes. Os resultados obtidos apontam fortes indícios de que essas características extras de diferentes potências são relevantes e melhoram a qualidade da localização obtendo-se erros de menos de 1 m em 96% dos casos em alguns cenários.

Os resultados obtidos são bastante promissores. Como trabalhos futuros, pretendemos experimentar o SPoT em ambientes maiores e com mais obstáculos. Além disso, serão realizados experimentos com uma quantidade maior de pacotes com diferentes potências, para avaliar até quando podemos aumentar a quantidade de pacotes e ainda obter resultados melhores, outra coisa a ser analisada é a possibilidade do uso de outras características como frequências diferentes e análises de interferências no canal.

Outra parte importante a ser feita é a implementação de fato para dispositivos móveis visto que nesse trabalho utilizamos um notebook para simular o *beacon* móvel.

Referências

- Bahl, P. and Padmanabhan, V. (2000). Radar: an in-building rf-based user location and tracking system. In *INFOCOM 2000. Nineteenth Annual Joint Conference of the IEEE Computer and Communications Societies. Proceedings. IEEE*, volume 2, pages 775–784 vol.2.
- Battiti, R., Nhat, T. L., and Villani, A. (2002). Location-aware computing: A neural network model for determining location in wireless lans. Technical report.
- Castro, P., Chiu, P., Kremenek, T., and Muntz, R. R. (2001). A probabilistic room location service for wireless networked environments. In *Proceedings of the 3rd international conference on Ubiquitous Computing, UbiComp '01*, pages 18–34, London, UK, UK. Springer-Verlag.
- Cover, T. and Hart, P. (1967). Nearest neighbor pattern classification. *Information Theory, IEEE Transactions on*, 13(1):21–27.
- Fang, S.-H. and Lin, T.-N. (2010). A dynamic system approach for radio location fingerprinting in wireless local area networks. *Trans. Comm.*, 58:1020–1025.
- Ferrero, C. A. (2009). Algoritmo knn para previsão de dados temporais: funções de previsão e critérios de seleção de vizinhos próximos aplicados a variáveis ambientais em limnologia. Master's thesis, Universidade de São Paulo.
- Hamza, L. N. C. (2010). A dynamic system approach for radio location fingerprinting in wireless local area networks. *Intelligent Signal Processing, 2009. WISP 2009. IEEE International Symposium on*, pages 253–258.
- Jan, R.-H. and Lee, Y. R. (2003). An indoor geolocation system for wireless lans. In *32nd International Conference on Parallel Processing Workshops (ICPP 2003 Workshops), 6-9 October 2003, Kaohsiung, Taiwan*, pages 29–34. "IEEE Computer Society".
- Moura, A. I. (2007). Wbls: um sistema de localização de dispositivos móveis em redes wi-fi. Master's thesis, Universidade de São Paulo.
- Ni, L. M., Liu, Y., Lau, Y. C., and Patil, A. P. (2004). Landmarc: indoor location sensing using active rfid. *Wireless Networks - Special issue: Pervasive computing and communications*, 10(6):701–710.

- Roos, T., Myllymäki, P., Tirri, H., Misikangas, P., and Sievänen, J. (2002). A probabilistic approach to wlan user location estimation. *International Journal of Wireless Information Networks*, 9(3):155–164.
- Saha, S., Chaudhuri, K., Sanghi, D., and Bhagwat, P. (2003). Location determination of a mobile device using ieee 802.11b access point signals. In *Wireless Communications and Networking, 2003. WCNC 2003. 2003 IEEE*, volume 3, pages 1987–1992 vol.3.
- Santos, D., Perkusich, A., and Almeida, H. O. (2011). Infraestrutura para o desenvolvimento de aplicações pervasivas cientes de redes sociais. In *XXIX Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos*, pages 501–514, Campo Grande, MS.
- Wettschereck, D., Aha, D. W., and Mohri, T. (1997). A review and empirical evaluation of feature weighting methods for aclass of lazy learning algorithms. *Artif. Intell. Rev.*, 11(1-5):273–314.
- Youssef, M. and Agrawala, A. (2004). Handling samples correlation in the horus system. In *INFOCOM 2004. Twenty-third Annual Joint Conference of the IEEE Computer and Communications Societies*, volume 2, pages 1023–1031 vol.2.
- Youssef, M. A., Agrawala, A., and Shankar, A. U. (2003). Wlan location determination via clustering and probability distributions. In *Proceedings of the First IEEE International Conference on Pervasive Computing and Communications, PERCOM '03*, pages 143–, Washington, DC, USA. IEEE Computer Society.