

Detecção de Alertas de Segurança em Redes de Computadores Usando Redes Sociais

Luiz Arthur F. Santos^{1,2}, Rodrigo Campiolo^{1,2}, Marco A. Gerosa², Daniel M. Batista²

¹Universidade Tecnológica Federal do Paraná (UTFPR)
Campo Mourão – PR – Brasil

²Departamento de Ciência da Computação – Universidade de São Paulo (USP)
São Paulo – SP – Brasil

{luizsantos,rcampiolo}@utfpr.edu.br, {gerosa,batista}@ime.usp.br

Resumo. Neste artigo é apresentado um método de extração de notificações de segurança a partir de mensagens postadas em redes sociais. Nossa metodologia consiste em coletar e processar as mensagens de segurança postadas no Twitter usando técnicas de mineração de dados, em específico, agrupamento e classificação. Desenvolvemos um método para extrair e evidenciar alertas e problemas de segurança em ambientes de redes de computadores, otimizado com heurísticas de aumento de relevância. Como resultado, verificou-se que cerca de 92% das mensagens recuperadas abordam tópicos relacionados com segurança de redes de computadores e que mais de 50% representam potenciais alertas.

Abstract. This paper presents a method of extracting security notifications based on messages posted on social networks. We collect and process security messages posted on Twitter using data mining techniques, in particular, clustering and classification. We developed a method to extract and to show alerts and security problems in computing environments, with optimized heuristics to increase relevance. As a result, it was found that about 92% of retrieved messages address topics relating to network security, and more than 50% represent potential alerts.

1. Introdução

O acesso rápido a informações sobre ameaças que afetam ambientes computacionais é fundamental para implantação de medidas preventivas. Sítios especializados e listas de e-mail são formas tradicionais de alerta sobre vulnerabilidades ou ameaças à segurança, entretanto nem sempre são eficazes em publicar rapidamente ameaças recentes [Frei et al. 2006]. Sistemas de detecção de intrusão e antivírus, por exemplo, sofrem com problemas de falsos negativos, causados pela ausência de assinaturas das ameaças em suas bases [Akyazi and Uyar 2010, Yuan and Zou 2011]. Como as redes sociais proveem uma fonte de dados rica e heterogênea, além de disseminarem informações de forma rápida e colaborativa, elas podem ser exploradas como formas de propagação de notificações de segurança.

[Santos et al. 2012] comprovaram que há mensagens no Twitter que alertam ou notificam sobre ameaças ou problemas de segurança. Entretanto, as mensagens devem

ser classificadas e evidenciadas para serem efetivamente exploradas por administradores de redes e usuários preocupados com a segurança. Esse processamento é necessário por conta de mensagens de segurança relacionadas a outros assuntos, como por exemplo, mensagens de *spams* e *phishing*, mensagens de segurança física e política, mensagens mal formadas, entre outras.

Neste artigo é proposto um método para extrair notificações de segurança em mensagens postadas no *microblog* Twitter. As mensagens com conteúdos irrelevantes são removidas de uma lista de interesse por meio do uso de técnicas heurísticas e de aprendizagem não supervisionada. Além disso, são apresentadas técnicas para agrupar e aumentar a relevância de mensagens de segurança baseada na sua propagação na rede social.

Considerando as características de heterogeneidade e colaboração dos usuários de redes sociais e, em específico, a característica de alta taxa de disseminação e propagação das mensagens no Twitter [Cha et al. 2012, Lerman and Ghosh 2010], tem-se como contribuição um mecanismo que viabiliza o acesso rápido a importantes notificações de segurança. Este artigo difere-se dos encontrados na literatura porque explora as redes sociais como fontes de informação sobre alertas de redes de computadores.

O artigo discute na Seção 2 os trabalhos relacionados, a Seção 3 descreve os procedimentos e questões de pesquisa que nortearam o desenvolvimento do trabalho, a Seção 4 apresenta os resultados, a análise e discussões dos procedimentos e resultados, e a Seção 5 apresenta as conclusões e trabalhos futuros.

2. Trabalhos Relacionados

As redes sociais possibilitam a colaboração e a difusão rápida de informações entre os usuários. Muitos trabalhos [Lerman and Ghosh 2010, Ye and Wu 2010, Kwak et al. 2010] verificaram que as mensagens propagadas no Twitter mantêm taxa de propagação constante e podem atingir uma alta taxa de disseminação em um curto período de tempo. Essa característica de redes sociais é útil para a área de segurança.

Ao contrário dos trabalhos que analisam as redes sociais como formas de propagação de *malware* e *spams* [Brown et al. 2008, Luo et al. 2009, Gao et al. 2010, Grier et al. 2010], as redes sociais podem ser exploradas como uma fonte valiosa de informações para prevenir ataques. O monitoramento e detecção de eventos em redes sociais já tem sido explorado por muitas áreas [Bonchi et al. 2011, Lee 2012].

[Sakaki et al. 2010] apresentaram um método para monitorar e correlacionar eventos de terremotos, usando um classificador baseado nas palavras-chaves, número de palavras e contexto de mensagens postadas no Twitter. [Sayyadi et al. 2009] partiram da premissa que documentos que descrevem o mesmo evento contém conjunto de palavras-chaves similares. [Aggarwal and Subbian 2012] realizaram experimentos combinando informações de conteúdo e fluxo de mensagens, e alcançaram melhores resultados que os métodos baseados apenas em texto.

No mesmo contexto de nosso trabalho, [Phuvipadawat and Murata 2010] propuseram um método para agrupar e monitorar notícias de última hora no Twitter baseado na similaridade definida pelo esquema TF-IDF (*Term Frequency-Inverse Document Frequency*), aperfeiçoado por um fator de identificação de substantivos importantes nas men-

sagens, o que possibilita obter melhores resultados no agrupamento de mensagens com pouco texto.

Outros trabalhos usam informações de tempo e espaço para detectar novos eventos em redes sociais [Petrović et al. 2010, Mathioudakis and Koudas 2010]. Destaca-se o uso de termos que aparecem em alta taxa durante um período para elevar a importância de um tópico de interesse. Nosso trabalho também explora as informações temporais como um fator para elevar a importância de uma notificação.

Na área de segurança em redes de computadores os sistemas de detecção de intrusão são notórios na identificação de invasões e/ou geração de alertas. Para isso, um fator determinante é obter informações confiáveis sobre atividades maliciosas em *hosts* ou redes. Entretanto, coletar dados confiáveis é uma atividade complexa [Kemmerer and Vigna 2002] por isso algumas abordagens de detecção de intrusão têm focado em colaboração [Locasto et al. 2005]. [Apel et al. 2009, Flegel et al. 2010] propõem a troca de informação entre organizações como forma de prevenção e detecção antecipada de ameaças à segurança. [Grobauer et al. 2006] apresentam uma infraestrutura e um arcabouço organizacional para compartilhar, correlacionar e analisar cooperativamente dados e alertas de diferentes organizações. Todas as abordagens apresentadas são direcionadas à colaboração entre organizações, não tratando informações e as ameaças a usuários finais. Também dependem de um contrato prévio entre as organizações para a geração de alertas.

A nossa abordagem explora técnicas fundamentadas por trabalhos de recuperação de informação, mas possui adaptações para explorar notificações de segurança. O conceito de colaboração e disseminação nas redes sociais é explorado para obter alertas antecipados em detrimento às abordagens clássicas de colaboração e propagação de alertas.

3. Metodologia Proposta

Nesta pesquisa propomos um método para extrair e evidenciar alertas a respeito de problemas de segurança em redes de computadores por meio de mensagens postadas em redes sociais. A ideia fundamental é explorar a disseminação rápida de informações das redes sociais para disponibilizar notificações de segurança em tempo hábil para reagir antecipadamente a problemas de segurança de computadores. Objetivamos também amenizar o problema de falta de informação sobre problemas de segurança recentes, tal como vulnerabilidades dia zero.

Nossos trabalhos anteriores [Santos et al. 2012, Campiolo et al. 2013] comprovaram que há mensagens sobre ameaças computacionais postadas no Twitter. Entretanto, foram identificados alguns desafios para usar efetivamente a informação de mensagens do Twitter: (a) muitas mensagens de segurança; (b) mensagens similares; (c) diferentes níveis de importância como notificação de segurança; e (d) mensagens irrelevantes para segurança computacional.

Os itens (a) e (b) implicam na dificuldade de processar e ler todas as mensagens com conteúdo relevante, pois é oneroso lidar com essa atividade sem auxílio de ferramentas específicas e alto poder computacional. Os itens (c) e (d) implicam na existência de mensagens relacionadas à segurança porém fora do contexto de segurança em redes de computadores, como por exemplo, propagandas de ferramentas de segurança, mensagens

informando a respeito de guerra entre povos, mensagens mal formadas e que não trazem informação suficiente para caracterizar alertas, mensagens contendo boatos sobre ataques e novas ameaças, e mensagens capturadas erroneamente como se fossem de segurança de computadores, por possuírem alguns termos relacionados.

Neste contexto, definimos duas questões de pesquisa para extrair efetivamente notificações de segurança postadas em redes sociais:

- Q1** É possível minimizar o impacto negativo das mensagens que não são notificações de segurança computacional?
- Q2** Dentre os inúmeros problemas de segurança postados em redes sociais, é possível evidenciar quais são os problemas com maior relevância e que estão sendo mais comentados neste tipo de ambiente?

Para extrair os alertas de segurança das redes sociais e responder as questões citadas anteriormente propomos a arquitetura ilustrada na Figura 1.




Figura 1. Método para extrair mensagens de segurança do Twitter.

O método proposto na Figura 1 é composto de cinco etapas:

1. Obter *tweets* de segurança: capturar mensagens de segurança postadas no Twitter.
2. Filtrar mensagens: remover os *tweets* que não representam mensagens de segurança da base de dados de *tweets* capturados.
3. Agrupar por similaridade: relacionar *tweets* que relatam um mesmo assunto.
4. Gerar lista de mensagens mais relevantes: selecionar mensagens que informam sobre os principais problemas de segurança comentados nas redes sociais.
5. Aumentar a visibilidade da mensagem: aumentar a importância das mensagens de segurança segundo as características do grupo de *tweets*.

As etapas do método são detalhadas nas subseções seguintes.

3.1. Obter *tweets* de segurança

A coleta de mensagens do Twitter foi realizada utilizando um software desenvolvido pelos autores a partir de uma API (*Application Programming Interface*) do Twitter¹. Pelo fato das consultas no Twitter serem restritas e não devolverem *tweets* de mais do que algumas semanas anterior à data corrente, optou-se por realizar consultas em intervalos periódicos

¹foi utilizada a API Twitter4j - <http://twitter4j.org>

de 1 minuto. O software implementado realiza a busca, descarta os *tweets* repetidos e armazena os novos *tweets* em uma base de dados.

As buscas por *tweets* de segurança foram realizadas por meio de uma consulta com os termos: *security, virus, worm, attack, intrusion, invasion, ddos, hacker, cracker, exploit* e *malware*. Basicamente os termos de busca obrigam que todos os *tweets* capturados tenham um ou mais termos comuns a área de segurança em redes de computadores.

A coleta por *tweets* de segurança foi realizada entre 28/04/2012 e 05/12/2012, ou seja, 222 dias. No processo de coleta foram obtidos 155.631 *tweets*, que foram postados por 74.809 usuários. Aproximadamente 84,9% dos *tweets* continham URLs, 37,0% continham *hashtags* (#) e 43% mencionavam (@) outros usuários no corpo da mensagem.

3.2. Filtrar mensagens

As mensagens coletadas na etapa anterior precisam ser analisadas e filtradas para não gerarem altos índices de falsos positivos. A Figura 2 apresenta o fluxograma do processo de filtragem.




Figura 2. Fluxograma do processo de filtragem.

O *Filtro termos inglês* remove mensagens que não são da língua inglesa. Pois, mesmo utilizando termos de busca em inglês, foram coletadas muitas mensagens em outras línguas. Como critério de filtragem, adotamos a política de remover da base todos os *tweets* com o código de linguagem diferente do inglês.

O *Filtro características* remove mensagens com as seguintes características: menos de quatro palavras, tamanho inferior a quarenta caracteres, mais de três URLs, menção a usuários e número de *hashtags* superior a metade do número de termos na mensagem. Essas características são importantes para remover mensagens mal formadas.

O *Filtro domínios* remove as mensagens irrelevantes como alertas considerando a URL presente nas mensagens dos *tweets*. Aproximadamente, 84,9% dos *tweets* coletados possuem URL, pois *tweets* de notificação geralmente contém referência para uma descrição mais detalhada. Para esta etapa, as mensagens com a mesma URL curta são agrupadas e, em seguida, submetidas a serviços de tradução para URLs longas. Para toda URL longa, foi extraído o endereço do domínio. Os domínios com mais citações nas mensagens foram analisados e uma lista de bloqueio com 160 domínios foi gerada. A lista de bloqueio continha endereços de sites que geravam notícias de segurança - mas que não são de segurança de redes de computadores, como por exemplo, cnn.com, washington-post.com, amazon.com, forbes.com.

Após aplicar o *Filtro domínios*, foram geradas duas bases: base de dados parcial “segurança” e a base de dados “spams”. Processando os termos mais frequentes na base de *spams*, foi gerada uma lista de palavras comuns em mensagens irrelevantes. Os termos foram selecionados manualmente. São exemplos de termos: *lybia*, *benghazi*, *obama*, *bomb*, *iran*, *officials*, *consulate* e *killed*. O *Filtro termos spam* remove da base de dados “segurança” os *tweets* com os termos na *Lista de bloqueio termos spam*. Como resultado, temos a base de dados “Segurança” contendo potenciais alertas.

3.3. Agrupar por similaridade

Nesta etapa temos em sua maioria mensagens relacionadas à segurança de redes de computadores. Essas mensagens são submetidas ao Apache Lucene², uma biblioteca de indexação e busca de texto. Ao submetermos uma consulta ao motor de busca do Lucene, são devolvidos os textos/documentos encontrados seguidos por um escore. Escores elevados representam alto grau de similaridade e o escores baixos representam pouca similaridade dos documentos em relação à busca. O Apache Lucene emprega o cálculo de similaridade de cosseno simplificado e variáveis ajustáveis para calcular o escore, tal como, atribuir pesos para termos utilizados na consulta, amenizar parágrafos repetidos, entre outros.

A estratégia de agrupamento consiste em comparar cada *tweet* na base com todos os outros, ou seja, o termo de busca é a mensagem de cada *tweet*. Dessa forma, a partir de um determinado grau de similaridade é possível considerar que os *tweets* abordem um mesmo assunto ou similar [Manning et al. 2008].

No processo de agrupamento do Lucene temos dois fatores muito importantes: grau de similaridade e o número de *tweets* similares. O grau de similaridade é um número que indica o quão similar é a mensagem de um *tweet* em relação a outro, esse número é calculado pelo Apache Lucene. Usamos o grau de similaridade para definir se os *tweets* abordam um mesmo assunto, por exemplo, caso a comparação entre dois *tweets* retorne um grau de similaridade 0,5 ou superior pode-se considerar que esses *tweets* são tão parecidos que podem ser *retweets* ou que relatam um mesmo assunto. Em nossa metodologia o grau de similaridade indica o nível de agrupamento que desejamos. Se ajustado para um valor alto tende a produzir mais grupos e aumenta a probabilidade de grupos distintos abordando o mesmo assunto. Se ajustado para um valor baixo tende a produzir menos grupos e aumenta a probabilidade de mensagens de contextos diferentes no mesmo grupo.

Inicialmente utilizávamos um grau de similaridade fixo, normalmente 0,5 ou 0,75, mas depois de experimentos preliminares, chegou-se a conclusão que usar um grau de similaridade fixo não produzia bons resultados devido ao tamanho variável do texto dos *tweets*. O problema é que quando submetemos uma mensagem pequena - menos que 70 caracteres, por exemplo - há uma grande chance dessa combinar com algumas palavras de outras mensagens maiores, assim o *tweet* pequeno parece falsamente ter um alto grau de similaridade com a mensagem maior e por consequência é dado como importante, sendo que na maioria das vezes não é importante. Para resolver este problema calculamos o grau de similaridade pela Equação 1, que permite que o valor seja calculado em função do tamanho do *tweet*. Na Equação 1 tem-se:

²<http://lucene.apache.org>

- δ representa o grau de similaridade mínima aplicada a uma mensagem de tamanho máximo. O tamanho máximo de uma mensagem é 160 e não 140 que seria o padrão. O δ pode ser por exemplo 0,75;
- x é o número de caracteres da mensagem que está sendo analisada;
- α é usado como um fator extra de crescimento para o grau de similaridade, que pode ser por exemplo 2 ou 8.

$$GrauSimilaridadeExigido = ((\delta - \frac{x * \delta}{160}) * \alpha) + \delta \quad (1)$$

Quanto menor o texto submetido para consulta, mais rígidas são as regras de agrupamento aplicadas pela Equação 1, pois o grau de similaridade exigido aumenta, o que valoriza a importância da informação e evita que assuntos de contextos diferentes sejam agrupados.

3.4. Gerar lista de *tweets* mais relevantes

A etapa de agrupamento por similaridade produz uma lista que contém o número de *tweets* similares em cada grupo e uma mensagem que representa esse grupo. A mensagem que representa o grupo é o texto do *tweet* que gerou a busca no Apache Lucene. Devemos apontar dentre esses grupos quais tem mensagens que são relevantes.

Para determinar se um grupo dessa lista é importante utilizamos uma premissa básica entre os usuários do Twitter, que é: uma mensagem importante tem a tendência de ser retransmitida entre os usuários do Twitter, ou seja, sofre um *retweet* [Morris et al. 2012]. Mas não olhamos somente para os *retweets* e sim para mensagens similares. Então, usamos o fator número de *tweets* similares para determinar se um grupo é importante ou não. Desta forma, quanto maior o número de *tweets* similares mais importante é a informação.

Um assunto postado no Twitter foi considerado relevante caso gerasse um grupo com 10 ou mais elementos, isso significa que pelo menos 10 pessoas acharam a informação relevante e decidiram repassá-la para seus seguidores, sem considerar as pessoas que podem ter lido a mensagem sem ser seguidor.

Após alguns experimentos preliminares, notamos que normalmente mensagens de *spam* continham um grande número de *tweets* similares e comprometiam os resultados na busca por notificações de segurança. Entretanto, também notamos que essas mensagens de *spam* vinham de alguns poucos usuários do Twitter, então passamos a considerar um grupo de mensagem importante não pelo número de mensagens que este continha, mas sim pelo número de usuários que postaram essas mensagens.

Ao final, temos uma lista com as mensagens mais relevantes. O Algoritmo 1 apresenta o pseudocódigo das etapas apresentadas nas Subseções 3.3 e 3.4.

3.5. Aumentar a visibilidade das mensagens

Durante o processo de agrupamento de mensagens vários *tweets* são descartados por não serem similares a nenhum outro. Este processo ajuda a determinar quais mensagens são mais relevantes. Porém, mesmo com o processo de filtragem podemos ter, ainda, uma lista com centenas ou milhares de mensagens consideradas relevantes o que pode inviabilizar a

Algoritmo 1: Agrupamento por similaridade

Entrada: Um vetor de *tweets* - *todosTweets*
Saída: Mensagens consideradas importantes por serem postadas por mais de 10 usuários

```

1  ApacheLucene.indexa(todosTweets)
2   $\alpha \leftarrow 2$ 
3   $\delta \leftarrow 0,75$ 
4  enquanto todosTweets  $\neq \phi$  faça
5      tweet  $\leftarrow$  todosTweets.proximo()
6      x  $\leftarrow$  tweet.textoMensagem.tamanho()
7      grauSimilaridadeExigido  $\leftarrow ((\delta - \frac{x*\delta}{160}) * \alpha) + \delta$ 
8      tweetsLucene  $\leftarrow$  ApacheLucene.obterTweetsSimilares(tweet.textoMensagem)
9      para cada tweetsLucene.proximo() faça
10         se tweetsLucene.score  $\geq$  grauSimilaridadeExigido então
11             tweetsSimilares.adiciona(tweetsLucene.tweet)
12     numeroUsuarios  $\leftarrow$  removerTweetsComUsuariosRepetidos(tweetsSimilares).tamanho()
13     se numeroUsuarios  $\geq 10$  então
14         mensagensImportantes.adiciona(numeroUsuarios, tweet.textoMensagem)
15         todosTweets.remover(tweetsSimilares)
16 retorna mensagensImportantes

```

leitura de todas essas mensagens. É necessário então algum mecanismo que aponte quais mensagens são mais importantes dentre as mensagens selecionadas anteriormente.

Existem inúmeras técnicas utilizadas para indicar a importância ou até mesmo a credibilidade de mensagens do Twitter [Lee 2012]. Essas técnicas vão desde análise de palavras contidas no *tweet* até a investigação do usuário que postou a mensagem.

Em nosso trabalho, o fator primordial para dizer se uma mensagem é importante ou não, é o número de usuários que postaram essa mensagem. Então, esse número é o ponto de partida para decidir a importância da mensagem. Nesta etapa incrementamos ou decrementamos a importância de uma mensagem por meio da análise de algumas peculiaridades da mensagem e do grupo de *tweets* ao qual essa mensagem pertence.

Um método muito utilizado para aumentar a importância de uma mensagem é a análise da frequência das palavras da mensagem. Podemos analisar a mensagem palavra por palavra e verificar se o uso de uma palavra aumentou de um dia para outro. Assim, caso exista uma palavra que apresente um grande aumento na frequência de seu uso, podemos considerar que foi muito comentada na data em que o *tweet* foi postado e pode ter um conteúdo importante. O conceito é muito parecido com a técnica de *trend topics* do Twitter.

Outra técnica é observar a ocorrência de palavras raras nas mensagens dos grupos. Caso exista uma palavra rara há uma grande chance desse *tweet* estar abordando um assunto novo e portanto importante. Para decidir se uma palavra é rara criamos uma lista formada pela tupla, palavra e número de ocorrências em todos *tweets*. Assim, se uma mensagem apresentar uma palavra que não ocorreu ou quase não apareceu na lista ela é considerada rara.

Durante nossos experimentos observamos que *tweets* que apresentam várias palavras raras, são em sua grande maioria, mensagens fora do contexto de segurança de computadores. Assim, caso a mensagem apresente uma ou duas palavras raras nós aumentamos a importância dessa mensagem. Se a mensagem apresentar mais de três pala-

avras raras diminuimos sua importância. O mesmo ocorre para o aumento da frequência do uso de palavras, portanto o mesmo procedimento foi aplicado.

Tweets que relatam assuntos da atualidade, tal como a ocorrência de uma catástrofe, possuem o comportamento de registrar mensagens sobre o assunto no primeiro dia, ter uma explosão no número de *tweets* no segundo dia e diminuir a sua intensidade gradativamente nos dias posteriores. Assim, analisamos o comportamento das mensagens de um grupo e se essas apresentarem esse comportamento de propagação aumentamos a sua importância. Também aumentamos a importância de um grupo se ele apresentar um dia de pico muito elevado, ou seja, se o número de *tweets* crescer muito de um dia para o outro e depois diminuir. Esses dois fatores são importantes, pois por exemplo *spams*, não apresentam dia de pico e a sua propagação é constante. Em trabalhos anteriores [Campiolo et al. 2013, Santos et al. 2012] verificamos que mensagens de segurança tem uma média de propagação de aproximadamente 12 dias, já *spams* são propagados por meses, por isso também aumentamos a importância de mensagens que são disseminadas durante um período de 10 a 14 dias.

4. Análise dos Resultados

Apresenta-se nesta seção a caracterização dos resultados da filtragem e do método de extração de notificações de segurança (sem e com filtragem), bem como, a avaliação dos procedimentos e a avaliação das questões de pesquisa.

4.1. Caracterização dos resultados

A filtragem das mensagens coletadas do Twitter (Seção 3.2) foi realizada para melhorar o resultado do agrupamento de mensagens relevantes.

O procedimento de filtrar por URL resultou na seleção de sítios Web que divulgam informações de segurança, mas não são sítios especializados. Por outro lado, identificou muitos sítios e *blogs* que propagam informações de alertas. As tabelas 1 e 2 apresentam, respectivamente, exemplos de domínios descartados por não tratarem de segurança de redes de computadores e domínios considerados úteis por relatarem ameaças a ambientes de redes de computadores.

Tabela 1. Domínios descartados.

Ocorrências	Domínio
1117	washingtonpost.com
484	forbes.com
428	amazon.com
405	computerworld.com
356	pcworld.com
27	infowars.com
26	inquisitr.com

Tabela 2. Domínios considerados.

Ocorrências	Domínio
1369	net-security.org
1311	zdnet.com
1266	sophos.com
1144	thehackernews.com
917	h-online.com
98	blog.sucuri.net
34	blog.webroot.com

O conteúdo da base de mensagens de “spam” foi indexado e a frequência dos termos mais comuns dessas mensagens foi calculada usando o Lucene. Após a inspeção dos termos mais frequentes, foi gerada uma lista de palavras-chaves que indicam mensagens fora do contexto. A Tabela 3 apresenta exemplos de termos selecionados. Foram inspecionados todos os termos com mais de 10 ocorrências.

Tabela 3. Exemplos de termos comuns em mensagens irrelevantes

Ocorrências	Termos
4164	libya
3304	benghazi
2291	obama
1848	iran
984	killed
708	nuclear
435	ambassador
429	dead
422	terrorism
345	free

Tabela 4. Exemplos de termos comuns em mensagens relevantes

Ocorrências	Termo
7334	exploit
3233	ddos
1919	zero(day)
1850	vulnerability
866	trojan
856	bots ou botnet
850	bug
628	hijack
558	inject
282	backdoor

A partir dos termos que indicam potenciais mensagens a serem descartadas, foi realizada uma filtragem na base de dados parcial “segurança” para remover *tweets* que apresentem esses termos. O filtro por palavras-chaves continha 120 termos.

O conteúdo da base de dados “segurança” filtrado foi indexado e a lista de termos mais frequentes foi calculada. Um conjunto de 300 palavras-chaves que caracterizam mensagens de segurança computacional foi selecionado baseado no número de ocorrências. O critério adotado durante a inspeção foi a seleção de termos que são específicos a área de segurança em redes de computadores. Dessa forma, termos como *security* e *attack* foram ignorados. A Tabela 4 apresenta exemplos de termos selecionados.

A Tabela 5 apresenta os resultados com o uso do Filtro de aumento de visibilidade de mensagens. Também aplicamos métodos para aumentar a importância da mensagem, identificada pelo campo *Brst*, que é o número de usuários que postaram a mensagem acrescido ou decrescido segundo as técnicas mencionadas na subseção 3.5.

Todas as mensagens apresentadas na Tabela 5 tiveram sua importância aumentada já que representam mensagens de segurança, conforme os valores apresentados pelos campos *Usu* e *Brst*. Ao comparar as mensagens da Tabela 5 com mensagens recuperadas sem o filtro de aumento de visibilidade notamos que todas as mensagens da Tabela 5 informam sobre problemas de segurança em rede de computadores, enquanto na lista de mensagens sem filtragem haviam 3 mensagens não relacionadas com segurança em redes de computadores (a lista de mensagens sem filtragem não é apresentada por falta de espaço).

4.2. Avaliação dos Procedimentos

Duas etapas importantes para a extração efetiva de notificações foram as de filtro de mensagem e aumento de relevância das mensagens. Os experimentos foram realizados em uma base de dados estática de 157 MiB, contendo mensagens coletadas durante 7 meses. Para a avaliação dos procedimentos de filtragem consideramos na análise os impactos na base de dados.

O *Filtro termos inglês* reduziu a base de 157 MiB para 144,4 MiB, ou seja, uma redução de aproximadamente 8%. Em uma amostra de 1.000 *tweets* na base reduzida, foi encontrado apenas uma mensagem em francês, mas que possuía alguns termos em inglês. Foram encontrados apenas 3 *tweets* em inglês em uma amostra de 100 *tweets*

Tabela 5. Lista de *tweets* relevantes com *Filtro de spam* e aumento de importância

Mês	Msgs	Usu	Brst	Texto da mensagem
Mai	88	85	116	Microsoft boots Chinese firm for leaking Windows exploit. http://t.co/0QMqcQAI
	78	78	97	Android has made malware for Linux a reality. http://t.co/Qi5PxGcM
	72	70	88	...The Pirate Bay returns Anonymous hater takes credit for DDoS http://t.co/FQ0OrdTj
Jun	318	312	474	...How Flame has changed everything for online security firms...
	271	260	360	Scientists crack RSA SecurID 800 tokens steal cryptographic keys...
	108	106	133	...Thousands of office printers hit by "gibberish" malware http://t.co/GgzSIFcx
Jul	151	144	217	Serial hacker says latest Android will be "pretty hard" to exploit...
	147	141	195	More malware found hosted in Google's official Android market...
	155	150	189	Security firm: Android malware pandemic by year's end...
Ago	156	141	195	...30K workstations fell victim to cyber attack http://t.co/5dcvvKyS
	119	119	163	Attack against Microsoft scheme puts hundreds of crypto apps at risk...
	118	118	161	...MS-CHAPv2 puts hundreds of crypto apps at risk http://t.co/TQPsRkpN
Set	89	86	117	Android security suffers as malware explodes by 700%...
	80	79	117	GoDaddy attack likely a psyop to discredit Anonymous while pushing cyber security...
	84	81	111	...Android security sucks hard as malware explodes...
Out	208	194	243	Hacker Steals Millions of...Social Security Numbers...
	167	166	208	DSL modem hack used to infect millions with banking fraud malware...
	107	107	147	...Hacker Scores \$60 000 From Google For Discovering Security Issue In Chrome...
Nov	133	133	183	...Mac OS X has more security holes than windows and they are easier to exploit too.
	98	95	130	New Linux rootkit injects mal HTML into Web servers...
	97	94	129	New Linux rookit injects malicious HTML into Web servers via ars technica...

removidos. Os 3% de *tweets* removidos não prejudica os resultados, pois as mensagens muito importantes são postadas por centenas de usuários.

Os demais filtros reduziram o tamanho da base da seguinte forma: *características*: removeu 292 mensagens irrelevantes, *domínios*: reduziu a base em 29,2%, *termos spam*: reduziu a base em 29,7%.

Concluimos duas importantes observações por meio das medições. Primeiro, a análise do comportamento de propagação da mensagem, número de dias que a mensagem é propagada e dia de pico das mensagens ajudam a identificar mensagens que não são *spam*. A análise da frequência de palavras e de palavras raras na fase de aumento de relevância identificou mensagens importantes e fora de contexto. Segundo, por meio de listas de termos específicos para aumentar ou diminuir a importância de uma mensagem, conseguimos filtrar mensagens relevantes e irrelevantes como alertas. Em um experimento, selecionamos 10 mensagens na base "segurança" e aplicamos +1 para termos de segurança e -1 para termos *spam*. Como resultado, verificamos que mensagens com poucas citações, mas interessantes como alertas, acabaram sendo notadas, enquanto mensagens de segurança, mas pouco importantes, perderam notoriedade.

4.3. Avaliação das Questões de Pesquisa

As questões de pesquisa foram avaliadas considerando somente os meses de junho e setembro. Os meses foram selecionados aleatoriamente. Não apresentamos informações detalhadas sobre os outros meses por limite de espaço.

Para responder a questão Q1, o gráfico apresentado na Figura 3 ilustra os resultados do método de extração de notificações nos meses de junho e setembro. Observa-se que o uso de filtro reduziu consideravelmente o número de mensagens fora do contexto de segurança de redes de computadores, pois em junho houve queda de 18% para 6% e em setembro de 38% para 6%. Logo, podemos afirmar que é possível eliminar ou pelo

menos suavizar o impacto das mensagens que não são notificações sobre problemas em redes de computadores.




Figura 3. Caracterização das mensagens do mês de junho e setembro após aplicação de filtros.

Para responder a questão Q2, analisamos manualmente as mensagens devolvidas como importantes nos meses de junho e setembro. Das 134 mensagens extraídas como mensagens de segurança importantes deste mês, 65,7%, são alertas reais de segurança para ambientes de redes de computadores. Já o mês de setembro apresentou 56,9% de alertas, dentre as mensagens de segurança consideradas importantes. A Tabela 6 apresenta três mensagens de alerta de cada mês analisado.

Tabela 6. Exemplo de alertas de junho e setembro

Mês	Msgs	Usu	Brst	Texto da mensagem
Jun	108	106	133	RT @ZDNet: Thousands of office printers hit by "gibberish"malware http://t.co/GgzSIFcx
	39	38	47	A virus specialized for AutoCAD a perfect cyber espionage tool — The Hacker News http://t.co/UhaHeXGn #THN #Security
	29	29	35	ALERT - A 0day exploit taking advantage of an unpatched Windows / Office vuln is being exploited in the wild http://t.co/BovMm9Nd
Set	91	89	111	Emergency security patch issued by Microsoft to squash Internet Explorer zero day #Exploit... http://t.co/D1FXvkO7 @SecurityPhresh
	73	70	88	#hackernews CRIME : New SSL/TLS attack for Hijacking HTTPS Sessions: Two security researchers claim to have deve... http://t.co/J0IOy0Hj
	35	34	50	Attack Easily Cracks Oracle Database Passwords: Oracle's software update for the flaw doesn't protect http://t.co/o1ibSeuw #infosec

Os alertas apresentados da Tabela 6 demonstram o potencial das redes sociais quanto a propagação de alertas. Por exemplo, a primeira mensagem do mês de junho alerta sobre um *malware* que afeta impressoras, através desse alerta o administrador pode tomar medidas, tal como, a atualização do antivírus e regras de IDS (*Intrusion Detection System*) para tentar impedir este problema. A segunda mensagem de junho alerta sobre um vírus para o software AutoCAD, tal vírus envia via e-mail projetos desenvolvidos no software, sabendo desse problema um administrador de rede pode implementar regras de *firewall*, *proxy* e/ou ferramentas anti-spam que impeçam o envio desses arquivos, ou simplesmente verificar se o antivírus consegue eliminar esse problema. Em casos mais

radicais os administradores podem retirar o acesso à Internet dessas máquinas, já que este vírus visa espionagem industrial.

5. Conclusões

O uso de mecanismos de filtragem, agrupamento e aumento de notoriedade de mensagens de segurança postadas no Twitter permitiram elaborar um método capaz de extrair alertas de segurança de mensagens postadas em redes sociais. O método foi eficiente em trazer apenas notícias associadas à segurança de redes. Os resultados produzidos por filtros e agrupamentos mostraram a dificuldade em lidar com a semântica de mensagens postadas em *microblogs*, mesmo quando essas abordam em sua maioria assuntos de segurança. Em trabalhos futuros pretendemos utilizar técnicas de aprendizagem supervisionada para melhorar a classificação das mensagens. Com a otimização do método, pretendemos também implementar um software para coleta e distribuição de alertas postados em redes sociais.

Referências

- Aggarwal, C. and Subbian, K. (2012). Event detection in social streams. In *Proceedings of the Twelfth SIAM International Conference on Data Mining*, pages 624–635.
- Akyazi, U. and Uyar, A. c. (2010). Detection of ddos attacks via an artificial immune system-inspired multiobjective evolutionary algorithm. In *Proceedings of the Evo-COMNET'10*, pages 1–10. Springer-Verlag.
- Apel, M., Biskup, J., Flegel, U., and Meier, M. (2009). Towards early warning systems - challenges, technologies and architecture. In *CRITIS*, pages 151–164.
- Bonchi, F., Castillo, C., Gionis, A., and Jaimes, A. (2011). Social network analysis and mining for business applications. *ACM Trans. Intell. Syst. Technol.*, 2(3):22:1–22:37.
- Brown, G., Howe, T., Ihbe, M., Prakash, A., and Borders, K. (2008). Social networks and context-aware spam. In *Proceedings of the ACM CSCW '08*, pages 403–412.
- Campiolo, R., Santos, L. A. F., Gerosa, M. A., and Batista, D. M. (2013). Evaluating the utilization of twitter messages as a source of security alerts. In *Proceedings SAC 2013*. ACM. To be published.
- Cha, M., Benevenuto, F., Haddadi, H., and Gummadi, K. (2012). The world of connections and information flow in twitter. *Systems, Man and Cybernetics, Part A: Systems and Humans, IEEE Transactions on*, PP(99):1–8.
- Flegel, U., Hoffmann, J., and Meier, M. (2010). Cooperation enablement for centralistic early warning systems. In *Proceedings of the ACM SAC '10*, pages 2001–2008.
- Frei, S., May, M., Fiedler, U., and Plattner, B. (2006). Large-scale vulnerability analysis. In *Proceedings of SIGCOMM Workshop on LSAD '06*, pages 131–138.
- Gao, H., Hu, J., Wilson, C., Li, Z., Chen, Y., and Zhao, B. Y. (2010). Detecting and characterizing social spam campaigns. In *Proceedings of the IMC '10*, pages 35–47.
- Grier, C., Thomas, K., Paxson, V., and Zhang, M. (2010). @spam: the underground on 140 characters or less. In *Proceedings of the 17th ACM CCS*, pages 27–37.

- Grobauer, B., Mehlaui, J. I., and Sander, J. (2006). Carmentis: A co-operative approach towards situation awareness and early warning for the internet. In *IMF*, pages 55–66.
- Kemmerer, R. and Vigna, G. (2002). Intrusion detection: a brief history and overview. *Computer*, 35(4):27–30.
- Kwak, H., Lee, C., Park, H., and Moon, S. (2010). What is twitter, a social network or a news media? In *Proceedings of the 19th WWW*, pages 591–600. ACM.
- Lee, C.-H. (2012). Mining spatio-temporal information on microblogging streams using a density-based online clustering method. *Expert Systems with Applications: An International Journal*, 39(10):9623–9641.
- Lerman, K. and Ghosh, R. (2010). Information contagion: An empirical study of the spread of news on digg and twitter social networks. In *Proceedings of 4th ICWSM*.
- Locasto, M., Parekh, J., Keromytis, A., and Stolfo, S. (2005). Towards collaborative security and p2p intrusion detection. In *Proceedings of IEEE SMC*, pages 333 – 339.
- Luo, W., Liu, J., Liu, J., and Fan, C. (2009). An analysis of security in social networks. In *Proceedings of the IEEE DASC '09*, pages 648–651.
- Manning, C. D., Raghavan, P., and Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press, Cambridge, UK.
- Mathioudakis, M. and Koudas, N. (2010). Twittermonitor: trend detection over the twitter stream. In *Proceedings of the 2010 ACM SIGMOD*, pages 1155–1158.
- Morris, M. R., Counts, S., Roseway, A., Hoff, A., and Schwarz, J. (2012). Tweeting is believing?: understanding microblog credibility perceptions. In *Proceedings of the ACM CSCW*, pages 441–450.
- Petrović, S., Osborne, M., and Lavrenko, V. (2010). Streaming first story detection with application to twitter. In *Proceedings of the HLT '10.*, pages 181–189. ACL.
- Phuvipadawat, S. and Murata, T. (2010). Breaking news detection and tracking in twitter. In *Proc. of the IEEE/WIC/ACM WI-IAT*, volume 3, pages 120 –123.
- Sakaki, T., Okazaki, M., and Matsuo, Y. (2010). Earthquake shakes twitter users: real-time event detection by social sensors. In *Proceedings of the 19th WWW*, pages 851–860. ACM.
- Santos, L. A. F., Campiolo, R., Gerosa, M. A., and Batista, D. M. (2012). Analysis of security messages posted on twitter. In *Proceedings of Brazilian Symposium on Collaborative Systems*, pages 20–28. IEEE.
- Sayyadi, H., Hurst, M., and Maykov, A. (2009). Event Detection and Tracking in Social Streams. In *Proceedings of the ICWSM'09*. AAAI.
- Ye, S. and Wu, S. F. (2010). Measuring message propagation and social influence on twitter.com. In *Proceedings of the Second SocInfo*, pages 216–231. Springer-Verlag.
- Yuan, S. and Zou, C. (2011). The security operations center based on correlation analysis. In *Proceedings of the 2011 IEEE ICCSN*, pages 334 –337.