

Sistemas de Recomendação de Conteúdo e Seus Impactos no Custo e Desempenho de Redes Par-a-Par

Diogo Munaro¹, Carla Delgado¹, Daniel S. Menasché¹

¹Departamento de Ciência da Computação
Universidade Federal do Rio de Janeiro (UFRJ)
Rio de Janeiro, RJ – Brazil

Abstract. *Recommendation systems and the performance of computer network systems have fundamental implications over each other. While recommendation systems impact system performance, the latter can be used to guide the former. In this paper, we study the interconnections between recommendation systems and the performance of the network. We propose an analytical model to capture the revenue and the cost to a content provider as a function of the quality of its recommendations and the cost to serve the content. The model is then used to suggest heuristics on how to recommend content accounting for service costs and user preferences.*

Resumo. *Sistemas de recomendação de conteúdo e o desempenho dos sistemas de redes usados para prover tais conteúdos têm implicações fundamentais uns sobre os outros. Os sistemas de recomendação impactam a disponibilidade de conteúdo na rede, e por consequência o desempenho da disseminação de conteúdo. Por outro lado, a disponibilidade de conteúdo pode ser usada para guiar o sistema de conteúdo, tendo em vista que conteúdos mais populares irão estar associados a maior QoS e por consequência maior satisfação do usuário. Nesse artigo, é proposto um modelo para estudar os tradeoffs envolvidos na recomendação de conteúdo e nos custos de redes Par-a-Par (P2P). Usando o modelo, foram derivadas heurísticas para recomendar conteúdo que levem em conta não só as preferências dos usuários mas também os custos para servi-los.*

1. Introdução

Sistemas de recomendação e de distribuição de conteúdo estão cada vez mais presentes no dia-a-dia de milhões de usuários na Internet. Embora tais sistemas tenham impacto direto no desempenho do sistema de distribuição de conteúdo e na própria disponibilidade do conteúdo, a relação entre os dois é ainda muito pouco compreendida. Entender esta relação torna-se cada vez mais importante, dada a prevalência das redes par-a-par (P2P).

A tecnologia P2P é aplicada em vários ambientes, desde AVoD (Áudio e Vídeo sob Demanda) [Wu and Lui 2012, Zhou et al. 2012] até ambientes de colaboração e troca de arquivos [Guarnieri et al. 2013, Guarnieri et al. 2014, Zhang et al. 2012, Trestian et al. 2014]. Para todos esses ramos da tecnologia P2P já existe uma série de algoritmos de recomendação visando maior comodidade do usuário em encontrar um melhor conteúdo de acordo com seu perfil [Hecht et al. 2012]. Mesmo com a comprovação de que os mecanismos de recomendação possuem grande influência na decisão de consumo - principalmente multimídia (em média 30% das visualizações de cada vídeo do

YouTube é oriunda de recomendação [Zhou et al. 2010]) - nenhum desses algoritmos de recomendação foi até então usado para influenciar a QoS fornecida pela rede.

Nesse trabalho são propostas heurísticas para recomendação de conteúdo que possam melhorar a disseminação de conteúdo da rede P2P, além de priorizar os aspectos comuns de *precision and recall* para manter a qualidade das recomendações. Para tal, é avaliado como o sistema de recomendação (SR) pode fazer uso de métricas de qualidade de serviço (QoS) para sugerir conteúdo visando maximizar a satisfação do usuário. Reciprocamente, também foi estudado como o SR pode ser usado para aumentar a QoS experimentada por usuários que requerem conteúdo que, *a priori*, seria pouco replicado.

O objetivo desse trabalho é responder duas grandes questões:

1. A satisfação do usuário ao consumir um conteúdo recomendado está relacionada ao conteúdo em si e também à qualidade com que este lhe é servido. Entrando no contexto multimídia, a exigência da QoS de alta qualidade aumenta, por ter a necessidade de transmissão sob demanda sequencial do conteúdo. Tendo isso como base, **como o sistema de recomendação de conteúdo pode fazer uso das métricas de redes para aumentar a satisfação do usuário?**
2. Classicamente, assume-se que a demanda de tráfego por cada conteúdo na rede é uma variável exógena (fora do controle do sistema). Porém, se considerarmos a recomendação como parte do sistema, essa prerrogativa não é mais válida. Sendo assim, **como o administrador de rede pode fazer uso do sistema de recomendação de conteúdo para aumentar o desempenho da rede e diminuir os custos de distribuição?**

Para responder essas perguntas, foi proposto um modelo analítico relacionando as recomendações de conteúdo e a disseminação de conteúdo pela rede. A partir deste modelo, heurísticas para a confecção de um sistema de recomendação foram propostas. Dados do banco de avaliações do Movielens foram utilizados para testar o modelo. O custo de disseminação de conteúdo está sendo utilizado como uma alternativa para uma medição simplificada da QoS.

As principais contribuições do artigo são:

- (a) A modelagem dos *tradeoffs* envolvidos na recomendação de conteúdo levando em conta atributos de desempenho e custo da rede;
- (b) O uso do modelo proposto para derivar heurísticas a fim de recomendar conteúdos de forma a satisfazer os usuários e ao mesmo tempo reduzir os custos da rede.

O restante deste artigo está organizado da seguinte forma. Na seção 2 são introduzidos os conceitos básicos de SR e redes P2P, além dos trabalhos relacionados. Na seção 3 é apresentado o modelo proposto que unifica sistemas de recomendação e de distribuição de conteúdo em redes. Na seção 4 o modelo é parametrizado. Em seguida, o modelo é usado para propor, na seção 5, heurísticas para *design* de um sistema de recomendação. Na seção 6 é apresentada uma metodologia alternativa, baseada em algoritmos genéticos, para determinar parâmetros para um sistema de recomendação. Resultados experimentais são apresentados na seção 7 e a seção 8 conclui o trabalho.

2. Trabalhos Relacionados

Os pilares do presente trabalho são redes P2P [Mendonça and Leão 2012] e sistemas de recomendação de conteúdo [Mei et al. 2007, Chakoo et al. 2008]. Embora a literatura

nessas duas áreas seja vasta, não é de nosso conhecimento nenhum trabalho sobre os possíveis benefícios de uma abordagem integrada para estudo desses dois tópicos.

Os mecanismos de recomendação de conteúdo visam automatizar a filtragem de dados buscados por um usuário a partir dos dados desse mesmo usuário ou de outros similares que o sistema já conheça. Automatizar essa detecção de preferências nunca se mostrou uma tarefa simples, pois as pessoas possuem necessidades e desejos inesperados, que - mesmo demorando - podem mudar com o tempo [Chakoo et al. 2008, Adomavicius and Tuzhilin 2005]. Os mecanismos de recomendação mais populares são o Filtro Baseado em Conteúdo e o Filtro Colaborativo, que normalmente são usados combinados com outras técnicas [Adomavicius and Tuzhilin 2005].

Redes P2P possuem arquitetura distribuída e são bastante vantajosas em termos de economia de recursos por dividir a carga utilizando seus *peers*. No escopo P2P, alguns trabalhos utilizam AVoD P2P [Zhou et al. 2012, Wu and Lui 2012] com o protocolo BitTorrent. O BitTorrent é um dos protocolos mais usados para transferência de arquivos, principalmente arquivos multimídia [Mendonça and Leão 2012].

Arquivos multimídia estão em foco também na área de recomendação [Mei et al. 2007, Chakoo et al. 2008], principalmente depois dos prêmios oferecidos pelo Netflix para melhorar a recomendação do seu sistema AVoD. Um exemplo recente de recomendação multimídia em sistemas P2P é o Radiommender [Hecht et al. 2012], que propôs um SR de músicas distribuído em que o *peer* possui sua rádio personalizada. Mesmo com toda essa inovação, nenhum desses trabalhos tentou melhorar a QoS da rede utilizando recomendação. A recomendação geralmente é voltada somente para a interação entre usuários e conteúdo, não levando em conta a rede.

A proposta aqui apresentada de recomendação de conteúdo visa mitigar os custos dos servidores, recomendando conteúdo de tal forma a satisfazer o usuário e ao mesmo tempo reduzir a sobrecarga nos servidores. Uma versão preliminar deste trabalho foi apresentada em [Vieira et al. 2013]. Este trabalho estende [Vieira et al. 2013] de várias formas, incluindo: (a) a proposição de um modelo analítico para estudar sistemas de recomendação e suas conexões com sistemas de distribuição de conteúdo; (b) o uso do modelo para derivar heurísticas de recomendação de conteúdo e (c) a aplicação de algoritmos genéticos para busca do sistema de recomendação ótimo.

3. Modelo

Nesta seção é apresentado o modelo analítico para estudo dos *tradeoffs* envolvidos na recomendação de conteúdo levando em conta os custos e desempenho da rede. Primeiro, foram apresentados os parâmetros do modelo, as variáveis de controle e a metodologia para parametrização do modelo em função de *traces*. Em seguida, são introduzidas as funções de custo e recompensa, e é formulado o problema central tratado neste artigo.

3.1. Parâmetros e Variáveis de Controle

Parâmetros do sistema Os parâmetros do sistema são dados coletados a partir de *traces* de um sistema já existente. A seguir, são descritos os quatro principais parâmetros considerados neste artigo. Consideram-se N arquivos (conteúdos) disseminados por meio de uma rede. Seja λ_i ($i = 1, 2, \dots, N$) a taxa de chegada de visualizações para o conteúdo i . Essa taxa de chegada é também referenciada como a popularidade do arquivo i (vide

Tabela 1). Seja r_{ki} a probabilidade de um usuário que assistiu o conteúdo k assistir o conteúdo i . O parâmetro r_{ki} depende da relação entre os conteúdos k e i , e pode ser parametrizado via *traces* como explicado na seção 4.

Variáveis de controle Considera-se p_{ki} a probabilidade do sistema de recomendação de conteúdo recomendar o conteúdo i para um usuário que requisitou e acessou previamente o conteúdo k , $k = 1, \dots, N$, $i = 1, \dots, N$. Deste ponto em diante, assumimos $p_{ii} = 0$. O principal objetivo deste artigo consiste na determinação de p_{ki} de tal forma a satisfazer o usuário e ao mesmo tempo levando em conta as características de rede. Assume-se p_{ki} como variável de controle, pois é possível manipular essa probabilidade para mudar a recomendação padrão que o usuário recebe.

Seja γ_i a taxa de chegada perturbada para o conteúdo i , ou seja, a taxa levando em conta o impacto do sistema de recomendação. A taxa γ_i é dada, em função dos parâmetros do sistema, por

$$\gamma_i = \sum_{k=1}^N \lambda_k p_{ki} \quad (1)$$

Note que ao considerar a taxa de chegada perturbada ao conteúdo i , γ_i , leva-se em conta apenas as requisições provenientes de recomendação. Em particular, os usuários não trazem nenhum arquivo ao entrarem no sistema. O histórico de requisições não corresponde aos arquivos que o usuário disponibiliza para o sistema. O usuário contribui apenas para a popularidade do arquivo i a ele recomendado. O modelo pode facilmente ser adaptado para o cenário em que os usuários também trazem os arquivos por eles previamente solicitados, adicionando-se λ_i ao lado direito de (1).

3.2. Recompensas do Sistema de Recomendação de Conteúdo

A recompensa desse modelo representa o quão satisfeito o usuário fica ao aceitar uma recomendação. Essa recomendação pode ser obtida pelo próprio sistema de recomendação, conforme descrito na seção 3.1.

Dadas as recompensas individuais dos pares de filmes, a recompensa total do sistema de recomendação de conteúdo, R , é definida como

$$R = \sum_{k=1}^N \sum_{i=1}^N \lambda_k p_{ki} r_{ki} \quad (2)$$

3.3. Custos do Sistema de Distribuição de Conteúdo

Nessa seção caracterizamos o custo de disseminação de um conteúdo por um provedor, conforme proposto inicialmente por [Menasche et al. 2009].

Um *swarm* k de um sistema P2P é modelado como um sistema auto-escalável. Em sistemas P2P, arquivos pouco populares dependem do servidor para sua disseminação, enquanto que arquivos muito populares são auto-sustentáveis entre os *peers*, e não requerem sobrecarga no servidor para sua disseminação (vide seção 2). Sendo μ a capacidade dos *peers* e a taxa de chegada λ_k , assume-se, como caso extremo, que o servidor só irá servir *peers* caso haja exatamente um *peer* no *swarm*.

Variável	Descrição
N	número de arquivos
λ_i	popularidade do conteúdo i normalizada
Λ	taxa agregada de chegada de usuários ao sistema
r_{ki}	recompensa por recomendar-se i para requisitante de k
p_{ki}	probabilidade de recomendar-se conteúdo i para requisitante do conteúdo k
R	recompensa total
C	custo total
P	custo total perturbado pelo sistema de recomendação

Tabela 1. Tabela de notação: há 4 parâmetros no modelo proposto, 1 variável de controle referente ao sistema de recomendação e 3 métricas de interesse.

Seja M_k o número de usuários no *swarm* k . A probabilidade de haver exatamente um usuário no *swarm* k , modelado como uma fila $M/M/\infty$, é dada por $P(M_k = 1) = (\lambda_k/\mu)e^{-\lambda_k/\mu}$. O custo para servir cada *swarm* é proporcional a fração de tempo em que o servidor fica ocupado.

$$C_k(\lambda_k) = (\lambda_k/\mu)e^{-\lambda_k/\mu}, \quad k = 1, \dots, N \quad (3)$$

O custo total do sistema, para todos os *swarms* (conteúdos) sem influência do sistema de recomendação é

$$C = \sum_{k=1}^N (\lambda_k/\mu)e^{-\lambda_k/\mu} \quad (4)$$

O custo varia em função de λ_k e μ . No restante deste artigo adota-se $\mu = 1$. Por sua vez, o custo total perturbado pelo sistema de recomendação é

$$P = \sum_{k=1}^N \gamma_k e^{-\gamma_k} \quad (5)$$

O custo total perturbado é obtido a partir de (3), substituindo-se λ_k por γ_k , vide (5). Esta transformação captura o fato de que o SR afeta a taxa de chegada dos usuário ao *swarm* k , que deixa de ser λ_k e passa a ser γ_k , vide (1).

3.4. Formulação do Problema

O problema consiste em recomendar os melhores conteúdos de acordo com os interesses dos usuários e com o menor custo de disseminação possível. Nesse modelo, isso corresponde a determinar p_{ki} ($k = 1, \dots, N$, e $i = 1, \dots, N$), de tal forma a minimizar os custos e maximizar as recompensas por recomendação. A seguir, serão apresentadas estratégias para lidar com esta tensão entre objetivos conflitantes, usando heurísticas e algoritmos genéticos.

4. Parametrização do Sistema de Recomendação de Conteúdo via Traces

Será apresentada uma abordagem simples para parametrizar r_{ki} , ou seja, o quanto que um usuário que gostou do filme k irá gostar do filme i (vide seção 3.1).

Para tal, assume-se que tem-se em mãos um *trace* indicando, para cada usuário, os filmes que este já assistiu e o número de estrelas que o usuário atribuiu a cada filme. Tal informação está disponível sobre os usuários do sistema MovieLens [MovieLens 2013], que contém não apenas as avaliações dos usuários mas também os instantes em que elas ocorreram. O *trace* do MovieLens possui mais de 100,000 avaliações de filmes, sendo que neste artigo amostramos de forma uniforme e aleatória 1,000 delas, resultando em 551 filmes.

Considera-se um *trace* no qual U usuários deram notas (*ratings*) a N filmes. Cada *rating* é um número de estrelas, entre 1 e 5. Seja $Nrating_i$ o número de *ratings* dados ao filme i . Na amostra de 551 filmes considerada, $Nrating_i$ variou de 1 a 7, $i = 1, 2, \dots, 551$. O número de filmes para os quais $Nrating_i$ é igual a 1, 2, $\dots$, 7 foi 301, 143, 58, 22, 17, 4 e 6 respectivamente.

Normalizando o número de avaliações a um filme k pelo total de avaliações, obtêm-se a taxa de chegada (popularidade) do filme k , λ_k ,

$$\lambda_k = \Lambda \left(Nrating_k / \sum_{i=1}^N Nrating_i \right), \quad k = 1, \dots, N \quad (6)$$

sendo Λ a taxa agregada de chegada de usuários ao sistema. Na seção 7, será investigado o efeito de Λ nas diferentes métricas de interesse.

Seja $rating_{uki}$ o *rating* do usuário u ao filme i , para um usuário u que tenha feito o trajeto do conteúdo k para o conteúdo i , ou seja, que avaliou o conteúdo k e posteriormente o conteúdo i . Caso o usuário u não tenha feito o trajeto do conteúdo k para o i , $rating_{uki} = 0$. Seja $Nrating_{ki}$ a quantidade de usuários que fizeram o trajeto do conteúdo k para o conteúdo i .

A partir do *trace* fornecido, calculam-se os valores de r_{ki} tomando como inspiração o modelo do PageRank [Page et al. 1999],

$$r_{ki} = \left[\left(\frac{\sum_{u=1}^U rating_{uki}}{Nrating_{ki}} \right) / \left(\sum_{i=1}^N \frac{\sum_{u=1}^U rating_{uki}}{Nrating_{ki}} \right) \right] \beta + \frac{(1-\beta)1_{k \neq i}}{N-1}, \quad (k, i) \in \{1, \dots, N\}^2 \quad (7)$$

onde $1_{k \neq i} = 1$ caso $k \neq i$ e 0 caso contrário.

O primeiro termo entre parêntesis na eq. (7) corresponde ao *rating* médio dado ao conteúdo i pelos usuários u que assistiram k e depois i , enquanto o segundo termo é um fator de normalização. O segundo termo é o somatório, para todos os arquivos i , $i = 1, \dots, N$, do *rating* médio dado ao conteúdo i pelos usuários que assistiram k . Note que $0 \leq r_{ki} \leq 1$.

Assim como no PageRank, foi assumido um fator de atenuação β . Nesse artigo, consideramos $\beta = 1$. Esse fator reflete a probabilidade do usuário continuar vendo e avaliando conteúdos, ao invés de simplesmente escolher assistir um filme aleatoriamente. Em trabalhos futuros iremos considerar $\beta < 1$ para capturar o fato de que, mesmo que nenhum usuário tenha assistido um determinado par de filmes, a recomendação mútua possa ser positiva.

5. Heurísticas para Recomendação de Conteúdo

Nesta seção são propostas heurísticas para a determinação de p_{ki} , $(k, i) \in \{1, \dots, N\}^2$. As heurísticas são motivadas pelo modelo apresentado na última seção. Sejam $\hat{\lambda}$ e $\hat{r}$ dois limiares (*thresholds*) de popularidade e recompensa, respectivamente. Considera-se que um conteúdo k é popular se $\lambda_k > \hat{\lambda}$ e se a recomendação do conteúdo i para um usuário que requisitou k gera alta recompensa se $r_{ki} > \hat{r}$. Então, as heurísticas são baseadas nas seguintes duas regras simples:

1. **se os usuários que assistem k gostam de i (alta recompensa de recomendação), e i é popular (baixo custo de disseminação), recomendar i :** se $\hat{\lambda} < \lambda_i$ e $\hat{r} < r_{ki}$, então o conteúdo i tem alta demanda e há alta recompensa em se recomendar o conteúdo i para usuários que requisitam k , logo favorecemos valores de p_{ki} mais elevados;
2. **se os usuários que assistem k não gostam de i (baixa recompensa de recomendação), e i é popular (já possui baixo custo de disseminação, logo não precisa de *boost*), não recomendar i :** se $\hat{\lambda} < \lambda_i$ e $r_{ki} < \hat{r}$, então i tem alta demanda (seu custo de disseminação é baixo) e há baixa recompensa e baixa redução de custos ao se recomendar o conteúdo i para usuários que requisitam k , então favorecemos valores de p_{ki} mais moderados;

Dado um conteúdo k , seja n_k^+ o número de conteúdos classificados como de alta prioridade de recomendação (regra 1), n_k^- o número de conteúdos classificados como de baixa prioridade de recomendação (regra 2), e n_k^o os demais, $n_k^- + n_k^+ + n_k^o = N$. Analogamente, dado um conteúdo k , sejam $\mathcal{N}_k^+$, $\mathcal{N}_k^-$ e $\mathcal{N}_k^o$ os respectivos conjuntos de conteúdos de prioridade de recomendação alta, baixa e neutra.

- $\mathcal{N}_k^+ = \{j \in \mathbb{N} \mid \hat{\lambda} < \lambda_j \wedge \hat{r} < r_{kj}\}$, $n_k^+ = |\mathcal{N}_k^+|$
- $\mathcal{N}_k^- = \{j \in \mathbb{N} \mid \hat{\lambda} < \lambda_j \wedge \hat{r} > r_{kj}\}$, $n_k^- = |\mathcal{N}_k^-|$
- $\mathcal{N}_k^o = \{j \in \mathbb{N} \mid j \notin \mathcal{N}_k^+ \cup \mathcal{N}_k^-\}$, $n_k^o = |\mathcal{N}_k^o|$

A seguir, consideramos três diferentes heurísticas para recomendação de conteúdo construídas usando os conjuntos $\mathcal{N}_k^+$, $\mathcal{N}_k^-$ e $\mathcal{N}_k^o$.

5.1. Heurística 1: recomendação uniforme de conteúdos de prioridade alta e neutra

Segundo esta heurística, os conteúdos de prioridade alta e neutra são recomendados de forma aleatória uniformemente. Assim,

$$p_{ki} = \begin{cases} 1/(n_k^+ + n_k^o), & \text{se } i \in \mathcal{N}_k^+ \cup \mathcal{N}_k^o \\ 0, & \text{caso contrário} \end{cases} \quad (8)$$

5.2. Heurística 2: recomendação de conteúdos de prioridade alta e neutra, favorecendo os primeiros

Segundo esta heurística, os conteúdos de prioridade alta e neutra são recomendados de forma aleatória uniformemente, mas os primeiros são favorecidos. Para tal, foi introduzido o parâmetro $\epsilon < 1/(n_k^+ + n_k^o)$. Seja ϵ a probabilidade de se redirecionar uma recomendação para um conteúdo de alta prioridade e que, de acordo com a heurística 5.1, seria feita para um conteúdo de prioridade neutra. Assim,

$$p_{ki} = \begin{cases} 1/(n_k^+ + n_k^o) + \epsilon n_k^o/n_k^+, & \text{se } i \in \mathcal{N}_k^+ \\ 1/(n_k^+ + n_k^o) - \epsilon, & \text{se } i \in \mathcal{N}_k^o \\ 0, & \text{caso contrário} \end{cases} \quad (9)$$

5.3. Heurística 3: recomendação de conteúdos de prioridade alta e neutra, favorecendo os primeiros de acordo com suas recompensas

Esta última heurística é similar à heurística 5.2. Entretanto, ao invés de redirecionar-se uniformemente as recomendações que, de acordo com a heurística 5.1, seriam feitas para um conteúdo de prioridade neutra, faz-se esse redirecionamento adotando as recompensas r_{ki} como pesos. Assim,

$$p_{ki} = \begin{cases} 1/(n_k^+ + n_k^o) + \epsilon n_k^o r_{ki} / (\sum_{i=1}^N r_{ki}), & \text{se } i \in \mathcal{N}_k^+ \\ 1/(n_k^+ + n_k^o) - \epsilon, & \text{se } i \in \mathcal{N}_k^o \\ 0, & \text{caso contrário} \end{cases} \quad (10)$$

5.4. Setando limiares de popularidade e recompensa

Os limiares de popularidade e recompensa são usados para determinar se um determinado conteúdo é popular e se está associado a alta recompensa por recomendações, respectivamente. O limiar $\hat{\lambda}$ é definido como sendo a média das popularidades,

$$\hat{\lambda} = \frac{\sum_{i=1}^N \lambda_i}{N} \quad (11)$$

Em seguida, é determinado o limiar de recompensa. Sejam $\bar{r}$ e $\bar{\bar{r}}$ o valor mínimo e máximo de todos os r_{ki} , $\bar{r} = \min_{(k,i)} r_{k,i}$ e $\bar{\bar{r}} = \max_{(k,i)} r_{k,i}$. O limiar de recompensa $\hat{r}$ é definido como a média aritmética entre a recompensa mínima e a máxima,

$$\hat{r} = (\bar{\bar{r}} + \bar{r})/2 \quad (12)$$

6. Algoritmos Genéticos

A seguir, é proposta uma metodologia envolvendo o uso de algoritmos genéticos para buscar o sistema de recomendação de conteúdo ótimo. Em cada cenário, são fixados valores para r_{ki} e λ_k , $i = 1, \dots, N$, $k = 1, \dots, N$, e executado o algoritmo genético para determinação dos p_{ki} ótimos. Foi utilizado o programa MatLab® 2009 com a extensão de algoritmo genético (AG).

Note que, enquanto nas seções anteriores assume-se $\sum_{i=1}^N p_{ki} = 1$, nessa seção considera-se o caso em que $\sum_{i=1}^N p_{ki} \leq 1$. Dessa forma, usuários que não receberem recomendação de conteúdo vão embora do sistema imediatamente após consumirem o conteúdo de interesse. Isto ocorre, por exemplo, se a recomendação de certo conteúdo geraria custo tão alto que é vantajoso não recomendar ao usuário nenhum conteúdo.

O nível de *fitness* é dado pela recompensa total menos o custo total normalizado. O custo total normalizado é determinado de tal forma a penalizar mais as alocações nas quais o custo modificado esteja muito distante do custo de referência. Esta ideia é inspirada na maximização da recompensa sob a restrição de que o custo não ultrapasse significativamente o custo de referência. Neste trabalho, considera-se uma função degrau para o custo normalizado que penaliza mais fortemente custos que sejam muito acima do valor de referência, como indicado a seguir

$$\bar{C} = \begin{cases} 0, & \text{se } P - C < -1 \\ 10.000, & \text{se } -1 \leq P - C < 1 \\ 1.000.000, & \text{se } 1 \leq P - C < 10 \\ 100.000.000, & \text{caso contrário} \end{cases} \quad (13)$$




Figura 1. Na análise via algoritmos genéticos mais simples, consideram-se apenas dois arquivos. O objetivo é obter p_{AB} e p_{BA} .

A função de *fitness* F a ser maximizada é a recompensa R dada por (2) menos o custo normalizado dado por (13),

$$F = R - \bar{C} \quad (14)$$

Nos resultados experimentais, o objetivo é maximizar (14).

6.1. Cenário com Dois Arquivos

Na primeira análise via algoritmos genéticos, considera-se em cada cenário apenas dois arquivos, A e B , para estudar a interação dos p_{ki} com o AG. Com isso, são obtidos resultados no ambiente mais simples possível para depois ampliar a base de estudo. Dados um perfil de recompensas e popularidades, ou seja, dadas as recompensas r_{AB}, r_{BA} e as taxas de chegada λ_A e λ_B , o objetivo é obter p_{AB} e p_{BA} . Para tal, considera-se uma população de 200 indivíduos com dois genes $p_{AB}^{(l)}$ e $p_{BA}^{(l)}$, $A, B \in \{1, \dots, N\}$, em cada indivíduo l da população, $l = 1, \dots, 200$. Foi avaliada então a evolução da população por 50 gerações e utilizados os seguintes parâmetros no AG: a) 2 indivíduos em elitismo; b) a seleção é proporcional utilizando o método do torneio entre os 4 melhores indivíduos; c) *crossover* em um ponto único com taxa de mutação de 1% (vide Figura 1).

Após executar-se o algoritmo genético por uma geração, obtêm-se um novo conjunto de amostras de $p_{AB}^{(l)}$ e $p_{BA}^{(l)}$, para $l = 1, \dots, 200$. Dado o perfil de popularidades e recompensas, obtêm-se o custo modificado pelo SR, P , o custo de referência, C e a recompensa total, R , dados por (5), (4) e (2), respectivamente. O nível de *fitness* da população é dado por (14). Repete-se o algoritmo por 50 gerações.

6.2. MovieLens

O intuito agora é usar o AG para analisar o *trace* do MovieLens, a fim de encontrar os valores de p_{ki} que maximizem a função de *fitness* e comparar o custo e a recompensa resultantes com aquelas obtidas usando as heurísticas propostas. Para isso, foram utilizados os mesmos parâmetros da seção 6, envolvendo 551 filmes amostrados do *trace* de 1,000 avaliações do MovieLens. Note que temos agora 87 genes a serem otimizados, correspondendo aos 87 valores de p_{ki} para os quais $r_{ki} > 0$ (assumimos que $r_{ki} = 0 \Rightarrow p_{ki} = 0$). Repete-se o algoritmo por 100 gerações.

7. Resultados

Nessa seção são apresentados os resultados experimentais. Os objetivos são a) avaliar a qualidade das heurísticas propostas e b) estudar o comportamento do algoritmo genético na determinação de parâmetros para um sistema de recomendação de conteúdo.

7.1. Heurísticas

Nesta seção, são apresentados os resultados obtidos com as heurísticas da seção 5. Como referência, considera-se o conjunto de $N = 551$ arquivos introduzido na seção 4. Tanto a taxa de chegada dos arquivos quanto as recompensas são setadas usando um *trace* do Movielens [Movielens 2013], de acordo com a metodologia descrita na seção 4.




Figura 2. Tradeoffs envolvidos no sistema de recomendação (custos e recompensas). Resultados com heurísticas 1, 2 e 3, nas linhas 1, 2 e 3, respectivamente. Na primeira e segunda colunas estão as curvas de custos (em azul, sem sistema de recomendação e em verde com sistema de recomendação) e recompensas (em vermelho, máxima alcançável, com sistema de recomendação que não leva em conta a rede, e em verde, valor obtido com recomendação que leva em conta a rede). As heurísticas apresentaram padrões de custos similares, sendo que a terceira destacou-se pela sua maior recompensa.

A seguir, comparam-se os custos e recompensas de referência *versus* aqueles obtidos com as heurísticas propostas na seção 5. As curvas na Figura 2 ilustram como os custos e recompensas variam em função do somatório das taxas de chegada Λ . Nessas curvas foi considerado Λ variando de 1 até 20930, em incrementos de 70 (vide eq. (6)).

As curvas verdes de custos (Figuras 2(a)-(c)) correspondem aos valores obtidos com o sistema de recomendação, e as azuis sem ele. Note que, ao utilizar o sistema de recomendação, o pico do custo diminui significativamente para qualquer uma das heurísticas adotadas.

Nos gráficos de recompensas (Figuras 2(d)-(f)), as curvas vermelhas correspondem à recompensas obtidas caso o sistema de recomendação não levasse em conta os fatores relativos à rede. Nesse cenário clássico, recomenda-se para o usuário que assistiu k o conteúdo i tal que r_{ki} seja maximizado, ou seja, aumentando a satisfação (r_{ki}) do usuário que assistiu k e agora pode assistir i . As Figuras 2(a)-(c) quantificam a diminuição do custo ao adotar-se o sistema de recomendação proposto (curva verde) contra o cenário clássico (curva azul). Note que a heurística 3 gerou recompensas maiores que as heurísticas 1 e 2, com redução similar de custos, sendo assim considerada superior no cenário em questão.

7.2. Algoritmo Genético

A seguir, é analisado o comportamento do algoritmo genético em um cenário simplificado com dois arquivos (Seção 7.2.1) e usando o trace do Movielens (Seção 7.2.2). No primeiro caso serviu para uma análise qualitativa de comparação das heurísticas com os resultados obtidos via AG, verificando em que situações as heurísticas são corroboradas pelos resultados obtidos via AG, enquanto que no segundo caso foi feita uma comparação quantitativa dos resultados obtidos com as heurísticas na seção anterior contra aqueles obtidos usando o AG.

7.2.1. Cenário com Dois Arquivos

A seguir, são apresentados os resultados obtidos com o algoritmo genético proposto na seção 6. Consideramos um cenário de 2 arquivos, A e B . Para esses arquivos, o algoritmo genético tenta otimizar os valores de p_{AB} e p_{BA} a cada rodada, buscando em uma população de 200 indivíduos. Cada indivíduo possui inicialmente um p_{AB} e um p_{BA} escolhidos de forma uniforme e aleatória de 0 a 1, sendo que esses parâmetros p_{AB} e p_{BA} associados a cada indivíduo são chamados de **genes**. A intenção do AG é confrontar esses 200 indivíduos e encontrar as melhores combinações de p_{AB} e p_{BA} que tenham um custo total baixo e uma recompensa total alta.

Os custos totais de disseminação dos arquivos, originais e perturbados pelo mecanismo de recomendação, são dados pelas equações (4) e (5), respectivamente. Às recompensas r_{AB} e r_{BA} são atribuídos valores 0,1 (baixa), 0,5 (média) ou 0,9 (alta), e às taxas de chegada λ_A e λ_B são atribuídos valores de 5 a 30, de acordo com os objetivos do experimento em questão. Os cenários analisados são listados na Tabela 2. Nela, aparecem quatro grandes grupos de parâmetros que categorizamos como:

- *Grupo de parâmetros G1*: conteúdos com alta recompensa e alta taxa de chegada;

- *Grupo de parâmetros G2*: conteúdos com baixa recompensa e alta taxa de chegada;
- *Grupo de parâmetros G3*: conteúdos com baixa recompensa e baixa taxa de chegada;
- *Grupo de parâmetros G4*: conteúdos com taxa de chegada intermediária, estipulada como 15.

<i>cenário</i>	r_{AB}	r_{BA}	λ_A	λ_B	p_{AB}	p_{BA}	<i>score</i>
Grupo G1: Conteúdo com alta recompensa e alta taxa de chegada							
1	0,9	0,9	30	30	0,993292	0,998423	-9704
Grupo G2: Conteúdo com baixa recompensa e alta taxa de chegada							
2	0,1	0,1	30	30	0,985521	0,972787	-9967
Grupo G3: Conteúdo com baixa recompensa e baixa taxa de chegada							
3	0,1	0,1	5	5	0,01	0,01	-9999
Grupo G4: Conteúdo com λ intermediário estipulado como 15.							
4	0,1	0,1	15	15	0,990565	0,988124	-999983
5	0,5	0,5	15	15	0,995851	0,99	-999918
6	0,9	0,9	15	15	0,993053	0,994235	-999852

Tabela 2. Alguns resultados obtidos com o AG. A tabela está dividida respectivamente entre os quatro grupos de parâmetros estudados. Cada cenário possui uma taxa de chegada λ , um r_{ki} e um p_{ki} para os arquivos A e B , além do melhor *score* (combinação entre custo e recompensa) encontrado pelo AG.

No grupo G1 da Tabela 2, é possível visualizar que os p_{AB} e p_{BA} estão bem próximos de 1. Sendo assim, o AG está informando que é interessante recomendar esses arquivos, por terem grande quantidade de usuários interessados neles (alto λ) e por serem muito desejados por esses usuários (alto r_{AB} e r_{BA}). Esse grupo corrobora com a regra 1 da seção 5 para criação das heurísticas de p_{ki} : se $\hat{\lambda} < \lambda_i$ e $\hat{r} < r_{ki}$, então recebe p_{ki} mais elevado.

Já no grupo G2, o AG aparentemente determinou uma solução que vai de encontro ao estabelecido na regra 2 da seção 5: se $\hat{\lambda} < \lambda_i$ e $r_{ki} < \hat{r}$, então recebe p_{ki} mais moderados. Nesse grupo, existem dois arquivos muito populares (alto λ), mas não recomendáveis um ao outro (baixo r_{AB} e r_{BA}). Mesmo assim, o AG determinou altos valores de p_{AB} e p_{BA} (próximos de 1). Isso pode ser explicado pelo fato de λ muito alto estar contribuindo muito mais na função de custo do que o r_{ki} baixo na recompensa. Por ter um λ muito elevado, naturalmente as funções de custo das equações (3) e (5) tendem a diminuir muito ao recomendarmos os arquivos, mesmo que eles não sejam fortemente complementares. Assim, na ausência de outras possibilidades o AG favorece a recomendação em prol da diminuição dos custos de rede.

No grupo G3 da Tabela 2, o AG corrobora com a regra 2 das heurísticas. Para um conteúdo pouco popular (baixo λ) e com pouco interesse via recomendação por parte dos usuários (baixo r_{AB} e r_{BA}), não parece ser interessante recomendar o conteúdo para qualquer usuário. Com isso, ficou estabelecido pelo AG que conteúdos desse tipo receberiam valores próximos a 0 de p_{AB} e p_{BA} .

No grupo G4 da Tabela 2, com $\lambda = 15$, foram considerados três cenários. Para os três cenários, o *score* é menor que o dos grupos 1, 2 e 3. Quando $\lambda = 15$, os custos

são muito elevados e a recompensa baixa. Isto se deve ao fato de que o AG não foi capaz de determinar os parâmetros ótimos neste grupo. Trabalhos futuros consistem em avaliar políticas alternativas para estas situações.

A partir de uma análise detalhada de todos os cenários é possível determinar valores adequados de p_{ki} para diferentes ecossistemas de variáveis. Isso simplifica a criação de um SR que leve em conta as características de cada grupo de parâmetros e, assim, pré-estabelecer valores de p_{ki} adequados para diferentes situações.

7.2.2. Inferindo p_{ki} de Movielens com Algoritmo Genético

Depois de explorar um ambiente mais simples com dois arquivos, foram obtidos alguns resultados com o *trace* do Movielens e o AG. A Figura 3, ilustra os resultados do AG que podem ser comparados com as heurísticas da Figura 2. Em (a) e (b) é possível verificar os resultados de custo e recompensa, respectivamente, para os p_{ki} determinados pelo AG. O AG conseguiu diminuir o custo total do sistema e aumentar a recompensa até bem perto do valor máximo de recompensa total. Esses resultados ilustraram maior recompensa e menor custo que os resultados obtidos via melhor heurística (heurística 3, vide Seção 5.3).




Figura 3. Tradeoffs envolvidos no sistema de recomendação com AG (custos e recompensas). Os p_{ki} gerados pelo AG reduziram o custo e aumentaram a recompensa comparados a Figura 2.

8. Conclusão

Neste trabalho foram discutidos alguns dos potenciais benefícios de se estabelecer uma visão unificada sobre redes P2P e recomendação de conteúdo. As ideias aqui apresentadas podem ter importante impacto em outras redes, como em ICNs (*Information Centric Networks*) para armazenamento do melhor conteúdo, ou até mesmo na determinação do melhor conteúdo a ser guardado no *cache* de servidores *proxy* para diminuir a quantidade de *cache misses*. A otimização dos parâmetros do sistema de recomendação foi mais eficiente quando ao utilizar o AG em comparação com heurísticas pré-estabelecidas, dando margem para o estabelecimento de melhores heurísticas em trabalhos futuros.

Agradecimentos: Agradecemos a Gabriel Mendonça por comentários valiosos na preparação final do artigo.

Referências

- Adomavicius, G. and Tuzhilin, A. (2005). Towards the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734 – 749.
- Chakoo, N., Gupta, R., and Hiremath, J. (2008). Towards Better Content Visibility in Video Recommender Systems. *2008 Japan-China Workshop Frontier Comp. Sci. Tech.*
- Guarnieri, T., da Silva, A. P. C., and Vieira, A. B. (2013). Impact of dynamic social relationship in a file sharing system. In *Workshop on Dynamic Networks*.
- Guarnieri, T. A., da Silva, A. P. C., Almeida, J. M., and Vieira, A. B. (2014). Influência do facebook em enxames bittorrent. In *32o. Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos - SBRC 2014*.
- Hecht, F., Bocek, T., Bar, N., Erdin, R., Kuster, B., Zeeshan, M., and Stiller, B. (2012). Radiommender: P2p on-line radio with a distributed recommender system. In *P2P Computing, 2012 IEEE 12th*, pages 73–74.
- Mei, T., Yang, B., Hua, X., and Yang, L. (2007). VideoReach: an online video recommendation system. *SIGIR '07. ACM*, pages 767–768.
- Menasche, D. S., Neglia, G., Towsley, D., and Zilberstein, S. (2009). Strategic reasoning about bundling in swarming systems. In *GameNets' 09*, pages 611–620. IEEE.
- Mendonça, G. G. and Leão, R. M. M. (2012). BTStream — Um ambiente para desenvolvimento e teste de aplicações de streaming P2P. In *XXX SBRC, Salão de Ferramentas*.
- Movielens (2013). Movielens - movie recommendations. <http://movielens.umn.edu/>. [Online; accessed 11-March-2013].
- Page, L., Brin, S., Motwani, R., and Winograd, T. (1999). The pagerank citation ranking: Bringing order to the web. Technical Report 1999-66, Stanford InfoLab. Previous number = SIDL-WP-1999-0120.
- Trestian, I., Huguenin, K., Erramilli, V., Traverso, S., Papagiannaki, K., and Laoutais, N. (2014). Social-aware replication in geo-diverse online systems. *IEEE Transactions on Parallel and Distributed Systems*, 99(Preliminary):1.
- Vieira, D. M., Delgado, C., and Menasché, D. S. (2013). Como influenciar seus pares? sistemas de recomendação de conteúdo para redes p2p. In *WP2P+/SBRC (resumo extendido)*, pages 67–72.
- Wu, W. and Lui, J.-S. (2012). Exploring the optimal replication strategy in p2p-vod systems: Characterization and evaluation. In *INFOCOM*, pages 1206–1214.
- Zhang, H., Liu, B., Weng, X., and Yu, C. (2012). Can online social friends help to improve data swarming performance? In *Computer Communications and Networks (ICCCN), 2012 21st International Conference on*, pages 1–7.
- Zhou, R., Khemmarat, S., and Gao, L. (2010). The impact of YouTube recommendation system on video views. *IMC '10*, page 404.
- Zhou, Y., Fu, T., and Chiu, D. (2012). A unifying model and analysis of p2p vod replication and scheduling. *INFOCOM, 2012 Proceedings IEEE*.