

Filas com Prioridades: Novas Metodologias de Análise

Paulo Henrique de Aguiar Rodrigues¹, Daniel Sadoc Menasché¹

¹Departamento de Ciência da Computação
Universidade Federal do Rio de Janeiro (UFRJ)
Av. Athos da S. Ramos, 149 – Blc C – 21.941-909
Rio de Janeiro – RJ – Brasil

aguiar@ufrj.br, sadoc@dcc.ufrj.br

Abstract. *Priority queues are one of the fundamental tools to analyze the performance of communications and computer networks, and scheduling in computing systems. Although priority queues have been analyzed for more than 5 decades, their treatment in the literature usually requires a significant background. In this paper, we present a novel methodology to derive closed form solutions for the mean number of users in a queue with priorities. The methodology is significantly simpler than the other ones found in literature, and, we believe, brings novel insights about the system.*

Resumo. *Filas com prioridades são uma das principais ferramentas analíticas para a análise de desempenho de redes de comunicação e de computadores, e disciplinas de escalonamento em sistemas computacionais. A análise destas filas tem sido alvo de estudo há mais de 5 décadas, mas através de derivações complexas e de difícil compreensão. Neste artigo, apresentamos uma nova abordagem para a determinação da média do número de clientes de alta e baixa prioridade em uma fila com prioridades. A abordagem baseia-se em princípios básicos de teoria de filas, e é significativamente mais simples e intuitiva que as abordagens prévias, encontradas na literatura.*

1. Introdução

Modelos de filas com prioridades podem ser usados para analisar políticas de QoS em aplicações multimídia [Markhasin 2008], escalonamento de processos em servidores [Gittins and Nash 1977, Wierman 2007], *data centers* [Liu et al. 2013] e aplicações *MapReduce* [Lin et al. 2013], e gerenciamento de tarefas administrativas [Gupta 2013]. Sistemas inteligentes envolvendo controladores, como *Software Defined Networks* (SDN) e OpenFlow, podem fazer uso de prioridades para melhorar o desempenho [McKeown et al. 2008]. Rádios cognitivos constituem outro território fértil para a aplicação de prioridades na decisão das ações de usuários primários e secundários. Dessa forma, filas com prioridades constituem uma ferramenta fundamental de análise, sendo pesquisadas há mais de 5 décadas [Jaiswal 1968, Harchol-Balter 2013].

Dada a importância do uso de filas com prioridade na avaliação de desempenho de diferentes cenários modernos, é surpreendente que não haja nenhuma abordagem intuitiva para o entendimento e derivação de propriedades básicas das mesmas. Mais além, os livros texto padrões de teoria de filas [Kleinrock 1976, Harchol-Balter 2013, Stewart 2009,

Le Boudec 2010] não tratam os casos com preempção sem continuidade, onde o serviço interrompido de menor prioridade recomeça depois de onde parou, devido à dificuldade da análise. Nosso objetivo é preencher esta lacuna, apresentando metodologia simples para derivar o tempo médio experimentado pelos usuários em diferentes cenários.

Num sistema com prioridade sem preempção, o usuário de baixa prioridade, após entrar em serviço, não pode ser mais interrompido. Este cenário é amplamente estudado em livros-texto (e.g., [Harchol-Balter 2013]), em vídeo [Menasché 2013] e analisado em [Rodrigues 2013a]. Por isso, o artigo abordará apenas cenários com preempção.

Neste artigo apresentamos duas abordagens gerais, que podem ser adaptadas para análise de inúmeros tipos de filas com prioridades, incluindo os casos com preempção e sem continuidade. A abordagem padrão para a análise de filas com prioridades com preempção sem continuidade consiste na obtenção da transformada do número de clientes no sistema, em função do tempo e de condições iniciais. As análises resultam em transformadas de Laplace multidimensionais (assunto em geral não coberto em livros texto elementares) e expressões de difícil interpretação mesmo para um especialista na área, sem qualquer aspecto intuitivo. Nossas abordagens, em contraste, dependem apenas de transformadas com um único parâmetro, sendo de fácil derivação e interpretação, e constituem uma contribuição importante para o entendimento de filas com prioridades.

O restante deste artigo está organizado da seguinte forma. Na seção 2 apresentamos o sistema a ser considerado. Nas seções 3 e 4 derivamos as duas abordagens propostas. A seguir, em cada uma das seções subsequentes, especializamos os resultados para cenários de especial interesse, a saber, filas com prioridades com preempção e continuidade (o serviço continua de onde parou, vide seção 5), e filas com prioridades com preempção e sem continuidade, com reamostragem (aloca um novo serviço a cada reentrada no servidor, vide seção 6) e sem reamostragem (repete o mesmo serviço a cada reentrada no servidor, vide seção 7). A seção 8 discute trabalhos relacionados e a seção 9 traz a conclusão e considerações finais.




Figura 1. Cenário geral. Clientes do tipo 1 tem prioridade sobre clientes do tipo 2 e dentro de cada classe a disciplina de atendimento é sempre FCFS.

2. Sistema com Prioridade

O sistema considerado é apresentado na Figura 1. Clientes de alta e baixa prioridades chegam a um servidor único, segundo fluxos Poisson com taxas λ_1 e λ_2 , respectivamente. Seja $\lambda = \lambda_1 + \lambda_2$. Clientes de alta prioridade (tipo 1) demandam serviço que é caracterizado pela variável aleatória X_1 (pdf $f_{X_1}(x)$), com transformada de Laplace (T.L.) $X_1^*(s)$, enquanto o serviço dos que clientes de baixa prioridade (tipo 2) é dado pela variável aleatória X_2 (pdf $f_{X_2}(x)$), com T.L. $X_2^*(s)$. Em cada classe, o atendimento é sempre na ordem de chegada (FCFS), implicando que, em cenários com preempção (Seções 5-7), o cliente interrompido seja sempre o próximo da classe a ser atendido.

As métricas de interesse são o tempo de espera na fila de espera (sem contar o tempo de serviço) dos clientes do tipo 1 e 2, W_1 e W_2 , respectivamente, com médias (ou esperanças) dadas por $E[W_1]$ e $E[W_2]$. O tempo de permanência dos usuários do tipo 1 e tipo 2 no sistema é dado por T_1 e T_2 , respectivamente, onde $T_i = W_i + X_i$, $i = 1, 2$. A partir dos tempos médios e usando o resultado de Little, pode-se obter o número médio na fila de espera e no sistema.

3. Metodologia geral I: analisando os ciclos

Para os clientes do tipo 1, seja $E[X_{1r}]$ a vida residual do serviço e $\rho_1 = \lambda_1 E[X_1]$, o número médio destes clientes no servidor, grandeza também conhecida como utilização. Como $E[W_1]$ independe da presença dos clientes do tipo 2 para sistemas com preempção, tem-se diretamente pela fórmula de Pollaczek-Khinchin para valor médio em M/G/1 que, para $\rho_1 < 1$, $E[W_1] = \rho_1 E[X_{1r}] / (1 - \rho_1)$ e $E[T_1] = E[W_1] + E[X_1]$.

Para calcular o tempo médio de espera dos clientes do tipo 2, vamos acompanhar C_2 , um freguês típico do tipo 2, através do sistema desde a sua chegada. Quando C_2 chega ao sistema, ele pode encontrar uma dentre três situações:

- sistema vazio (evento V)
- sistema ocupado com período ocupado iniciado por cliente do tipo 2 (evento O_2)
- sistema ocupado com período ocupado iniciado por cliente do tipo 1 (evento O_1)




Figura 2. Ciclos do sistema

A probabilidade de um período ocupado iniciar com uma chegada do tipo i é

$$P(I = i) = \frac{\lambda_i}{\lambda_1 + \lambda_2} = \frac{\lambda_i}{\lambda}, i = 1, 2 \quad (1)$$

O tempo médio que o servidor fica ocioso, contado desde o instante que o servidor fica vazio até ocorrer uma chegada, é $1/\lambda$.

Seja $E[B|I = i]$ a duração média de um período ocupado iniciado por um cliente do tipo i . Usando a teoria da renovação, e observando os ciclos ilustrados na Figura 2, percebemos que a probabilidade de uma chegada encontrar o servidor vazio é,

$$P(V) = \frac{1/\lambda}{E[B] + 1/\lambda} = \frac{1}{\lambda_2 E[B|I = 2] + \lambda_1 E[B|I = 1] + 1}$$

De forma semelhante, a probabilidade de uma chegada encontrar o servidor ocupado com um período ocupado iniciado por um cliente do tipo i é,

$$P(O_i) = \frac{\lambda_i E[B|I = i]}{\lambda_2 E[B|I = 2] + \lambda_1 E[B|I = 1] + 1}$$

Dessa forma, $E[W_2] = E[W_2|V]P(V) + E[W_2|O_1]P(O_1) + E[W_2|O_2]P(O_2)$ e, como $E[W_2|V] = 0$, temos

$$E[W_2] = \frac{E[W_2|O_1]\lambda_1 E[B|I = 1] + E[W_2|O_2]\lambda_2 E[B|I = 2]}{\lambda_2 E[B|I = 2] + \lambda_1 E[B|I = 1] + 1} \quad (2)$$

Inicialmente, vamos deduzir as médias condicionadas ao evento O_2 , quando C_2 encontra no sistema o cliente do mesmo tipo que iniciou o período ocupado.

Seja D_2 o tempo entre o instante que C_2 entra em serviço pela primeira vez até sair do sistema. O tempo até C_2 entrar no servidor pode ser imaginado com o tempo de espera em uma fila virtual M/G/1, na qual clientes do tipo 2 chegam com taxa λ_2 e são servidos por um tempo D_2 , formado pelo tempo de serviço X_2 e pelos serviços de todos os clientes do tipo 1 que interrompem o cliente do tipo 2 até que ele saia do sistema. Quando o cliente é interrompido, assume-se na fila virtual que ele continua em serviço. Para $\rho_2^\# = \lambda_2 E[D_2] < 1$, o tempo médio de espera será na fila virtual dado pela fórmula da M/G/1, $E[W_2^\#] = \frac{\rho_2^\# E[D_2^2]}{1 - \rho_2^\#}$, e a vida residual do serviço dada por $E[D_2^r] = \frac{E[D_2^2]}{2E[D_2]}$.

Assumindo $N_2^\# =$ o número de clientes na fila virtual, temos

$$E[W_2|O_2] = E[W_2^\# | N_2^\# > 0] = \frac{E[W_2^\#]}{P(N_2^\# > 0)} = \frac{E[D_2^r]}{1 - \rho_2^\#}, \quad \rho_2^\# < 1 \quad (3)$$

O período ocupado médio iniciado por um cliente do tipo 2 é igual ao período ocupado médio da fila virtual descrita acima e então

$$E[B|I = 2] = \frac{E[D_2]}{1 - \rho_2^\#}, \quad \rho_2^\# < 1 \quad (4)$$

A seguir, vamos analisar o evento O_1 , onde C_2 encontra um período ocupado iniciado por um freguês do tipo 1. Considerando B_1 como o período ocupado de uma fila M/G/1 alimentada apenas por fregueses do tipo 1, $E[B|I = 1]$ pode ser visto como o período ocupado médio da fila virtual acima modificada, onde o primeiro serviço em cada período ocupado é dado por B_1 e os demais são dados por D_2 .

Sabendo que $E[B_1] = \frac{E[X_1]}{1 - \rho_1}$, $\rho_1 < 1$, temos

$$E[B|I = 1] = \frac{E[B_1]}{1 - \rho_2^\#} = \frac{E[X_1]}{(1 - \rho_1)(1 - \rho_2^\#)}, \quad \rho_2^\# < 1 \quad (5)$$

Resta-nos calcular $E[W_2|O_1]$. Seja W_0 o tempo de espera na fila M/G/1 virtual modificada descrita acima e seja N_0 o número de clientes nessa fila. $E[W_0]$ pode ser obtido via cadeia embutida (vide [Harchol-Balter 2013] ou [Rodrigues 2013a, pg 87]). Então,

$$E[W_2|O_1] = \frac{E[W_0]}{P(N_0 > 0)} = \frac{E[W_0]}{1 - P(N_0 = 0)} = \frac{\frac{\lambda_2 E[D_2^2]}{2(1-\rho_2^\#)} + \frac{\lambda_2 E[B_1^2] - \lambda_2 E[D_2^2]}{2(1-\rho_2^\# + \lambda_2 E[B_1])}}{\frac{\lambda_2 E[B_1]}{1 - \lambda_2 E[D_2] + \lambda_2 E[B_1]}} \quad (6)$$

Substituindo (4), (3), (5) e (6) em (2), obtemos $E[W_2] = E[W_2^\#] + \rho_1 E[B_1^r]$, onde é conhecido que $E[B_1^r] = \frac{E[B_1^2]}{2E[B_1]} = \frac{E[X_1^2]}{2(1-\rho_1)^2 E[X_1]}$. Consequentemente,

$$E[T_2] = E[D_2] + E[W_2] = E[D_2] + E[W_2^\#] + \rho_1 E[B_1^r] \quad (7)$$

Analisando $E[T_2]$, o termo $E[D_2] + E[W_2^\#]$ representa o tempo médio na fila virtual, onde os serviços são sempre do tipo D_2 . Todavia, nas situações em que C_2 chega ao sistema e encontra um serviço iniciado por um freguês do tipo 1, o período ocupado residual dos fregueses do tipo 1 pode ser visto como um tempo de férias do servidor. A teoria clássica de filas mostra que $E[T_{férias}] = E[T_{M/G/1}] + \text{vida residual das férias}$, o que justifica nossa interpretação e justifica como escrever a equação de $E[T_2]$ sem qualquer dedução. Como já observado, a condição de estabilidade para a classe 2 é dada por $\rho_2^\# < 1$.

3.1. Comparação com resultados da literatura

De acordo com as equações (3.21) do cap. IV do livro *Priority Queues*, Jaiswal e eq (6.6) do cap. III do mesmo livro, temos,

$$E[N_2] = \lambda_2 E[D_2] + \frac{\lambda_1 \lambda_2 E[X_1^2]}{2(1 - \rho_1)^2} + \frac{\lambda_2^2 E[D_2^2]}{2(1 - \lambda_2 E[D_2])}$$

Fazendo uma simples manipulação algébrica da expressão de $E[N_2]$ acima obtemos

$$\begin{aligned} E[N_2] &= \lambda_2 \left(E[D_2] + \lambda_1 \frac{E[B_1^2]}{2(1 + \lambda_1 E[B_1])} + \frac{\lambda_2 E[D_2^2]}{2(1 - \lambda_2 E[D_2])} \right) \\ &= \lambda_2 \left(E[D_2] + \rho_1 E[B_1^r] + E[W_2^\#] \right) \end{aligned}$$

demonstrando, por Little, que obtemos o mesmo resultado que Jaiswal para $E[T_2]$.

4. Metodologia geral II: foto do sistema no instante de chegada

Apresentamos agora a segunda metodologia para análise de filas com prioridades. A metodologia consiste em fazer uma tirada de foto virtual do sistema no instante de chegada do cliente típico ao sistema. Nessa foto, o cliente típico registra o número médio de pessoas de cada tipo que ele encontra no sistema e que devem ser servidas antes dele. A partir desses valores e considerando o tempo de serviço de cada pessoa em média, ele pode identificar o trabalho médio pendente até que ele possa entrar no servidor (quando se obter $E[W_2]$ para sistemas não preemptivos) ou sair do sistema (quando se procura obter $E[T_2]$ para sistemas preemptivos), imaginando-se que não ocorram mais chegadas ao sistema. Caso esteja-se considerando um sistema sem preempção, calcula-se o tempo

médio até entrar-se no servidor. Caso esteja-se considerando um sistema com preempção, calcula-se o tempo médio até a saída do sistema. Em ambos os casos, em primeiro passo, não se leva em conta o impacto dos períodos ocupados gerados pelos clientes de mais alta prioridade que chegarem, enquanto os clientes encontrados pelo cliente típico e ele próprio estiverem ainda no sistema. Finalmente, expande-se o tempo de espera para levar em conta estes períodos ocupados usando a expressão do período ocupado modificado (quando o tempo do serviço inicial é diferente de todos os outros) e obtém-se a solução final para o problema. Resumimos na Tabela 1 as principais ideias envolvidas em tal abordagem, focando nos clientes do tipo 2 (menos prioritários). A Tabela 2 resume as definições das variáveis envolvidas nas deduções analíticas.

tipo de fila	métrica de interesse	trab. pendente na chegada	per. ocup. modificado
sem preempção	$E[W]$, tempo em fila de espera	$E[W_{02}]$	$E[W_2] = \frac{E[W_{02}]}{1-\rho_1}$
com preempção	$E[T]$, tempo no sistema	$E[T_{02}]$	$E[T_2] = \frac{E[T_{02}]}{1-\rho_1}$

Tabela 1. Metodologia da foto para análise de filas FCFS com duas prioridades

variável	descrição
T_1	tempo no sistema do cliente de alta prioridade
T_2	tempo no sistema do cliente de baixa prioridade
$W_2^\#$	tempo de espera do cliente de baixa prioridade na fila de espera virtual
B_1^r	vida residual do período ocupado dos clientes de alta prioridade
D_2	tempo de serviço dos clientes de baixa prioridade na fila virtual
D_2^r	vida residual de D_2
ρ_1	utilização do servidor por clientes de alta prioridade, $\rho_1 = \lambda_1 E[X_1]$
ρ_2	utilização do servidor por clientes de baixa prioridade, $\rho_2 = \lambda_2 E[X_{t2}]$
$\rho_2^\#$	utilização do servidor virtual, $\rho_2^\# = \lambda_2 E[D_2]$
X_{t2}	tempo no servidor desde que cliente entra pela primeira vez, até sair do sistema, $E[X_{t2}] = (1 - \rho_1)E[D_2]$
$X_{t2}^\#$	vida residual de X_{t2}

Tabela 2. Tabela de notação. A fila virtual refere-se a uma fila M/G/1 com taxa de chegadas λ_2 e tempo médio de serviço $1/\mu_2^\# = E[D_2]$.

5. Preempção com continuidade: após uma interrupção, o serviço do menos prioritário recomeça de onde parou

Neste sistema, os clientes do tipo 2 podem ter o serviço interrompido pela chegada de clientes mais prioritários do tipo 1. Quando não mais existirem clientes prioritários no sistema, o cliente interrompido retorna e recomeça o serviço de onde parou. Um exemplo ilustrativo deste cenário envolve tarefas que podem ser interrompidas por um rejuvenescimento do monitor de máquina virtual (VMM) no servidor. VMM pode esperar que o processo em serviço termine (nesse caso, temos prioridade sem preempção) ou então salvar o estado atual e reiniciar o processo a partir do ponto de interrupção, quando temos prioridade com preempção e continuidade [Machida et al. 2014]. Queremos obter $E[T_2]$.

5.1. Usando a metodologia geral I: ciclos

No sistema com preempção com continuidade, D_2 , o serviço virtual, é formado pelo serviço X_2 do frequês típico C_2 e da soma dos períodos ocupados $B_{1,k}$ formados pelos serviços do tipo 1, a cada interrupção de serviço de C_2 . Sendo K o número de interrupções sofridas por C_2 , a teoria indica que $K(z) = X_2^*(\lambda_1 - \lambda_1 z)$.

O tempo médio na fila espera virtual é dado por

$$E[W_2^\#] = \frac{\rho_2^\# E[X_2^\#]}{1 - \rho_2^\#} = \frac{\lambda_2 E[D_2] E[D_2^r]}{1 - \lambda_2 E[D_2]} = \frac{\lambda_2 E[D_2] E[D_2^r]}{1 - \lambda_2 E[D_2]} = \frac{\lambda_2 E[D_2^2]/2}{1 - \lambda_2 E[D_2]} \quad (8)$$

Dado $D_2^*(s)$, $E[D_2] = -D_2'^*(0)$ e $E[D_2^2] = D_2''^*(0)$. Conhecido $K(z)$ e $E[B_{1,k}] = E[B_1] = \frac{E[X_1]}{1 - \rho_1}$, $\rho_1 < 1$, e dado que $D_2 = \sum_{j=0}^K B_{1,j} + X_2$, $D_2^*(s)$ pode ser obtida através de condicionamento duplo, visto que X_2 e K são dependentes. Temos

$$\begin{aligned} D_2^*(s) &= \int_{x_2=0}^{\infty} e^{-sx_2} \sum_{k=1}^K E[e^{-sB_1}]^k P(K = k | x_2 < X_2 < x_2 + dx_2) f_{X_2}(x_2) dx_2 \\ &= \int_{x_2=0}^{\infty} e^{-sx_2} K(B_1^*(s) | x_2 < X_2 < x_2 + dx_2) f_{X_2}(x_2) dx_2 \\ &= \int_{x_2=0}^{\infty} e^{-sx_2} e^{-\lambda_1(1-B_1^*(s))x_2} f_{X_2}(x_2) dx_2 = X_2^*(\lambda_1 - \lambda_1 B_1^*(s) + s) \end{aligned}$$

Logo,

$$E[D_2] = -X_2'^*(0)(1 - \lambda_1 B_1'^*(0)) = \frac{E[X_2]}{1 - \rho_1} \quad (9)$$

$$E[D_2^2] = X_2''^*(0)(1 + \lambda_1 E[B_1])^2 - \lambda_1 X_2'^*(0) B_1'^*(0) = \frac{E[X_2^2]}{(1 - \rho_1)^2} + \frac{\rho_2 E[X_1^2]}{(1 - \rho_1)^3} \quad (10)$$

Usando (9) e (10) em (7), obtém-se o tempo médio de espera $E[T_2]$. A estabilidade da fila 2 requer $\rho_2^\# = \lambda_2 E[D_2] = \frac{\rho_2}{1 - \rho_1} < 1$, implicando em $\rho_1 + \rho_2 < 1$.

5.2. Usando a metodologia geral II: fotos

Com esta metodologia, para a obtenção de $E[T_2]$, identificamos o trabalho médio pendente na chegada de C_2 e aplicamos o conceito do período ocupado modificado, como indicado na seção 4. Como o atendimento é FCFS em cada classe e o servidor está sempre ocupado quando o sistema não está vazio (sistema conservativo), o trabalho médio pendente $E[T_{02}]$ pode ser interpretado como o tempo médio de espera em uma fila M/G/1 alimentada pelos dois tipos de clientes mais o serviço $E[X_2]$ do próprio C_2 . Então, $E[T_{02}] = E[X_2] + \frac{\rho_1 E[X_{1r}] + \rho_2 E[X_{2r}]}{1 - \rho_1 - \rho_2}$, $\rho_1 + \rho_2 < 1$.

Lembrando que $E[T_2] = \frac{E[T_{02}]}{1 - \rho_1}$, obtém-se

$$E[T_2] = \frac{E[X_2](1 - \rho_1 - \rho_2) + \rho_1 E[X_{1r}] + \rho_2 E[X_{2r}]}{(1 - \rho_1)(1 - \rho_1 - \rho_2)}, \quad \rho_1 + \rho_2 < 1 \quad (11)$$

É fácil mostrar que a solução acima é igual à obtida usando a metodologia geral via ciclos.

6. Preempção e reamostragem da classe menos prioritária: um novo serviço X_2 é alocado a cada reentrada no servidor

Neste sistema, a cada reentrada da classe menos prioritária no servidor, um novo serviço X_2 é alocado. Como exemplo de aplicação, em redes de rádios cognitivos, quando o usuário primário entra em cena os usuários secundários são imediatamente interrompidos. Considere um canal altamente dinâmico (*fading* varia muito em função do tempo) [Cabric et al. 2004]. Quando o canal fica disponível novamente para os usuários secundários, o canal já mudou de estado, o que implica em um novo tempo de serviço para a classe 2, menos prioritária, caracterizando o modelo preemptivo com reamostragem.

6.1. Usando metodologia geral I: ciclos

Seja D_2 o tempo que um cliente leva desde que entra no servidor pela primeira vez até sair do sistema. Seja Y uma variável exponencialmente distribuída com taxa λ_1 e que representa o intervalo entre chegadas dos clientes mais prioritários. Quando o serviço de C_2 , o freguês típico do tipo 2, é interrompido pela j -ésima vez, o serviço interrompido é dado por $R_j = Y|Y < X_2$. Após a interrupção, segue um período ocupado B_1 . Somente ao final de B_1 , C_2 retorna ao servidor, iniciando um novo serviço X_2 . O tempo entre retornos ao servidor após a j -ésima interrupção é dado por $Z_j = R_j + B_1$. Em sua última passagem pelo servidor, C_2 não sofre interrupção e o serviço é dado por $V = X_2|X_2 < Y$.

No que segue, seja N o número de interrupções sofridas por C_2 . A probabilidade de um serviço X_2 não ser interrompido por uma chegada do fluxo 1 é dada por $X_2^*(\lambda_1)$ e a probabilidade de ser interrompido é $1 - X_2^*(\lambda_1)$. É imediato então verificar que a variável N terá uma distribuição geométrica com parâmetro $X_2^*(\lambda_1)$.

Então $D_2 = \sum_{j=0}^N Z_j + V$, com $Z_0 = 0$. Temos

$$E[D_2] = E[N](E[Y|Y < X_2] + E[B_1]) + E[X_2|X_2 < Y] \quad (12)$$

e as esperanças condicionais acima são facilmente obtidas por condicionamento [Rodrigues 2013a]. Pode-se mostrar que $D_2^*(s) = N(Z_i^*(s))V^*(s)$ e

$$D_2^{''*}(s) = N''(1)(Z_i^*(s))^2 + 2N'(1)Z_i^*(s)V^*(s) + V^{''*}(s) + N'(1)Z_i^{''*}(s) \quad (13)$$

$E[D_2^2]$ será dado por $D_2^{''*}(0)$. Usando $E[D_2]$ e $E[D_2^2]$ em (7), obtem-se $E[T_2]$.

6.2. Usando metodologia geral II: fotos

6.2.1. Tempo de permanência efetiva no servidor

Seja $E[X_{t2}]$ o tempo médio que um cliente do tipo 2 passa no servidor desde o instante em que entra no servidor pela primeira vez até finalmente sair. Assim, a utilização da classe 2 será dada por $\rho_2 = \lambda_2 E[X_{t2}]$. Sendo D_2 o tempo entre entrar em serviço pela primeira vez até sair do sistema e que durante este tempo $\lambda_1 E[D_2]$ clientes do tipo 1 chegaram e foram atendidos antes de C_2 , então $E[X_{t2}] = E[D_2] - \lambda_1 E[D_2]E[X_1] = (1 - \rho_1)E[D_2]$, $E[D_2]$ dado por (12). Embora existam outras formas de deduzir a relação entre as duas grandezas, esta é a mais simples. Da relação temos $\rho_2 = (1 - \rho_1)\rho_2^\#$ e $\rho_2^\# < 1$ implica em $\rho_1 + \rho_2 < 1$.

6.2.2. Tempo de permanência no sistema

Ao chegar, C_2 encontra na média $E[N_{q1}]$ clientes do tipo 1 na fila de espera, cada um deles requerendo $E[X_1]$ de serviço, e ρ_1 clientes deste tipo no servidor, com $E[X_{1r}]$ de serviço residual. Então, o trabalho pendente do tipo 1 na chegada é $E[N_{q1}]E[X_1] + \rho_1 E[X_{1r}] = E[W_1]$, fórmula básica de M/G/1. Do tipo 2, são encontrados $E[N_{q2}] = \lambda_2 E[W_2]$ clientes na fila de espera, cada um deles requerendo $E[X_{t2}]$ de serviço, e $\rho_2 = \lambda_2 E[X_{t2}]$ clientes em serviço, com um serviço residual $E[X_{t2r}]$.

Observando que $E[W_2] = E[T_2] - E[X_{t2}]$ e que o serviço de C_2 será também $E[X_{t2}]$, temos $E[T_{02}] = E[W_1] + \rho_2 E[T_2] - \rho_2 E[X_{t2}] + \rho_2 E[X_{t2r}] + E[X_{t2}]$. Como todo este tempo é expandido pelas chegadas prioritárias, temos $E[T_2] = \frac{E[T_{02}]}{1 - \rho_1}$. Então,

$$E[T_2] = \frac{E[W_1] + \rho_2 E[X_{t2r}] + (1 - \rho_2) E[X_{t2}]}{1 - \rho_1 - \rho_2}, \rho_1 + \rho_2 < 1 \quad (14)$$

Para o cálculo de $E[T_2]$, a variável $E[X_{t2r}]$ tem que ser obtida, o que será feito a seguir.

6.2.3. Obtenção de $E[X_{t2r}]$

Nosso objetivo é calcular $E[X_{t2r}]$, a vida residual do serviço do tipo 2 na chegada de C_2 . A Figura 3 mostra a ocupação do servidor no tempo, quando apenas clientes do tipo 2 são considerados. O servidor passa por ciclos, onde cada ciclo é formado por um serviço do tipo 2, seja ele interrompido ou não por uma chegada do tipo 1. Uma chegada C_2 pode encontrar um dos dois tipos de serviço 2 em andamento. Para cálculo dos ciclos, seja Y uma variável exponencial com taxa λ_1 . A duração de um ciclo não interrompido




Figura 3. Ciclos de serviço dos clientes do tipo 2

é $X_2 | X_2 < Y$ e a duração de um ciclo interrompido é $Y | Y < X_2$. Para cada ciclo não interrompido temos, em média, $\frac{1 - X_2^*(\lambda_1)}{X_2^*(\lambda_1)}$ ciclos interrompidos. Note que a fração de ciclos não interrompidos é $X_2^*(\lambda_1)$. Será preciso calcular as vidas residuais médias dos ciclos acima, de modo que teremos que calcular a média e o segundo momento das variáveis condicionais. Os momentos condicionais podem ser obtidos a partir de transformadas (veja deduções em [Rodrigues 2013a]), como se segue

$$E[e^{-sY} | Y < X_2] = \frac{\lambda_1(1 - X_2^*(\lambda_1 + s))}{(\lambda_1 + s)(1 - X_2^*(\lambda_1))}, \quad E[e^{-sX_2} | X_2 < Y] = \frac{X_2^*(s + \lambda_1)}{X_2^*(\lambda_1)}$$

As vidas residuais médias de $(X_2|X_2 < Y)$ e $(Y|Y < X_2)$ são por definição

$$E[(X_2|X_2 < Y)_r] = \frac{E[X_2^2|X_2 < Y]}{2E[X_2|X_2 < Y]}, \quad E[(Y|Y < X_2)_r] = \frac{E[Y^2|Y < X_2]}{2E[Y|Y < X_2]}$$

Seja q a probabilidade de se encontrar o servidor ocupado com um cliente do 2 que não tem seu serviço interrompido. Usando a teoria da renovação, temos que

$$q = \frac{E[X_2|Y > X_2]}{E[X_2|Y > X_2] + E[Y|Y < X_2] \frac{1-X_2^*(\lambda_1)}{X_2^*(\lambda_1)}}$$

Seja R_0 a vida residual do primeiro subserviço do cliente do tipo 2 encontrado no servidor.

$$E[R_0] = qE[(X_2|Y > X_2)_r] + (1 - q)E[(Y|Y < X_2)_r] \quad (15)$$

onde o primeiro termo se refere ao serviço que não é interrompido e o segundo termo se refere ao serviço que é interrompido. Expandido os termos, temos

$$E[R_0] = \frac{X_2''^*(0|X_2 < Y)X_2^*(\lambda_1) + Y''^*(0|Y < X_2)(1 - X_2^*(\lambda_1))}{2(-X_2'^*(0|X_2 < Y)X_2^*(\lambda_1) - Y'^*(0|Y < X_2)(1 - X_2^*(\lambda_1)))} \quad (16)$$

Após efetuarmos os algebrismos, pode-se mostrar que $E[R_0] = \frac{1}{\lambda_1} - \frac{X_2^*(\lambda_1)}{X_2^*(\lambda_1)-1}$.

Sabendo que com probabilidade $(1 - q)$ o serviço será interrompido e o cliente levará novamente X_{t2} em serviço até sair, o tempo total que o cliente que foi encontrado no servidor irá levar efetivamente em serviço antes de finalmente sair do sistema é

$$E[X_{t2r}] = E[R_0] + E[X_{t2}](1 - q) \quad (17)$$

Em [Menasché and Rodrigues 2013] mostramos o código Matlab (pacote simbólico) que demonstra que substituindo (17) em (14) obtém-se (7).

7. Preempção sem reamostragem: repete o mesmo serviço de baixa prioridade anteriormente interrompido a cada reentrada no servidor

Um exemplo prático deste cenário ocorre em redes de rádios cognitivos, nas quais a condição do canal permanece praticamente inalterada ao longo do tempo. Nestas condições, o tempo de transmissão ou tempo de serviço de um pacote depende apenas do seu tamanho, sendo modelado como um sistema com preempção (perda da transmissão por interferência) e sem reamostragem, pois retransmite integralmente o mesmo pacote.

Seja D_2 o tempo que um cliente leva desde que entra no servidor pela primeira vez até sair do sistema. Seja Y uma variável exponencialmente distribuída com taxa λ_1 e que representa o intervalo entre chegadas dos clientes mais prioritários. Quando o serviço de C_2 , o freguês típico do tipo 2, é interrompido, o serviço interrompido é dado por $R_i = Y|Y < X_2$. Após a interrupção, segue um período ocupado B_1 . Somente ao final de B_1 , C_2 retorna ao servidor, repetindo o mesmo serviço X_2 . O tempo entre retornos ao servidor após a i -ésima interrupção pode ser representado como $Z_i = R_i + B_1$. Em sua última passagem pelo servidor, C_2 não sofre interrupção e o serviço recebido é dado X_2 . Seja N o número de interrupções sofridas por C_2 .

Neste cenário, $D_2 = \sum_{i=0}^N (R_i + B_1) + X_2$. As variáveis N , R_i e X_2 são dependentes. Condicionando em $x_2 < X_2 < x_2 + dx_2$, no entanto, possibilita o tratamento do problema. A probabilidade de um serviço $X_2, x_2 < X_2 < x_2 + dx_2$ não ser interrompido por uma chegada do fluxo 1 é dada por $p = e^{-\lambda_1 x_2}$ e a probabilidade do serviço ser interrompido é $1 - p$. Consequentemente, pode-se ver que a variável $N|x_2 < X_2 < x_2 + dx_2$ é geometricamente distribuída com transformada Z da pmf dada por

$$N(z|x_2 < X_2 < x_2 + dx_2) = \frac{p}{1 - z(1 - p)} = \frac{e^{-\lambda_1 x_2}}{1 - z(1 - e^{-\lambda_1 x_2})} \quad (18)$$

Sabendo que $X_2^*(s|x_2 < X_2 < x_2 + dx_2) = e^{-sx_2}$ e condicionando, temos

$$\begin{aligned} D_2^*(s) &= \int_{x_2=0}^{\infty} D_2^*(s|x_2 < X_2 < x_2 + dx_2) f_{X_2}(x_2) dx_2 \\ &= \int_{x_2=0}^{\infty} N(R_i^*(s) B_1^*(s)|x_2 < X_2 < x_2 + dx_2) e^{-sx_2} f_{X_2}(x_2) dx_2 \\ &= \int_{x_2=0}^{\infty} \frac{p}{1 - R_i^*(s|x_2 < X_2 < x_2 + dx_2) B_1^*(s)(1 - p)} e^{-sx_2} f_{X_2}(x_2) dx_2 \end{aligned} \quad (19)$$

Como $R_i^*(s|x_2 < X_2 < x_2 + dx_2) = \left(\frac{\lambda_1}{\lambda_1 + s} \right) \left(\frac{1 - e^{-(s+\lambda_1)x_2}}{1 - e^{-\lambda_1 x_2}} \right)$, obtemos finalmente

$$D_2^*(s) = \int_{x_2=0}^{\infty} \frac{e^{-(\lambda_1+s)x_2}}{1 - \left(\frac{\lambda_1}{\lambda_1+s} \right) B_1^*(s)(1 - e^{-(\lambda_1+s)x_2})} f_{X_2}(x_2) dx_2 \quad (20)$$

Finalmente, derivando (20) podemos obter a média e o segundo momento de D_2 ,

$$E[D_2] = \left(\frac{1}{\lambda_1} + E[B_1] \right) (X_2^*(-\lambda_1) - 1) \quad (21)$$

$$\begin{aligned} E[D_2^2] &= 2 \left(\frac{1}{\lambda_1} + E[B_1] \right)^2 E[(e^{\lambda_1 X_2} - 1)^2] + \left[E[B_1^2] + \frac{2E[B_1]}{\lambda_1} + \frac{2}{\lambda_1^2} \right] \\ &\quad \times (X_2^*(-\lambda_1) - 1) - 2 \left(\frac{1}{\lambda_1} + E[B_1] \right) (-X_2'^*(-\lambda_1)) \end{aligned} \quad (22)$$

As expressões acima para os momentos podem ser encontradas na página 89 de [Jaiswal 1968]. Usando (21) e (22) em (7), obtém-se o tempo médio de espera $E[T_2]$. A condição de estabilidade continua sendo $\rho_2^\# = \lambda_2 E[D_2] < 1$.

8. Trabalhos relacionados

A literatura sobre filas com prioridades é vasta [Jaiswal 1968, Harchol-Balter 2013, Gaver Jr 1962, Simatos et al. 2013]. Entretanto, não conhecemos nenhum trabalho anterior que tenha apresentado os resultados sobre filas com prioridades da forma que fazemos neste artigo, utilizando duas abordagens simples. Os livros texto sobre teoria de filas [Kleinrock 1976, Harchol-Balter 2013, Stewart 2009, Le Boudec 2010] não consideram a análise de filas com prioridades com preempção e sem continuidade. Livros [Jaiswal 1968] e artigos [Gaver Jr 1962, Gaver Jr 1959], por outro lado, não apresentam a intuição mostrada neste trabalho. Vale destacar que [Jaiswal 1968, Gaver Jr 1962,

Gaver Jr 1959] apresentam uma análise menos intuitiva, mas ao mesmo tempo mais geral, dado que os autores derivam também distribuições. Na literatura existem inúmeros exemplos numéricos ilustrando a aplicabilidade dos resultados apresentados neste artigo (e.g., [Jaiswal 1968, pg. 97-98]), e, por limitação de espaço, focamos estritamente em nossa contribuição, que consiste nas novas metodologias para análise de filas com prioridades.

Em engenharia de sistemas, visa-se soluções rápidas e eficientes para tomada de decisões importantes. Muitas vezes, estas decisões precisam ser tomadas com poucos dados, já que por motivos de privacidade ou dificuldade de coleta torna-se impeditivo ter acesso a uma grande quantidade de dados. Assim sendo, médias muitas vezes são suficientes para guiar a tomada de decisões. Ter uma intuição sobre os fatores que afetam as médias é de grande valia na construção de heurísticas e soluções, mesmo que sem a variância [Ben-Haim 2012].

A metodologia apresentada neste trabalho é ilustrada em dois vídeos disponibilizado no Youtube [Menasché 2013]. Ela pode ser facilmente estendida para a análise de filas com reentrada, como apresentado na apostila [Rodrigues 2013a] e nos slides [Rodrigues 2013b].

9. Conclusão e Considerações Finais

Neste trabalho apresentamos duas novas abordagens intuitivas para obtenção de valores médios (número médio de clientes, tempo no sistema) em sistemas de filas com prioridades. Consideramos duas filas com prioridades, a fila 1 com prioridade sobre a fila 2. A extensão dos resultados aqui apresentados para o caso de múltiplas filas é natural. Por exemplo, para analisar o caso de 3 filas, basta considerar primeiro a interação entre a primeira e a segunda filas, ignorando a terceira. Em seguida, analisa-se a terceira fila levando em conta o fato de que, os usuários da terceira fila, ao serem interrompidos terão que esperar por um período ocupado composto por usuários das filas 1 e 2.

A avaliação numérica dos resultados apresentados nesse artigo pode ser facilmente executada usando a ferramenta de modelagem e análise Tangram II [de Souza e Silva and Leão 2000], comprovando a corretude das fórmulas obtidas. No site [Menasché and Rodrigues 2013] disponibilizamos os modelos do Tangram II associados aos diferentes cenários apresentados neste artigo. Caso os tempos de serviço sejam caracterizados por variáveis exponenciais, pode-se resolver a cadeia de Markov associada ao problema de via métodos diretos ou iterativos. Caso contrário, os modelos precisam ser resolvidos via simulação. Dessa forma, os resultados aqui apresentados contribuem para um melhor entendimento sobre filas com prioridades, que constituem peça chave no estudo de redes de computadores, além de servirem para a obtenção de limitantes (*bounds*) simples para métricas de interesse como o tempo médio no sistema [Rodrigues 2013a].

Referências

- Ben-Haim, Y. (2012). Doing our best: Optimization and the management of risk. *Risk Analysis*, 32(8):1326–1332.
- Cabric, D., Mishra, S. M., and Brodersen, R. W. (2004). Implementation issues in spectrum sensing for cognitive radios. In *Asilomar Conference on Signals, systems and computers*, pages 772–776. IEEE.

- de Souza e Silva, E. and Leão, R. M. (2000). The tangram-ii environment. In *Computer Performance Evaluation. Modelling Techniques and Tools*, pages 366–369. Springer.
- Gaver Jr, D. (1962). A waiting line with interrupted service, including priorities. *Journal of the Royal Statistical Society. Series B (Methodological)*, pages 73–90.
- Gaver Jr, D. P. (1959). Imbedded markov chain analysis of a waiting-line process in continuous time. *The Annals of Mathematical Statistics*, pages 698–720.
- Gittins, J. and Nash, P. (1977). Scheduling, queues and dynamic allocation indices. In *Prague Conference on Information Theory, Statistical Decision Functions and Random Processes*, pages 191–202. Springer.
- Gupta, D. (2013). Queueing models for healthcare operations. In *Handbook of Healthcare Operations Management*, pages 19–44. Springer.
- Harchol-Balter, M. (2013). *Performance Modeling and Design of Computer Systems: Queueing Theory in Action*. Cambridge University Press.
- Jaiswal, N. K. (1968). *Priority queues*, volume 50. Academic Press New York.
- Kleinrock, L. (1976). *Queueing systems: volume 2: computer applications*, volume 82. John Wiley & Sons New York.
- Le Boudec, J.-Y. (2010). *Performance evaluation of computer and communication systems*. EPFL Press.
- Lin, M., Zhang, L., Wierman, A., and Tan, J. (2013). Joint optimization of overlapping phases in mapreduce. *Performance Evaluation*, 70(10):720–735.
- Liu, Z., Wierman, A., Chen, Y., Razon, B., and Chen, N. (2013). Data center demand response: Avoiding the coincident peak via workload shifting and local generation. *Performance Evaluation*, 70(10):770–791.
- Machida, F., Nicola, V. F., and Trivedi, K. S. (2014). Job completion time on a virtualized server with software rejuvenation. *ACM Journal on Emerging Technologies in Computing Systems (JETC)*, 10(1):10.
- Markhasin, A. (2008). Analysis and optimization of multiservice mobile systems. *Optoelectronics, Instrumentation and Data Processing*, 44(5):477–485.
- McKeown, N., Anderson, T., Balakrishnan, H., Parulkar, G., Peterson, L., Rexford, J., Shenker, S., and Turner, J. (2008). Openflow: enabling innovation in campus networks. *ACM SIGCOMM Computer Communication Review*, 38(2):69–74.
- Menasché, D. S. (2013). Vídeos de alunos sobre filas com prioridades. <http://www.dcc.ufrj.br/~sadoc/ad20122/> (clique na caixa sobre filas com prioridades).
- Menasché, D. S. and Rodrigues, P. A. (2013). Filas com prioridades. <http://www.dcc.ufrj.br/~sadoc/prioridade/>.
- Rodrigues, P. H. A. (2013a). Apostila sobre avaliação de desempenho. <http://www.dcc.ufrj.br/~sadoc/ad20132/apostila.pdf>.
- Rodrigues, P. H. A. (2013b). Slides sobre avaliação de desempenho. <http://www.voip.nce.ufrj.br/cursos/images/files/mab515/aulas/adaula17.pdf>.

Simatos, F., Bouman, N., and Borst, S. (2013). Lingering issues in distributed scheduling. In *Proceedings of the ACM SIGMETRICS/international conference on Measurement and modeling of computer systems*, pages 141–152. ACM.

Stewart, W. J. (2009). *Probability, Markov chains, queues, and simulation: the mathematical basis of performance modeling*. Princeton University Press.

Wierman, A. (2007). *Scheduling for today's computer systems: Bridging theory and practice*. PhD thesis, Carnegie Mellon University.

10. Apêndice

Para facilitar a comparação da solução apresentada neste artigo com a literatura e apreciar a simplicidade das deduções aqui apresentadas, indicamos neste apêndice mais detalhes sobre a abordagem adotada em [Jaiswal 1968] para calcular o número médio de clientes.

Segundo [Jaiswal 1968, pg 61], considere um período ocupado do sistema, que inicia-se em $t = 0$. Nesse período ocupado, seja $p(m_1, m_2, x_1, x_2, t)dx_1dx_2$ a probabilidade de, no instante t , haver m_1 e m_2 tarefas de alta e baixa prioridade, respectivamente, no sistema, a quantidade de serviço gasto com a tarefa do tipo 1 no servidor estar no intervalo $(x_1, x_1 + dx_1)$, e a quantidade de tempo que a tarefa do tipo 2 gastou no servidor até a última preempção estar no intervalo $(x_2, x_2 + dx_2)$. Analogamente, seja $q(m_1, m_2, x_2, t)dx_2$ a probabilidade de, no instante t , haver m_1 e m_2 tarefas de alta e baixa prioridade, respectivamente, no sistema, e a quantidade de serviço gasto com a tarefa do tipo 2 no servidor estar no intervalo $(x_2, x_2 + dx_2)$. Note que $p(m_1, m_2, x_1, x_2, t)dx_1dx_2$ e $q(m_1, m_2, x_2, t)dx_2$ denotam os eventos em que uma tarefa do tipo 1 e do tipo 2 estão no servidor, respectivamente. A função geradora da probabilidade conjunta do tamanho das filas 1 e 2 em t , dado que um período ocupado iniciou-se em $t = 0$, é dada por,

$$\begin{aligned} M_{1,2}(z_1, z_2, t) = & \sum_{m_1=0}^{\infty} \sum_{m_2=0}^{\infty} \int_{x_1=0}^{\infty} \int_{x_2=0}^{\infty} z_1^{m_1} z_2^{m_2} p(m_1, m_2, x_1, x_2, t) dx_1 dx_2 \\ & + \sum_{m_1=0}^{\infty} \sum_{m_2=1}^{\infty} \int_{x_2=0}^{\infty} z_1^{m_1} z_2^{m_2} q(m_1, m_2, x_1, x_2, t) dx_2 \end{aligned} \quad (23)$$

A derivação das quantidades de interesse é feita então a partir de (23). Para tal, as funções p e q são escritas em termos da probabilidade de que, no instante t , um cliente de baixa prioridade entre em serviço com $m_2 - 1$ clientes de baixa prioridade em fila. Então, denotando esta probabilidade no instante t por $H(m_2, t)$, segundo [Jaiswal 1968, pg 60],

$$H(m_2, t) = \frac{\lambda_2}{\lambda_1 + \lambda_2} H(m_2, t | \textcircled{2}) + \frac{\lambda_1}{\lambda_1 + \lambda_2} H(m_2, t | \textcircled{1}) \quad (24)$$

onde $\textcircled{1}$ e $\textcircled{2}$ denotam o evento de o período ocupado ter se iniciado com um serviço de alta e baixa prioridade, respectivamente. Dessa forma, estabelece-se uma conexão entre a derivação de [Jaiswal 1968] e aquela apresentada na seção 3 deste artigo (vide eq.(1)). A derivação alternativa apresentada neste artigo é complementar à descrita acima, e traz novos *insights* sobre o problema.