

Definição, Modelagem e Aplicações de Camadas de Sensoriamento Participativo

Thiago H. Silva¹, Pedro O. S. Vaz de Melo¹, Jussara M. Almeida¹,
Aline C. Vianna,² Juliana Salles,³ Antonio A. F. Loureiro¹

¹DCC-UFMG, Belo Horizonte, Brasil

²INRIA, França

³Microsoft Research, Redmond, EUA

Abstract. *Data from different participatory sensor networks can be represented as sensing layers, each one enabling the access of data related to a certain aspect of predefined geographical regions. The joint analysis of multiple sensing layers may be useful to develop new applications. The purposes of this paper are three-fold. First, we define the concept of sensing layers. Then we define a framework for integrating multiple sensing layers, which can be applied to more sophisticated services, for example, identification of causes of traffic jams. Finally, we propose two applications that illustrate the proposed framework and the potential of using multiple sensing layers.*

Resumo. *Dados de diferentes redes de sensores participativos podem ser representados como camadas de sensoriamento, cada uma possibilitando o acesso a observações relacionadas a certo aspecto de regiões geográficas pré-definidas. A análise conjunta de múltiplas camadas de sensoriamento pode ser útil no desenvolvimento de novas aplicações. Com isso, os objetivos deste trabalho são três. Primeiro, definir o conceito de camadas de sensoriamento. Em seguida, definir um arcabouço para integração de múltiplas camadas de sensoriamento, que pode ser aplicado em serviços mais sofisticados, por exemplo, identificação de causas de congestionamentos. Finalmente, nós propomos duas aplicações que ilustram o uso do arcabouço proposto e o potencial da utilização de múltiplas camadas de sensoriamento.*

1. Introdução

Mídias sociais baseadas em localização, tais como o Foursquare¹, Instagram² ou Waze³, são bastante populares hoje em dia, graças à popularização dos *smartphones* e ao acesso à Internet por meio desses dispositivos. Por exemplo, o Foursquare registrou 40 milhões de usuários em setembro de 2013⁴. Esses aplicativos podem ser vistos como redes de sensores participativos (RSPs) [Burke et al. 2006, Silva et al. 2013a]. Nesse tipo de rede o dispositivo móvel do usuário é uma peça fundamental. Indivíduos carregando esses dispositivos são capazes de sensoriar o ambiente e fazer observações relevantes. Assim, cada nó em uma RSP consiste de um usuário com o seu dispositivo móvel [Silva et al. 2013a]. Cada RSP fornece acesso aos dados relacionados a certo aspecto de uma região geográfica pré-definida (por exemplo, condições de tráfego, imagens de locais, condição do clima, etc.), e pode ser representada como uma camada de sensoriamento (ou simplesmente camada).

Uma camada de sensoriamento permite o estudo em larga escala de cada aspecto monitorado em (quase) tempo real, além de fornecer dados históricos sobre padrões observados

¹<http://www.foursquare.com>. Todos os websites foram acessados pela última vez em 05/11/2013.

²<http://www.instagram.com>.

³<http://www.waze.com>.

⁴<https://foursquare.com/about>.

Anais do 32º Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos – SBRC 2014 durante longos períodos de tempo. Isso nos ajuda a compreender melhor a dinâmica de cidades e o comportamento social urbano em diferentes regiões do mundo, bem como reagir mais rapidamente a mudanças inesperadas nos padrões observados.

A exploração de forma independente de camadas de sensoriamento pode ser muito útil. Por exemplo, uma camada de sensoriamento contendo informações de trânsito pode possibilitar a identificação em tempo real de rodovias com acidentes e buracos, cuja detecção é difícil com sensores tradicionais, mas torna-se mais factível quando os usuários participam do processo de sensoriamento. Tal detecção abre oportunidades para vários serviços, por exemplo, auxiliar carros inteligentes na correta identificação de problemas na estrada [Silva et al. 2013d]. De fato, trabalhos anteriores já analisaram diferentes camadas de sensoriamento, tais como check-ins [Cranshaw et al. 2012], fotos de lugares [Silva et al. 2013b] e alertas de tráfego [Silva et al. 2013d] e sugeriram aplicações no projeto de serviços diversos.

A análise conjunta de múltiplas camadas de sensoriamento também pode ser extremamente útil na construção de outras aplicações mais sofisticadas. Por exemplo, sabemos que uma queixa comum dos habitantes das grandes cidades é congestionamento. Com isso, uma aplicação que emerge naturalmente é uma que possui o objetivo de inferir as causas de congestionamento, passo fundamental para tratar o problema. Esta não é uma tarefa fácil de realizar, e o resultado pode variar de lugar para lugar. No entanto, a análise conjunta de diferentes camadas de sensoriamento na cidade poderia contribuir para essa aplicação. Por exemplo, poderíamos cruzar as informações fornecidas pelas camadas: alertas de tráfego, derivadas do Waze; check-ins, derivados do Foursquare; e foto de lugares, derivados do Instagram. A primeira camada fornece dados próximos do tempo real sobre onde estão acontecendo congestionamentos, a segunda fornece dados sobre os tipos de lugares localizados nas áreas dos congestionamentos, com isso é possível entender melhor as áreas de interesse, por exemplo, identificando que é uma área comercial. Finalmente, através da análise da camada fotos de lugares nós podemos obter evidência visual do que acontece em tempo real próximo das áreas durante os congestionamentos. Ao analisar conjuntamente dados destas três camadas podemos detectar, por exemplo, carros bloqueando cruzamentos, e inferir as possíveis causas disso. Obviamente, outras camadas podem também ser utilizadas, tal como a condição do clima, camada derivada de sistemas como o Weddar⁵.

As contribuições deste trabalho podem ser divididas em três: (1) definição do conceito de camadas de sensoriamento; (2) proposta de um arcabouço para integração de múltiplas camadas de sensoriamento, que pode ser aplicado em serviços mais sofisticados do que serviços baseados em uma única camada; (3) proposta de aplicações que ilustram o uso do arcabouço apresentado e o potencial da utilização de múltiplas camadas de sensoriamento.

O restante deste trabalho está organizado da seguinte forma. A Seção 2 descreve os trabalhos relacionados. A Seção 3 define o emergente conceito de camadas de sensoriamento. A Seção 4 propõe um arcabouço para trabalhar com camadas de sensoriamento. A Seção 5 define algumas operações que podem ser aplicadas em camadas de sensoriamento. A Seção 6 apresenta algumas aplicações propostas que ilustram o potencial da utilização de camadas de sensoriamento. Finalmente, a Seção 7 apresenta as conclusões e os trabalhos futuros.

2. Trabalhos Relacionados

Como os dados fornecidos por RSPs podem ser muito complexos, um passo fundamental antes de qualquer investigação é a caracterização dos dados, a fim de entender seus desafios e utilidade. As propriedades de RSPs derivadas de diferentes aplicações, tais como o Foursquare, um serviço

⁵<http://www.weddar.com>.

Anais do 32º Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos – SBRC 2014 de compartilhamento de localização, e o Instagram, um serviço de compartilhamento de fotos, já foram investigadas na literatura [Noulas et al. 2011a, Crandall et al. 2009, Vasconcelos et al. 2012, Long et al. 2012, Cheng et al. 2011, Cho et al. 2011]. Em particular, nós analisamos as propriedades das RSPs derivadas das aplicações mencionadas acima, bem como uma RSP derivada do Waze, como redes de sensores, analisando mais de 30 milhões de registros (fotos, check-ins ou alertas) [Silva et al. 2013b, Silva et al. 2013a, Silva et al. 2013d]. Dentre os resultados, nós mostramos a escala planetária dessas redes, bem como a frequência altamente desigual do compartilhamento de dados, no espaço e no tempo, o que é altamente correlacionado com a rotina das pessoas. Alguns dos estudos anteriores também exploraram as propriedades das redes de sensores participativos para construir várias aplicações e serviços em diferentes áreas. Essas aplicações variam da extração de regiões distintas de uma cidade que refletem padrões de atividade coletiva similares, até a identificação automática de pontos de interesse [Cranshaw et al. 2012, Noulas et al. 2011b, Frias-Martinez et al. 2012, Quercia et al. 2012, Silva et al. 2013b, Sakaki et al. 2010].

Este estudo diferencia dos anteriores, incluindo os nossos, porque todos eles estudam diferentes camadas de sensoriamento de forma independente. Em contraste, o presente estudo objetiva propor um arcabouço de integração para permitir a análise e exploração de várias camadas simultaneamente. Ele foi motivado por um estudo anterior [Silva et al. 2013c] onde realizamos uma comparação entre as RSPs derivados do Instagram e Foursquare com o objetivo de entender se os dados de um sistema podem complementar dados de outro, ou se eles são compatíveis para o estudo da dinâmica de cidades e comportamento social urbano. Encontramos indícios de que estes sistemas podem completar um ao outro, no caso de identificação de pontos de interesse. Este resultado chamou nossa atenção para o potencial de utilização conjunta de camadas de sensoriamento.

Existem também estudos que consideram diferentes fontes de dados para entender melhor a dinâmica de cidades. Por exemplo, em [Bollen et al. 2011] os autores investigaram se os estados de humor coletivos derivados de mensagens compartilhadas no Twitter estão correlacionados com os índices da bolsa de valores Dow Jones (*Dow Jones Industrial Average*) ao longo do tempo. Os resultados indicam que é possível obter previsões relativamente precisas das variações diárias para cima e para baixo do fechamento da bolsa de valores estudada. Em [Sagl et al. 2012] os autores analisaram o comportamento humano coletivo utilizando dados de telefonia móvel correlacionados com dados meteorológicos. Os autores identificaram *insights* interessantes sobre a dinâmica humana coletiva no contexto de condições meteorológicas.

O presente trabalho também difere dessas propostas, pois aqui nós propomos um arcabouço para a integração de múltiplas camadas de sensoriamento, que pode ser aplicado em serviços mais sofisticados. Por exemplo, em qualquer cidade é provável encontrar vários locais onde as pessoas realizam com maior frequência uma determinada atividade, por exemplo uma área de bares e restaurantes onde as pessoas se encontram para socializar. Esses locais poderiam ser identificados com a ajuda da camada check-ins. As informações fornecidas por outras camadas poderiam ajudar os usuários na escolha das melhores áreas de interesse. Por exemplo, um usuário poderia usar as informações fornecidas pela camada de alertas de tráfego para identificar, dentre todas as opções, a área com menor número de problemas de trânsito no momento, e utilizar a camada fotos de lugares para visualizar o perfil dos estabelecimentos das áreas e das pessoas que os frequentam.

3. O Conceito de Camadas de Sensoriamento

Nós sensores em uma RSP são compostos por usuários, cada um com um dispositivo portátil. Assim, quando nos referimos a um usuário, estamos nos referindo a um nó sensor em um RSP. Perceba que o sensoriamento depende da vontade das pessoas participarem no processo de sensoriamento, assim um usuário pode ser contribuinte ou não em uma determinada janela de tempo. Em estudos anteriores [Silva et al. 2013b, Silva et al. 2013a, Silva et al. 2013d] apresentamos alguns exemplos de RSPs que oferecem dados sobre vários aspectos de uma região geográfica. Isto ajuda a ilustrar a ubiquidade e diversidade dos dados que podem estar disponíveis. Este universo de “dados ubíquos” pode ser complexo de entender e lidar, abrindo oportunidades de pesquisa para apresentação de propostas para facilitar essas tarefas.

Uma camada de sensoriamento representa dados, com seus atributos correspondentes, provenientes de uma determinada fonte de dados. Exemplos de fontes de dados incluem: dados disponibilizados através de *web services*, por exemplo a condição do tempo fornecida pela empresa “The Weather Channel”⁶; dados de redes de sensores sem fio tradicionais; e dados de redes de sensores participativos. Discutimos o conceito de camadas de sensoriamento para RSPs. No entanto todos os conceitos discutidos aqui podem ser utilizados para outras fontes de dados associadas a regiões geográficas pré-definidas, com as adaptações necessárias.

A Figura 1 ilustra essa ideia, exibindo quatro camadas diferentes para Nova York: **alertas de tráfego** (obtida, por exemplo, a partir do Waze); **check-ins** (obtida, por exemplo, a partir do Foursquare); **condição do clima** (obtida, por exemplo, a partir do Weddar), e **fotos de lugares** (obtida, por exemplo, a partir do Instagram). Tal como ilustrado, uma camada de sensoriamento é representada por um plano, onde as observações de certo aspecto de uma região geográfica pré-definida estão dispostas. A cada observação (em cada camada) estão associados dados relativos a: tempo (i.e., quando a observação foi feita), espaço (localização geográfica), pessoa (usuário), e dados específicos de cada camada (*especialidade*).




Figura 1. Camadas de sensoriamento para a cidade de Nova York.

A Figura 2 complementa a definição de RSP apresentada em [Silva et al. 2013b], agora incorporando o conceito de camadas de sensoriamento. Esta figura ilustra três camadas de sensoriamento diferentes, a saber: *fotos de lugares*; *alertas de tráfego*; e *check-ins*. Essa figura ilustra ainda outras camadas derivadas da camada fotos de lugares. Como podemos ver, existem dois tipos de camadas de sensoriamento: **primitiva** e **contextual**.

Uma camada de sensoriamento primitiva é composta por dados básicos provenientes diretamente do sorvedouro/fonte, descrevendo aspectos específicos de localizações geográficas no espaço, tempo e usuários contribuintes. Cada sensor (usuário + dispositivo portátil) em uma RSP pode produzir um fluxo de dados. Neste contexto, as aplicações provêm um fluxo contínuo de dados. Como representado na Figura 2, esses dados devem ser coletados (por exemplo,

⁶<http://www.weather.com>




Figura 2. Visão geral de redes de sensores participativos com o conceito de camadas de sensoriamento.

usando uma API) e processados, passo que inclui as tarefas de análise e padronização dos dados, uma vez que todos os registros de todas as camadas primitivas devem possuir a mesma estrutura. O último passo é o armazenamento dos dados. Essas etapas não buscam extrair contexto [Dey and Abowd 2000] (ou conhecimento) a partir dos dados medidos, mas sim organizá-los. Com isso, camadas primitivas oferecem dados básicos que podem ser utilizados para a inferência de contexto.

Para ilustrar este processo, considere os dados provenientes de um RSP derivada do Foursquare. No Foursquare, os usuários podem, dentre outras ações, realizar check-ins em lugares e deixar dicas sobre locais visitados. Destes dados mencionados, podemos extrair pelo menos duas camadas primitivas, a saber: check-ins, contendo os check-ins realizados pelos usuários (check-ins podem ser usados para descobrir locais populares, por exemplo), e dicas de lugares, contendo dicas (*tips*), por exemplo “este restaurante tem uma comida incrível”, enviadas por usuários sobre determinados lugares. A geração de camadas primitivas é representada na Figura 2 por uma caixa nomeada “dados grandes brutos”, e depende de operações específicas de cada sistema. Considere check-ins do Foursquare, por exemplo. Uma maneira de obtê-los é através do Twitter, como explicado em [Silva et al. 2013a]. Isso significa que temos que coletar, analisar e processar *tweets*. A codificação de ferramentas para realizar estas etapas varia de acordo com o sistema ou aplicação. Posteriormente, nós devemos criar uma estrutura para representar os dados de interesse associados com um certo local onde foram compartilhados, assim representando uma camada primitiva. Em uma camada primitiva, cada dado tem os seguintes atributos:

- t - instante em que o dado foi compartilhado;
- a - localização (coordenadas GPS), onde o dado foi compartilhado. Cada dado tem uma coordenada GPS. Como esta informação está sujeita a erros, consideramos que a localização dos dados é representada por uma área. Essa área pode ser, por exemplo, um círculo com raio de x metros a partir da coordenada GPS;
- s - especialidade da camada;
- u - id do usuário que compartilhou o dado.

Uma ou várias camadas primitivas podem ser processadas (possivelmente após uma fusão) para construir camadas contextuais. Uma camada contextual representa contexto ou conhecimento obtido através da transformação dos dados disponíveis em uma ou mais camadas primitivas. Pontos de interesse (PDI) em uma cidade, obtidos a partir dos dados compartilhados no Instagram, conforme descrito em [Silva et al. 2013b], representam um exemplo de camada contextual. Em uma camada contextual c o contexto inferido, possui os seguintes atributos:

- w_t - um vetor que descreve uma janela de tempo contendo os dados da camada primitiva utilizados para inferir um contexto;
- a - um vetor com uma ou mais áreas associadas com o contexto. Por exemplo, um PDI representa um contexto, nesse caso a é um vetor contendo a área do PDI.
- s - especialidade (o próprio contexto);
- O - grupo de ids dos usuários que contribuíram os dados usados na geração do contexto.

Cada camada tem uma variável h , onde $h = 0|1$, representando os estados ativos e inativos de uma camada. A lista abaixo representa alguns exemplos de camadas, primitivas e contextuais, que estão disponíveis hoje:

1. Check-ins (**primitiva**, exemplo de fonte: Foursquare);
2. Dicas sobre locais (**primitiva**, exemplo de fonte: Foursquare) ;
3. Alertas de tráfego (**primitiva**, exemplo de fonte: Waze) ;
4. Fotos de lugares (**primitiva**, exemplo de fonte: Instagram);
5. *City Image* (**contextual**, derivada da camada check-ins);
6. Pontos de interesse (**contextual**, derivada, por exemplo, da camada fotos de lugares);
7. Pontos turísticos (**contextual**, derivada, por exemplo, da camada pontos de interesse);

O contexto referente à camada *city image* é um resumo da dinâmica de uma área geográfica com base em movimentos realizados pelos usuários (camada detalhada em [Silva et al. 2012]). O contexto da camada PDI refere-se às áreas que atraem mais atenção de moradores e visitantes. Dentre os PDIs temos os pontos turísticos, contexto referente à camada pontos turísticos. As camadas pontos de interesse e pontos turísticos são detalhadas em [Silva et al. 2013b].

4. Formalização do Modelo de Camadas de Sensoriamento

Seja $U = \{u_1, u_2, \dots, u_n\}$ um conjunto de usuários (nós sensores), e seja $P = \{p_1, p_2, \dots, p_n\}$ um conjunto de RSPs. Cada usuário $u_i \in U$ pode compartilhar dados ilimitados em qualquer RSP $p_k \in P$. Cada j -ésimo dado compartilhado $d_j^{p_k}$ em uma RSP p_k possui o formato $d_j^{p_k} = \langle t, m \rangle$, em que t refere-se ao instante em que o usuário u_i compartilhou o dado em p_k e m é uma tupla contendo os atributos deste dado. A tupla m é composta pelos atributos presentes em todos os dados provenientes de uma RSP, ou seja, $m = (a, u, s)$, onde a é a área⁷ do local onde o dado foi compartilhado, s é a especialidade, e u refere-se ao usuário $u_i \in U$ que compartilhou o dado.

Os dados compartilhados em $p_k \in P$ podem ser vistos como um fluxo de dados B^{p_k} . Definimos que um fluxo de dados B^{p_k} é composto por todos os n dados compartilhados pelos usuários U em uma RSP p_k em um determinado intervalo de tempo. Desta forma, $B^{p_k} = \langle d_1^{p_k}, d_2^{p_k}, \dots, d_n^{p_k} \rangle$, e B^{p_k} representa uma camada primitiva r_{p_k} . A Tabela 1 mostra exemplos de dados presentes em camadas primitivas que foram compartilhados nas três RSPs derivadas do Foursquare, Waze e Instagram, ilustradas na Figura 2. Observe que dados no mesmo fluxo podem ter o mesmo tempo, pois podem ter sido compartilhados por dois usuários simultaneamente.

Para trabalhar com camadas precisamos representá-las em um *plano de trabalho*, que contém uma ou mais camadas. Esse plano de trabalho representa uma combinação dos dados das camadas que desejamos trabalhar. Como efetuar essa combinação dos dados depende da funcionalidade da camada, do que ela captura. A abstração usada para representar uma combinação é um dicionário de dados M , que representa uma coleção de pares *chave : valor*. Definimos que a função responsável por realizar esse passo chama-se $COMBINATION(\mathcal{F}, relation())$, em


⁷Lembre-se de que um ponto GPS é representado por uma área, devido a erros de GPS.

Tabela 1. Fluxo de dados descrevendo a atividade de usuários em três RSP diferentes: Foursquare, Waze e Instagram.

Fluxo de dados de uma RSP derivada do Foursquare			
Tempo (t)	Atributos (m)		
	Área (a)	Usuário (u)	Especialidade (s)
T1	a_1	1	“Times Square”
T1	a_1	2	“Times Square”
T2	a_2	1	“Fifth Av.”
T3	a_4	1	“Statue of Liberty”

Fluxo de dados de uma RSP derivada do Waze			
Tempo (t)	Atributos (m)		
	Área (a)	Usuário (u)	Especialidade (s)
T1	a_1	3	“Congestionamento”
T2	a_3	2	“Acidente”
T2	a_3	3	“Controle policial”

Fluxo de dados de uma RSP derivada do Instagram			
Tempo (t)	Atributos (m)		
	Área (a)	Usuário (u)	Especialidade (s)
T1	a_1	3	“dados da foto”
T3	a_4	1	“dados da foto”

**Figura 3. Ilustração de compartilhamento de dados em três RSP ao longo do tempo, resultando em camadas primitivas.**

que $\mathcal{F}$ é um subconjunto de $\mathcal{B}$, ou $\mathcal{F} \subseteq \mathcal{B}$, e $relation()$ é uma função que define a relação entre os dados dos fluxos B^{pk} contidos em $\mathcal{F}$. A função $relation()$ define as chaves do dicionário M , bem como os dados que essas chaves irão referenciar, que são as demais observações do dado d_i^{pk} não utilizadas como chave. A operação *COMBINATION* resulta em um dicionário M .

Nós ilustramos aqui dois tipos de relações utilizadas para agregar os dados: (1) por locais e (2) por usuários. Para simplificar, vamos ilustrar a combinação apenas para as camadas primitivas, mas a mesma ideia também é válida para camadas contextuais. Para ilustrar um plano de trabalho contendo os dados combinados por localidade, vamos considerar a atividade representada na Figura 3. O plano de trabalho M_1 representa essa atividade, onde $M_1 = \{a_1 : \{d_1^{r1'}, d_2^{r1'}, d_1^{r2'}, d_1^{r3'}\}, a_2 : \{d_3^{r1'}, d_2^{r2'}\}, a_3 : \{d_3^{r2'}\}, a_4 : \{d_4^{r1'}, d_2^{r3'}\}\}$. Nesse plano de trabalho uma chave k_i é representada por a_i , que é uma área única dentre todas as áreas de todos os dados compartilhados nas camadas consideradas: r_1 , r_2 e r_3 . Já $d_i^{rj'}$ refere-se às observações não utilizadas como chave do dado d_i da camada primitiva r_j , ou seja $\langle t, u, s \rangle$. Assim, todas as áreas únicas tornaram-se uma chave no plano de trabalho M_1 . Os dados compartilhados em um mesmo local foram agrupados e são indexados pela chave que representa o local. O plano




Figura 4. Combinação por localidade.




Figura 5. Combinação por usuários.

de trabalho M_1 , como descrito, está representado na Figura 4. Veja que o plano de trabalho representa dados que foram compartilhados em todas as camadas consideradas. A cor do símbolo que representa um dado d'_i indica de qual camada ele foi extraído, por exemplo, a cor vermelha é referente à camada r_1 .

A Figura 5 ilustra uma combinação por usuário. Neste caso, é criado um plano de trabalho contendo chaves que representam os usuários. A figura mostra o plano de trabalho M_2 , que foi criado considerando as atividades mostradas na Figura 3. O conteúdo desse plano de trabalho é: $M_2 = \{u_1 : \{d_1^{r1'}, d_3^{r1'}, d_4^{r1'}, d_2^{r3'}\}, u_2 : \{d_2^{r1'}, d_2^{r2'}\}, u_3 : \{d_1^{r2'}, d_1^{r3'}, d_3^{r2'}\}\}$. Todos os usuários únicos tornaram-se uma chave em M_2 . Os dados foram combinados e cada grupo foi apontado pela chave que representa o usuário que efetuou o compartilhamento dos dados no grupo.

5. Operações

Na Seção 4, dentre outras coisas, ilustramos como representar camadas de sensoriamento em um plano de trabalho, por exemplo, por localidade (M_1) ou usuários (M_2). Os planos de trabalho gerados são estruturas básicas que podem ser facilmente manipuladas. De posse de um plano de trabalho, como o M_1 ou o M_2 mostrado nas figuras 4 e 5, podemos aplicar operações para derivar outras estruturas e também extrair conhecimento. Exemplos de operações são:

- **uGRAPH** (*undirected graph*): Espera um plano de trabalho. Resulta em um grafo não direcionado. Essa operação cria, a partir de um plano de trabalho, um grafo $G = (V, E)$ não direcionado, que consiste em um conjunto de nós V e um conjunto de arestas E . Cada chave k_i no plano de trabalho representa um nó $v_i \in V$, e os dados que são indexados por k_i são atributos de v_i . Uma aresta $e = (v_i, v_j)$ pode ser adicionada conectando os nós v_i e v_j dependendo da análise desejada, que é expressa através de algumas operações específicas, que descrevemos a seguir. Inicialmente, $E = \emptyset$. Todas as variáveis do plano de trabalho são incorporadas no grafo gerado;
- **dGRAPH** (*directed graph*): Espera um plano de trabalho. Resulta em um grafo direcionado. A operação cria um grafo *direcionado* respeitando a operação **uGRAPH**;
- **CNG** (*change*): Espera um plano de trabalho, um ID da camada e um status (0 ou 1). Resulta em um plano de trabalho com as modificações impostas pela mudança de h . Essa operação altera o status atual de uma camada através de h . Se o status informado é igual a 0 então a camada em questão é desabilitada. Essa camada pode ser reabilitada posteriormente.
- **dEDGE** (*directed edge*): Espera um grafo direcionado resultante de um plano de trabalho combinado por localidade. Resulta em um grafo com arestas direcionadas. A operação cria uma aresta direcionada do nó v_i para o nó v_j se e somente se pelo menos um mesmo usuário compartilhou um dado, em qualquer camada, no local representado pelo nó v_j logo após o compartilhamento de um dado, também em qualquer camada, em uma localização representada pelo nó v_i . O peso de uma aresta representa o número




Figura 6. Ilustração da criação de grafo de fluxo considerando uma única e múltiplas camadas.

total de transições realizadas a partir de v_i para v_j considerando transições de todos os usuários.

- **DEL**: Espera um grafo G e um inteiro t . Resulta em um subgrafo derivado de G . A operação apaga arestas $e_i \in E$ (E é o conjunto de arestas de G), com peso $w_i < t$.

Todas estas operações mencionadas, com as devidas adaptações, são adequadas para camadas primitivas e contextuais. Existem ainda operações específicas para criar camadas contextuais, como as operações mostradas a seguir:

- **fPOIS** (*find POIs*): Espera um plano de trabalho representando uma camada de sensoria-mento. Resulta em um plano de trabalho contendo PDIs. A operação identifica pontos de interesse (PDIs), que são obtidos aplicando o algoritmo especificado no trabalho [Silva et al. 2013b] em áreas geográficas desejadas.
- **fSIGHTS** (*find sights*): Espera um plano de trabalho contendo PDIs. Resulta em um grafo contendo pontos turísticos. A operação identifica pontos turísticos a partir de um grafo $G^{PDIs} = (V, E)$, onde os nós $v_i \in V$ são as áreas a dos PDIs identificados em uma determinada região geográfica pré-definida (algoritmo detalhado em [Silva et al. 2013b]).

Para dar um exemplo de uso de operações, vamos demonstrar como gerar grafos de fluxo, que grafos que mapeiam os locais onde um mesmo usuário contribuiu dados, capturando assim a movimentação ou transição dos usuários em uma área geográfica. É particularmente interessante ilustrar a criação de grafos de fluxo, pois usamos esse tipo de grafo nas aplicações descritas na Seção 6. A Figura 3 representa três usuários que compartilharam dados em diferentes RSPs, p_1 (vermelha), p_2 (verde) e p_3 (laranja) em três intervalos diferentes de tempo ($T1$, $T2$ e $T3$). Dados compartilhados pelos usuários em cada intervalo são apontados com setas tracejadas. Observe que os usuários não participam necessariamente em múltiplos sistemas todo o tempo, além disso podem contribuir para diferentes camadas no mesmo intervalo de tempo.

Após um determinado tempo, pode-se modelar os dados com o intuito de extrair conhecimento de diferentes maneiras. Por exemplo, na Figura 6 a parte nomeada “Grafo de fluxo - camada $r2$ ” mostra um grafo de fluxo que chamamos de G_{r2}^{flow} . Para a geração desse grafo vamos considerar o plano de trabalho M_1 como explicado acima (combinado por localidades). Primeiramente, escondemos as camadas $r1$ e $r3$: $M'_1 \leftarrow \mathbf{CNG}(M_1, r1, 0)$ e $M''_1 \leftarrow \mathbf{CNG}(M'_1, r3, 0)$. Em seguida geramos um grafo direcionado: $G \leftarrow \mathbf{dGRAPH}(M''_1)$. Por último aplicamos a operação **dEDGE** em G : $G_{r2}^{flow} \leftarrow \mathbf{dEDGE}(G)$. Neste caso, temos um grafo de fluxo que representa dados de uma única camada. Com este grafo podemos extrair diversas informações valiosas, por exemplo, as trajetórias regulares em uma cidade, como demonstrado em [Silva et al. 2012].

Outra possibilidade de análise é considerar diferentes camadas ao mesmo tempo. Na Figura 6, a parte nomeada “Grafo de fluxo - todas as camadas” mostra um grafo que chamamos de G^{flow2} . Vamos considerar também o plano de trabalho M_1 , usado acima. Com o intuito de obter G^{flow2} primeiramente criamos um grafo direcionado G : $G \leftarrow \mathbf{dGRAPH}(M_1)$. Depois disso aplicamos $\mathbf{dEDGE}$ em G : $G^{flow2} = \mathbf{dEDGE}(G)$. No grafo resultante, os nós representam dados compartilhados no mesmo local, em qualquer camada. As arestas conectam os nós $v_i \rightarrow v_j$ se pelo menos um mesmo usuário compartilhou um dado no local representado pelo nó v_j logo após compartilhar um dado no local representado pelo nó v_i .

6. Aplicações do Arcabouço de Camadas de Sensoriamento

Nesta seção discutimos duas aplicações que ilustram o potencial do arcabouço proposto.

6.1. Identificação de Pontos Turísticos

Em [Silva et al. 2013c] mostramos indícios de que o uso integrado de múltiplas camadas, especificamente uma derivada do Instagram e outra do Foursquare, poderia melhorar a precisão da identificação de pontos turísticos em uma cidade. Com base nisso, nesta seção discutimos uma aplicação que identifica pontos turísticos considerando múltiplas camadas simultaneamente, destacando as melhorias sobre a estratégia apresentada em [Silva et al. 2013c], que considera apenas uma camada.

Nesta análise, consideramos os datasets do INSTAGRAM (1.855.235 fotos) e FOURSQUARE (4.548.941 check-ins) que foram coletadas diretamente do Twitter⁸, uma vez que fotos do Instagram e check-ins do Foursquare não são publicamente disponíveis por *default*. Ambos datasets foram coletados durante o mesmo período. Cada conteúdo (foto ou check-in) consiste de coordenadas GPS (latitude e longitude) e do instante em que foi compartilhado. Neste trabalho consideramos os dados compartilhados na área de Belo Horizonte representada pela Figura 7, que cobre praticamente toda a cidade.

A camada fotos de lugares (r_1) é representada pelo dataset INSTAGRAM, e a camada check-ins (r_2) pelo dataset FOURSQUARE. Nosso intuito é trabalhar com esses dados conjuntamente. Para isso, agregamos os dados por localização, produzindo um plano de trabalho representado pelo plano de trabalho M_1 . Inicialmente identificamos os pontos turísticos para r_1 . Com isso em mente desabilitamos a camada r_2 de M_1 obtendo M_{r_1} : $M_{r_1} \leftarrow \mathbf{CNG}(M_1, r_2, 0)$. Depois disso aplicamos $\mathbf{fPOIS}$ em M_{r_1} para gerar $M_{r_1}^{pdis}$, plano de trabalho contendo os pontos de interesse. No plano de trabalho resultante $M_{r_1}^{pdis}$, as chaves são as áreas dos PDIs identificados. No cenário ilustrado pela Figura 2 temos apenas duas chaves em um plano de trabalho, representadas por “área 1” e “área 2”.

Cada PDI em $M_{r_1}^{pdis}$ representa uma área a popular em uma determinada região geográfica, por exemplo uma cidade. A popularidade é identificada através do volume de contribuição de dados realizada pelos usuários O ⁹. Ou seja, um PDI representa a atividade realizada por um grupo de usuários O em uma janela de tempo w_t . Note que, a especialidade s , neste caso particular, é a própria área. Utilizamos o plano de trabalho $M_{r_1}^{pdis}$ para a extração de pontos turísticos com o auxílio da operação $\mathbf{fSIGHTS}$. Primeiramente é criado um grafo direcionado (no exemplo $G_{r_1}^{pois}$), a partir de um plano de trabalho (no exemplo $M_{r_1}^{pois}$), usando a operação $\mathbf{dGRAPH}$. Em seguida a operação mapeia as transições realizadas pelos usuários entre os PDIs. Para isso, é aplicada a operação $\mathbf{dEDGE}$ em $G_{r_1}^{pdis}$ obtendo $G_{r_1}^{pdis-flow}$.

⁸<http://www.twitter.com>.

⁹Relembre a notação na Seção 3.




Figura 7. Todos os pontos turísticos identificados com Foursquare e Instagram datasets.




Figura 8. Exemplos de setores de Nova York que têm o rendimento mediano fornecido pelo U.S. Census Bureau.

Depois disso, são selecionadas transições populares que ligam dois nós $v_i \rightarrow v_j$. Para isso, é utilizada a operação **DEL** no grafo $G_{r_1}^{pois-flow}$ usando um parâmetro t (calculado como mostrado em [Silva et al. 2013b]). De acordo com a conjectura considerada no algoritmo da operação **fSIGHTS**, as transições populares selecionadas conectam os pontos turísticos, que estão representados no grafo $G_{r_1}^{sights} = (V', E')$. Nesse grafo os nós $v_i \in V'$ são as áreas a dos pontos turísticos identificados, representados em $M_{r_1}^{sights}$.

Em seguida, identificamos os pontos turísticos $M_{r_2}^{sights}$ para r_2 . Primeiramente reativamos a camada r_2 e desativamos r_1 em M_1 , utilizando a operação **CNG**, obtendo assim o plano de trabalho M_{r_2} . Os próximos passos são realizados de maneira semelhante ao que foi apresentado para r_1 . Depois disso agrupamos as camadas contendo os pontos turísticos para as camadas r_1 e r_2 , $M_{r_1}^{sights}$ e $M_{r_2}^{sights}$, no plano de trabalho M_{total}^{sights} (por exemplo utilizando uma operação **MERGE** que agrupa dois planos de trabalho). Este plano de trabalho contém todos os pontos turísticos identificados, que são mostrados pela Figura 7. O ponto turístico apontado por uma seta vermelha (Mercado Central), foi identificado apenas pelo Foursquare. Os pontos turísticos apontados por uma seta azul (Igreja da Pampulha, Lagoa da Pampulha e área de lazer 2) não foram identificados com Foursquare. Todos os locais são muito relevantes, note com isso o potencial para a complementação de resultados usando ambos os sistemas.

6.2. Análise Econômico-Cultural de Regiões

A aplicação descrita nesta seção permite a realização de várias análises econômico-culturais, porém neste trabalho vamos focar em apenas duas. O objetivo da primeira análise é correlacionar o sentimento geral expressado nas dicas¹⁰ para todos os locais de um determinado setor a_i , com a renda mediana dos habitantes desse setor. Já o objetivo da segunda análise é estudar o movimento dos usuários nos setores considerados, levando em consideração a renda típica desses setores. Essa segunda análise possibilita o estudo de segregação social em uma cidade.

Para ilustrar essa aplicação, consideramos dois conjuntos de dados derivados do Foursquare. O primeiro, nomeado CHECKINS-NY, é composto por 34.677 check-ins realizados na cidade de Nova York, em uma semana de Abril de 2012. Os dados desse dataset foram coletados diretamente do Twitter e cada check-in consiste de uma coordenada GPS (latitude e longitude), de um ID do local onde o check-in foi realizado, do instante em que foi compartilhado e da categoria do local. O segundo dataset, nomeado DICAS-NY, contém todas as dicas contribuídas até 01/2013, em todos os locais únicos do dataset CHECKINS-NY. As dicas foram coletadas por meio da API do Foursquare, e cada dica contém um ID do local onde ela foi

¹⁰veja o artigo [Vasconcelos et al. 2012] para saber mais sobre dicas no Foursquare.

Anais do 32º Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos – SBRC 2014 compartilhada, o instante de tempo do compartilhamento, e o conteúdo textual da dica. Consideramos apenas dicas em Inglês. Definimos que uma dica está na língua Inglesa se pelo menos metade das palavras constam em um dicionário contendo as principais palavras dessa língua. Isso resultou em: 157.197 dicas (2.531 descartadas).

O dataset DICAS-NY é utilizado para representar uma camada primitiva chamada dicas de locais (r_1). A camada r_1 é composta por um fluxo de dados B_i . Cada dado no fluxo tem a forma: $\langle t, (a, u, s) \rangle$. Um exemplo de especialidade s desta camada é: “Este lugar é incrível, eu recomendo o fígado com jiló.”. A camada contextual renda c_1 é composta por um dataset d_j para diferentes setores j da cidade de Nova York. Essa camada foi derivada de uma camada primitiva contendo informações individuais dos habitantes de determinados setores, que participaram do censo de Nova York. A área de cada setor é pré-definida pelo censo de Nova York. Cada especialidade em d_j possui a renda mediana dos habitantes de um setor específico. A Figura 8 representa alguns exemplos de setores considerados em Nova York. Todos os dados são referentes ao *2006-2010 American Community Survey*. A forma de d_1 é $\langle t = 2006-2010, a = [\text{área setor 1}], O = [\text{habitantes do setor 1 que participaram do censo}], s = [\text{renda mediana em US\$ para o setor 1}] \rangle$. Note que apesar dessa fonte de dados não ser proveniente de um usuário com seu dispositivo móvel, também pode ser considerada uma camada contextual sobre uma região geográfica pré-definida. Isso mostra a flexibilidade do modelo proposto.

Para a primeira análise, inicialmente devemos agregar os dados das camadas r_1 e c_1 . O método escolhido é a combinação por localidades, método descrito na Seção 4. Este processo de combinação resulta em um plano de trabalho M_1 , onde as chaves são as áreas dos setores. Cada chave k_i agrega, dentre os demais dados, as dicas de todos os locais que se localizam dentro da área de um setor, bem como a informação de renda mediana do setor.

A partir disso, usamos o plano de trabalho criado para calcular o sentimento geral sobre todos os locais de cada setor. Para esta análise foi utilizado o programa SentiStrength [Thelwall et al. 2010] para classificar o sentimento expressado nas dicas em positivo ou negativo em uma escala de -4 (fortemente negativo) a 4 (fortemente positivo), 0 indica um sentimento neutro. Esse programa é aplicado a cada dica e depois agregado por lugar e por último por setor. Com isso, calculamos o sentimento médio para todos os locais de um determinado setor. Em seguida, agrupamos os setores por cinco faixas de renda: inferior a US\$25.000; entre US\$25.000 e US\$50.000; entre US\$50.000 e US\$75.000; entre US\$75.000 e US\$100.000; e superior a US\$100.000. Finalmente, calculamos o valor médio do sentimento para cada um dos cinco grupos de renda, considerando todos os setores que pertencem a cada um desses grupos. A tabela 2 apresenta esse resultado, e para cada grupo de renda, a percentagem do valor médio do sentimento dos setores em cinco faixas de sentimento: (+3,+4); (+1,+2); (0); (-1,-2); e (-3,-4). Conforme é possível observar, o resultado sugere que setores pobres tendem a ter o pior sentimento expressado pelos usuários. Isto pode estar associado a serviços de baixa qualidade nesses setores. Com o aumento da renda do setor as opiniões tendem a ser melhores. Apesar do sentimento médio do grupo de setores mais ricos (superior a US\$100.000) ser um pouco menor do que o segundo mais rico (entre US\$75.000 e US\$100.000), esse ainda tem um maior número de dicas positivas do que todos os outros grupos, e ainda não possui dicas negativas. Note o potencial desta análise para estudos sociais, por exemplo para o estudo de desigualdades na qualidade de serviços em cidades.

Para a segunda análise utilizamos o dataset CHECKINS-NY, que é usado para representar uma camada primitiva chamada check-ins (r_2). Nós agregamos as camadas r_2 e c_1 por localidade no plano de trabalho M_2 . A partir de M_2 criamos um grafo $G_2 = \mathbf{uGRAPH}(M_2)$. Nós usamos G_2 para gerar um grafo de fluxo $G_2^{flow} = \mathbf{dEDGE}(G_2)$, onde as arestas são as

Tabela 2. Sentimento geral por grupos de setores

Grupo	Sent. Médio (std)	(+3,+4)%	(+1,+2)%	(0)%	(-1,-2)%	(-3,-4)%
<25000	0,46 (0,67)	0	73,08	21,15	5,77	0
≥25000 e <50000	0,73 (0,63)	1,23	84,31	12,92	1,23	0,31
≥50000 e <75000	0,81 (0,46)	0,40	93,28	5,93	0,39	0
≥75000 e <100000	0,9 (0,36)	0	96,97	3,03	0	0
≥100000	0,87 (0,28)	0,96	98,08	0,96	0	0

transições (como explicado na Seção 5), realizadas pelo mesmo usuário em diferentes setores (nós no grafo). Excluímos laços, ou seja, visitas do mesmo usuário no mesmo setor. Com isso, estudamos a assortatividade relacionada com a renda mediana por setor em G_2^{flow} . Isso é uma maneira de tentar observar a existência de segregação.

A assortatividade mede a similaridade de conexões na rede em relação a um determinado atributo, e varia de -1 a +1 [Newman 2002]. Em uma *rede assortativa* (com assortatividade positiva), vértices com valores similares por um dado atributo (por exemplo, a mesma faixa de renda), tendem estarem conectados (serem semelhantes) entre si, enquanto que em uma *rede disassortativa* (com assortatividade negativa), acontece o contrário. Todos os setores foram associados a uma classe com base no rendimento mediano do setor. A classe A para a renda mediana até \$75.000 e a classe B para uma renda mediana superior. A assortatividade considerando essas duas classes como atributos de G_2^{flow} é de 0,14. Assim, a rede para este atributo é assortativa, o que indica um traço de segregação, ou seja, usuários tendem a compartilhar conteúdo em (ou frequentar) setores que possuem a mesma classe de renda.

Depois disso, criamos dez grafos aleatórios¹¹ $G_{Ri}(V, E_{Ri})$, onde $i = 1, \dots, 10$. Cada grafo aleatório é construído usando o mesmo número de transições individuais de G_2^{flow} . No entanto, em vez de considerar a transição real $v_i \rightarrow v_j$ realizada por um indivíduo, escolhemos aleatoriamente dois setores para substituir v_i e v_j , simulando transições aleatórias realizadas pelos usuários. Para cada grafo G_{Ri} também é associado aleatoriamente a classe de um nó, A ou B. O número de nós da classe A e B também estão de acordo com o observado em G_2^{flow} . Depois disso, calculamos a assortatividade para todos os grafos aleatórios $G_{R1..10}$. A assortatividade para todos os grafos, com 95% de confiança, está no intervalo: $[-0,0084, -0,0014]$. Como podemos ver, essas redes aleatórias são disassortativas, não indicando segregação. Obviamente, a fim de tirar qualquer conclusão nesse sentido é necessário uma investigação mais detalhada, no entanto, isso serve para demonstrar o potencial de análise conjunta de múltiplas camadas.

Observe ainda o potencial de se considerar as mesmas camadas para gerar um plano de trabalho M_3 combinado por usuários. Além de identificar as preferências dos usuários, também podemos tentar inferir sua classe social estudando a renda dos setores que o usuário frequenta. Isto pode ser útil para estudos sociais, bem como para uma publicidade mais eficaz.

7. Conclusão e Trabalhos Futuros

Neste estudo apresentamos o que é, no melhor de nosso conhecimento, o primeiro trabalho que define e usa o conceito emergente de camadas de sensoriamento. Para isso, propomos um arcabouço para integração de múltiplas camadas de sensoriamento, que foi ilustrado na construção de duas aplicações que utilizam múltiplas camadas de sensoriamento.

Como trabalhos futuros, pretendemos desenvolver outras aplicações que exploram o arcabouço proposto para integrar outras camadas de sensoriamento. Por exemplo, a camada alerta

¹¹Note que poderíamos ter uma nova operação no arcabouço para esse propósito.

Agradecimentos

Este trabalho é parcialmente financiado pelo INCT-Web (MCT/CNPq 57.3871/2008-6), e pelas bolsas e projetos individuais dos autores financiados pelo CNPq, CAPES (bolsa 7356/12-9), e FAPEMIG.

Referências

- Bollen, J., Mao, H., and Zeng, X. (2011). Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1):1–8.
- Burke, J., Estrin, D., Hansen, M., Parker, A., Ramanathan, N., Reddy, S., and Srivastava, M. B. (2006). Participatory sensing. In *Workshop WSW'06*, pages 117–134.
- Cheng, Z., Caverlee, J., Lee, K., and Sui, D. Z. (2011). Exploring Millions of Footprints in Location Sharing Services. In *Proc. of ICWSM'11*, Barcelona, Spain.
- Cho, E., Myers, S. A., and Leskovec, J. (2011). Friendship and mobility: user movement in location-based social networks. In *Proc. of ACM KDD'11*, pages 1082–1090, San Diego, California, USA.
- Crandall, D. J., Backstrom, L., Huttenlocher, D., and Kleinberg, J. (2009). Mapping the world's photos. In *Proc. of the WWW '09*, pages 761–770, Madrid, Spain. ACM.
- Cranshaw, J., Schwartz, R., Hong, J. I., and Sadeh, N. (2012). The Livehoods Project: Utilizing Social Media to Understand the Dynamics of a City. In *Proc. of the ICWSM'12*, Dublin, Ireland.
- Dey, A. K. and Abowd, G. D. (2000). Towards a Better Understanding of Context and Context-Awareness. In *CHI 2000 Workshop on the What, Who, Where, When, and How of Context-Awareness*.
- Frias-Martinez, V., Soto, V., Hohwald, H., and Frias-Martinez, E. (2012). Characterizing urban landscapes using geolocated tweets. In *Proc. of PASSAT-SocialCom'12*, pages 239–248, Amsterdam, The Netherlands. IEEE.
- Long, X., Jin, L., and Joshi, J. (2012). Exploring trajectory-driven local geographic topics in foursquare. In *Proc. of the UbiComp'12*, pages 927–934, Pittsburgh, Pennsylvania. ACM.
- Newman, M. E. (2002). Assortative mixing in networks. *Phy. rev. let.*, 89(20):208701.
- Noulas, A., Scellato, S., Mascolo, C., and Pontil, M. (2011a). An Empirical Study of Geographic User Activity Patterns in Foursquare. In *Proc. of ICWSM'11*, Barcelona, Spain.
- Noulas, A., Scellato, S., Mascolo, C., and Pontil, M. (2011b). Exploiting Semantic Annotations for Clustering Geographic Areas and Users in Location-based Social Networks. In *Proc. of ICWSM'11*, Barcelona, Spain.
- Quercia, D., Capra, L., and Crowcroft, J. (2012). The social world of twitter: Topics, geography, and emotions. In *Proc. of the ICWSM'12*, Dublin, Ireland.
- Sagl, G., Blaschke, T., Beinatz, E., and Resch, B. (2012). Ubiquitous geo-sensing for context-aware analysis: Exploring relationships between environmental and human dynamics. *Sensors*, 12(7):9800–9822.
- Sakaki, T., Okazaki, M., and Matsuo, Y. (2010). Earthquake shakes twitter users: real-time event detection by social sensors. In *Proc. of the WWW'10*, pages 851–860, New York, NY, USA. ACM.
- Silva, T. H., Vaz de Melo, P. O. S., Almeida, J. M., and Loureiro, A. A. F. (2013a). Challenges and opportunities on the large scale study of city dynamics using participatory sensing. In *Proc. of the IEEE ISCC'13*, Split, Croatia.
- Silva, T. H., Vaz de Melo, P. O. S., Almeida, J. M., and Loureiro, A. A. F. (2013b). Uma Fotografia do Instagram: Caracterização e Aplicação. In *Proc. of XXXII SBRC'13*, Brasília, DF.
- Silva, T. H., Vaz de Melo, P. O. S., Almeida, J. M., Salles, J., and Loureiro, A. A. F. (2012). Visualizing the invisible image of cities. In *Proc. of IEEE CPScom'12*, Besancon, France.
- Silva, T. H., Vaz de Melo, P. O. S., Almeida, J. M., Salles, J., and Loureiro, A. A. F. (2013c). A comparison of foursquare and instagram to the study of city dynamics and urban social behavior. In *Proc. ACM SIGKDD UrbComp'13*, Chicago, USA.
- Silva, T. H., Vaz de Melo, P. O. S., Viana, A., Almeida, J. M., Salles, J., and Loureiro, A. A. F. (2013d). Traffic Condition is more than Colored Lines on a Map: Characterization of Waze Alerts. In *Proc. of the SocInfo'13*, Kyoto, Japan.
- Thelwall, M., Buckley, K., Paltoglou, G., Cai, D., and Kappas, A. (2010). Sentiment in short strength detection informal text. *J. Am. Soc. Inf. Sci. Technol.*, 61(12):2544–2558.
- Vasconcelos, M., Ricci, S., Almeida, J., Benevenuto, F., and Almeida, V. (2012). Caracterização e Influência do Uso de Tips e Dones no Foursquare. In *Proc. of XXX SBRC'12*, Ouro Preto, MG.