

Reduzindo o Erro de Algoritmos de Localização Baseados em Alcance Durante o Rastreamento de Alvos em Redes de Sensores Sem Fio

Éfren L. Souza¹, Richard W. Pazzi³, Eduardo F. Nakamura^{1,2}

¹ Universidade Federal do Amazonas – UFAM

²Fundação Centro de Análise, Pesquisa e Inovação Tecnológica – FUCAPI

³University of Ontario Institute of Technology – UOIT

efren@icomp.ufam.edu.br, richard.pazzi@uoit.ca, eduardo.nakamura@fucapi.br

Abstract. *In target tracking of Wireless Sensor Networks (WSNs), the nodes cooperate to estimate the target position based on geographical informations previously provided by localization algorithms. However, the errors introduced by localization algorithms may affect the performance of target tracking. Range-based localization algorithms use the distance between nodes to estimate node locations. In this case, the errors are generated by noises in these distances estimated. In this paper, we demonstrate and evaluate an simultaneous localization and tracking approach that uses multiple distance estimations to filter the noises. In this process there is no extra communication cost because it uses the messages sent by tracking application. We use Recursive Position Estimation (RPE) or Directed Position Estimation (DPE) – two range-based localization algorithms – to pre-localize the nodes, then their errors are reduced during tracking. We also evaluate the performance of predictions methods (Kalman, Particle, and Alpha-Beta filters) during the localization refinement. The results show that localization errors can be reduced more than 70%, depending of scenario.*

Resumo. *Em rastreamento de alvos em Redes de Sensores Sem Fio (RSSFs), os nós cooperam para estimar a posição do alvo com base em informações geográficas previamente fornecidas por algoritmos de localização. Entretanto, a localização desses algoritmos possuem erros que afetam o desempenho do rastreamento. Algoritmos de localização baseados em alcance estimam a distância entre os nós para localizá-los, nesse caso os erros são consequência de ruídos presentes nessas distâncias estimadas. Neste artigo, demonstramos e avaliamos uma abordagem de localização e rastreamento simultâneos em que os ruídos da distância estimada entre um par de nós são filtrados usando múltiplas estimativas de distância. Esse processo não possui custo de comunicação adicional, pois aproveita as mensagens do rastreamento. Usamos Recursive Position Estimation (RPE) ou Directed Position Estimation (DPE) – dois algoritmos de localização baseados em alcance – para pré-localizar os nós, então reduzimos os seus erros durante o rastreamento. Também avaliamos o desempenho das previsões dos filtros de Kalman, Partículas e Alfa-Beta enquanto o erro de localização é reduzido. Os resultados mostram que os erros de localização podem ser reduzidos em mais de 70%, dependendo do cenário.*

1. Introdução

Uma Rede de Sensores Sem Fio (RSSF) [Akyildiz et al., 2002] é um tipo especial de rede *ad-hoc* composta por dispositivos com recursos limitados, chamados nós sensores. Esses sensores são capazes de monitorar um ambiente, coletar dados, realizar processamento localmente e disseminar dados. O maior objetivo dessas redes é monitorar o ambiente para detectar e avaliar eventos de interesse.

Rastreamento de alvos é uma importante aplicação que vem sendo bastante estudada nos últimos anos [Sharma et al., 2011; Teng et al., 2012; Campos et al., 2012]. O propósito dessa aplicação é coletar dados sobre um ou mais alvos (objetos móveis de interesse) e então estimar suas posições no campo de sensores. Em algumas situações, prever a próxima posição do alvo também é interessante [Nakamura et al., 2007; Sharma et al., 2011]. A previsão pode ser usada pelo usuário da aplicação, por exemplo, para interceptar um animal que se dirige para uma área de risco, como estradas em uma reserva ecológica.

Aplicações de rastreamento usam informações geográficas para estimar a posição do alvo, dessa forma os nós precisam conhecer as suas localizações. O sistema de posicionamento global (GPS) [Goswami, 2013] pode ser usado para obter a localização dos nós, mas equipar todos os nós com um receptor de GPS representa um alto custo que torna sua utilização inviável em redes de sensores [Fang et al., 2007]. Além disso, as redes de sensores podem ser implantadas em grande escala e em locais de difícil acesso, impossibilitando que a localização dos nós seja pré-determinada. Esses problemas criaram a necessidade de se desenvolver algoritmos que utilizem a capacidade de cooperação dos nós para obter a suas localizações de forma distribuída. Esses algoritmos são chamados de algoritmos de localização [Boukerche et al., 2007].

Os algoritmos de localização geralmente usam um conjunto de nós que possuem a capacidade de auto-localização, chamados nós *beacons*, utilizando GPS ou configuração manual. Os outros nós da rede calculam as suas localizações com base nos dados de localização fornecidos pelos nós *beacons* [Oliveira et al., 2009; Yifeng & Lamont, 2011].

Os algoritmos de localização podem ser classificados como não baseados em alcance (*range-free*) [Niculescu & Nath, 2003; Fang et al., 2007] ou como baseados em alcance (*range-based*) [Albrowicz et al., 2001; Oliveira et al., 2009], esses se diferem nos dados usados para calcular as posições dos nós. Os algoritmos não baseados em alcance assumem que os nós são distribuídos uniformemente pelo campo de sensores, de forma que a quantidade de saltos entre dois nós represente a distância entre eles. Já os algoritmos baseados em alcance assumem que os nós são equipados com algum dispositivo que possibilita medir a distância entre os nós. A potência de sinal recebida (RSSI) é a técnica mais comum para estimar a distância entre os nós, pois não precisa que o nó sensor seja equipado com hardware adicional [Oliveira et al., 2009].

A posição estimada pelos algoritmos de localização possuem erros que podem prejudicar o funcionamento do rastreamento [Souza et al., 2013; Huang et al., 2013]. Os erros dos algoritmos de localização baseados em alcance são gerados por ruídos presentes nas distâncias estimadas entre os nós [Oliveira et al., 2009; Yifeng & Lamont, 2011].

Neste artigo desenvolvemos uma extensão do trabalho de Souza et al. [2013]. O objetivo é reduzir o erro dos algoritmos de localização baseados em alcance durante o rastreamento. Para isso, demonstramos e avaliamos uma abordagem de localização e

rastreamento simultâneos em que os ruídos da distância estimada entre um par de nós são filtrados usando múltiplas estimativas de distância. Cada referência de localização em um dado nó possui um Filtro de Kalman (KF) [Nakamura et al., 2007] responsável por filtrar esse ruídos iterativamente. Com isso, a localização dos nós e, consequentemente, o rastreamento ficam mais precisos com o passar do tempo. O processo de filtragem e a aplicação de rastreamento são executados simultaneamente.

Antes do rastreamento iniciar, os nós se localizam usando com localização baseada em alcance, e.g., *Recursive Position Estimation* (RPE) [Albowicz et al., 2001] e *Directed Position Estimation* (DPE) [Oliveira et al., 2009]. Durante o rastreamento, os nós que detectam o alvo trocam mensagens das suas observações sobre o evento. Essa cooperação é necessária para calcular a posição do alvo. Em nossa abordagem, antes de calcular a posição do alvo, os nós aproveitam essas mensagens para filtrar as distâncias estimadas das suas referências e melhorar as suas localizações. A posição do alvo é calculada usando as novas posições dos nós como referências. Dessa forma, os erros de localização dos nós são reduzidos por onde o alvo passa. Enquanto o erro de localização é refinado, avaliamos o desempenho das previsões dos filtros de Kalman, Partículas e Alfa-Beta [Nakamura et al., 2007; Sharma et al., 2011].

O restante deste artigo está organizado como segue. A Seção 2 apresenta e discute os trabalhos relacionados. A Seção 3 define alguns conceitos usados neste artigo. A Seção 4 apresenta nossa proposta que reduz o erro de localização durante o rastreamento. A Seção 5 apresenta a metodologia experimental e as avaliações quantitativas. Por fim, a Seção 6 apresenta as conclusões e trabalhos futuros.

2. Trabalhos Relacionados

Niculescu & Nath [2003] apresentam a solução pioneira para localização não baseada em distância. Todos os nós da rede obtêm a quantidade de saltos até os nós *beacons*. Com isso, a distância média de um salto é estimada para calcular a localização dos nós. Esse algoritmo é melhorado por Chen et al. [2008] que usam um esquema de correção de erro diferencial para reduzir o erro acumulado durante os múltiplos saltos. Fang et al. [2007] apresenta um algoritmo de localização não baseado em distância que dispensa a utilização de nós *beacons*. Esse considera que os nós são implantados em grupos, sendo que os nós de um mesmo grupo são implantados ao redor de uma posição conhecida e com uma probabilidade de distribuição Gaussiana. Com isso, a localização dos nós é calculada usando estimação estatística, observando os grupos dos vizinhos de cada nó.

Albowicz et al. [2001] propõem a solução pioneira para localização baseada em alcance. Nesse algoritmo, os nós *beacons* divulgam suas localizações para ajudar outros nós a se localizarem. Os nós que se localizam se tornam referências para outros nós. Com base nessa solução, Oliveira et al. [2009] propõem um algoritmo que usa estruturas de *beacons* para fazer a recursão iniciar de um único ponto e seguir uma direção conhecida. Com isso, um nó pode estimar sua localização usando apenas duas referências.

Alguns trabalhos da literatura avaliam o impacto dos erros de localização nos algoritmos geográficos. Oliveira et al. [2009] avaliam o efeito desses erros no roteamento geográfico. Souza et al. [2009] e Campos et al. [2012] avaliam o desempenho do rastreamento na presença desses erros. Os erros de localização desses trabalhos são resultantes de algoritmos de localização baseados em alcance.

Alguns trabalhos reduzem o erro dos algoritmos de localização. Taylor et al. [2006] e Teng et al. [2012] reduzem o erro de localização enquanto o rastreamento é executado. Os nós são pré-localizados por um algoritmo não baseado em alcance, similar ao apresentado por Fang et al. [2007]. O erro é reduzido observando as inconsistências geométricas entre as localizações dos nós e do alvo. Souza et al. [2013] reduzem o erro de localização de algoritmos baseados em alcance. Para isso, esse realiza múltiplas estimativas de distância durante a localização para obter uma estimativa de distância mais precisa. Nesse caso, a aplicação deve definir o *trade-off* entre custo e precisão.

3. Considerações e Definições

Os nós sensores são distribuídos aleatoriamente pelo campo de sensores. Todos os nós possuem os mesmos raios de comunicação e sensoramento. Os nós estão sincronizados para detectar o alvo nos mesmos intervalos de tempo.

Um algoritmo de localização baseado em alcance é executado para pré-localizar os nós. Nesses algoritmos os nós podem ser classificados como: (1) beacons – nós que conhecem precisamente e antecipadamente as suas localizações, pois são equipados com GPS ou configurados manualmente; (2) estabelecidos – nós que calculam as suas posições durante a execução do algoritmo de localização; (3) livres – nós que não conhecem a sua localização. Durante a localização, os nós estimam as distâncias entre eles e suas referências. Essas distâncias estimadas possuem ruídos que são responsáveis pelo erro de localização que se acumula a cada iteração do algoritmo de localização.

A rede de sensores é aplicada para rastrear um alvo que se move aleatoriamente pelo campo de sensores. Os nós periodicamente consultam seus sensores para verificar se podem detectar o alvo. O modelo de detecção binário é usado para detectar o alvo, i.e., um nó sempre detecta o alvo se ele está dentro do seu raio de sensoramento.

Para reduzir o tráfego de comunicação, os nós que detectam o alvo formam um agrupamento. Consideramos que o raio de comunicação é duas vezes o raio de sensoramento, com isso apenas um agrupamento é formado em cada amostragem e todos os membros do agrupamentos podem se comunicar com apenas um salto. Cada nó que detecta o alvo estima a distância entre ele e o alvo, depois disso envia uma mensagem contendo a sua localização e a distância estimada para o alvo. Essa distância estimada também está sujeita à ruídos que interferem no cálculo de posição do alvo. Com isso, cada nó passa a conhecer a localização de todos os membros do agrupamento e a que distância cada um deles está do alvo. Todos os nós calculam a posição do alvo com multilateração [Oliveira et al., 2009] e verificam qual nó está mais próximo do alvo.

Somente o nó mais próximo do alvo reporta a posição do alvo para o nó *sink*, que por sua vez faz previsões da posição do alvo usando os filtros de Kalman, Partículas e Alfa-Beta. Esses filtros são considerados as soluções canônicas de previsão em rastreamento de alvos. As previsões também são afetadas pelos erros de localização.

4. Abordagem Proposta

Neste trabalho, aproveitamos as mensagens enviadas durante o rastreamento para melhorar a localização dos nós e, conseqüentemente, melhorar o rastreamento. A localização dos nós é refinada ao longo do tempo, a medida que o alvo é rastreado, sem utilizar

comunicação adicional. Além disso, os nós que não puderam ser localizados durante a execução do algoritmo de localização podem ser localizados durante o rastreamento.

Nos algoritmos de localização baseados em distância, os ruídos presentes nas distâncias estimadas entre os nós são responsáveis pelos erros de localização. Dessa forma, neste trabalho, refinamos a localização dos nós filtrando esses ruídos. Souza et al. [2009] também filtra os ruídos das distâncias estimadas entre os nós para reduzir o erro de localização. Entretanto o custo de localização aumenta, pois precisa que cada nó envie múltiplas mensagens durante a execução do algoritmo de localização.

A Figura 1 mostra que cada nó sensor possui dois módulos: o módulo de localização e o módulo de rastreamento. O módulo de localização possui as rotinas que são executadas pelos nós durante a localização. Esse módulo armazena a localização do nó e os dados sobre as referências usadas para calcular essa localização. O módulo de rastreamento possui as rotinas necessárias para calcular a posição do alvo. O módulo de rastreamento precisa da localização do nó para calcular a posição do alvo, ele deve consultar o módulo de localização para obter essa informação




Figura 1. Comunicação entre os módulos de rastreamento e localização.

Cada nó que detecta o alvo inicia um *timer* e divulga uma mensagem do tipo *TargetDetection*, essa contém a sua localização e a distância entre ele e o alvo. Enquanto o *timer* não expirar, o nó fica esperando por mensagens de outros nós que também detectaram o alvo. Essa troca de informações é necessária para calcular a posição do alvo. Nossa abordagem tira proveito dessa troca de mensagens para filtrar os ruídos presentes nas distâncias estimadas entre os nós.

O nó que recebe uma mensagem *TargetDetection* adiciona os dados dessa mensa-

gem como referência de posição do alvo. Depois disso, o nó verifica no seu módulo de localização se o nó que originou a mensagem é uma referência de localização. Caso positivo, a distância estimada dessa referência é filtrada e atualizada na lista de referências.

Para filtrar os ruídos das distâncias estimadas das referências, cada referência de localização de um nó possui uma instância de KF configurada como

$$\begin{cases} x_{k+1} = d_{k+1} = \begin{bmatrix} 1 \end{bmatrix} \times \begin{bmatrix} d_k \end{bmatrix} + w_k \\ y_k = \begin{bmatrix} 1 \end{bmatrix} \times \begin{bmatrix} d_k \end{bmatrix} + v_k, \end{cases} \quad (1)$$

em que $x = d$ representa o estado (distância nesse caso) de um evento k ; y é o valor de medição; w e v são os ruídos do processo e da medição, respectivamente.

Sempre que um nó estabelecido recebe uma mensagem de uma referência de localização, ele usa a potência de sinal para estimar uma nova distância entre ele e a referência. Essa distância é passada para o KF correspondente, que por sua vez filtra os ruídos e retorna uma estimativa de distância mais precisa. O KF calcula iterativamente a média das distâncias estimadas, dessa forma o nó não precisa armazenar as informações de distância e refazer o cálculo sempre que uma mensagem nova for recebida.

Em algumas situações, um nó não consegue ser localizado pelo algoritmo de localização. Isso é inevitável quando o nó está isolado de forma que não obtém as referências necessárias. Colisão de pacotes durante a localização também pode fazer com que o nó não complete as referências para se localizar. Isso também pode acontecer devido ao erro das estimativas de distâncias que tornam inviável o cálculo de posição. Nossa abordagem, além de reduzir o erro de localização, possibilita localizar os nós livres durante o rastreamento. As mensagens do tipo *TargetDetection* possuem todas as informações necessárias para a localização. Então um nó livre adiciona os nós que originam essas mensagens como referências e depois calculam a sua localização.

Quando as referências são atualizadas, as melhores referências são escolhidas de acordo com os critérios do algoritmo de localização. No caso do RPE as melhores referências são aquelas que possuem menor valor residual [Albowicz et al., 2001]. No caso do DPE são escolhidas as duas referências mais distantes entre si e mais próximas da origem da recursão [Oliveira et al., 2009].

A abordagem apresentada reduz os erros de localização gerados por ruídos presentes nas estimativas de distância. Para isso, tira proveito das mensagens enviadas durante o rastreamento, então não há custo de comunicação adicional. Nossa abordagem foi adotada em uma aplicação de rastreamento, mas pode ser adaptada para qualquer aplicação geográfica em que os nós precisam divulgar as suas localizações.

5. Avaliações

5.1. Metodologia

As avaliações são realizadas por meio de simulações com ns-2. A configuração padrão da rede é composta de 289 nós sensores monitorando uma região de $200 \times 200 \text{m}^2$. Cada simulação tem duração de 10^4s , sendo que os primeiros 10s são reservados para o algoritmo de localização. Os raios de comunicação dos nós da rede são de 30m. Isso

possibilita que todos os nós se comuniquem através de múltiplos saltos e garante a cobertura necessária para localizar a maioria dos nós. Já o raio de sensoriamento é de 15m. Isso garante, na maioria dos casos, que existe pelos menos três nós detectando o alvo independente da sua posição no campo de sensores.

As localizações dos nós são estimadas com RPE ou DPE. O RPE usa 10% dos nós como *beacons* e o DPE usa quatro estruturas de *beacons* para localizar a maior parte dos nós. Para simular os erros de RSSI nas distâncias estimadas entre os nós, cada amostra de distância é perturbada por uma variável Gaussiana de média zero e desvio padrão de 8% da distância. As distâncias estimadas entre os nós e o alvo também são perturbadas por uma variável Gaussiana de média zero e desvio padrão de 6% da distância. A posição inicial do alvo é aleatória. A velocidade do alvo é de 1m/s e o seu modelo de mobilidade é a caminhada aleatória correlacionada (CRW) [Wu et al., 2000] com grau de correlação de 0,70, com isso o alvo percorre todo o campo de sensores.

O *sink* prevê a próxima posição do alvo usando KF, PF, ou ABF. No Filtro Alfa-Beta $\alpha = \beta = 0,99$. O filtro de Kalman tem seu sistema de equações lineares configurado como a Equação 2, em que x representa o estado de um tempo discreto k formado pela posição (px, py) e velocidade (vx, vy); y é o valor de medição; w e v são os ruídos do processo e da medição, respectivamente. O filtro de Partículas foi fixado em 1000 partículas, valor obtido em avaliações anteriores que mostraram que mais de 1000 partículas não reduz significativamente o erro do rastreamento. O filtro de Partículas usado nos experimentos é representado pelo Algoritmo 1.

$$\left\{ \begin{array}{l} x_{k+1} = \begin{bmatrix} px_{k+1} \\ py_{k+1} \\ vx_{k+1} \\ vy_{k+1} \end{bmatrix} = \begin{bmatrix} 1 & 0 & T & 0 \\ 0 & 1 & 0 & T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \times \begin{bmatrix} px_k \\ py_k \\ vx_k \\ vy_k \end{bmatrix} + w_k \\ y_k = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \times \begin{bmatrix} px_k \\ py_k \\ vx_k \\ vy_k \end{bmatrix} + z_k, \end{array} \right. \quad (2)$$

```

input : medição  $y_k$ 
output: previsão  $x_{k+1}$ 
1 for  $i = 1 : N$  do  $x_0^i \leftarrow random()$ ;
2  $totalWeight \leftarrow 0$ ;
3 for  $i = 1 : N$  do
4    $x_k^i \leftarrow x_{k-1}^i + v_{k-1}^i + gaussian()$ ;
5    $v_k^i \leftarrow v_{k-1}^i + gaussian() * 0.05$ ;
6    $w_k^i \leftarrow \frac{1}{distance(y_k, x_k^i)}$ ;
7    $totalWeight \leftarrow totalWeight + w_k^i$ ;
8 end
9 for  $i = 1 : N$  do  $w_k^i \leftarrow \frac{w_k^i}{totalWeight}$ ;
10  $slice_k^0 \leftarrow w_k^0$ ;
11 for  $i = 2 : N$  do
12    $slice_k^i \leftarrow slice_k^{i-1} + w_k^i$ ;
13 for  $i = 1 : N$  do
14    $c \leftarrow random()$ ;
15    $j \leftarrow 0$ ;
16   while  $j < N - 1$  and  $slice_k^j < c$ 
17     do  $j \leftarrow j + 1$ ;
18    $resampling_k^i \leftarrow particle_k^j$ ;
19 end
20 for  $i = 1 : N$  do
21    $x_{k+1} \leftarrow x_{k+1} + x_k^i \times w_k^i$ ;
22 return  $x_{k+1}$ ;

```

Algorithm 1: PF para rastreamento.

Para efeito de ilustração, o Algoritmo 1 considera apenas uma dimensão, sendo x a posição, v a velocidade e w o peso de cada uma das N partículas de um tempo discreto k ; y é o valor de medição passado como entrada. O algoritmo distribui as partículas

aleatoriamente (linha 1). A propagação das partículas e o cálculo de suas importâncias consideram a distância da posição de cada partícula para a posição da medição (linhas 3–8). O processo de normalização (linha 9) prepara o peso das partículas para o processo de reamostragem (linhas 12–17). Por fim, a previsão é calculada. (linha 18).

Cada mensagem enviada pelos nós tem tamanho 32bytes. Modelamos o consumo de energia de acordo com os diferentes modos de operação do rádio CC2420 [Wang et al., 2007]. A Tabela 1 mostra os parâmetros de energia usados nas simulações.

Tabela 1. Parâmetros de energia.

Parâmetro	Valor
Energia inicial	18720 joules
Sensoriamento	2×10^{-5} watts
Transmissão	3132×10^{-5} watts
Recepção	3546×10^{-5} watts
Escutando	$76,68 \times 10^{-5}$ watts

Os resultados dos experimentos são obtidos da média de 35 execuções diferentes. As barras de erro representam um intervalo de confiança de 99%. Consideramos três métricas: erro de localização, erro de estimação, erro de previsão, mensagens e energia. O erro de localização é a distância Euclidiana entre a posição real do nó e a posição estimada pelo algoritmo de localização. O erro de estimação é a distância Euclidiana entre a posição real do alvo e a posição estimada pelo algoritmo de rastreamento. O erro de previsão é a distância Euclidiana entre a posição real do alvo e a previsão. A métrica de mensagens contabiliza todas as mensagens enviadas para localizar os nós e para rastrear o alvo. A métrica de energia é a energia consumida pelos nós até o final da simulação.

5.2. Resultados das Simulações

5.2.1. Avaliação Geral – Localização, Rastreamento e Tempo

A abordagem apresentada reduz o erro de localização filtrando as estimativas de distância usando as mensagens enviadas durante o rastreamento. As Figuras 2 e 3 mostram a distribuição dos erros de localização ao longo do tempo em intervalos de 5000s. Nessas figuras, os quadrados são os nós *beacons*, as cruzes são os nós livres, e os círculos representam a localização real dos nós estabelecidos, sendo que as setas apontam para a localização estimada.

Na Figura 2 os nós são pré-localizados com RPE, enquanto na Figura 3 os nós são pré-localizados com DPE. As figuras que marcam 10s de simulação mostram a localização inicial dos nós, i.e., a localização gerada apenas pelos algoritmos de localização. Nos demais tempos, a localização dos nós é refinada durante o rastreamento. O DPE apresenta erros de localização menores que o RPE, pois a forma como a posição do nó é calculada sofre menos interferência dos ruídos presentes nas estimativas de distância Oliveira et al. [2009]. Os nós mais distantes dos *beacons*, geralmente, possuem erros de localização maiores, devido ao erro acumulado nos nós estabelecidos.

Os nós que estão próximos do alvo tiram proveito da troca de mensagens, necessária para calcular a posição do alvo, para filtrar os ruídos das estimativas de distância




Figura 2. Distribuição dos erros de localização do RPE ao longo do tempo.

e melhorar as suas localizações estimadas. O erro de localização é reduzido gradualmente à medida que o tempo passa, como pode ser observado nas figuras e na Tabela 2. Quando a rede é pré-localizada com RPE, a solução converge com 7500s de rastreamento. Com DPE, a solução converge em 5000s, pois o erro de localização inicial é menor, como as referências são melhores, o trabalho de reduzir o erro de localização é facilitado.

Tabela 2. Erro de localização e nós livres reduzidos durante o rastreamento.

Tempo de Rastreamento	RPE		DPE	
	Erro Médio	Nós Livres	Erro Médio	Nós Livres
10s	9.60m	19	6.45m	8
2500s	7.07m	4	3.64m	0
5000s	3.60m	0	1.52m	0
7500s	2.57m	0	1.32m	0
10000s	2.35m	0	1.23m	0

Alguns nós não conseguem se localizar porque o erro das estimativas de distância não possibilitam o cálculo de posição. Além disso, os nós podem não conseguir as referências para isso, pois os dados são perdidos em colisões. Aplicando nossa abordagem, os nós livres podem se localizar mesmo depois do algoritmo de localização. Isso ocorre porque as mensagens de rastreamento melhoram as estimativas de distância entre os nós, possibilitando que a posição seja calculada. As mensagens também são usadas para adicionar referências aos nós que precisam. Na localização inicial do RPE, há um grupo de nós próximo do ponto (140, 70) que não foram localizados. Em 2500s de rastreamento a maior parte desses nós é localizada, e em 5000s de rastreamento todos eles são localizados. No caso do DPE, em 2500s de rastreamento, todos os nós livres são localizados.

Mesmo com 10000s de simulação, uma fração dos nós ainda apresenta erro de localização elevado. Esses nós são, geralmente, os mais afastados dos *beacons*, então os erros acumulados em suas referências durante os saltos de comunicação impossibilitam




Figura 3. Distribuição dos erros de localização do DPE ao longo do tempo.

um cálculo de posição mais preciso. Futuramente, pretendemos resolver esse problema aplicando seleção de referências [Xiao, 2011].

5.2.2. Imprecisão das Estimativas de Distância do Rádio

A distância estimada pelos nós sensores não é perfeita. Dependendo do ambiente monitorado, os erros associados são altos, afetando o desempenho da localização e do rastreamento. Em geral, esses erros dependem da distância e podem ser modelados como uma variável Gaussiana de média zero, em que o desvio padrão é um percentual da distância atual [Boukerche et al., 2007]. Desse modo, para avaliarmos diferentes situações, variamos o desvio padrão de 4% a 12% da distância para RPE e DPE.

As Figuras 4(a) e 4(b) mostram como a localização dos nós é afetada pela imprecisão das estimativas de distância e como ela é refinada durante o rastreamento. Enquanto a aplicação de rastreamento é executada, os nós filtram os ruídos presentes nas distâncias estimadas para suas referências e com isso melhoram a localização dos nós. Entretanto, chega um ponto em que a qualidade da localização converge e não apresenta mais melhoras significativas. O RPE possui erros de localização iniciais maiores que o DPE, por isso os ajustes nos erros de localização do RPE precisam de cerca de 7000s para convergir, enquanto o DPE converge em aproximadamente 5000s.

A Figura 4(c) compara os erros de localização antes e depois do refinamento. No pior caso, quando a imprecisão das estimativas de distância é de 12%, o RPE tem seus erros reduzidos em aproximadamente 54% e o DPE em 78%. O DPE é ajustado de forma mais eficiente porque direciona a recursão durante a localização, dessa forma o cálculo de posição dos nós é menos influenciado pelos erros das referências.

As Figuras 4(d) e 4(e) mostram como as previsões do KF são afetadas pela imprecisão das estimativas de distância e como elas são ajustadas ao longo do tempo. As previsões são afetadas pelo erro das estimativas de posição do alvo, que por sua vez são




Figura 4. Impacto das imprecisões das estimativas de distância na localização.

afetadas pelos erros de localização. Dessa forma, o desempenho das previsões melhora com o passar do tempo porque a localização dos nós usados como referências para calcular a posição do alvo também melhora.

A Figura 4(f) mostra as estimativas de posição do alvo com RPE e também compara o desempenho das previsões dos métodos KF, PF e ABF. A localização dos nós são usadas como referências para estimar a posição do alvo, logo o erro das estimativas de posição do alvo crescem juntamente a imprecisão das estimativas de distância. Essas estimativas são usadas como medidas pelos filtros KF, PF e ABF para fazerem previsões, por isso a qualidade das previsões refletem a qualidade das estimativas de posição do alvo.

O ABF é uma versão simplificada do KF, ele tem desempenho inferior, porém é menos complexo computacionalmente. O KF é a solução ótima para problemas lineares e com ruídos Gaussianos, entretanto os ruídos introduzidos pelos erros de localização são não-Gaussianos, por isso o PF possui um desempenho melhor. O PF, devido à sua natureza não-linear e não-Gaussiana, reduz uma fração do ruído não-Gaussiano introduzido pelos algoritmos de localização.

5.2.3. Escalabilidade

Avaliamos como a escala da rede afeta a combinação localização-rastreamento e a redução dos erros ao longo do tempo. Essa análise é importante porque as redes de sensores sem fio preveem situações em que precisam ser implantadas em larga escala. Sendo assim, variamos a quantidade de nós de 169 até 841, mantendo constante a densidade de 0,007 nós/m². Portanto, a área monitorada é redimensionada de acordo com a quantidade de nós sensores. Como o percentual de *beacons* usados no RPE é de 10%, o número de *beacons* aumenta de acordo com a quantidade de nós. O DPE mantém o uso de 4 estruturas de *beacons*, e passa a usar 5 estruturas quando a rede possui 441 nós ou mais.

As Figuras 5(a) e 5(b) mostram o impacto da escala da rede na localização. No RPE, a quantidade de nós *beacons* sempre é 10% da quantidade total de nós, por isso o erro de localização se mantém constante em qualquer escala usada. Já no DPE, a escala aumenta, mas a quantidade de estrutura de *beacons* utilizada não acompanha o crescimento da rede. Com isso, mais saltos de comunicação são necessários para alcançar toda a rede e mais erros são acumulados. Dessa forma, aumentar a escala da rede implica em aumentar o erro de localização. Por outro lado, a qualidade da localização do DPE seria mantida se a quantidade de estruturas de *beacons* utilizadas acompanhasse a escala da rede. Esses dois algoritmos de localização têm seus erros reduzidos ao longo do tempo, isso pode ser visto de forma mais clara na Figura 5(c).




Figura 5. Impacto da escala da rede na localização.

As Figuras 5(d) e 5(e) mostram que o rastreamento reflete o mesmo comportamento da localização na mudança de escala, pois a localização dos nós são usadas como referências para localizar o alvo. No RPE o erro de rastreamento permanece o mesmo em qualquer escala, pois a quantidade de *beacons* cresce na mesma proporção que o número de nós. Já com o DPE, no cenário que avaliamos, a quantidade de estruturas de *beacons* não foi suficiente para para conservar a qualidade do rastreamento. Em ambos os algoritmos, o erro de localização é reduzido com o tempo, por isso o rastreamento é beneficiado e tem seus erros reduzidos com o passar do tempo.

A Figura 5(f) mostra o impacto da escala na quantidade de mensagens enviadas e energia consumida pelos nós. A quantidade de mensagens enviadas cresce com a escala da rede porque mais mensagens são necessárias para localizar os nós e para reportar o resultado do rastreamento para o nó *sink*. Por outro lado, a energia consumida pela rede diminui com a escala. Isso acontece porque a quantidade de nós que detecta o evento é a mesma em qualquer escala, mas o consumo médio por nó é menor em escalas maiores, uma vez que a carga de trabalho é distribuída entre mais nós.

6. Conclusões e Trabalhos Futuros

Neste artigo propomos e avaliamos uma abordagem de fusão de dados que reduz os erros de localização durante o rastreamento. Essa é focada em localização baseados em alcance, em que os erros são resultado da imprecisão das estimativas de distância. Dessa forma, filtramos os erros dessas estimativas para reduzir o erro de localização. Esse processo não possui custo de comunicação adicional, pois é realizado durante o rastreamento, aproveitando as mensagens enviadas pela aplicação. Essa abordagem também possibilita localizar nós que não puderam ser localizados durante a etapa de localização.

Em nossas avaliações utilizamos dois algoritmos de localização baseados em alcance: RPE e DPE. Nossa abordagem reduz com sucesso o erro desses dois algoritmos de localização. Dependendo do cenário, os erros podem ser reduzidos em mais de 70%. Entretanto, se a localização precisa de muitos saltos de comunicação para ser completada, os erros acumulados nas referências geram erros que são difíceis de serem removidos.

Também comparamos três métodos de previsão em rastreamento de alvos: KF, ABF e PF. Na presença de erros de localização, o PF apresenta um desempenho superior quando comparado com as outras técnicas. Diferente do KF e do ABF, o PF pode ser aplicado para filtrar ruídos não-Gaussianos, por isso é menos influenciado pelo cálculo de posição do alvo estimado com referências que possuem erros de localização.

Futuramente pretendemos avaliar as inconsistências geométricas nas posições nós e nas distâncias estimadas entre eles para reduzir o erro de localização acumulado.

Referências

- Akyildiz, I. F., Su, W., Sankarasubramaniam, Y., and Cayirci, E. (2002). Wireless sensor networks: A survey. *Computer Networks*, 38(4):393–422.
- Albrowicz, J., Chen, A., and Zhang, L. (2001). Recursive position estimation in sensor networks. In *Proceedings of the 9th International Conference on Network Protocols (ICNP'01)*, pages 35–41, Riverside, USA.
- Boukerche, A., de Oliveira, H. A. B. F., Nakamura, E. F., and Loureiro, A. A. F. (2007). Localization systems for wireless sensor networks. *IEEE Wireless Communications*, 14(6):6–12.
- Campos, A. N., Souza, E. L., Nakamura, F. G., Nakamura, E. F., and Rodrigues, J. J. P. C. (2012). On the impact of localization and density control algorithms in target tracking applications for wireless sensor networks. *Sensors*, 12(6):6930–6952.
- Chen, H., Sezaki, K., Deng, P., and So, H. C. (2008). An improved dv-hop localization algorithm with reduced node location error for wireless sensor networks. *Trans. on Fundamentals of Electronics, Comm. and Computer Sciences*, E91-A(8):2232–2236.
- Fang, L., Du, W., and Ning, P. (2007). A beacon-less location discovery scheme for wireless sensor networks. In *Secure Localization and Time Synchronization for Wireless Sensor and Ad Hoc Networks*, volume 30, pages 33–55. Springer.
- Goswami, S. (2013). Global positioning system. In *Indoor Location Technologies*, pages 51–63. Springer.
- Huang, B., Yu, C., and Anderson, B. D. O. (2013). Understanding error propagation in

- multihop sensor network localization. *IEEE Transactions on Industrial Electronics*, 60:5811–5819.
- Nakamura, E. F., Loureiro, A. A. F., and Orgambide, A. C. F. (2007). Information fusion for wireless sensor networks: Methods, models, and classifications. *ACM Computing Surveys*, 39(3):55. Article 9.
- Niculescu, D. and Nath, B. (2003). Dv based positioning in ad hoc networks. *Telecommunication Systems*, 22(1-4):267–280.
- Oliveira, H. A. B. F., Boukerche, A., Nakamura, E. F., and Loureiro, A. A. F. (2009). An efficient directed localization recursion protocol for wireless sensor networks. *IEEE Transactions Computing*, 58(5):677–691.
- Sharma, S., Deshpande, S., and Sivalingam, K. (2011). On guided navigation in target tracking sensor networks using alpha-beta filters. In *Proceedings of the 31st Conference on Distributed Computing Systems Workshops (ICDCSW'11)*, pages 294 –303, Minneapolis, Minnesota, USA.
- Souza, E. L., Nakamura, E. F., de Oliveira, H. A. B. F., and Figueiredo, C. M. S. (2013). Reducing the impact of location errors for target tracking in wireless sensor networks. *Journal of the Brazilian Computer Society*, 19(1):89–104.
- Souza, E. L., Nakamura, E. F., and Oliveira, H. A. B. F. (2009). On the performance of target tracking algorithms using actual localization systems for wireless sensor networks. In *Proceedings of the 12th International Conference on Modeling, Analysis and Simulation of Wireless and Mobile Systems (MSWiM'09)*, pages 418–423, Tenerife, Canary Islands, Spain.
- Taylor, C., Rahimi, A., Shrobe, H., Bachrach, J., and Grue, A. (2006). Simultaneous localization, calibration, and tracking in an ad hoc sensor network. In *Proceedings of the 5th International Conference on Information Processing in Sensor Networks (IPSN'06)*, pages 27–33, Nashville, Tennessee, USA.
- Teng, J., Snoussi, H., Richard, C., and Zhou, R. (2012). Distributed variational filtering for simultaneous sensor localization and target tracking in wireless sensor networks. *IEEE Transactions on Vehicular Technology*, 61(5):2305–2318.
- Wang, H., Zhang, X., Naït-Abdesselam, F., and Khokhar, A. (2007). DPS-MAC: an asynchronous MAC protocol for wireless sensor networks. In *Proceedings of the 14th international conference on High performance computing (HiPC'07)*, pages 393–404, Goa, India.
- Wu, H., Li, B.-L., Springer, T. A., and Neill, W. H. (2000). Modelling animal movement as a persistent random walk in two dimensions: expected magnitude of net displacement. *Ecological Modelling*, 132(2):115–124.
- Xiao, Q. (2011). *Range-Free and Range-Based Localization of Wireless Sensor Networks*. PhD thesis, Hong Kong Polytechnic University.
- Yifeng, Z. and Lamont, L. (2011). A map registration localization approach based on mobile beacons for wireless sensor networks. In *Proceedings of the Global Telecommunications Conference (GLOBECOM'11)*, pages 1–5, Houston, Texas, USA.