

Caracterização e Modelagem da Carga de Trabalho do Dropbox

Glauber Gonçalves², Idilio Drago³, Ana Paula Couto da Silva²,
Jussara Marques de Almeida², Alex Borges Vieira¹

¹ Departamento de Ciência da Computação - Universidade Federal de Juiz de Fora

² Departamento de Ciência da Computação - Universidade Federal de Minas Gerais

³ Politecnico di Torino - Italy

{ggoncalves, ana.coutosilva, jussara}@dcc.ufmg.br; idilio.drago@polito.it; alex.borges@ufjf.edu.br

Resumo. Este artigo apresenta a caracterização e modelagem de padrões de carga de trabalho de um sistema de armazenamento em nuvem muito popular atualmente, o Dropbox. A carga é analisada sob dois pontos de vista complementares. Por um lado, propriedades dos repositórios compartilhados por um conjunto de 333 usuários voluntários, tais como número, tipo e tamanho dos arquivos, nível de replicação e dinâmica de atualizações, são analisadas. Por outro lado, os padrões de comportamento de clientes são modelados a partir de dados de tráfego coletados em 3 redes universitárias. Nossos resultados podem ser aplicados na geração de cargas sintéticas realistas e servir como substrato para o desenvolvimento e avaliação de novas soluções de armazenamento em nuvem mais eficazes.

Abstract. This paper presents a characterization and modeling of the workload of the currently most popular cloud storage system, Dropbox. The workload is analyzed from two complementary perspectives. On one side, characteristics of the Dropbox folders of a set of 333 volunteers, including number, type and sizes of files, replication level, and file update dynamics are analyzed. On the other side, the client behavior patterns are modeled based on the analysis of Dropbox traffic collected from 3 universities. Our results can be explored to design realistic synthetic workloads, which in turn can support the design and evaluation of more cost-effective cloud storage services.

Palavras-chave: Dropbox, Caracterização e Modelagem, Carga de Trabalho.

1. Introdução

Computação na nuvem (*cloud computing*) [Zhang et al. 2010] tem atraído um grande interesse da indústria e da academia, servindo como plataforma para uma variedade de serviços. Em particular, armazenamento na nuvem (*cloud storage*) tem ganhado popularidade entre empresas e usuários domésticos por ser um mecanismo simples, prático e seguro de armazenar dados. Tal popularidade crescente se evidencia com a entrada recente de grandes empresas da Internet no mercado de armazenamento na nuvem (e.g., Google e Microsoft). Como consequência, o volume de tráfego gerado por essas aplicações tem crescido a uma taxa muito grande. Por exemplo, o Dropbox, uma das aplicações mais populares, trata mais de 1 bilhão de *uploads* de arquivos por dia¹.

¹<https://www.dropbox.com/news/company-info>

O conhecimento da carga típica imposta a um serviço é fundamental para o projeto de soluções com melhor relação custo-benefício. No contexto de serviços de armazenamento na nuvem, diversos aspectos tornam a análise da carga de trabalho uma tarefa desafiadora. Como o conteúdo armazenado é privado e os protocolos de sincronização são proprietários, o conhecimento sobre o funcionamento dessas aplicações ainda é limitado. Além disso, o uso de criptografia torna difícil a captura e a análise de dados gerados por essas aplicações.

De fato, existem apenas alguns trabalhos recentes que analisam características de aplicações de armazenamento na nuvem [Mager et al. 2012, Gracia-Tinedo et al. 2013], com foco na arquitetura [Lenk et al. 2009] e na privacidade e segurança dos dados [Zhou et al. 2010]. A despeito de alguns estudos de desempenho [Drago et al. 2013a, Li et al. 2010, Wang and Ng 2010] e de padrões de tráfego [Drago et al. 2012], ainda existe uma lacuna na literatura quanto às cargas típicas dessas aplicações.

Neste artigo, nós apresentamos a caracterização e a modelagem da carga de trabalho de uma aplicação de armazenamento na nuvem de grande popularidade, o Dropbox (Seção 3). A carga é analisada sob dois pontos de vista complementares: os conteúdos armazenados nos repositórios pessoais e os padrões de comportamento de clientes (Seções 4.1 e 4.2, respectivamente). Especificamente, nós caracterizamos várias propriedades dos repositórios Dropbox, incluindo tamanho, número e tipo dos arquivos, nível de replicação e dinâmica de alterações a partir de dados coletados de 333 voluntários. Nós também propomos um modelo hierárquico de duas camadas que captura o comportamento de um cliente Dropbox. A *camada de sessão* (superior) captura as sucessivas sessões que um usuário pode ter durante um período de tempo. A *camada de transmissão de dados* (inferior) captura as interações que um cliente tem com os servidores do Dropbox durante uma sessão. Utilizando dados de tráfego coletados de 3 campi universitários, nós caracterizamos várias propriedades de cada camada, incluindo duração e tempo entre sessões, número de transferências de dados por sessão, duração das transferências, tempos entre transferências consecutivas e volume e duração de cada fluxo de dados em uma transferência. Os nossos resultados podem ser explorados no futuro para a geração de cargas sintéticas realistas, que por sua vez podem ser úteis no desenvolvimento e avaliação de soluções de armazenamento em nuvem mais eficazes (Seção 5).

2. Trabalhos Relacionados

Este artigo caracteriza e modela a carga de trabalho do Dropbox considerando os repositórios pessoais e os padrões de comportamento de clientes. Apesar de alguns esforços recentes de avaliação do desempenho de aplicações de armazenamento em nuvens, detalhados a seguir, a literatura não apresenta modelos de carga de trabalhos dessas aplicações. Em particular, este artigo é inovador quanto à modelagem dos repositórios pessoais e suas implicações para o funcionamento da aplicação.

Alguns estudos recentes analisam soluções específicas de armazenamento na nuvem [Mager et al. 2012] ou realizam comparações entre os provedores destes serviços [Li et al. 2010], focando em aspectos relacionados ao desempenho, segurança e privacidade. Por exemplo, a arquitetura de 5 sistemas populares e seus desempenhos são avaliados em [Drago et al. 2013a], enquanto que em [Hu et al. 2010] os autores estudam

o desempenho do armazenamento e da recuperação dos dados e questões relacionadas à privacidade de 5 aplicações. Gracia-Tinedo *et al.* [Gracia-Tinedo et al. 2013] apresentam um estudo baseado em medição ativa de 3 sistemas diferentes, provendo distribuições estatísticas que modelam aspectos de desempenho, como o tempo de transferência e taxa de falhas. Já em [Drago et al. 2012], os autores apresentam uma caracterização da aplicação Dropbox, focando no uso típico, padrões de tráfego e possíveis gargalos de desempenho. Nenhum desses trabalhos anteriores focam na caracterização e modelagem dos repositórios dos usuários e do comportamento dos clientes.

Outros trabalhos focam nos gargalos de desempenho de sistemas existentes e propõem novos mecanismos para reduzir os atrasos de sincronização, incluindo estratégias mais eficientes de alocação de tarefas [Wang et al. 2012] e de agrupamento de atualizações (*bundling*) [Li et al. 2013]. Nessa linha, nosso trabalho provê novos elementos que suportam a geração futura de cargas sintéticas realistas, o que também pode contribuir para o desenvolvimento e a avaliação de novos sistemas.

Este artigo estende dois trabalhos recentes [Drago et al. 2013b, Gonçalves et al. 2014], incluindo novos resultados e discussões sobre as implicações dos mesmos no funcionamento do Dropbox². Particularmente, em [Drago et al. 2013b] nós realizamos uma análise preliminar de repositórios Dropbox. Este estudo é aqui revisitado, após uma limpeza dos dados para remoção de arquivos automaticamente criados pelo sistema e dados duplicados, o que levou a conclusões mais robustas. Além disto, nossa caracterização estende os estudos anteriores ao incluir aspectos relacionados à dinâmica de atualizações e as distribuições estatísticas que melhor modelam cada propriedade analisada. Estas distribuições são essenciais para a geração de cargas sintéticas.

3. Conceituação e Metodologia de Coleta de Dados

De acordo com o Google Trends³, o volume de buscas por Dropbox ultrapassa o volume por serviços similares desde 2010. Isto sugere que o Dropbox é a aplicação de armazenamento na nuvem mais popular atualmente, o que motivou o foco deste estudo nesta aplicação. Assim, esta seção apresenta os conceitos básicos do Dropbox e descreve a metodologia adotada em nosso estudo, incluindo o modelo hierárquico para caracterização do comportamento dos clientes e a metodologia de coleta de dados.

3.1. Dropbox

Cada usuário do Dropbox tem um repositório local associado à sua conta, contendo arquivos que podem ser compartilhados com outros usuários. O Dropbox identifica múltiplas réplicas de um arquivo em um repositório (aplicando técnicas de deduplicação de arquivos), e armazena apenas uma cópia em seus servidores de armazenamento. Porém, a economia gerada por esse processo não é repassada ao usuário: arquivos replicados ocupam espaço no repositório local proporcional ao número de réplicas.

A arquitetura do Dropbox apresenta dois componentes principais: (i) *servidores de controle*, que são gerenciados pelo Dropbox em sua infraestrutura privada; e (ii) *servidores de armazenamento*, que são hospedados pela Amazon. Logo, os arquivos

²Resultados da modelagem de comportamento de clientes foram submetidos para o *IEEE International Conference on Communications* [Gonçalves et al. 2014].

³<http://www.google.com/trends/>




Figura 1. Modelo de comportamento de um cliente Dropbox.

de usuários são sempre armazenados na nuvem pública da Amazon. Tanto para servidores de controle quanto de armazenamento, subdomínios de `dropbox.com` são usados para identificar as diferentes partes do serviço oferecido e suas funcionalidades específicas.

Os arquivos transferidos entre clientes e servidores são comprimidos no lado do cliente para reduzir o consumo de banda de rede e o tempo de transferência [Hu et al. 2010]. Somente a diferença entre versões consecutivas de um mesmo arquivo é transferida entre cliente e servidor e arquivos duplicados são transferidos somente uma vez. Todas as transferências são criptografadas com TLS/SSL. Mais detalhes sobre o protocolo Dropbox estão disponíveis em [Drago et al. 2012, Drago et al. 2013a].

3.2. Modelo Hierárquico do Comportamento do Cliente Dropbox

Para caracterizar o comportamento de um cliente Dropbox, nós propomos um modelo hierárquico de duas camadas composto por sessões (camada superior) e transferências de dados durante uma mesma sessão (camada inferior), como mostrado na Figura 1.

Uma sessão é iniciada com uma ação de *login* de um dispositivo particular, identificado pelo endereço IP⁴, e é finalizada com uma ação de *logout*. Nós denominamos o tempo entre sessões consecutivas do cliente como *tempo entre sessões*. Durante uma sessão, o cliente mantém uma conexão TCP continuamente aberta com um servidor de notificação (e.g., `notify1.dropbox.com`), utilizada para receber informações sobre mudanças realizadas nos arquivos por outros dispositivos/compartilhamentos. Os clientes iniciam transferências de dados utilizando outra conexão TCP. Logo, os endereços IP dos servidores de notificação podem ser utilizados para identificar sessões de clientes na rede.

Durante uma sessão, o cliente alterna entre períodos de atividade (transferência) e de inatividade. Uma transferência inicia com um contato do cliente a um subdomínio específico do Dropbox para iniciar o processo de sincronização. Uma transferência é subdividida em múltiplos fluxos de dados que são iniciados juntamente com o processo de sincronização. Um fluxo pode ser mantido aberto, ainda que inativo, por um período curto, à espera de mais dados a serem transferidos. Logo, nós utilizamos o *timeout* aplicado pelo Dropbox (Seção 4.2.1) como um limiar mínimo para distinguir transferências consecutivas de um mesmo cliente: fluxos consecutivos de um mesmo endereço IP, separados por um intervalo de até 60 segundos (*timeout*), são agrupados como uma única transferência de dados. O tempo total de sincronização durante uma transferência de dados é denominado *período ON*, enquanto o intervalo de tempo entre transferências consecutivas é denominado *período OFF*.

⁴Note que, na presença de NAT, não é possível distinguir sessões distintas de dispositivos que compartilham o mesmo endereço IP.

Em suma, nosso modelo de comportamento do cliente é composto pelos seguintes componentes. A camada superior inclui a duração da sessão, tempo entre sessões, número de transferência de dados por sessão, assim como os tempos de *ON* e *OFF*. Já a camada inferior, relativa às transferências de dados, é analisada considerando o número de fluxos por transferência de dados, duração e volume de cada fluxo.

3.3. Coleta de Dados

Nossa caracterização é feita em conjuntos de dados complementares que descrevem, por um lado, os repositórios de arquivos de usuários voluntários, e por outro, o comportamento dos clientes ao interagir com o Dropbox.

Repositórios de Arquivos

A coleta de dados sobre os arquivos compartilhados no Dropbox foi feita com a participação de voluntários, recrutados a partir de uma chamada à comunidade científica por meio de e-mails para diferentes listas e contatos em redes sociais.

Cada voluntário respondeu algumas perguntas sobre seu perfil e executou um programa desenvolvido por nós. Este programa analisa as características do repositório Dropbox do usuário, armazenando para cada arquivo encontrado: o tamanho, a extensão e o tipo *MIME* do arquivo, a data da última alteração e um identificador composto pela chave *Hash* dos 8 kB iniciais e dos 8 kB finais do arquivo. Arquivos com mesma chave composta, mesmo tamanho e mesmo tipo *MIME* são considerados *réplicas*. Essa heurística foi adotada para reduzir o tempo de coleta. Uma análise preliminar mostrou que a maioria das réplicas tem o mesmo nome, sugerindo que nossa heurística provê uma boa aproximação. Cada voluntário recebeu um identificador único, permitindo que um mesmo voluntário contribua mais de uma vez com a coleta. No entanto, apenas os dados mais recentes de cada usuário foram considerados.

Os dados coletados foram preliminarmente analisados em [Drago et al. 2013b]. Contudo, diferentemente daquele trabalho, nós fizemos uma limpeza dos dados para remover arquivos de sistema (e.g., arquivos `.dropbox` e `.ini`), que não refletem a carga pois não são transferidos durante sincronizações. O conjunto de dados aqui analisado cobre cerca de 3 milhões de arquivos (1,38 TB) de 333 usuários únicos. Estes usuários são principalmente do Brasil (45%), Europa (40%) e EUA (7%), sendo a maioria alunos e pesquisadores de instituições acadêmicas. Cerca de 88% deles são homens entre 20 e 30 anos, e apenas 4,5% declararam pagar pelo uso de *cloud storage*. A capacidade de armazenamento média declarada é de 23,4 GB.

Os repositórios dos voluntários são caracterizados quanto ao espaço total ocupado, número, tipos e tamanhos dos arquivos compartilhados, porcentagens de arquivos e bytes replicados e *idade* dos arquivos (i.e., tempo desde a última alteração).

Comportamento dos Clientes

O comportamento de clientes é analisado a partir de dados de tráfego coletados passivamente, conforme a metodologia proposta em [Drago et al. 2012]. Diferente de repositórios de arquivos, nessa coleta analisamos o tráfego de dados de 3 locais, especificamente campi universitários, descritos a seguir. A ferramenta tstat [Finamore et al. 2011] foi usada para coletar informações sobre todas as conexões TCP nas redes de interesse, incluindo os endereços IPs de clientes e servidores e volume de dados

trocados. Foram utilizadas as mesmas heurísticas de [Drago et al. 2012] para identificar e classificar o tráfego Dropbox. Por exemplo, para classificar o tráfego entre diferentes funcionalidades do Dropbox (i.e., controle, armazenamento de dados, etc), nós usamos o texto `*.dropbox.com` encontrado nos certificados TLS/SSL e no domínio de nome que os clientes requisitam aos servidores DNS. Uma lista completa dos domínios usados pelo Dropbox e detalhes da metodologia de isolamento e classificação de tráfego Dropbox estão disponíveis em [Drago et al. 2012].

O tstat foi executado nos roteadores de borda de 3 campi universitários, denominados campus 1, 2 e 3. O campus 1, de uma universidade europeia, tem uma população de 13 mil pessoas, entre estudantes, funcionários e docentes. Os campi 2 e 3 pertencem a universidades brasileiras, com 57 mil e 20 mil pessoas, respectivamente. Os 3 conjuntos de dados incluem tráfego gerado por laboratórios e escritórios de administração. Os dados do campus 1 também incluem o tráfego da moradia estudantil.

Como mencionado, várias heurísticas foram usadas para filtrar dados não relacionados ao Dropbox. Considerando o modelo de comportamento proposto, nós focamos em fluxos TCP relacionados a transferências de *dados* e sessões de clientes. O tráfego direcionado à interface Web do Dropbox foi desconsiderado, já que, como descrito em [Drago et al. 2012] e confirmado em nossos dados, a vasta maioria do tráfego Dropbox é produzida pela aplicação cliente. Fluxos de até 2 segundos ou com até 5 kB de dados, que em sua maioria refletem problemas de comunicação, foram também descartados.

Múltiplos fluxos de dados foram agrupados em uma sessão, conforme modelo proposto, avaliando o endereço IP do cliente e os tempos de início e fim associados à sessão e aos fluxos. Um fluxo f_i foi atribuído à sessão s_i se: os endereços IPs dos clientes de f_i e s_i eram iguais, $start(f_i) \geq start(s_i)$ e $end(f_i) \leq end(s_i)$. Porém, foram detectados casos em que o início de uma sessão ocorria antes do término explícito da sessão anterior do mesmo endereço IP, ou seja, casos de sobreposição de sessões de um mesmo endereço IP. Nestes casos, não foi possível atribuir fluxos de dados que ocorrem durante a sobreposição a uma única sessão. Testes com o Dropbox em ambiente controlado [Drago et al. 2013a] mostraram que tais sobreposições podem ocorrer devido a: (i) uso de NAT, o que faz com que sessões de múltiplos clientes apareçam com o mesmo endereço; ou (ii) falhas de comunicação entre clientes e servidores, que forcem o cliente Dropbox a abrir uma sessão antes do término da anterior.

Para o caso (ii), esperamos sobreposições de mais curta duração. Logo, foi aplicada a seguinte heurística para lidar com sobreposições entre sessões de um mesmo endereço. Como é sabido que o campus 1 não adota oficialmente NAT em suas sub-redes, é esperado que a maioria das sobreposições neste conjunto de dados seja devido a falhas de comunicação⁵. Foram observadas sobreposições em 42% das sessões do campus 1. A distribuição das durações dessas sobreposições apresenta um ponto de inflexão (joelho) claro por volta de 140 segundos. Logo, esse limiar foi adotado para identificar sobreposições causadas por problemas de comunicação. Isto é, nos 3 conjuntos de dados, sessões com sobreposição de até 140 segundos foram agrupadas, formando uma única sessão. Essa operação foi realizada em 36%, 38% e 50% das sessões coletadas nos campi 1, 2 e 3, respectivamente. Sessões com sobreposições maiores que esse limiar -

⁵Observamos alguns poucos casos de sessões com sobreposições longas no campus 1, possivelmente devido ao uso de NAT nas moradias estudantis.

Tabela 1. Descrição dos Conjuntos de Dados de Tráfego.

Campus	Período	Volume total (TB)	Tráfego Dropbox			
			# IPs	# Sessões	# Fluxos de dados	Volume (TB)
1	6/3-9/5/13	526,3	17.457	718.631	1.752.516	10,80
2	19/2-14/3/13	38,9	4.637	98.789	132.672	1,08
3	6/3-6/5/13	30,8	155	10.823	74.558	0,56

4%, 15% e 45% das sessões dos campi 1, 2 e 3, respectivamente - foram descartadas. O maior descarte nos campi 2 e 3 é devido ao uso mais frequente de NAT em suas redes. Embora esse descarte possa ter afetado quantitativamente algumas métricas de nosso modelo hierárquico, como discutimos na Seção 4.2, acreditamos que não tenha afetado qualitativamente, pois obtivemos as mesmas distribuições para os 3 campi com leve variação de parâmetros conforme particularidades de cada campus (população e estabilidade da rede), a despeito das taxas de descarte diferentes.

A Tabela 1 sumariza os 3 conjuntos de dados, apresentando o período de coleta, o tráfego total coletado, e, para o tráfego Dropbox analisado (após filtragem), os números de endereços de clientes únicos, sessões, fluxos de dados e o volume de dados transferidos.

Ressaltamos que existe um viés nos dados analisados (tanto de tráfego quanto de repositório) para ambientes acadêmicos e poucas regiões geográficas. Porém, considerando a falta de estudo semelhante na literatura, esperamos que os resultados obtidos, discutidos a seguir, forneçam uma referência para estudos futuros.

4. Resultados da Caracterização

Esta seção discute os resultados da caracterização dos repositórios de arquivos (Seção 4.1) e do comportamento dos clientes do Dropbox (Seção 4.2). Estes resultados provêm visões complementares da carga do sistema. Para cada componente analisado, nós apresentamos a distribuição estatística que melhor se adequa aos dados, escolhida entre os seguintes modelos usados na literatura: Normal, Log-Normal, Exponencial, Gamma, Logística, Beta, Uniforme, Weibull e Pareto para variáveis contínuas; Poisson, Binomial, Binomial Negativa, Geométrica e Hipergeométrica para variáveis discretas. Para cada modelo, os parâmetros da distribuição que mais se aproxima dos dados são determinados usando o método de estimativa por máxima verossimilhança. Após definição dos parâmetros de cada modelo, a distribuição com menor distância de Kolmogorov-Smirnov (distribuições contínuas) ou menor erro quadrático mínimo (LSE) (distribuições discretas) em relação aos dados é escolhida [Venables and Ripley 2002]. Esta escolha também é validada com uma avaliação visual do ajuste das curvas.

4.1. Repositórios de Arquivos

A maioria dos voluntários do nosso estudo tem um grande volume de dados em seus repositórios, talvez devido ao perfil acadêmico frequente entre eles. Mais de 70% dos voluntários armazenam pelo menos 1 GB de dados e praticamente 9% armazenam pelo menos 10 GB. O tamanho médio dos repositórios é 4,23 GB, bem acima do limite inicial para acesso gratuito (2 GB). Observa-se que uma distribuição Weibull⁶ com parâmetros

⁶Função de densidade de probabilidade (PDF) da distribuição Weibull: $p_X(x) = \frac{\alpha}{\beta} \left(\frac{x}{\beta}\right)^{\alpha-1} e^{-(x/\beta)^\alpha}$.




Figura 2. Características dos arquivos em repositórios Dropbox. (a) Número: distribuição Weibull⁶ com $\alpha=0,60$ e $\beta=6.080,77$; (b) Tamanho: distribuição Pareto⁷ com $\alpha=0,37$ e $\kappa=0,66$; (c) Porcentagem de replicação: distribuições Exponenciais⁹ com $\lambda=4,82$ (arquivos) e $\lambda=11,81$ (bytes).

$\alpha=0,69$ e $\beta=3,32$ provê o melhor modelo para os tamanhos dos repositórios. As curvas são omitidas por limitações de espaço e por serem produto das distribuições dos números e tamanhos de arquivos por repositório, discutidas a seguir.

A Figura 2(a) mostra a distribuição do número de arquivos nos repositórios (escala logarítmica no eixo x). Os voluntários tendem a armazenar muitos arquivos, possivelmente devido ao perfil acadêmico da maioria: 71% deles têm pelo menos 1.000 arquivos e cerca de 13% têm mais de 20 mil arquivos. Como nenhuma das distribuições discretas analisadas apresentou um bom modelo, foram avaliadas aproximações com distribuições contínuas. Como mostrado na figura, uma distribuição Weibull⁶ (parâmetros α e β na legenda da figura) apresentou uma aproximação justa.


A Figura 2(b) apresenta a distribuição dos tamanhos dos arquivos nos repositórios. Mais de 93% dos arquivos são menores que 1 MB, e o tamanho médio é 493 KB. Logo, a vasta maioria dos arquivos é pequena, o que sugere uma sobrecarga na rede não desprezível imposta pelo uso de criptografia antes da transferência de cada arquivo. Uma distribuição Pareto⁷, de cauda pesada, apresentou o melhor ajuste dos dados, implicando que, a despeito da tendência observada, alguns arquivos muito grandes (e.g., até 5.5 GB) são armazenados com frequência não desprezível.

A Figura 2(c) apresenta as distribuições das porcentagens de arquivos e bytes replicados nos repositórios⁸. Note que o volume de réplicas por repositório é significativo: na média, 20,7% dos arquivos e 8,4% dos bytes são réplicas. Pelo menos 40% dos arquivos de 18% dos voluntários são réplicas, e 20% dos voluntários têm mais de 17% do espaço total ocupado por réplicas. Mais ainda, os usuários replicam entre si 42% dos arquivos (14% dos bytes). A figura mostra que as duas distribuições são razoavelmente bem aproximadas por distribuições exponenciais⁹, principalmente para valores mais altos que têm maior impacto na carga. Estes resultados são relevantes para geração de cargas pois, embora todas as réplicas sejam contabilizadas para o consumo de espaço do usuário, somente uma cópia de cada réplica é mantida nos servidores e transferida

⁶PDF da distribuição Pareto: $p_X(x) = \frac{\alpha \kappa^\alpha}{(x+\kappa)^{\alpha+1}}$. Note que esta é uma distribuição Pareto tipo II.

⁸São considerados apenas conteúdos repetidos, ou seja, são contabilizados todos os bytes/cópias de um mesmo arquivo exceto a primeira ocorrência.

⁹PDF da distribuição Exponencial: $p_X(x) = \lambda e^{-\lambda x}$.



(a) Porcentagem de arquivos

(b) Espaço ocupado pelos arquivos

Figura 3. Distribuição dos tipos de arquivos em repositórios Dropbox.

durante atualizações. Nossos resultados mostram que o Dropbox tem muita oportunidade para economizar recursos ao identificar réplicas e tratá-las de forma especial.

A Figura 3 mostra as distribuições de arquivos e bytes nos repositórios por tipo de arquivo. Mais de 45% dos arquivos são documentos (e.g., arquivos Word, Excel e PDF), e eles são responsáveis por mais de 30% do espaço total do repositório. Há também uma grande quantidade de conteúdo comprimido (imagens, áudio, etc), sugerindo que a compressão realizada antes de uma atualização pode ser um desperdício de recurso computacional, pelo menos para estes arquivos.

Por fim, analisamos a dinâmica de alteração dos arquivos, caracterizando a distribuição das idades dos arquivos. A idade de um arquivo é definida como o intervalo de tempo entre a sua última alteração e o momento da coleta. A Figura 4(a) mostra que a maioria dos arquivos dos voluntários não é constantemente alterada: quase 80% dos arquivos foram modificados em menos de 1 ano antes da coleta, e somente 14% dos arquivos foram modificados no último mês antes da coleta. Uma distribuição Binomial Negativa¹⁰ se mostrou uma boa aproximação dos dados.

O Dropbox apresenta uma estratégia de agrupamento de arquivos - *bundling* – em que as atualizações são postergadas e agrupadas para reduzir latência e sobrecarga de controle [Drago et al. 2013a]. A idade dos arquivos nos permite especular até que ponto *bundling* pode ser feito. Para tal, os arquivos de cada repositório foram agrupados pelo instante da última alteração (com granularidade de 10 segundos), e a distribuição dos tamanhos dos grupos, em número de arquivos, foi caracterizada (Figura 4(b)). Foram também analisadas as porcentagens de bytes e de arquivos em grupos de determinado tamanho (Figura 4(c)). Note que 70% dos grupos têm apenas 1 arquivo e totalizam quase 70% dos dados. Porém, alguns grupos chegam a conter até 10.000 arquivos. Mais ainda, a maioria dos arquivos (80%) estão nos grupos com mais de um arquivo, sendo que 40% deles estão em grupos de pelo menos 100 arquivos. Logo, múltiplos arquivos pequenos são frequentemente adicionados/modificados ao mesmo tempo, sugerindo que o sistema deve estar preparado para lidar com transferências contendo muitos arquivos pequenos. A Figura 4(b) mostra que uma distribuição Zipf¹¹ aproxima bem os tamanhos dos grupos. As distribuições que aproximam os números de bytes e de arquivos por grupo são omitidas pois estas variáveis são função das distribuições das idades dos arquivos e dos tamanhos dos grupos (fornecidas), podendo então ser geradas sinteticamente a partir delas.

¹⁰Distribuição de probabilidade de massa (PMF) da Binomial Negativa: $p_X(x) = \frac{\Gamma(x+r)}{\Gamma(r)x!} p^r (1-p)^x$.

¹¹PMF da distribuição Zipf: $p_X = \frac{1}{Z} x^{-\alpha}$, onde Z é uma constante de normalização.




Figura 4. Dinâmica de alteração dos arquivos e potencial para *bundling*. (a) Idade dos arquivos: distribuição Binomial Negativa¹⁰ com parâmetros $r=0,828$ e $p=0.003$; (b) Tamanho dos grupos (*bundles*): distribuição Zipf¹¹ com $\alpha=2.32$; (c) Porcentagens de arquivos e bytes por grupo. Log nos eixos x de (b) e (c).

4.2. Comportamento de Clientes

Esta seção apresenta os resultados da caracterização do comportamento dos clientes, conforme modelo apresentado na Seção 3.2.

Camada de Sessão

A Figura 5(a) mostra as distribuições da duração das sessões nos 3 campi monitorados (escala logarítmica no eixo x). No geral, as sessões nos campi 2 e 3 tendem a ser mais curtas que as do campus 1: a fração de sessões com até 200 minutos é de 83% no campus 1 chegando a 92% nos outros campi. As durações médias são 143,95, 84,65 e 93,75 minutos para os campi 1, 2 e 3 respectivamente. As durações mais curtas nos campi 2 e 3 podem ser devido ao uso frequente de NAT e uma maior instabilidade da rede durante o período de monitoração (i.e., quedas dos links internacionais), principalmente no campus 3, que geram interrupções mais frequentes das sessões. Já a rede do campus 1 tem melhor estabilidade e menor uso de NAT, o que pode explicar as sessões mais longas. Ainda assim, as durações de sessões nos 3 campi são bem modeladas por distribuições Weibull⁶ (parâmetros na figura), um modelo previamente usado para aproximar as durações de sessões em outros sistemas (e.g., transmissão de vídeo ao vivo [Borges et al. 2012]).

Durante uma sessão, o cliente alterna entre períodos de transferência de dados (*On*) e períodos de inatividade (*Off*). A Figura 5(b) mostra as distribuições do número de transferências (períodos *On*) por sessão para os 3 campi. A maioria das sessões não tem nenhuma transferência, principalmente nos campi 2 e 3 (85% das sessões). Nesses casos, os clientes conectam ao servidor Dropbox, sincronizam suas informações de conta, mas não transferem nenhum arquivo. Note que os usuários do campus 1 tendem a realizar mais transferências por sessão, possivelmente devido às sessões mais longas. Porém, o número médio de transferências de dados por sessão é, em geral, muito baixo: 1,3, 0,56 e 0,57 para os campi 1, 2 e 3, respectivamente. Apesar das diferenças quantitativas, distribuições binomiais negativas¹⁰ aproximam bem os dados dos 3 campi. Note que a grande presença de sessões curtas e frequentemente sem nenhuma transferência de dados sugere que o uso de *caches* locais nos clientes durante sessões pode ter benefícios limitados.

A Figura 6(a) mostra que as distribuições das durações dos períodos de transferência (*ON*) nos 3 campi são muito semelhantes, com uma maioria de




Figura 5. Características das sessões. (a) Duração: distribuições Weibull⁶ com $\alpha=0,52, \beta=71,8$ (campus 1), $\alpha=0,38, \beta=20,8$ (campus 2) e $\alpha=0,39, \beta=20,4$ (campus 3); (b) Número de transferências: distribuições binomiais negativas¹⁰ com $r=0,12, p=0,09$ (campus 1), $r=0,07, p=0,11$ (campus 2) e $r=0,06, p=0,12$ (campus 3).




Figura 6. Períodos de transferência e inatividade (ON/OFF). (a) ON: distribuições log-normais¹² com $\mu=4,89, \sigma=0,71$ (campus 1), $\mu=4,95, \sigma=0,83$ (campus 2) e $\mu=4,80, \sigma=0,72$ (campus 3); (b) OFF: distribuições Pareto⁷ com $\alpha=1,38, \kappa=9,62$ (campus 1), $\alpha=1,13, \kappa=9,17$ (campus 2) e $\alpha=0,79, \kappa=6,78$ (campus 3).

transferências muito curtas: aproximadamente 75% das transferências duram até 200 segundos. Nota-se também um joelho nas distribuições dos dados por volta de 60 segundos, que conjecturamos ser o valor padrão de *timeout* aplicado pelo Dropbox (corroborando resultados em [Drago et al. 2012]). Em média, as transferências duram 192, 247 e 179 segundos nos campi 1, 2 e 3. Todas as 3 distribuições são bem modeladas por distribuições log-normais¹², modelo que já foi utilizado para aproximar durações de transferências em outros contextos (e.g., vídeo ao vivo na Web [Veloso et al. 2002]).

A Figura 6(b) apresenta as distribuições para os períodos de inatividade (*OFF*) de uma sessão. Na média, um usuário permanece inativo por 29, 39 e 81 minutos nos campi 1, 2 e 3, respectivamente. A maior presença de clientes atrás de NAT e com IPs dinâmicos no campus 3 pode explicar os períodos *OFF* mais longos, já que isto dificulta a identificação de sessões consecutivas de um mesmo usuário. Apesar das diferenças, distribuições Pareto⁷ aproximam bem os períodos *OFF* nos três campi. Note que, como esperado, os períodos *OFF* são bem mais longos que os períodos *ON*, já que os usuários gastam mais tempo em seus trabalhos locais que transferindo dados de/para os servidores. Alguns usuários podem também desabilitar a sincronização de seus clientes para evitar transferências. O uso de *bundling* também favorece períodos *OFF* mais longos.

Finalmente, discutimos o último componente da camada de sessão, os tempos

¹²PDF da distribuição Log-Normal: $p_X(x) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{(\ln(x)-\mu)^2}{2\sigma^2}}$.




Figura 7. Tempos entre sessões aproximados por distribuições log-normais¹²:
(a) $\mu=2.04, \sigma=3.18$ (campus 1), $\mu=-0.02, \sigma=2.94$ (campus 2) e $\mu=0.24, \sigma=3.33$ (campus 3);
(b) $\mu=7.02, \sigma=0.24$ (campus 1), $\mu=6.99, \sigma=0.20$ (campus 2) e $\mu=7.00, \sigma=0.22$ (campus 3);
(c) $\mu=8.65, \sigma=0.70$ (campus 1), $\mu=8.46, \sigma=0.56$ (campus 2) e $\mu=8.44, \sigma=0.50$ (campus 3).

entre sessões. Nenhum modelo de distribuição analisado apresentou um bom ajuste para todos os dados medidos em cada campus. Logo, optamos por modelar separadamente os tempos nas três faixas de valores: até 720 minutos, entre 720 e 2.000 minutos e acima de 2.000 minutos. Estas faixas foram escolhidas a partir de inspeção visual dos dados.

A Figura 7 apresenta as distribuições dos tempos entre sessões para cada faixa. No geral, os tempos entre sessões tendem a ser curtos. Esse comportamento é mais frequente nos campi 2 e 3, onde o uso de NAT e instabilidade da rede causam desconexões mais frequentes. De fato, a maioria dos tempos medidos (69%, 81% e 79% para os campi 1, 2 and 3) são inferiores a 720 minutos (Figura 7(a)). Mais ainda, 52% (campi 2 e 3) e 27% (campus 1) dos tempos entre sessões nesta faixa são menores que 5 minutos. Quanto às outras duas faixas de valores, cerca de 12% dos tempos entre sessões nos campi 2 e 3 e 14% dos tempos no campus 1 estão na faixa intermediária (entre 720 e 2.000 minutos). Apesar da diferenças, para os três conjuntos de dados, distribuições log-normais¹² apresentaram os melhores ajustes para os dados medidos em cada faixa¹³.

Camada de Transmissão de Dados

A camada de transmissão de dados está relacionada aos múltiplos fluxos que uma transferência de dados (período *ON*) pode conter. As distribuições do número de fluxos por transferência são mostradas na Figura 8(a). As distribuições são semelhantes nos 3 campi: a maioria (pelo menos 71%) das transferências têm um único fluxo. Dentre todos modelos testados, a distribuição geométrica¹⁴ foi a que apresentou o melhor ajuste para os 3 conjuntos de dados. Entretanto, como mostrado na figura, essa distribuição superestima um pouco o número de fluxos por transferência. Porém, ressaltamos que, para estudos de desempenho (e.g., planejamento de capacidade), é preferível superestimar o número de fluxos a subestimá-lo, já que superestimativas podem levar a decisões mais conservadoras.

A Figura 8(b) mostra que as distribuições de volume dos fluxos são muito semelhantes nos 3 campi: cerca de 82% dos fluxos carregam até 1 MB. Esta concentração em volumes pequenos está consistente com os resultados sobre tamanhos de arquivos nos

¹³Os ajustes são um pouco piores para tempos acima de 2.000 minutos. Entretanto, ressaltamos que somente uma minoria dos dados medidos estão neste intervalo.

¹⁴PMF da distribuição Geométrica: $p_X(x) = p(1 - p)^x$.




Figura 8. Características dos fluxos. (a) Número: distribuições geométricas¹⁴ com $p=0,38$ (campus 1), $p=0,37$ (campus 2) e $p=0,42$ (campus 3); (b) Volume: distribuições Pareto⁷ com $\alpha=0,50, \kappa=0,02$ (campus 1), $\alpha=0,44, \kappa=0,01$ (campus 2) e $\alpha=0,43, \kappa=0,01$ (campus 3); (c) Duração: distribuições log-normais¹² com $\mu=0,50, \sigma=4,63$ (campus 1), $\mu=0,67, \sigma=4,78$ (campus 2), $\mu=0,75, \sigma=4,65$ (campus 3).

repositórios dos usuários voluntários (Figura 2(b)), apesar dos dados terem sido obtidos de fontes diferentes. Porém, pelo menos 5% dos fluxos têm mais de 10 MB, e o volume médio é em torno de 7MB. De fato, as distribuições dos dados apresentam cauda pesada e são bem ajustadas por distribuições Pareto⁷. Por fim, as distribuições das durações dos fluxos, mostradas na Figura 8(c), são semelhantes às das durações de períodos *ON* (Figura 6(a)), já que a maioria das transferências contém apenas um fluxo.

5. Conclusões e Trabalhos Futuros

Este artigo apresentou a caracterização e modelagem de componentes da carga de trabalho do Dropbox relacionados aos repositórios de arquivos e ao comportamento dos clientes. O estudo foi feito a partir de dados coletados de repositórios de voluntários e dados de tráfego de 3 campi universitários. Para analisar o comportamento dos clientes foi proposto um modelo hierárquico composto das camadas de sessão e de transmissão de dados.

Observamos que a maioria dos voluntários tem um grande volume de dados em seus repositórios, embora muitos arquivos sejam pequenos. O nível de replicação por repositório é significativo, o que pode levar a uma economia significativa de recursos nos servidores do Dropbox. Além disto, a maioria dos arquivos não é frequentemente alterada embora, com frequência significativa, múltiplos arquivos pequenos sejam atualizados ao mesmo tempo, sugerindo que *bundling* de arquivos pode melhorar o desempenho.

Quanto ao comportamento dos clientes, apesar de diferenças quantitativas devido a variações no uso de NAT e na estabilidade da rede, os 3 campi analisados apresentam padrões semelhantes. Isto sugere que as distribuições encontradas descrevem bem o comportamento de clientes Dropbox, pelo menos no ambiente acadêmico. A maioria das sessões são curtas, e muitas delas não incluem nenhuma transferência de dados, o que sugere um benefício limitado do uso de *caches* nos clientes. As durações de sessão e dos períodos de transferência seguem distribuições previamente adotadas em medidas semelhantes em outros contextos [Borges et al. 2012, Veloso et al. 2002] mas com parâmetros bem diferentes, indicando padrões de carga significativamente distintos.

Trabalhos futuros incluem extensões para novos conjuntos de dados, coletados fora do ambiente acadêmico, e a construção de um gerador de cargas sintéticas.

Agradecimentos

Os autores agradecem o apoio do CNPq, CAPES, FAPEMIG, Instituto Nacional de Ciência e Tecnologia para Web (InWeb) e do projeto EU-IP mPlane (n-318627).

Referências

- Borges, A., Gomes, P., Nacif, J., Mantini, R., Almeida, J. M., and Campos, S. (2012). Characterizing SopCast Client Behavior. *Computer Communications*, 35(8):1004–1016.
- Drago, I., Bocchi, E., Mellia, M., Slatman, H., and Pras, A. (2013a). Benchmarking personal cloud storage. In *Proc. IMC*.
- Drago, I., Borges, A., and da Silva, A. P. C. (2013b). Caracterização dos arquivos armazenados no dropbox. In *Proc. WP2P+ - SBRC*.
- Drago, I., Mellia, M., Munafò, M. M., Sperotto, A., Sadre, R., and Pras, A. (2012). Inside Dropbox: Understanding Personal Cloud Storage Services. In *Proc. IMC*.
- Finamore, A., Mellia, M., Meo, M., Munafò, M. M., and Rossi, D. (2011). Experiences of Internet traffic monitoring with tstat. *IEEE Network*, 25(3):8–14.
- Gonçalves, G., Drago, I., da Silva, A. P. C., Vieira, A. B., and Almeida, J. M. (2014). Modeling the dropbox client behavior. In *Submetido ao ICC*.
- Gracia-Tinedo, R., Artigas, M., Moreno-Martínez, A., Cotes, C., and López, P. (2013). Actively Measuring Personal Cloud Storage. In *Proc. IEEE CLOUD*.
- Hu, W., Yang, T., and Matthews, J. N. (2010). The Good, the Bad and the Ugly of Consumer Cloud Storage. *ACM SIGOPS Operating Systems Review*, 44(3):110–115.
- Lenk, A., Klems, M., Nimis, J., Tai, S., and Sandholm, T. (2009). What's inside the Cloud? An architectural map of the Cloud landscape. In *Proc. ICSE*.
- Li, A., Yang, X., Kandula, S., and Zhang, M. (2010). Cloudcmp: comparing public cloud providers. In *Proc. SIGCOMM*.
- Li, Z., Wilson, C., Jiang, Z., Liu, Y., Zhao, B., Jin, C., Zhang, Z.-L., and Dai, Y. (2013). Efficient Batched Synchronization in Dropbox-like Cloud Storage Services. In *Proc. Middleware Conference*.
- Mager, T., Biersack, E., and Michiardi, P. (2012). A Measurement Study of the Wuala On-line Storage Service. In *Proc. of the IEEE P2P*.
- Veloso, E., Almeida, V., Meira, W., Bestavros, A., and Jin, S. (2002). A Hierarchical characterization of a live streaming media workload. In *Proc. SIGCOMM WIM*.
- Venables, W. N. and Ripley, B. D. (2002). *Modern Applied Statistic with S*. Springer.
- Wang, G. and Ng, T. S. E. (2010). The impact of virtualization on network performance of amazon ec2 data center. In *Proc. INFOCOM*.
- Wang, H., Shea, R., Wang, F., and Liu, J. (2012). On the Impact of Virtualization on Dropbox-Like Cloud File Storage/Synchronization Services. In *Proc. WQS*.
- Zhang, Q., Cheng, L., and Boutaba, R. (2010). Cloud Computing: State-of-the-Art and Research Challenges. *Journal of Internet Services and Applications*, 1(1):7–18.
- Zhou, M., Zhang, R., Xie, W., Qian, W., and Zhou, A. (2010). Security and privacy in cloud computing: A survey. In *Proc. SKG*.