

Decisão de Espectro em Redes de Sensores Sem Fio Empregando Aprendizado de Máquina

Vinicius F. e Silva¹, Daniel F. Macedo¹, Jesse L. Leoni¹

¹Departamento de Ciência da Computação – Instituto de Ciências Exatas
Universidade Federal de Minas Gerais (UFMG) – Belo Horizonte, MG – Brasil

{viniciusfs,damacedo}@dcc.ufmg.br, jleoni@ufmg.br

Abstract. *Wireless Sensor Networks (WSNs) employ ISM spectrum bands for communication, which are overloaded due to various technologies such as WLANs and other WSNs. Therefore, such networks must employ intelligent methods such as Cognitive Radio to coexist with other networks. This study evaluates the use of Supervised Machine Learning (ML) for channel selection in WSNs, considering the channel quality and communication metrics. The methods were evaluated experimentally and compared with energy-based methods. The results show that ML-based methods increase the communication performance by reducing the number of transmission attempts and therefore also reducing the delivery delay.*

Resumo. *Redes de Sensores Sem Fio (RSSFs) utilizam faixas de espectro ISM, sobrecarregadas devido a diversas tecnologias como WLANs e outras RSSFs. Por isso, tais redes devem empregar métodos inteligentes, como por exemplo de Rádio Cognitivo, de forma a coexistir com outras redes. Este trabalho avalia o uso de métodos baseados em Aprendizado de Máquina (AM) Supervisionado para a seleção de canal em RSSFs, considerando métricas de qualidade do canal e de comunicação. Os métodos foram avaliados experimentalmente, e comparados com métodos baseados em energia. Os resultados mostram que métodos baseados em AM aumentam o desempenho da comunicação, reduzindo o número de tentativas de transmissão e com isso o atraso no envio de quadros.*

1. Introdução

Um estudo da FCC (*Federal Communications Commission*) [FCC 2002] mostrou que as regras atuais adotadas para alocação de canal causam perdas consideráveis na eficiência e aproveitamento do espectro, pois em inúmeros intervalos de tempo os usuários licenciados ao uso desses canais não estão em operação [Yucek and Arslan 2009, Zeng et al. 2010]. Além disso, o acúmulo de usuários não licenciados em frequências livres gera interferências, causando perdas de informação e um aumento no consumo de energia. Redes de Sensores Sem Fio (RSSFs) são suscetíveis a esse problema, o que leva à redução do seu tempo de vida.

Por isso, as RSSFs deveriam adotar técnicas que explorem o espectro com mais eficiência, de forma a coexistir com usuários de diferentes redes sem causar conflitos entre elas. Os Rádios Cognitivos (RCs) permitem uma melhor exploração de faixas de frequência pouco utilizadas [Zeng et al. 2010]. Neste trabalho seguimos a definição de [FCC 2005], onde o RC mensura o ambiente eletromagnético no qual ele opera, para

ajustar seus parâmetros de forma autônoma e dinâmica, de forma a aumentar o fluxo de dados, reduzir a interferência e facilitar a interoperabilidade.

No caso das RSSFs, que empregam a faixa de frequência não licenciada ISM (*Industrial, Scientific and Medical*), as funções de RC são utilizadas para aumentar a coexistência de múltiplas redes, ao mesmo tempo que garantem uma comunicação mais eficiente e confiável [Sherman et al. 2008]. Enquanto nos RCs “tradicionais” procura-se selecionar faixas de frequência livres de usuários licenciados (também chamados de *Usuários Primários*), nas RSSFs os RCs selecionam canais com melhores condições para a comunicação, evitando a interferência tanto de outras RSSFs instaladas na região quanto de outros tipos de redes operando na faixa ISM (Wi-Fi, Bluetooth, etc). Entretanto, o principal desafio na implementação de RCs em RSSFs é a limitação de recursos de processamento, memória e energia destas redes. Assim, as soluções de RC existentes devem ser adequadas às restrições das RSSFs.

Neste trabalho propomos o emprego de Aprendizado de Máquina (AM) para a seleção de canais em RSSFs. As soluções propostas são avaliadas experimentalmente, comparando o seu desempenho com soluções baseadas somente em energia, as quais são populares em ambientes reais. Foram coletados dados de desempenho acerca de uma sequência de transmissões e recepções realizadas, como forma de quantificar o nível de ocupação de cada canal. A partir dos dados coletados, foram construídas bases de treinamento que permitiram a criação de modelos de previsão de baixo consumo de memória e processamento, tornando possível sua implementação em uma RSSF real. Por meio de testes práticos, observamos que o uso de AM melhorou o desempenho da RSSF, reduzindo a quantidade de tentativas de transmissão, a quantidade de colisões e o atraso sobre os pacotes transmitidos, em cenários com interferências de outras redes.

O restante do artigo está organizado da seguinte forma. A Seção 2 apresenta os conceitos envolvidos e os trabalhos relacionados. A modelagem do problema é apresentada na Seção 3, e a coleta dos dados para as bases de treinamento é apresentada na Seção 4. A Seção 5 apresenta uma análise da acurácia dos algoritmos de AM, seguida da avaliação dos melhores algoritmos em uma plataforma real na Seção 6. A Seção 7 apresenta as conclusões e trabalhos futuros.

2. Conceitos e Trabalhos Relacionados

As características de um RC podem ser divididas em quatro partes [Akyildiz et al. 2009]. O *Sensoreamento de Espectro* obtém informações sobre um conjunto de canais, detectando os intervalos de tempo não utilizados, bem como os canais menos utilizados e portanto mais propícios ao uso pelos RCs. A *Decisão de Espectro* analisa as informações obtidas na fase de Sensoreamento e determina os melhores canais a serem utilizados com base em um ou mais critérios de Qualidade de Serviço (*Quality of Service - QoS*). O *Compartilhamento de Espectro* aloca os canais selecionados e coordena as transmissões entre os diversos usuários, de forma a minimizar as colisões e a interferência causada sobre os usuários primários. Já a *Mobilidade de Espectro*, em canais não reservados como nas RSSFs, estima as condições futuras da rede, identificando se uma troca de canal é necessária. Neste trabalho o foco principal é na *Decisão de Espectro*.

Em RCs, as técnicas de AM são empregadas para otimizar métricas de *QoS*, ou parâmetros provenientes de uma ou mais camadas da pilha de protocolos. Uma das prin-

cipais vantagens no uso de algoritmos de AM é a sua capacidade de modelar o comportamento da rede em intervalos futuros, permitindo a aplicação de soluções em tempo hábil, como a troca de canal [Bantouna et al. 2012]. Em aplicações onde não é possível obter informações do meio em tempo real, são usadas técnicas alternativas como os modelos estatísticos de uso do espectro, propostos por [Zhao and Swami 2007].

Existem três abordagens em AM [Katidiotis et al. 2010]. O *Aprendizado Supervisionado* busca construir as regras de decisão com base em exemplos conhecidos e bem definidos. O *Aprendizado não supervisionado* não dispõe de uma base inicial de conhecimento, de forma que o sistema refina durante a sua operação o seu processo de decisão. O *Aprendizado semi supervisionado* realiza o aprendizado tanto com uma base de treino, antes da ativação do sistema, quanto a cada execução do sistema em operação.

Em aprendizado supervisionado, uma das técnicas mais utilizadas, devido à sua modelagem simples, são as Redes Neurais Artificiais (RNA). Em [Tsagkaris et al. 2008] são propostas estruturas de RNA para predição da vazão. Foi mostrado que a acurácia da predição pode mudar consideravelmente em função dos parâmetros considerados. Um exemplo é RNA desenvolvida por [Baldo et al. 2009], onde é considerada a variabilidade do tráfego ao longo do dia e da semana. Estes trabalhos, entretanto, não avaliaram a viabilidade da obtenção dos parâmetros de entrada e tomada de decisão em tempo hábil.

Existem poucos trabalhos em RCs que empregam aprendizado não supervisionado. Em [Tsagkaris et al. 2012], são apresentados os Mapas Auto-Organizáveis (*Self-Organizing Maps* - SOMs). SOMs coletam amostras multi-dimensionais e, a partir delas, constroem uma rede composta por neurônios cujas distâncias entre si determinam a sua similaridade. Neurônios próximos entre si, ou seja, cuja distância entre os valores dos atributos é reduzida, definem um *cluster*, o qual representa uma classe. A principal desvantagem foi a alta quantidade de memória necessária para sua execução, o que pode inviabilizar a aplicação de SOMs em RSSFs.

Em [Unnikrishnan and Veeravalli 2010] o sensoreamento e acesso ao espectro são tratados como um Processo de Decisão de Markov Parcialmente Observado, onde o uso dos canais não é conhecido de forma explícita pelos usuários não licenciados (também chamados de *Usuários Secundários*). Uma vez que o usuário acessa um canal livre, o mesmo recebe uma recompensa proporcional à largura de banda do canal acessado. De forma contrária, o canal sofre penalização caso esteja ocupado. [Felice et al. 2010] apresentam um conjunto de técnicas envolvendo aprendizado por reforço (*Reinforcement Learning* - RL) que podem ser aplicadas em RCs.

A principal desvantagem destas técnicas é a dependência de funções de recompensa e penalização que sejam altamente precisas. Muitas RSSFs, por possuírem *hardware* limitado, não conseguem realizar os cálculos exigidos por essas funções em tempo viável ou com a precisão necessária. Este trabalho procura adotar algoritmos de AM que, mesmo com a precisão de valores reduzida, oferecem desempenho adequado.

Fora do escopo de AM, é possível encontrar na literatura recente diferentes propostas de métodos de decisão de espectro para seleção de canal. No trabalho de [Masonta et al. 2013], são apresentados e descritos os estudos mais recentes de RCs para esse propósito. São também apresentados estudos relacionados à caracterização do canal, considerada pelos autores como uma etapa anterior à seleção de canal, e reconfiguração,

considerada uma etapa posterior, ambas inerentes à decisão de espectro. Os autores fazem uma divisão entre trabalhos com decisão centralizada ou não centralizada.

Em RSSF, [Correia et al. 2012] propõem dois métodos de decisão de espectro para seleção de canal. O primeiro deles toma como base medições de RSSI (*Received Signal Strength Indicator*) e resultados apresentados pelo algoritmo CCA (*Clear Channel Assessment*) em cada canal analisado. Já o segundo método toma como base informações provenientes da camada física e requisitos da aplicação em execução, os quais são ponderados por meio de entropia.

O uso de AM tem sido cada vez mais comum em algoritmos de sensoriamento e decisão de espectro. Entretanto, há uma deficiência na literatura de trabalhos que avaliem experimentalmente o uso de técnicas de AM em RSSFs. Trabalhos recentes, como o de [Thilina et al. 2013], seguem uma linha de pesquisa semelhante à aqui adotada, propondo o uso de diferentes algoritmos de AM supervisionado e não supervisionado em RC, porém, os resultados não são validados em uma rede real. O presente trabalho avalia diversos algoritmos de AM e implementa os mais eficazes em uma plataforma comercial de RSSFs, os quais serão utilizados como preditores no algoritmo de decisão de espectro proposto. Nossos preditores tomam como base o desempenho médio obtido em uma sequência de transmissões e recepções em cada um dos canais de operação, de forma a escolher o melhor canal.

3. Rádios Cognitivos Empregando AM

Esta seção apresenta a modelagem da escolha do melhor canal em RSSF como um problema de AM. Construímos um preditor baseado em regressão que procura aproximar o número de tentativas de transmissão necessário pra uma sequência finita de pacotes. O canal escolhido é aquele com o menor número de tentativas de transmissão esperado. Esse processo é executado periodicamente. Os seguintes atributos foram selecionados como entrada do preditor:

- **RSSI:** Medido em *dBm*, quantifica a potência com a qual o sinal do meio é recebido pelo rádio em um determinado instante. Para este atributo, é coletada uma quantidade fixa de amostras imediatamente antes de cada transmissão realizada. Aqui, o *RSSI* varia entre *-91dBm* e *-10dBm*, com granularidade de *3dBm*.
- **Número de Tentativas de Transmissão Total:** Quantidade de tentativas realizadas para se transmitir um pacote, com sucesso ou não, a um determinado destinatário da rede. Como determinado na implementação padrão do rádio RF230 no TinyOS, o número máximo de tentativas de transmissão é 10;
- **Contagens das Razões de cada Tentativa Realizada:** Em caso de uma ou mais falhas na transmissão de um determinado pacote, também serão contabilizadas as suas razões, definidas abaixo:
 1. **ERX:** O rádio estava ocupado com a recepção de outro pacote;
 2. **ECCA:** O algoritmo CCA (*Clear Channel Assessment*), implementado em *hardware*, indicou que o canal estava ocupado (detecção de portadora);
 3. **ENACK:** Falha ocorrida em razão do rádio ter transmitido um pacote e a sua confirmação (pacote *ACK* - *Acknowledgement*) não ter sido recebida. Esta métrica captura as colisões e erros de bit.

- **Dados do último pacote recebido:** São coletados a cada pacote recebido o seu RSSI e o LQI (*Link Quality Indication*). O LQI é uma métrica definida pelo padrão IEEE 802.15.4, que mensura a qualidade do enlace na recepção de dados, em termos do nível de distorção do sinal recebido. O RSSI aqui coletado possui maior granularidade que o RSSI coletado antes das transmissões (1 dBm), em razão do rádio utilizado.

Como as variáveis de entrada variam significativamente a cada transmissão e a cada recepção, processamos os dados para gerar um histórico de desempenho das últimas transmissões e recepções realizadas. Empregamos uma média móvel ponderada, desta forma designamos um menor peso às transmissões e recepções mais antigas e reduzimos a variação na entrada do preditor. A Equação 1 mostra o cálculo da média móvel, onde E_t é o desempenho obtido no instante t , e V_{t-1} é o valor da média móvel obtido no instante $t - 1$.

$$V_t = V_{t-1} \times (1 - \alpha) + E_t \times \alpha \quad (1)$$

O valor de α determina a rapidez com a qual a entrada reage a uma mudança no seu sinal (por exemplo um aumento no valor de entrada). Para evitar que o preditor tome uma decisão com base em informações que não condizem com a realidade, o meio deve ser sensoreado diversas vezes. Podemos estimar esta quantidade da seguinte forma. Em um cenário ideal, onde temos uma entrada constante E , o valor da média móvel no instante t é dado por (a partir da Equação 1):

$$V_t = E \times \alpha \times \left(\sum_{i=0}^t (1 - \alpha)^i \right) \quad (2)$$

O valor de V_t tende a E quando o número de termos tende a infinito. Na prática, devemos estimar um fator de aproximação p empregando a fórmula abaixo.

$$(1 - \alpha)^{n+1} = p \quad (3)$$

O valor p da Equação 3 se encontra em um intervalo entre 0 (distância nula do valor real) e 1 (distância infinita). O termo n define a quantidade de pacotes de sondagem enviados para que as condições reais do meio sejam aproximadas por um fator p . Esta sequência de pacotes de sondagem é aqui denominada de *janela de sensoreamento*.

O preditor proposto define um regressor para a variável *número de tentativas de transmissão dos próximos N pacotes*, aqui denominada de *janela de previsão*, onde N é um parâmetro que será ajustado posteriormente. Esta variável foi escolhida pois o seu valor indica a qualidade do meio tendo em vista tanto interferências externas (ruídos do ambiente, interferências de outras redes no mesmo espectro) como internas (transmissões de dados no mesmo canal). Um canal que transmite a informação com menor quantidade de tentativas (devido a interferências internas e externas) deverá ser um canal com menor atraso e taxa de perda.

4. Coleta dos Dados para as Bases de Treinamento

Em seguida, capturamos a massa de dados para as bases de treinamento a serem aplicadas nos algoritmos de AM. Os cenários de coleta foram escolhidos de forma a representar

redes com variados graus de interferência. Para tanto, empregamos roteadores Wi-Fi para geração de interferência. Os dados foram coletados em três cenários distintos, descritos com mais detalhes abaixo, juntamente com uma descrição da geração de interferência pelos roteadores.

1. **Baixa Interferência:** Cenário em que apenas os nós sensores transmitiam dados entre si, com um nível de interferência externa quase nulo;
2. **Média Interferência:** Além da transmissão de dados entre os nós da RSSF, foram também colocados dois roteadores transmitindo dados entre si, a baixa potência e distantes um do outro, na mesma faixa de frequência da RSSF;
3. **Alta Interferência:** Semelhante ao cenário de Média Interferência, os mesmos roteadores foram colocados próximos um do outro e da RSSF, transmitindo na mesma faixa de frequência e a alta potência.

Foi escolhida a Plataforma *Iris* [Crossbow 2008] para coleta dos dados de desempenho a cada transmissão, empregando o rádio padrão da plataforma (RF230). A RSSF projetada para coleta dos dados foi composta por dez nós sensores, cada qual conectado a um computador para armazenar os dados de desempenho coletados.

Cada nó transmitia pacotes de 28 *bytes* a cada 500ms a um destinatário fixo. Antes de cada transmissão, eram coletadas dez amostras de RSSI, e após a transmissão eram coletados os atributos restantes descritos na Seção 3. Foram coletados dados durante quatro horas. A Figura 1 mostra a RSSF projetada, juntamente com os roteadores para geração de interferência.




Figura 1. RSSF projetada para coleta dos dados de desempenho.

5. Análise da Acurácia dos Algoritmos de AM

Foi utilizada a Ferramenta Weka [Hall et al. 2009] para a análise dos algoritmos de AM. Dentre os algoritmos disponibilizados na Ferramenta, foram avaliados os 16 algoritmos de regressão que permitiam a obtenção de resultados de desempenho em tempo hábil, inferior a uma semana de tempo de execução para o treinamento. Em vista disso, o algoritmo *SVM* (*Support Vector Machine*), considerado o estado-da-arte entre os algoritmos de AM, não foi selecionado. Os algoritmos avaliados foram:

- Algoritmos baseados em função:
 1. *Isotonic Regression*
 2. *Linear Regression*
 3. *MLP Regressor*
 4. *Multilayer Perceptron*
 5. *Pace Regression*
 6. *RBF Regressor*
- Algoritmos baseados em busca:
 1. *KNN - K-Nearest Neighbours*
- Algoritmos de meta-aprendizado:
 1. *Additive Regression* – com *Decision Stump* como algoritmo base
 2. *Bagging* – com *REP Tree* como algoritmo base
- Algoritmos baseados em regra de decisão:
 1. *Conjunctive Rule*
 2. *Decision Table*
 3. *M5 Rules*
- Algoritmos baseados em árvore de decisão:
 1. *Decision Stump*
 2. *Extra Tree*
 3. *M5P*
 4. *REP Tree*

Para a validação do desempenho dos algoritmos, foi utilizado o método *10-Fold Cross Validation*. Nele, o conjunto de instâncias é dividido em dez partes, obtendo-se dez combinações treinamento-teste (nove partes para treinamento, e uma para teste). Cada algoritmo foi executado dez vezes, obtendo-se assim o desempenho em cem combinações treinamento-teste. Cada execução realiza a divisão das partes de Teste de forma diferente, gerando assim diferentes combinações de dados.

Para a classificação dos algoritmos, foi utilizado o teste t-pareado, disponibilizado como teste padrão no Weka, o qual considera a dependência entre amostras, e portanto é o mais adequado para uso em conjunto com o método *10-Fold Cross Validation*. Foi considerada a métrica *Raiz do Erro Médio Quadrático*¹ [Hamilton 1994], a qual é mais sensível a *outliers*, o que é importante em RSSFs devido às oscilações bruscas do meio eletromagnético.

A análise de desempenho dos algoritmos se dividiu em duas etapas. A primeira analisou o impacto do valor de α no desempenho dos algoritmos de AM. Foram testados valores entre 0.01 e 0.09, com passo 0.02. Para cada valor de α testado, foi criada uma base de treinamento distinta, a qual reuniu dados de transmissão e recepção obtidos nos três cenários analisados. Para todas as bases, o tamanho da janela de previsão foi fixado em dez, ou seja, os *dez pacotes subsequentes*, dos quais a soma do número de tentativas de transmissão foi escalonado em um intervalo entre 0 e 100. A segunda etapa analisou a influência do tamanho da janela de previsão sobre o desempenho de cada algoritmo de AM. Assim como na etapa anterior, para cada tamanho de janela considerado, foi criada uma respectiva base de treinamento, com o mesmo escalonamento da janela de previsão

¹Não empregamos a taxa de acertos ou erros, pois esta métrica somente pode ser empregada em algoritmos de AM baseados em *classificação*.

feito na primeira etapa. Nestes testes, o tamanho da janela de previsão foi variado entre 1 e 30, com α fixo em 0.01, valor que apresentou o melhor desempenho na primeira etapa, como será mostrado a seguir.

A Tabela 1 apresenta a Raiz do Erro Médio Quadrático média, obtida em dez execuções no Weka para cada um dos algoritmos de AM avaliados. Observamos que uma redução do valor de α causa um aumento no desempenho dos algoritmos de regressão. Isso se deve ao fato de que, quanto menor o valor de α , menor será a variabilidade sobre os valores de entrada. Como aqui consideramos três cenários distintos, uma menor variabilidade nas entradas faz com que a base de treinamento se aproxime de três pontos distintos, cada um relacionado a um determinado cenário, simplificando a distribuição espacial entre as instâncias e com isso as soluções geradas por algoritmos de regressão, consequentemente aumentando o seu desempenho.

Tabela 1. Raiz do Erro Médio Quadrático: valor de α variável.

Algoritmo Aplicado	Peso (α)				
	0.01	0.03	0.05	0.07	0.09
Isotonic Regression	7.35	7.30	7.33	7.35	7.39
LinearRegression	7.51	7.55	7.79	8.06	8.33
MLP Regressor	7.06	7.07	7.10	7.13	7.16
Multilayer Perceptron	7.67	7.75	7.76	7.80	7.78
Pace Regression	7.51	7.55	7.78	8.04	8.30
RBF Regressor	7.25	7.15	7.17	7.22	7.27
KNN	3.22	3.31	3.59	4.40	5.57
Additive Regression	7.12	7.12	7.12	7.13	7.16
Bagging - REPTree	5.56	6.19	6.49	6.67	6.78
Conjunctive Rule	7.80	7.78	7.78	7.77	7.77
Decision Table	6.84	6.99	7.05	7.09	7.10
M5Rules	7.35	7.53	7.54	7.10	7.05
Decision Stump	7.87	7.81	7.79	7.78	7.79
Extra Tree	5.66	6.98	7.81	8.37	8.76
M5P	6.25	6.84	6.83	6.95	7.01
REPTree	5.99	6.70	6.95	7.05	7.10

A Figura 2 apresenta a Raiz do Erro Médio Quadrático média obtida em dez execuções para os cinco algoritmos de AM de melhor desempenho ao variarmos o tamanho da janela de previsão. Descartamos os resultados obtidos pelos outros algoritmos em razão de limitações de espaço e representação gráfica, além destes terem apresentado desempenho semelhante aos aqui mostrados. Observamos um comportamento logarítmico em todos os algoritmos apresentados, com o aumento do tamanho da janela de previsão. Esse fator indica a existência de um possível padrão de comportamento do meio ao longo de um intervalo específico, aqui representado pela janela de previsão.

6. Testes Práticos

Com base na Equação 3, escolhemos o valor de $\alpha = 0.7$ para a base de treinamento a ser utilizada na construção dos modelos de previsão a serem implementados. Consideramos um fator de aproximação das condições do meio igual ou menor que 1% (fator p na




Figura 2. Raiz do Erro Médio Quadrático - Tamanho de Janela Variável.

Equação 3). Escolhemos estes valores de forma que o tempo necessário para coleta dos atributos de entrada, em cada canal, fosse de aproximadamente dois segundos, sendo um segundo para atributos relacionados ao envio de pacotes, e um segundo para atributos relacionados à recepção de pacotes. O tamanho da janela de previsão foi definido de forma empírica em aproximadamente seis minutos.

Foram realizados dois testes distintos, descritos nas seções a seguir. Para ambos, os nós da RSSF foram configurados para operar em cinco canais consecutivos. Foram empregados seis nós sensores, sendo que um deles, denominado *Nó Central*, executava uma das soluções de decisão de espectro, com um dos modelos de previsão gerados pelos algoritmos de AM implementado. Outros cinco nós sensores, denominados *Nós Auxiliares*, por sua vez, se mantinham fixos em um dos cinco canais. A função destes nós é se comunicar com o *Nó Central* quando necessário. A seguir é apresentado o funcionamento das soluções de decisão de espectro, além de uma representação gráfica desse funcionamento na Figura 3.

1. Para cada canal:
 - (a) O *Nó Central* envia pacotes de sondagem durante um segundo ao *Nó Auxiliar*, de forma a coletar dados referentes à transmissão;
 - (b) O *Nó Auxiliar* envia pacotes de sondagem ao *Nó Central* durante um segundo, para que o *Nó Central* colete dados referentes à recepção.
 - (c) É realizada a previsão para o respectivo canal;
2. O *Nó Central* seleciona o canal com melhor previsão (menor valor de saída obtido);
3. O *Nó Central* transmite 30 pacotes de dados ao *Nó Auxiliar* localizado no canal selecionado, encaminhando o sumário do desempenho obtido ao computador, para mensurar o desempenho do algoritmo de troca de canal;
4. Reinicia-se o processo de decisão, retornando ao Passo 1.

Apesar de empregarmos um *Nó Auxiliar* por canal nos experimentos, o algoritmo pode ser modificado para que seja empregado somente um *Nó Auxiliar* para todos os canais sensoreados, de forma a reduzir o consumo de recursos.

Foram implementados os modelos de previsão obtidos pelos quatro melhores algoritmos de AM, os quais eram passíveis de implementação nos nós sensores (executável




Figura 3. Algoritmo de Decisão de Espectro.

gerado inferior ao tamanho de ROM e RAM da plataforma *Iris*), segundo a métrica *Raiz do Erro Médio Quadrático*. Os algoritmos selecionados são listados abaixo:

1. *M5 Rules*: Algoritmo baseado em árvore de decisão com funções de regressão nas folhas, que gera um modelo de previsão sob a forma de uma lista de regras;
2. *REP Tree (Reduced Error Pruning Tree)*: Algoritmo baseado em árvore de decisão, com valores fixos nas folhas;
3. *Additive Regression*: Algoritmo de Meta-Aprendizado que realiza incremento ou decremento no valor de saída de acordo com o resultado obtido pelo algoritmo-base. Nos testes realizados, foi utilizado como algoritmo-base o *Decision Stump*;
4. *Isotonic Regression*: Algoritmo que toma como base o atributo que proporciona o menor erro quadrático, gerando a previsão de acordo com o intervalo de valores no qual se encontra esse atributo.

Como *baseline*, foram implementadas duas soluções. A primeira, chamada *Fixo*, operava em um canal fixo. Já o segundo *baseline*, chamado *RSSI*, é baseado somente em energia, e foi inspirado no algoritmo proposto em [Stabellini and Javed 2010]. Ele coleta 100 amostras de RSSI em cada canal sensoreado, somando-se os valores obtidos. O canal escolhido é aquele que apresenta a menor soma. O funcionamento desta solução é semelhante ao das soluções de decisão, com diferença apenas no critério de escolha do melhor canal e no tempo de sensoreamento.

É importante observar o consumo de energia para execução das soluções não é considerado neste trabalho, uma vez que a medição desta variável de forma experimental, em especial na plataforma *Iris*, é um procedimento complexo. Por isso, o foco principal dos testes práticos foi quantificar o desempenho do enlace sem fio, de forma a verificar a eficácia das soluções propostas em nós sensores reais. A quantificação do consumo de energia é considerada aqui como trabalho futuro.

6.1. Primeiro Teste - Baixa Interferência Externa

Neste teste avaliamos o comportamento da RSSF em um ambiente com baixa interferência de outras redes. Aqui, os *Nós Auxiliares* foram posicionados a aproximadamente seis

metros do *Nó Central*, sendo utilizada como fonte de interferência principal as redes WLAN existentes nas proximidades do ambiente de testes. As soluções de decisão e os *baselines* foram executados em sequência durante 15 minutos cada, sendo realizadas cinco repetições independentes. Os resultados obtidos são apresentados com intervalo de confiança de 95% segundo a distribuição t de Student.

A Tabela 2 apresenta o desempenho obtido com as soluções implementadas, de acordo com taxa de entrega, o total de tentativas de transmissão, o total de colisões e a latência média a cada pacote enviado.

Tabela 2. Resultados de desempenho - primeiro teste.

Solução Implementada	Taxa de Entrega (%)	Tentativas/ Pacote	Colisões/ Pacote	Latência/ Pacote (ms)
REP Tree	96,44 (+/- 5,29)	1,50 (+/- 0,32)	0,37 (+/- 0,41)	6,78 (+/- 1,64)
M5 Rules	97,14 (+/- 2,33)	1,49 (+/- 0,18)	0,27 (+/- 0,18)	6,62 (+/- 0,73)
Additive Regression	98,88 (+/- 1,55)	1,29 (+/- 0,18)	0,14 (+/- 0,07)	5,80 (+/- 0,42)
Isotonic Regression	93,01 (+/- 16,48)	1,54 (+/- 0,82)	0,46 (+/- 0,87)	7,13 (+/- 3,70)
RSSI	97,50 (+/- 2,09)	1,43 (+/- 0,25)	0,25 (+/- 0,15)	6,37 (+/- 0,85)
Fixo	92,13 (+/- 6,15)	2,27 (+/- 0,75)	0,55 (+/- 0,34)	8,78 (+/- 2,04)

Com base nos resultados da Tabela 2, apenas uma das soluções de decisão (*Additive Regression*) se mostrou melhor em relação à solução baseada em canal fixo, para todas as métricas analisadas. Para as outras soluções de decisão, com exceção do *Isotonic Regression*, houve melhora segundo o total de tentativas de transmissão por pacote, ainda em relação à solução baseada em canal fixo. Além do total de tentativas de transmissão, o algoritmo *M5Rules* ainda foi superior ao mesmo *baseline* segundo a latência média por pacote. Nestes casos, foi possível verificar que as soluções propostas foram capazes de detectar variações de comportamento das redes WLAN locais, acarretando na escolha de canais distintos e melhorando o desempenho, ao contrário da solução baseada em canal fixo que esteve sujeita às variações do canal utilizado.

Por outro lado, a desvantagem das soluções de decisão, em relação à solução baseada em RSSI, se deve ao fato de que a fonte de interferência principal era o sinal das redes WLAN locais, que apresentaram poucas mudanças na sua configuração, como a potência de transmissão e o canal de operação, por exemplo. Além disso, essas redes atuaram em baixa magnitude sobre a RSSF. As soluções de decisão têm de forma intrínseca, em seus modelos de previsão, interferências externas de maior magnitude, que acarretam em impactos consideráveis no desempenho da transmissão. Por isso, a aplicação dessas soluções em cenários onde a fonte de interferência é de menor magnitude pode acarretar em erros na previsão em determinados momentos. Nesses casos, a simples leitura do RSSI permite uma conclusão adequada sobre a situação de cada canal.

6.2. Segundo Teste - Alta Interferência Externa

Neste teste avaliamos o comportamento das soluções de decisão em um cenário de coexistência. Os *Nós Auxiliares* foram colocados próximos do *Nó Central*, a uma distância de aproximadamente trinta centímetros. Como fonte de interferência principal, além das redes WLAN localizadas na região, foram colocados dois roteadores próximos da RSSF transmitindo dados entre si, em alta potência e a taxa máxima. Foi utilizado o programa *iperf*, e escolhemos canais próximos a um dos cinco empregados na RSSF. Os roteadores se comunicavam durante 15 segundos, e em seguida trocavam de canal de forma aleatória. Antes de voltar a transmitir, os roteadores aguardavam 10 segundos para que a troca de canal fosse realizada com sucesso. A Tabela 3 apresenta o desempenho médio obtido com as soluções implementadas, em cinco repetições independentes e intervalo de confiança de 95%, segundo a distribuição t de Student.

Tabela 3. Resultados de desempenho - segundo teste.

Solução Implementada	Taxa de Entrega (%)	Tentativas/Pacote	Colisões/Pacote	Latência/Pacote (ms)
REP Tree	93,94 (+/- 4,07)	1,96 (+/- 0,42)	0,26 (+/- 0,19)	7,33 (+/- 1,30)
M5 Rules	92,88 (+/- 2,05)	2,29 (+/- 0,52)	0,26 (+/- 0,08)	7,92 (+/- 0,99)
Additive Regression	92,36 (+/- 1,88)	2,23 (+/- 0,31)	0,30 (+/- 0,09)	7,93 (+/- 0,60)
Isotonic Regression	94,78 (+/- 3,54)	1,88 (+/- 0,59)	0,18 (+/- 0,11)	7,01 (+/- 1,33)
RSSI	89,09 (+/- 3,12)	2,86 (+/- 0,39)	0,35 (+/- 0,04)	9,23 (+/- 0,68)
Fixo	88,55 (+/- 6,91)	2,90 (+/- 0,76)	0,36 (+/- 0,11)	9,34 (+/- 1,60)

Ao contrário do que foi observado no primeiro teste, observamos melhorias consideráveis no desempenho das transmissões, quando comparamos as soluções de decisão com os *baselines* implementados. Verificamos também a importância de se considerar uma gama maior de atributos durante o sensoramento, como realizado nas soluções de decisão, quando variações de comportamento do meio de maior magnitude são observadas. Nesses casos, a simples leitura do RSSI acarreta em escolhas ruins em determinados momentos, uma vez que a relação sinal-ruído varia consideravelmente.

Outro fator apresentado por meio da Tabela 3 é a equivalência de desempenho entre as soluções de decisão, por meio do intervalo de confiança. Apesar das diferenças de desempenho obtidas no Weka, as imprecisões presentes nas medidas e a variação do meio podem explicar o desempenho similar na implementação em uma RSSF real. Isso também mostra que o fator predominante no desempenho prático de um algoritmo de decisão de espectro utilizando AM é a modelagem dos dados da base de treinamento, e não a escolha do melhor algoritmo de AM segundo o desempenho obtido na ferramenta de análise, ou o ajuste fino dos seus parâmetros. Portanto, vemos que para a decisão de espectro em RSSFs é mais interessante selecionar o algoritmo de AM que apresenta menor consumo de recursos computacionais.

7. Conclusões

Tendo em vista a poluição da faixa ISM e as restrições de energia em RSSFs, este trabalho propôs o uso de modelos de previsão gerados por algoritmos de AM, de baixo custo computacional, para a seleção do melhor canal de transmissão. Foram construídos modelos de regressão, com base em dados coletados a partir de plataformas reais. Estes modelos estimam o desempenho das transmissões a curto e longo prazo, permitindo a escolha do canal com melhor qualidade de comunicação para uso na RSSF.

Por meio da abordagem de regressão definiu-se, como valor de saída para os algoritmos de AM, a soma do número de tentativas de transmissão dos pacotes subsequentes, atributo que permitiu aproximar de forma simplificada o tempo necessário para a transmissão bem sucedida de uma sequência de pacotes em um determinado canal. Por meio da média móvel aplicada sobre os valores de entrada, incorporamos o comportamento histórico do canal em um único conjunto de atributos, simplificando as bases de treinamento a serem aplicadas nos algoritmos de AM. Com isso, foi possível criar modelos de previsão mais simples e passíveis de implementação em uma plataforma de RSSFs comercial.

Verificou-se, por meio dos testes práticos, que o uso de AM aumenta o desempenho da RSSF em relação a métodos de canal fixo e de decisão baseada em energia, principalmente em cenários de coexistência, onde a variação no comportamento do meio é de maior magnitude, ou seja, quando o desempenho médio das transmissões e recepções sofre impacto considerável. Isso reitera a aplicação final destinada a esses algoritmos, onde o meio se modifica constantemente, devido à existência de múltiplas redes no espectro.

Como trabalhos futuros, pretende-se refinar o ajuste dos parâmetros dos modelos, adicionando também mecanismos para que o número de canais sensoreados seja reduzido a longo prazo. Além disso, pretende-se investigar métodos de AM semi-supervisionados ou outras formas para a atualização periódica do modelo de previsão.

Agradecimentos

Este trabalho foi realizado com financiamento das agências CAPES, CNPq e FAPEMIG.

Referências

- Akyildiz, I., Lee, W.-Y., and Chowdhury, K. (2009). Spectrum management in cognitive radio ad hoc networks. *Network, IEEE*, 23(4):6–12.
- Baldo, N., Reddy, T. B., Manoj, B. S., Rao, R., and Zorzi, M. (2009). A neural network based cognitive controller for dynamic channel selection. In *ICC*, pages 1–5. IEEE.
- Bantouna, A., Stavroulaki, V., Kritikou, Y., Tsagkaris, K., Demestichas, P., and Moessner, K. (2012). An overview of learning mechanisms for cognitive systems. *EURASIP J. Wireless Comm. and Networking*, 2012:22.
- Correia, L. H. A., Oliveira, E. E., Macedo, D. F., Moura, P., Loureiro, A. A. F., and Silva, J. S. (2012). A framework for cognitive radio wireless sensor networks. In *ISCC*, pages 611–616. IEEE.
- Crossbow (2008). *Iris Datasheet*. Crossbow Technology. 2p.

- FCC (2002). Spectrum policy task force report. Federal Communications Commission, Federal Communications Commission (FCC'02), Washington, DC, USA, November.
- FCC (2005). Notice of proposed rule making and order: Facilitating opportunities for flexible, efficient, and reliable spectrum use employing cognitive radio technologies. ET Docket No. 03-108.
- Felice, M. D., Chowdhury, K. R., Wu, C., Bononi, L., and Meleis, W. (2010). Learning-based spectrum selection in cognitive radio ad hoc networks. In Osipov, E., Kassler, A., Bohnert, T. M., and Masip-Bruin, X., editors, *WWIC*, volume 6074 of *Lecture Notes in Computer Science*, pages 133–145. Springer.
- Hall, M., Frank, E., Holmes, G., Pfahringer, B., Reutemann, P., and Witten, I. H. (2009). The Weka data mining software: an update. *SIGKDD Explor. Newsl.*, 11(1):10–18.
- Hamilton, J. (1994). *Time series analysis*. Princeton Univ. Press, Princeton, NJ.
- Katidiotis, A., Tsagkaris, K., and Demestichas, P. (2010). Performance evaluation of artificial neural network-based learning schemes for cognitive radio systems. *Computers & Electrical Engineering*, 36(3):518–535.
- Masonta, M., Mzyece, M., and Ntlatlapa, N. (2013). Spectrum decision in cognitive radio networks: A survey. *Communications Surveys Tutorials, IEEE*, 15(3):1088–1107.
- Sherman, M., Mody, A., Martinez, R., Rodriguez, C., and Reddy, R. (2008). IEEE standards supporting cognitive radio and networks, dynamic spectrum access, and coexistence. *Communications Magazine, IEEE*, 46(7):72–79.
- Stabellini, L. and Javed, M. (2010). Experimental comparison of dynamic spectrum access techniques for wireless sensor networks. In *Vehicular Technology Conference (VTC 2010-Spring)*, 2010 IEEE 71st, pages 1–5.
- Thilina, K. M., Choi, K. W., Saquib, N., and Hossain, E. (2013). Machine learning techniques for cooperative spectrum sensing in cognitive radio networks. *IEEE Journal on Selected Areas in Communications*, 31(11):2209–2221.
- Tsagkaris, K., Bantouna, A., and Demestichas, P. (2012). Self-organizing maps for advanced learning in cognitive radio systems. *Comput. Electr. Eng.*, 38(4):862–881.
- Tsagkaris, K., Katidiotis, A., and Demestichas, P. (2008). Neural network-based learning schemes for cognitive radio systems. *Computer Communications*, 31(14):3394–3404.
- Unnikrishnan, J. and Veeravalli, V. V. (2010). Algorithms for dynamic spectrum access with learning for cognitive radio. *IEEE Transactions on Signal Processing*, 58(2):750–760.
- Yucek, T. and Arslan, H. (2009). A survey of spectrum sensing algorithms for cognitive radio applications. *Communications Surveys Tutorials, IEEE*, 11(1):116–130.
- Zeng, Y., Liang, Y.-C., Hoang, A. T., and Zhang, R. (2010). A review on spectrum sensing for cognitive radio: challenges and solutions. *EURASIP J. Adv. Signal Process*, 2010:2:2–2:2.
- Zhao, Q. and Swami, A. (2007). A survey of dynamic spectrum access: Signal processing and networking perspectives. In *Acoustics, Speech and Signal Processing, 2007. ICASSP 2007. IEEE International Conference on*, volume 4, pages IV–1349–IV–1352.