

Latência Versus Sobrevivência no Projeto de Centros de Dados Geograficamente Distribuídos

Rodrigo S. Couto^{1,2}, Stefano Secci²,
Miguel Elias M. Campista¹, Luís Henrique M. K. Costa¹ *

¹Universidade Federal do Rio de Janeiro - PEE/COPPE/GTA - DEL/POLI

²Sorbonne Universités, UPMC Univ Paris 06, UMR 7606, LIP6, F-75005, Paris, France

{souza,miguel,luish}@gta.ufrj.br, stefano.secci@lip6.fr

Resumo. Uma tendência atual no projeto de centros de dados é realizar a distribuição geográfica de seus servidores, permitindo uma maior proximidade aos usuários finais e um aumento na capacidade de sobrevivência a falhas. Entretanto, essa solução aumenta a latência de comunicação entre os servidores, causada pela maior distância entre eles. Neste trabalho, aborda-se o compromisso entre latência e sobrevivência em centros de dados geodistribuídos, através da formulação de um problema de otimização. Os resultados obtidos a partir de cenários realistas mostram que, para redes de longa distância, o aumento na latência é significativo apenas no caso de exigências muito fortes de sobrevivência, enquanto que o mesmo é insignificante para exigências moderadas. Por exemplo, o pior caso de latência é menor que 4 ms ao garantir que 80% dos servidores estarão disponíveis após uma falha, em uma rede na qual o pior caso de latência poderia chegar a 33 ms.

Abstract. A current trend in data center design is to geo-distribute its servers, allowing better proximity to the end users and higher survivability. As a shortcoming, this solution increases the latency between servers, caused by a greater distance between them. In this work we tackle the trade-off between survivability and latency in geo-distributed data centers, through the formulation of an optimization problem. The results obtained from realistic scenarios show that, for wide area networks, the latency increase is significant only in case of very strong survivability requirements, whereas it is negligible for moderate requirements. For instance, the worst-case latency is less than 4 ms when guaranteeing that 80% of servers are available after a failure, in a network where the maximum possible latency is 33 ms.

1. Introdução

A computação em nuvem, através da virtualização, pode usufruir da consolidação de servidores de modo a facilitar o gerenciamento da infraestrutura. Por outro lado, a virtualização também possibilita que uma infraestrutura de computação em nuvem possua seus servidores espalhados por diversos sítios, o que pode tornar o centro de dados (DC - *Data Center*) mais próximo do usuário e com maior capacidade de sobrevivência

*Este trabalho foi realizado com recursos da FAPERJ, CNPq e CAPES, e do projeto NU@GE FSN.

a falhas. De fato, a tendência atual em redes de centro de dados é criar uma arquitetura geograficamente distribuída, utilizando alguns poucos sítios de uma rede de longa distância (WAN - *Wide Area Network*), de forma a reduzir a latência percebida pelos usuários finais [Lam et al., 2010]. Além disso, a distribuição geográfica tem a vantagem de permitir uma maior capacidade de sobrevivência a falhas nos sítios e enlaces da rede. As máquinas virtuais (VMs - *Virtual Machines*) alocadas para um determinado usuário podem, dessa forma, estar distribuídas em diversas localidades definidas pelo mecanismo de orquestração de recursos da nuvem [Endo et al., 2011]. Em suma, as principais motivações para a construção de um DC geograficamente distribuído são:

- o aumento da sobrevivência do DC, devido à redução de pontos únicos de falha;
- a redução do atraso para acesso à nuvem do ponto de vista dos usuários finais, devido a uma maior proximidade física do DC com alguns clientes;
- a possibilidade de ampliar o DC mesmo com limitações de capacidade (fornecimento de energia, espaço físico, etc) de um sítio.

Este trabalho foca no primeiro item, que diz respeito à sobrevivência. A sobrevivência de uma infraestrutura de nuvem pode ser aumentada pela distribuição do DC em diversos sítios dentro de uma determinada região geográfica. Quanto maior a região, menor o risco de o DC inteiro ser afetado por um pequeno conjunto de falhas inter-relacionadas como, por exemplo, rompimento de fibras ópticas, quedas de energia ou outros desastres de larga escala [Grover, 2004]. Um exemplo de desastre de larga escala que afetou a comunidade de redes recentemente foi o furacão Sandy em Novembro de 2012: os servidores da *IEEE Communications Society* (web, email, FTP, DNS, etc.) permaneceram completamente desconectados durante 5 dias.

Apesar de a distribuição geográfica possuir efeitos positivos, o projeto desse tipo de DC deve considerar o aumento da latência da comunicação entre seus servidores causado pela maior distância entre eles, além do custo necessário para interconectar sítios em WANs. O último aspecto geralmente depende de vários fatores externos, como a matriz de tráfego do DC e o montante de investimento necessário para sua construção física. O primeiro aspecto, entretanto, é de natureza operacional e possui crescente importância em redes para nuvem, visto que um acréscimo na latência de apenas alguns milissegundos pode causar considerável impacto nos serviços fornecidos [Develder et al., 2012b]. Assim, este trabalho foca no compromisso entre capacidade de sobrevivência e latência de interconexão no projeto de DCs geograficamente distribuídos. Este artigo objetiva responder às seguintes questões:

- O quanto a latência aumenta quando a sobrevivência do centro de dados é melhorada a partir da distribuição geográfica?
- Qual é a influência da capacidade (número de servidores suportados) dos sítios presentes na WAN no compromisso entre latência e sobrevivência?

Para responder essas questões, neste trabalho o projeto de DCs geograficamente distribuídos é modelado como um problema de otimização, possuindo ambos objetivos de sobrevivência e latência. Em um panorama geral, o projeto de DCs geograficamente distribuídos levando em consideração a sobrevivência começou a ser abordado recentemente na literatura [Develder et al., 2012a, Xiao et al., 2014, Habib et al., 2012]. O estado da arte foca no provisionamento de capacidade de fibra óptica entre os sítios. O presente trabalho se diferencia da literatura existente pois aborda a otimização da latência

e da sobrevivência. Assim, preenche uma lacuna no projeto de DCs geograficamente distribuídos, pois foca nesses dois importantes objetivos, ignorando outros fatores como a capacidade da rede. Os resultados de simulação mostram que um nível moderado de sobrevivência consegue ser alcançado em redes em malha WAN, sem comprometer significativamente a latência. Considerando todas as redes analisadas, o problema proposto encontra configurações de DC que, após a falha em um elemento, garantem a sobrevivência de 80% dos servidores, enquanto o aumento de latência em relação ao uso de apenas um sítio (sobrevivência zero) é de 3,6 ms. Por outro lado, o aumento da capacidade de sobrevivência, quando esta já possui um nível muito elevado, acarreta em um alto aumento da latência. Por exemplo, o aumento da sobrevivência de 94% para 95% pode levar a um aumento de 46% na latência.

Este artigo está organizado da seguinte forma. A Seção 2 apresenta o modelo de DC utilizado e os critérios escolhidos. A Seção 3 descreve o problema de otimização proposto, enquanto a Seção 4 apresenta os resultados. A Seção 5 descreve os trabalhos relacionados. Por fim, a Seção 6 conclui o trabalho e identifica direções futuras.

2. Modelo da Rede do Centro de Dados

O modelo da rede utilizado neste trabalho é baseado nas seguintes considerações:

- a menor unidade do DC é um bastidor (*rack*), que é um conjunto de servidores interligados. Em um sítio, os bastidores são interligados por uma topologia intra-sítio como, por exemplo, árvore, Fat-Tree, BCube, DCell, entre outras [Verdi et al., 2010]. Neste trabalho, a sobrevivência da topologia intra-sítio não é considerada, sendo abordada especificamente em [Couto et al., 2012];
- diversos sítios são dispostos em uma determinada região geográfica, nos quais é possível instalar um certo número de bastidores. Um sítio ativo é aquele que possui pelo menos um bastidor instalado e operacional;
- os usuários do DC acessam os serviços através de *gateways* espalhados pela rede;
- o DC é suscetível a falhas de enlace e nó. O nó é um roteador da rede WAN ou um sítio, enquanto o enlace é o meio físico que interconecta os nós, ou que provê acesso aos *gateways*. Cada enlace ou nó pertence a um ou mais grupos de risco compartilhado (SRGs - *Shared Risk Groups*). Um SRG é definido como um grupo de elementos suscetíveis a uma falha comum [Habib et al., 2013]. Por exemplo, um SRG pode ser composto de sítios ligados a uma mesma subestação elétrica.

A Figura 1 ilustra um exemplo do cenário descrito acima. Os sítios, que são interconectados pela WAN, podem hospedar diferentes números de bastidores. Dependendo da topologia da WAN e do número de *gateways*, a rede pode apresentar diferentes níveis de sobrevivência e latência de interconexão, como descrito nos próximos parágrafos.

O modelo descrito acima captura as características de um DC que fornece, principalmente, sua infraestrutura como serviço (IaaS - *Infrastructure as a Service*). Em serviços IaaS, cada cliente possui diversas VMs alocadas no DC. Além disso, o DC gerencia os recursos destinados às VMs, provendo alocação de recursos computacionais, enlaces virtuais, migração de VMs, etc. Um bastidor pode hospedar VMs de diversos clientes, e as VMs de cada cliente podem ser espalhadas por diferentes bastidores e sítios, de forma a aumentar a sobrevivência e a elasticidade.




Figura 1. Exemplo de um DC geodistribuído, composto por diferentes sítios.

Como as VMs de um cliente podem estar geograficamente distribuídas, a sobrevivência de um serviço IaaS pode ser aumentada espalhando seus recursos entre diferentes sítios. Entretanto, como as VMs podem possuir padrões de comunicação entre elas (p.ex., o tráfego interno a um DC pode ser maior que o tráfego oriundo de usuários [Cisco, 2013]), a geodistribuição aumenta a distância entre bastidores e assim pode afetar o desempenho de suas aplicações. Note que este trabalho considera o projeto físico do DC, sendo a alocação de VMs executada por outro algoritmo que considera a infraestrutura do DC construída. Evidentemente, uma infraestrutura na qual o compromisso entre latência e sobrevivência é bem ajustado pode prover uma melhor alocação de VMs. Esse problema é uma preocupação constante em redes para nuvem, especialmente para redes de armazenamento de dados, nas quais um acréscimo de apenas 1 ms no RTT (*Round-Trip Time*) pode representar uma degradação de desempenho considerável [Telikepalli et al., 2004]. A seguir são detalhados os dois objetivos analisados.

2.1. Sobrevivência

Para quantificar a sobrevivência de um DC geodistribuído, utiliza-se neste trabalho o conceito de “sobrevivência de pior caso” definido em [Bodík et al., 2012]. Essa métrica é definida como a fração dos serviços do DC que permanecem operacionais após o pior caso de falha de um SRG. Neste trabalho, esse conceito é utilizado através da definição de “sobrevivência”, como *a menor fração dos bastidores que permanecem disponíveis após a falha de um único SRG, considerando todos os possíveis SRGs*. Essa definição é apropriada para um DC geodistribuído que fornece serviços IaaS, uma vez que possuir menos de 100% dos bastidores disponíveis não significa que o DC perdeu sua capacidade de hospedar VMs. Formalmente, a métrica de sobrevivência pode ser calculada por:

$$s = \min_{f \in \mathcal{F}} \left(\frac{\sum_{k \in \mathcal{A}_f} r_k}{R} \right), \quad (1)$$

onde $\mathcal{F}$ é o conjunto formado por todos os SRGs, R é o número total de bastidores, $\mathcal{A}_f$ é o conjunto das sub-redes acessíveis após a falha do SRG f , e r_k é o número de bastidores na sub-rede acessível $k \in \mathcal{A}_f$. Uma sub-rede acessível é definida como uma parte da rede que está isolada das outras sub-redes, mas possui acesso a pelo menos um gateway. Note que, após uma falha, a rede pode ser particionada em diferentes sub-redes. Se uma

sub-rede não possui acesso a um *gateway*, seus bastidores não estão acessíveis ao mundo externo e então não podem fornecer os serviços IaaS. Por exemplo, se na Figura 1 os enlaces B e D falharem, a rede é dividida em duas sub-redes acessíveis: uma composta pelos sítios 1, 2 e 3, e outra composta pelos sítios 4 e 5. Considerando outro cenário, no qual apenas o enlace A falha, a rede se particiona em duas sub-redes. Uma delas é acessível e composta pelos sítios 1, 3, 4 e 5. A outra, composta pelo sítio 2, não é acessível pois não possui caminhos para um *gateway*. Assim, $\sum_{k \in \mathcal{A}_f} r_k$ na Equação 1 é o número total de bastidores acessíveis após a falha do SRG f .

De acordo com a definição fornecida acima, a métrica de sobrevivência assume valores no intervalo $[0, 1]$. Seu valor mínimo (zero) ocorre quando todos os bastidores são afetados por um mesmo SRG. O valor máximo, por sua vez, ocorre quando a rede tem um certo nível de redundância e o DC é distribuído de forma que nenhuma falha única de SRG pode desconectar um bastidor.

2.2. Latência de interconexão

Neste trabalho assume-se que a latência de interconexão entre os diferentes sítios do DC é afetada principalmente pelo atraso de propagação de seus caminhos. Assim, considera-se que a capacidade de rede é bem provisionada, tornando desprezível o atraso devido a congestionamento e retransmissões nos nós intermediários. Partindo desse pressuposto, é apropriado quantificar a latência de interconexão como *o maior atraso entre pares de sítios ativos, considerando todas as possíveis combinações*. A escolha do valor máximo como métrica de referência é importante para considerar o fato de que VMs alocadas para um determinado cliente podem ser espalhadas por diversos sítios. Assim, a latência máxima corresponde ao pior caso, no qual a consolidação de VMs é realizada independentemente da localização dos sítios ou quando não há capacidade suficiente para realizar uma melhor alocação. Formalmente, a latência de interconexão é definida como:

$$l = \max_{i,j \in \mathcal{D}} (\Delta_{ij} u_i u_j), \quad (2)$$

onde $\mathcal{D}$ é o conjunto de todos os sítios, ativos ou não, Δ_{ij} é o atraso de propagação entre os sítios i e j como definido acima, e u_i é uma variável binária indicando se o sítio i está ativo ou não (em outras palavras, se ele possui pelo menos um bastidor instalado). Considera-se que $\Delta_{ij} = \Delta_{ji}$, uma vez que os caminhos em WANs são geralmente configurados simetricamente. É importante salientar que, neste trabalho, a latência de interconexão é calculada sem considerar situações de falhas, de forma a melhor analisar o compromisso entre latência e sobrevivência. Entretanto, após uma falha, caminhos alternativos podem ser escolhidos. Se esse caminhos possuírem maiores comprimentos, a latência aumenta.

3. Formulação do Problema de Projeto de DCs Geodistribuídos

O problema de projeto de DCs geodistribuídos, formulado neste trabalho com programação linear inteira mista (MILP - *Mixed Integer Linear Programming*), possui o duplo objetivo de maximizar a sobrevivência enquanto minimiza a latência de interconexão. A otimização considera como parâmetros a latência entre os sítios, o número de bastidores suportados em cada sítio, informação sobre SRGs e o número total de bastidores a serem posicionados. A saída do problema fornece a quantidade de bastidores alocados para cada sítio. A Tabela 1 resume as notações utilizadas e seus tipos. Notações

Tabela 1. Notações utilizadas no problema.

Notação	Descrição	Tipo
$\mathcal{D}$	Sítios candidatos	Conjunto
$\mathcal{F}$	SRGs	Conjunto
M_{fi}	Valor binário indicando se o SRG f desconecta da rede o sítio i	Parâmetro
Δ_{ij}	Atraso de propagação (latência) entre os sítios i e j	Parâmetro
L_{max}	Valor máximo de latência entre todos os sítios da rede, ativos ou não.	Parâmetro
R	Número total de bastidores a serem posicionados	Parâmetro
Z_i	Capacidade (máximo número de bastidores suportados) do sítio i	Parâmetro
β	Valor de ajuste da importância da latência em relação à sobrevivência	Parâmetro
s	Sobrevivência do DC	Variável
l	Latência de interconexão do DC	Variável
x_i	Número de bastidores na localização i	Variável
u_i	Valor binário indicando se o sítio i está ativo ($x_i > 0$)	Variável

do tipo conjunto e parâmetro se referem aos dados do problema, enquanto as variáveis são ajustadas pelo algoritmo de otimização. A formulação MILP é apresentada a seguir:

$$\text{maximizar } (1 - \beta)s - \beta \frac{l}{L_{max}} \quad (3)$$

$$\text{sujeito a } \sum_{i \in \mathcal{D}} M_{fi} x_i - sR \geq 0 \quad \forall f \in \mathcal{F}. \quad (4)$$

$$l - \Delta_{ij} u_i - \Delta_{ij} u_j \geq -\Delta_{ij} \quad \forall i, j \in \mathcal{D}, i < j. \quad (5)$$

$$R u_i - x_i \geq 0 \quad \forall i \in \mathcal{D}. \quad (6)$$

$$u_i \leq x_i \quad \forall i \in \mathcal{D}. \quad (7)$$

$$\sum_{i \in \mathcal{D}} x_i = R. \quad (8)$$

$$x_i \leq Z_i \quad \forall i \in \mathcal{D}. \quad (9)$$

$$s \geq 0, \quad l \geq 0, \quad x_i \geq 0 \quad \forall i \in \mathcal{D}. \quad (10)$$

$$s \in \mathbb{R}; \quad l \in \mathbb{R}; \quad u_i \in \{0, 1\}, \quad \forall i \in \mathcal{D}; \quad x_i \in \mathbb{Z}, \quad \forall i \in \mathcal{D}. \quad (11)$$

O objetivo dado pela Equação (3) maximiza a sobrevivência s , como definida na Equação 1, enquanto minimiza a latência l , definida na Equação 2. O compromisso entre latência e sobrevivência é ajustado na Equação (3) pelo fator de escala $0 \leq \beta \leq 1$. Além disso, $L_{max} = \max_{i,j \in \mathcal{D}}(\Delta_{ij})$ normaliza l no intervalo $[0, 1]$. Assim, l e s assumem valores dentro do mesmo intervalo.

Como as Equações 1 e 2 não são lineares, a linearização de cada uma é dada respectivamente pelas Equações (4) e (5). Para a sobrevivência, aplicar a Equação (4) é equivalente a forçar s a ser menor ou igual ao valor definido na Equação 1. Como a Equação (3) tenta aumentar a sobrevivência, s assumirá o valor mais alto, que é dado de fato pela Equação 1. Utilizando o mesmo princípio, a Equação (5) força l a assumir a máxima latência entre dois sítios ativos. Para considerar apenas sítios ativos no cálculo de l , utiliza-se as variáveis binárias $u_i, i \in \mathcal{D}$. Assim, se u_i ou u_j possuírem valor zero

para um determinado par de sítios, a restrição dada pela Equação (5) não será efetiva para esse par. Por exemplo, se $u_i = 0$ e $u_j = 1$, a restrição será $l \geq 0$. Os valores binários u_i são definidos pelas Equações (6) e (7), fazendo $u_i = 0$ se $x_i = 0$ e $u_i = 1$ se $x_i > 0$. A Equação (8) restringe o número total de bastidores do DC (R), enquanto a Equação (9) limita o número de bastidores (x_i) permitido em cada sítio i , respeitando sua capacidade Z_i . Finalmente, as Equações (10) e (11) definem, respectivamente, os limitantes inferiores e o domínio de cada variável.

Para uma dada rede, os parâmetros de latência Δ_{ij} são calculados a partir dos caminhos mais curtos entre os sítios i e j . Os parâmetros binários M_{fi} , para um SRG f , são obtidos pela remoção de todos os elementos (nós e enlaces) que pertencem a esse SRG. Assim, após a remoção, verifica-se para cada SRG quais os sítios possuem acesso aos *gateways*. Obviamente, se um sítio pertence a um determinado SRG, ele já é considerado como desconectado na análise desse SRG.

4. Avaliação do Compromisso entre Latência e Sobrevivência

A análise deste trabalho utiliza topologias de WANs reais de educação e pesquisa, as quais são formadas por diversos pontos de presença (PoP - *Point of Presence*). Considera-se que cada PoP dessas redes é um sítio candidato a hospedar bastidores. Neste trabalho, são adotadas as topologias da RNP (Figura 2(a)) no Brasil, RENATER (Figura 2(b)) na França, e GEANT (Figura 2(c)) na Europa. Cada figura das redes utilizadas mostra seus sítios e *gateways*. Para maior clareza, são especificados nas figuras apenas os nomes de sítios mencionados ao longo do texto. Note que cada topologia cobre uma área de tamanho diferente. Em relação à RENATER, as redes RNP e GEANT cobrem uma área muito maior, com uma superfície mais de 10 vezes maior que a França metropolitana. Entretanto, a rede francesa possui mais nós que a RNP. Por fim, a GEANT possui um número de sítios próximo à RENATER.

O problema MILP é resolvido neste trabalho utilizando a ferramenta IBM ILOG CPLEX 12.5.1. Além disso, cada nó ou enlace da rede é um SRG. Dessa forma, considera-se o modelo de falha única (*single failure model*) [Habib et al., 2013]. A distância de um enlace é estimada como o comprimento de uma linha reta entre os centros das duas cidades que hospedam os sítios. Assim, o atraso de propagação é diretamente proporcional à distância, e utiliza-se uma velocidade de propagação de 2×10^8 m/s, comumente adotada para análise de redes ópticas [Ramaswami et al., 2009]. Para cálculo dos parâmetros da rede, utiliza-se a ferramenta de análise de grafos NetworkX.

O número total de bastidores considerado nesta avaliação é $R = 1024$. Esse valor foi arbitrariamente escolhido, já que a alocação de bastidores depende da relação entre R e a capacidade Z_i de cada sítio i , e não de valores absolutos. Além disso, a análise é realizada para diferentes valores de Z_i considerando, para simplificar, que todos os sítios possuem a mesma capacidade. Por fim, o compromisso entre sobrevivência e latência é analisado variando o parâmetro β da Equação (3) de 0 até 1 em passos de 0,05. Considerando todas as rodadas (isto é, todas as escolhas de β para todas as redes e valores de Z_i), em 89% delas o problema de otimização encontrou a solução em menos de 30 s em um PC com processador i7-3930K, e em 97% das rodadas a solução foi encontrada em menos de 5 min. Apenas 1 rodada (0,4% do número de rodadas) durou mais de 30 min, possuindo a duração de 117 min. Note que a complexidade dos métodos de




Figura 2. Topologias de redes de ensino e pesquisa consideradas na avaliação.

otimização utilizados não apresenta barreiras para o cenário considerado, que geralmente possui poucas variáveis (p.ex. dezenas de sítios e de SRGs).

As Figuras 3 e 4 mostram, respectivamente, os valores de sobrevivência e latência obtidos para todas as redes analisadas. Cada curva representa uma capacidade Z_i diferente (64, 128, 256, ou 1024), atribuída a todos os sítios. Como o número total de bastidores é constante, a redução da capacidade dos sítios força o problema a encontrar soluções com mais sítios ativos. Por exemplo, fixando a capacidade em 64, impõe-se a utilização de pelo menos $\frac{1024}{64} = 16$ sítios ativos. Por outro lado, fixando a capacidade em 1024 é o mesmo que desconsiderar a capacidade no problema, visto que um sítio poderá hospedar todos os bastidores. Como esperado, os resultados mostram que o aumento de β compromete a sobrevivência enquanto melhora a latência (Figura 4). Além disso, ao diminuir a capacidade dos sítios o problema de otimização possui menos escolhas de alocação de bastidores, mantendo as métricas constantes para uma faixa de β mais larga.

Como mostrado também nas Figuras 3 e 4, a capacidade dos sítios influencia os valores mínimos possíveis de sobrevivência e latência (valores alcançados para $\beta = 1$).




Figura 3. Sobrevivência em um DC com 1024 bastidores.




Figura 4. Latência em um DC com 1024 bastidores.

Essa influência é consequência do número mínimo de sítios ativos imposto pela capacidade, como visto mais adiante. Finalmente, pode-se observar que os valores mais baixos

de latência são alcançados pela rede RENATER, visto que ela cobre uma área menor que a RNP e a GEANT. Consequentemente, os caminhos na RENATER tendem a ser mais curtos se comparados com as outras duas redes.

Para melhor analisar o compromisso abordado neste trabalho, a Figura 5 mostra, para todas as redes, a latência normalizada em relação à sobrevivência. A latência normalizada é simplesmente $\frac{l}{L_{max}}$. L_{max} é o maior valor possível de latência entre dois sítios, como definido anteriormente, e seu valor para cada rede está indicado na legendas dos gráficos. Cada ponto da Figura 5 é obtido plotando o valor de latência e o valor de sobrevivência alcançados para um mesmo β . Os resultados mostram um comportamento similar para todas as topologias: para valores altos de sobrevivência, um pequeno ganho na sobrevivência representa um alto acréscimo na latência. Isso ocorre pois, em todas as redes consideradas, sempre existem alguns nós com caminhos significativamente longos entre si. Assim, quando os requisitos de sobrevivência aumentam (i.e. β diminui), esses nós são escolhidos devido à falta de opções. Consequentemente, uma pequena melhora na sobrevivência acarreta em um severo acréscimo na latência. Como exemplo, para uma capacidade de 1024 e $\beta = 0$ na GEANT, entre os sítios ativos encontram-se os de Nicósia (Chipre) e Jerusalém (Israel), cada um hospedando 34 bastidores. Apesar de esses sítios estarem próximos geograficamente, o caminho na rede entre eles é bastante longo. O tráfego entre eles deve passar por um nó em Frankfurt (Alemanha), percorrendo no total uma distância de 5.581 km, resultando em uma latência de 27,9 ms. Quando o valor de β é incrementado para 0,05, o que representa uma diminuição pequena da importância da sobrevivência, o pior caso de latência passa a ser o caminho entre Riga (Letônia) e Bucareste (Romênia). Esse caminho possui um comprimento de 2.267 km, possuindo uma latência de 11,33 ms. Note então que a latência sofre uma alta redução (46%) para uma pequena variação de β , como visto na Figura 4(c). Entretanto, a consequente redução de sobrevivência é de apenas 2%, como visto na Figura 3(c).

Inversamente ao exposto acima, outro comportamento é observado para todas as redes: para valores mais baixos de sobrevivência, um aumento significativo da sobrevivência resulta em uma piora insignificante na latência. Como exemplo, a Figura 5(b) mostra que variando a sobrevivência de 0,5 para 0,75, com uma capacidade de 256 bastidores na RENATER, a latência normalizada possui um aumento desprezível de 0,06 ($l = 0,42ms$) para 0,08 ($l = 0,58ms$). Esse comportamento mostra que o DC pode atingir valores satisfatórios de sobrevivência com um acréscimo muito baixo na latência. Considerando todas as redes, o maior aumento na latência ao melhorar a sobrevivência de 0 para 0,5 é de 0,70 ms, que ocorre na rede RNP. Nessa mesma rede, uma sobrevivência de 0,8 é alcançada com um acréscimo de apenas 3,6 ms em relação ao caso de um único sítio ativo. Os baixos valores de latência alcançados, mesmo com valores de sobrevivência satisfatórios, são consequência de uma característica comum a todas as redes: todas as topologias consideradas possuem uma alta densidade de sítios em uma determinada região e eles não desconectam simultaneamente após a falha de qualquer SRG. Como exemplo, podem ser citados os sítios no Nordeste do Brasil (Natal, Campina Grande, Recife, etc.) e no Sul da França (Toulon, os dois sítios em Marselha, etc.). Assim, o DC pode ser espalhado nessas regiões sem um aumento significativo da latência.

Em suma, se a exigência de sobrevivência do DC não for muito alta, é fácil assegurar valores moderados de sobrevivência sem causar um aumento significativo da latência.




Figura 5. Latência versus sobrevivência.

Entretanto, aumentar a sobrevivência para valores próximos de 1 produz um aumento grande da latência entre os bastidores, podendo impactar o desempenho de aplicações com exigências mais estritas de latência. É importante salientar que essas conclusões são válidas para todas as topologias consideradas, e os indícios apontam que são independentes da área geográfica atendida pela WAN e do número de nós e enlaces.

A Figura 5 também mostra que, ao diminuir a capacidade dos sítios, a latência mínima possível mantém-se a mesma, ou aumenta. No último caso, isso ocorre apenas para o mínimo valor de sobrevivência ($\beta = 1$) e, após isso, os pontos do experimento encontram-se na mesma curva na qual a capacidade é desconsiderada (capacidade de 1024). Esse comportamento ocorre, pois a limitação da capacidade reduz as possibilidades de alocação de bastidores, podendo inviabilizar soluções melhores. Para $\beta = 1$, o problema não considera a sobrevivência e tenta melhorar a latência o quanto possível. Entretanto, como a gama de soluções possíveis é limitada pelo número mínimo de sítios (p.ex. 16 para uma capacidade de 64), o problema tende a escolher sítios que estejam mais próximos geograficamente de forma a melhorar a latência. Esses sítios mais próximos tendem a estar no mesmo SRG. Por exemplo, considerando a RNP com uma capacidade de 64, a redução ocorre pois a escolha ótima é alocar 2 sítios afetados pelo mesmo SRG: Goiânia e Palmas. Para a RNP isso ocorre apenas para a capacidade de 64, enquanto para a RENATER esse comportamento começa a partir de uma capacidade de 256. Para a GEANT, todos os pontos encontram-se na mesma curva, independente da capacidade.

A Figura 6 mostra a métrica de sobrevivência em função do número de sítios ativos, para o mesmo experimento realizado anteriormente. Apesar de a otimização não controlar diretamente essa métrica, o acréscimo da sobrevivência é influenciado pela




Figura 6. Sobrevivência em função do número de sítios ativos.

distribuição do DC. Por sua vez, a distribuição do DC é influenciada pelo número de sítios ativos. Quanto mais sítios são usados, os bastidores do DC tendem a pertencer a mais SRGs e assim a sobrevivência tende a aumentar. Os resultados mostram que a sobrevivência cresce de forma logarítmica com o número de sítios ativos. Isso significa que o aumento do número de sítios ativos não melhora significativamente a sobrevivência quando o DC se torna amplamente distribuído em diferentes regiões. Além disso, os resultados mostram que a rede pode possuir diferentes níveis de sobrevivência para um mesmo número de sítios ativos. Esse comportamento é observado apenas para o valor mínimo de sítios ativos impostos pela capacidade (p.ex., $\frac{1024}{256} = 4$ para uma capacidade de 256). A razão é a mesma daquela observada na Figura 5, na qual ao fazer $\beta = 1$ obtém-se uma alta redução de sobrevivência e uma pequena melhora na latência.

5. Trabalhos Relacionados

O projeto de DCs geodistribuídos possui diversos fatores em comum com o projeto de redes para computação em grade. Essas redes também podem exigir uma infraestrutura geograficamente espalhada para executar cálculos distribuídos como, por exemplo, em aplicações de e-ciência. [Develder et al., 2011] formula um problema de otimização para o projeto de redes para computação em grade considerando a sobrevivência, que pode também ser utilizado para DCs, como mostrado pelos autores em [Develder et al., 2012a]. O cenário de [Develder et al., 2011] consiste em diversas fontes que submetem tarefas para nós de destino. Os nós de destino possuem servidores, e todos os nós (fontes e destinos) são interconectados por uma rede óptica. Assim, o trabalho propõe um problema de otimização que determina quais nós da rede executarão cada tarefa, as rotas ópticas entre as fontes e destinos e a capacidade, em comprimen-

tos de onda, alocada para cada rota. O objetivo do problema é minimizar a capacidade necessária nos servidores e na rede. Para prover sobrevivência, o problema escolhe destinos e rotas alternativos para cada serviço. Problemas similares são propostos em [Xiao et al., 2014] e [Habib et al., 2012] para DCs. Uma característica comum dos trabalhos mencionados é o fato de a função objetivo do problema de otimização minimizar o custo para prover capacidade de rede e de servidores, deixando a sobrevivência como uma restrição. Além disso, esses trabalhos assumem que todos os serviços do DC e suas respectivas demandas são conhecidos no momento de sua construção. O atraso de propagação devido à distribuição geográfica é considerado apenas em [Xiao et al., 2014], porém esse trabalho não analisa o compromisso entre latência e sobrevivência.

O presente trabalho é diferente do atual estado da arte pois a função objetivo do problema de otimização consiste em métricas de latência e sobrevivência, de forma a explorar o compromisso entre esses fatores. Assim, este trabalho isola essas duas métricas, ignorando outros fatores como o custo (p.ex., a capacidade utilizada pelas rotas e o custo para ativar um sítio). Além disso, as conclusões apresentadas aqui são independentes dos serviços suportados pelo DC e da matriz de tráfego gerada por esses serviços. O custo e a matriz de tráfego são, sem dúvida, fatores importantes no projeto de um DC. Entretanto, esses fatores devem ser ignorados em uma primeira análise, para melhor observar o compromisso entre latência e sobrevivência.

6. Conclusões

Neste trabalho analisou-se o compromisso entre latência e sobrevivência no projeto de centros de dados (DC) geodistribuídos em redes de longa distância (WANs). As simulações realizadas em cenários diversos e realísticos mostram que quando a exigência de sobrevivência do DC é muito alta, uma pequena melhora na sobrevivência acarreta em um aumento significativo na latência. Esse comportamento é essencialmente devido à presença de caminhos muito longos para alguns poucos pares de sítios. Em níveis altos de sobrevivência, os resultados mostram que um aumento de 2% (de 0,94 para 0,96) na sobrevivência pode aumentar a latência em 46% (de 11,33 ms para 27,9 ms). Por outro lado, quando a exigência de sobrevivência permanece moderada, esta pode ser consideravelmente melhorada com um baixo acréscimo na latência. Considerando todas as redes analisadas, o máximo aumento na latência é de 0,7 ms quando a sobrevivência é melhorada de 0 para 0,5. Além disso, observa-se uma máxima latência de 3,6 ms quando a sobrevivência é 0,8. Por fim, os resultados mostram que a diminuição da capacidade dos sítios provoca um aumento nos menores valores possíveis de sobrevivência e latência (i.e. métricas alcançadas para $\beta = 1$). Apesar disso, o compromisso entre latência e sobrevivência não mudam significativamente para diferentes capacidades dos sítios.

Os cenários atuais de infraestrutura como serviço (IaaS) apresentam geralmente centros de dados monolíticos com um único ou um número baixo de sítios, provendo baixos níveis de sobrevivência a falhas, como frequentemente observado por usuários na Internet. Este estudo sugere que, considerando um cenário realístico de projeto de DCs em WANs, aumentar a sobrevivência a um nível moderado apresenta pouco ou nenhum impacto no desempenho de um IaaS.

Como trabalho futuro, pretende-se estender o estudo para incluir também falhas de larga escala modelando, por exemplo, grandes catástrofes naturais. Esse tipo de falha

pode afetar diversos sítios em uma grande área geográfica. Outra direção futura é adicionar outros objetivos ou restrições ao problema de otimização, como o custo da rede e a latência do ponto de vista dos usuários.

Referências

- Bodík, P., Menache, I., Chowdhury, M., Mani, P., Maltz, D. A. e Stoica, I. (2012). Surviving failures in bandwidth-constrained datacenters. Em *ACM SIGCOMM*, p. 431–442.
- Cisco (2013). Cisco global cloud index: Forecast and methodology, 2012–2017.
- Couto, R. S., Campista, M. E. M. e Costa, L. H. M. K. (2012). A reliability analysis of datacenter topologies. Em *IEEE GLOBECOM*, p. 1890—1895.
- Develder, C., Buysse, J., De Leenheer, M., Jaumard, B. e Dhoedt, B. (2012a). Resilient network dimensioning for optical grid/clouds using relocation. Em *IEEE ICC*, p. 6262–6267.
- Develder, C., Buysse, J., Shaikh, A., Jaumard, B., De Leenheer, M. e Dhoedt, B. (2011). Survivable optical grid dimensioning: anycast routing with server and network failure protection. Em *IEEE ICC*, p. 1–5.
- Develder, C., De Leenheer, M., Dhoedt, B., Pickavet, M., Colle, D., De Turck, F. e De-meester, P. (2012b). Optical networks for grid and cloud computing applications. *Proceedings of the IEEE*, 100(5):1149–1167.
- Endo, P. T., de Almeida Palhares, A. V., Pereira, N. N., Gonçalves, G. E., Sadok, D., Kelner, J., Melander, B. e Mangs, J. (2011). Resource allocation for distributed cloud: concepts and research challenges. *IEEE Network*, 25(4):42–46.
- Grover, W. D. (2004). *Mesh-based survivable transport networks: options and strategies for optical, MPLS, SONET and ATM networking*. Prentice Hall Professional, primeira edição.
- Habib, M. F., Tornatore, M., De Leenheer, M., Dikbiyik, F. e Mukherjee, B. (2012). Design of disaster-resilient optical datacenter networks. *Journal of Lightwave Technology*, 30(16):2563–2573.
- Habib, M. F., Tornatore, M., Dikbiyik, F. e Mukherjee, B. (2013). Disaster survivability in optical communication networks. *Computer Communications*, 36(6):630 – 644.
- Lam, C., Liu, H., Koley, B., Zhao, X., Kamalov, V. e Gill, V. (2010). Fiber optic communication technologies: What’s needed for datacenter network operations. *IEEE Communications Magazine*, 48(7):32–39.
- Ramaswami, R., Sivarajan, K. e Sasaki, G. (2009). *Optical networks: a practical perspective*. Morgan Kaufmann, terceira edição.
- Telikepalli, R., Drwiega, T. e Yan, J. (2004). Storage area network extension solutions and their performance assessment. *IEEE Communications Magazine*, 42(4):56–63.
- Verdi, F., Rothenberg, C., Pasquini, R. e Magalhães, M. (2010). Novas arquiteturas de data center para cloud computing. Em *Minicursos do XXVIII SBRC*, p. 103–152.
- Xiao, J., Wen, H., Wu, B., Jiang, X., Ho, P.-H. e Zhang, L. (2014). Joint design on DCN placement and survivable cloud service provision over all-optical mesh networks. *IEEE Transactions on Communications*, 62(1):235–245.