

ResiDI: Um Sistema de Decisão Inteligente para Infraestruturas Residenciais via Sensores e Atuadores Sem Fio

Geraldo P. R. Filho¹, Jó Ueyama¹, Bruno S. Faical¹
Daniel L. Guidoni², Leandro A. Villas³

¹Instituto de Ciência Matemáticas e de Computação – ICMC
Universidade de São Paulo – USP
São Carlos – SP – Brasil

²Universidade Federal de São João del-Rei – UFSJ
São João del-Rei – MG – Brasil

³Instituto de Computação – Universidade Estadual de Campinas – UNICAMP
Campinas – SP – Brasil

{geraldop, joueyama, bsfaical}@icmc.usp.br
guidoni@ufsj.edu.br, leandro@ic.unicamp.br

Abstract. *This work proposes an intelligent decision system for a residential infrastructure based on wireless sensors and actuator networks, called ResiDI. In order to achieve this, the proposal is based on the development of a neural network that aims to increase the accuracy in the decision-making, and a temporal correlation mechanism that aims to reduce the energy consumption of the network. When compared with an approach adopted in the literature, both simulated and real results show that ResiDI reduces the energy consumption of its network, while maintaining a degree of accuracy in the decision-making.*

Resumo. *Este trabalho propõe um sistema de decisão inteligente para infraestruturas residenciais usando uma rede de sensores e atuadores sem fio, nomeado como ResiDI. Para isso, a proposta baseia-se no desenvolvimento de uma rede neural que visa aumentar a precisão nas tomadas de decisões, e um mecanismo de correlação temporal que visa reduzir o consumo de energia da rede. Quando comparado com uma abordagem da literatura, os resultados simulados e reais mostram que o ResiDI reduz o consumo de energia da sua rede, enquanto mantém uma precisão nas tomadas de decisão.*

1. Introdução

Nos últimos anos, um dos principais desafios globais está relacionado com a eficiência energética, sendo o desperdício de energia um dos fatores a ser destacado. Isto ocorre, devido a crescente demanda de energia por parte das indústrias, comércios e residências, as quais utilizam a energia de maneira não controlada. Nesse cenário, o setor residencial obteve o maior crescimento, cerca de 6,9% em relação a 2012 [EPE 2013]. Esse aumento, muitas vezes desordenado, atribuído à expansão do uso dos eletrodomésticos, ocasiona um desperdício significativo no uso da energia.

O Sistema de Automação Residencial (HAS, do inglês *Home Automation System*), integrado no sistema elétrico de potência, também conhecido como *smart home*, é um dos

caminhos para prover soluções relacionadas com a eficiência energética. O HAS permite o gerenciamento dos recursos habitacionais, tais como iluminação, aquecimento, ar condicionado e aparelhos eletrônicos, levando em consideração grandezas físicas do ambiente (temperatura, presença e umidade, por exemplo) para monitorar, bem como atuar de forma inteligente em benefício dos moradores [Baraka et al. 2013, Lee et al. 2014].

Apesar dos avanços conquistados nessa área, os HASs são fortemente dependentes da rede interna, visto que esta é a base de uma casa inteligente. Há vários trabalhos [Lee and Hong 2009, Ramlee et al. 2013] que usam infraestruturas cabeadas, juntamente com sensores analógicos, para sensoriar o ambiente. No entanto, tais infraestruturas são: (i) dependentes do ambiente; (ii) custosas devido a instalação da fiação que muitas vezes são escassas; e (iii) utilizam, por exemplo, um equipamento centralizador para gerenciar as informações da rede. Além disso, a falta de uma infraestrutura padronizada para atender as necessidades do usuário, representa um dos desafios a serem considerados na implantação de uma HAS.

A Rede de Sensores Sem Fio (RSSF) [Akyildiz et al. 2002] surge como uma alternativa promissora para superar as limitações mencionadas anteriormente, permitindo flexibilidade na remoção e/ou adição de componentes, facilidade em integrá-la dentro de outros *backbones*, além de ser escalável, colaborativa e de baixo custo. No entanto, as RSSFs são formadas por dispositivos passíveis (nós sensores), limitados em recursos (memória, bateria e processamento, por exemplo), que apenas coletam e disseminam dados, sem atuarem no ambiente. Nesse sentido, a combinação de sensores e de atuadores em uma mesma rede, nomeado como Redes de Sensores e Atuadores Sem Fio (RSASF) [Akyildiz and Kasimoglu 2004], aumenta o potencial das RSSFs no HAS, uma vez que as RSASFs possuem maior poder de processamento, comunicação e energia, podendo atuar no ambiente físico mediante os dados provenientes dos sensores.

Neste contexto, as RSASFs fornecem uma infraestrutura moderna e ubíqua para uma casa inteligente. Entretanto, o uso das RSASFs para monitorar e atuar como infraestrutura de controle dentro do contexto de uma HAS provoca novos desafios [Lee and Hong 2009, Han and Lim 2010, Soares et al. 2012, Ramlee et al. 2013, Wang et al. 2013, Baraka et al. 2013, Filho et al. 2013, Filho et al. 2014, de Farias et al. 2014, Lee et al. 2014], dos quais dois se destacam, a saber: (i) o desenvolvimento de soluções computacionais inteligentes, para que o processo de tomada de decisão seja realizado de maneira distribuída dentro da própria RSASF; e (ii) o prolongamento da vida útil dos nós da RSASF, mantendo um *trade-off* entre precisão das decisões e consumo de energia dos sensores, sem que haja perdas de confiabilidade na infraestrutura distribuída.

Para superar os desafios mencionados anteriormente, este trabalho propõe o ResiDI (*Residential Distributed Infrastructure*), um sistema de decisão inteligente para uma infraestrutura residencial distribuída usando sensores e atuadores sem fio. Para isso, a proposta baseia-se no desenvolvimento de uma rede neural para aumentar a precisão nas tomadas de decisões, bem como um mecanismo de correlação temporal para reduzir o consumo de energia da rede. Desta forma, o ResiDI permite a formação de uma RSASF para sensoriar e atuar no processo de tomada de decisão de forma autônoma dentro da própria rede, sendo ciente no tempo de vida útil dos nós da infraestrutura e na precisão das tomadas de decisões.

Os resultados dos experimentos, evidenciam o desempenho satisfatório do ResiDI quando comparado com o CONDE [Soares et al. 2012], superando-o em diferentes cenários para as avaliações realizadas.

O restante deste artigo está organizado da seguinte forma. A Seção 2 apresenta os trabalhos relacionados. A Seção 3 descreve estratégia utilizada para o desenvolvimento do ResiDI. A Seção 4 apresenta os resultados obtidos da avaliação de desempenho. Finalmente, a Seção 5 apresenta as conclusões e os trabalhos futuros.

2. Trabalhos Relacionados

Diversos trabalhos encontrados na literatura [Lee and Hong 2009, Han and Lim 2010, Soares et al. 2012, Baraka et al. 2013, Ramlee et al. 2013, Wang et al. 2013, Filho et al. 2013, Filho et al. 2014, de Farias et al. 2014, Lee et al. 2014] têm tratado do uso de sensores nos sistemas residências. Contudo, apesar dos avanços conquistados, ainda há vários problemas nessa área. Por exemplo, a inexistência de uma solução baseada em rede neural juntamente com correlação temporal, incorporando-as no processo de tomada de decisão dentro da rede.

Os trabalhos descritos em [Han and Lim 2010, Baraka et al. 2013, Ramlee et al. 2013] propõem sistemas específicos para apenas uma aplicação como iluminação ou ar-condicionado, por exemplo. Particularmente em [Ramlee et al. 2013], é proposto um sistema de automação residencial de baixo custo voltado para os eletrodomésticos. Para tanto, uma placa de controle principal (nó *sink*) é desenvolvida para gerenciar a comunicação entre os eletrodomésticos e os moradores. No entanto, as principais limitações desses tipos de sistemas são a sua centralização e não correlacionar os dados coletados.

Embora haja trabalhos sobre a composição de mais de uma aplicação, tais trabalhos utilizam sensores apenas como infraestrutura para a coleta de dados, como propostos por [Wang et al. 2013, Filho et al. 2014]. Por isso, essas soluções não aproveitam os benefícios que uma RSASF possui para a tomada de decisão. Em [Lee et al. 2014], é proposto um sistema sensível ao contexto para ambientes residências ubíquos. Para isso, utilizou-se dados providos dos sensores para analisar padrões e gerar regras, inferindo assim as preferências dos moradores. Tal sistema diferencia-se deste trabalho por depender de *feedbacks* dos moradores para a tomada de decisão, ferindo um dos princípios da computação ubíqua que defende as interfaces invisíveis.

Outros trabalhos relacionados que merecem destaques são propostos por [Soares et al. 2012, de Farias et al. 2014]. Convém salientar que o trabalho apresentado por [de Farias et al. 2014], é um complemento do trabalho realizando anteriormente em [Soares et al. 2012]. Em ambos os trabalhos, os autores propõem um sistema de CONTrole e DEcisão (CONDE) com o intuito de automatizar o processo de tomada de decisão em um ambiente usando uma RSASF. O CONDE é desenvolvido para coletar e manipular os dados sensoreados, processando-os dentro da própria infraestrutura. A diferença do [de Farias et al. 2014] para o [Soares et al. 2012], é a proposta de um subsistema de inferência de nível múltiplo para proporcionar um consenso no processo de apoio à tomada de decisão. Contudo, deve-se ressaltar que ambos os trabalhos possuem duas limitações, a saber: (i) regras pré-estabelecidas para a tomada de decisão; e (ii) não há uma abordagem que explore a correlação para a redução do consumo de energia da

infraestrutura. Por esses motivos, a seguir será apresentado o ResiDI.

3. Sistema de Decisão Inteligente para Infraestruturas Residenciais

Nesta seção é apresentado o ResiDI, uma proposta para a tomada de decisão em uma infraestrutura residencial distribuída usando sensores e atuadores sem fio. Para tanto, uma solução baseada em rede neural para atuar no processo de tomada de decisão, bem como um mecanismo de correlação temporal para maximizar a eficiência energética da infraestrutura foram desenvolvidas. Com isto, o principal objetivo do ResiDI é manter uma precisão na tomada de decisão, e prover uma redução no consumo de energia nos nós da rede. Para alcançar tais objetivos, considerou-se os seguintes papéis:

- *Nó Sensor* (Rótulo 1, Figura 1). Coleta dados de diferentes grandezas físicas do ambiente (por exemplo, temperatura e presença), transmitindo-os para o nó decisor (linha tracejada, Figura 1). Além disso, é executado um mecanismo de correlação temporal ponderada.
- *Nó Decisor* (Rótulo 2, Figura 1). Recebe os dados coletados dos nós sensores, processa tais dados para a tomada de decisão, e encaminha a decisão para o nó atuador (linha contínua, Figura 1).
- *Nó Atuador* (Rótulo 3, Figura 1). Recebe a ação a ser realizada do nó decisor e atua na aplicação desejada. Além disso, o nó atuador pode atuar em diferentes aplicações (por exemplo, iluminação, ar-condicionado e aparelhos eletrônicos), as quais estão em seu alcance.
- *Nó Sink* (Rótulo 4, Figura 1). Responsável por realizar a comunicação externa e possíveis atualizações vindas fora da rede. Nesse cenário, o nó *sink* pode permanecer ativo por mais tempo, e por essa conveniência a sua implantação pode ser próximo de um roteador ou uma tomada, tendo como fonte alternativa de energia o *Power over Ethernet* ou um carregador, respectivamente.




Figura 1. Exemplo de funcionamento do ResiDI.

A Figura 1 sumariza a proposta do ResiDI, o qual é baseado em sensores da plataforma MicaZ¹ que representa os nós sensores, decisores e atuadores; bem como o Raspberry Pi² que representa o nó *sink*. Como já é constatado que acumular mais de um papel em um nó é energeticamente ineficiente [Souza and Mateus 2006, Soares et al. 2012], as funcionalidades do ResiDI foram distribuídas em papéis. Com essa abordagem, além de deixar a infraestrutura com alta disponibilidade para os nós que a compõem, também reduz o tráfego da rede e maximiza a sua eficiência na entrega dos dados. Além disso, caso ocorra uma falha no nó atuador, o nó decisor mantém-se ativo, escolhendo outro nó atuador para finalizar a tarefa, sendo possível acionar, caso necessário, mais de um nó atuador usando apenas um nó decisor. Por outro lado, ao considerar uma infraestrutura sem divisão de papéis, com um único nó para decidir e atuar, por exemplo, caso ocorra uma falha no componente de atuação a tarefa não é finalizada com êxito. Ainda nesse cenário, para realizar uma tomada de decisão adequada, os nós necessitariam compartilhar dados entre si [Soares et al. 2012]. Com isto, além de aumentar o tráfego na rede, haveria transmissões de ações repetidas para os atuadores. Portanto, haveria a necessidade de utilizar algoritmos de sincronização, o que deixaria a proposta complexa e inviável na prática. Para o desenvolvimento do ResiDI, algumas etapas foram necessárias: (i) a infraestrutura, Subseção 3.1; e (ii) a tomada de decisão, Subseção 3.2. Tais etapas são apresentadas a seguir.

3.1. Infraestrutura do ResiDI

Esta seção apresenta como foi definida a infraestrutura do ResiDI. Para tanto, dividiu-se a solução desta etapa em três fases. Na primeira, os nós cooperam entre si para a construção da tabela de roteamento. Na segunda, os dados são sensoreados e a correlação temporal é aplicada. Finalmente, na terceira, a tomada de decisão é transmitida para o nó atuador.

3.1.1. Construção da Tabela de Roteamento

A tabela de roteamento é construída contendo as distâncias dos nós sensores vizinhos. A obtenção da distância como métrica para encaminhar as mensagens é realizada mediante a intensidade do sinal recebido (RSSI). A utilização do RSSI é preferível em RSASF por ser uma técnica simples, eficaz e por não necessitar de *hardware* extra. Ainda, a técnica do RSSI como métrica de distância vem sendo aplicada em diversos cenários, que vão desde ambientes *indoor* [Pessin et al. 2014] até *outdoor* [Lima et al. 2013].

Para facilitar o entendimento da técnica, a Figura 2 ilustra como é estimada a distância entre os nós. Para isso, quando um nó recebe uma mensagem, a força do sinal captada por ele é utilizada para estimar a distância do nó que transmitiu a mensagem. Assim, por exemplo, quanto mais próximo o nó sensor está do nó decisor, maior é a potência do sinal para o nó sensor e consequentemente menor é a sua distância. Desta forma, os nós sensores armazenam em sua tabela de roteamento as distâncias dos nós decisores para encaminhar os dados sensoreados. Já os nós decisores armazenam as distâncias dos nós atuadores. Em razão disso, os nós comunicam-se em um único salto. Deve-se ressaltar que a propagação de sinal foi baseada no modelo *Two-Ray Ground*. Tal modelo além de assumir que o sinal transmitido não é recebido por apenas um caminho, considera a possibilidade de reflexões.

¹Micaz, <http://www.memsic.com/wireless-sensor-networks/>

²Raspberry Pi, <http://www.raspberrypi.org/>




Figura 2. Potência do sinal em dBm decrescendo à medida que a intensidade do sinal se propaga na rede, tornando a distância inversamente proporcional a intensidade do sinal.

3.1.2. Comunicação do nó Sensor com o nó Decisor

Para sensorar os dados do ambiente e transmiti-los para o nó decisor com maior eficiência energética, foi necessário propor um mecanismo de correlação temporal ponderada, apresentado no Algoritmo 1. Por correlação temporal, entende-se que os dados coletados são correlacionados ao tempo, comparando o padrão de leitura atual com as leituras anteriores para transmitir, ou não, o dado coletado. Desta forma, é possível reduzir o consumo de energia da rede, eliminando transmissões desnecessárias. Para tanto, esse processo ocorre depois dos nós sensores descobrirem os nós decisores mediante o RSSI, descrito na Seção 3.1.1. Após a descoberta, cada nó n mantém um conjunto S das leituras reportadas R_{old} , $\{R_{old}, old \in S\}$, em seu *buffer* (Linha 1, Algoritmo 1). Com o intuito de oferecer prioridade aos dados de leitura mais novos, atribui-se um conjunto de pesos $P(w) = \{1, 2, 3, \dots, w\}$ aos índices mais recentes de acordo com o tamanho do conjunto S (Linha 2, Algoritmo 1). Com isto, é possível definir um *threshold*: $\frac{\sum_{w=1}^S R_{old} * P_w}{\sum P_w}$ (Linha 5, Algoritmo 1). Assim, a cada leitura realizada R_{new} , o nó verifica se a R_{new} é maior que o *threshold* (Linha 6, Algoritmo 1). Caso a condição seja satisfeita, o valor sensorado (R_{new}) é transmitido para o nó decisor, utilizando a tabela de roteamento (Linha 7, Algoritmo 1). Por fim, a R_{new} é adicionada no conjunto S com maior prioridade, enquanto que o valor (R_{old}) de menor prioridade é suprimindo (Linha 9, Algoritmo 1).

3.1.3. Comunicação do nó Decisor com o nó Atuador

Os nós decisores decidem e coordenam as ações na residência. Ainda, é nessa etapa que os dados coletados são associados às aplicações. Para isso, modelou-se uma rede neural (descrito com mais detalhes na Seção 3.2), a qual é capaz de dar sentido mais amplo para os dados sensorados.

No Algoritmo 2, é descrito o funcionamento do nó decisor. Antes de inicializar tal fase, cada nó decisor descobre os nós atuadores mediante o RSSI. Ainda nessa fase, são obtidas as informações dos *Mac Address* dos atuadores, bem como suas respectivas

Algoritmo 1: Mecanismo de correlação temporal e transmissão dos dados monitorados

```
1  $S_n \leftarrow \text{GetR}_{old}()$ ; // Leituras reportadas no buffer
2  $P_w \leftarrow \text{SetIndex}(S_n)$ ; // Atribui pesos aos dados reportados
3  $R_{new} \leftarrow \text{GetNew}()$ ; // Leitura atual
4 para cada  $n \in S_n$  faça
5    $\text{Threshold} \leftarrow \frac{\sum_{w=1}^S R_{old} * P_w}{\sum P_w}$ ; // Calcula a correlação temporal ponderada
   // verifica se o  $R_{new}$  passa o Threshold
6   se  $R_{new} > \text{Threshold}$  então
7      $\text{ToSend}(R_{new}, \text{TabelaRoteamento})$ ; // Envia dados para o nó decisor
8   fim
   // Atualiza o Threshold adicionando o  $R_{new}$  e suprimindo o  $R_{old}$ 
9    $S_n \leftarrow \text{UpdateS}(S_n, R_{new})$ ;
10 fim para
```

aplicações que eles podem atender. A próxima fase do Algoritmo 2 está relacionada com o processo de tomada de decisão dentro do próprio nó decisor. Esse processo só é iniciado quando o nó decisor recebe um conjunto de dados dos nós sensores mediante uma correlação temporal. O nó decisor ao receber esses dados toma a decisão com base na proposta de uma rede neural já treinada, descrito na próxima seção. Desta forma, a informação da aplicação e sua respectiva decisão são obtidas (Linha 3, Algoritmo 2). Com tais informações, encaminha-se a decisão para o nó atuador. Deve-se ressaltar, portanto, que a decisão é transmitida para o nó atuador mais próximo (Linhas 4 a 6, Algoritmo 2) com o intuito de poupar energia residual do nó decisor.

Algoritmo 2: Coordena as tomadas de decisões e transmissi para o nó atuador

```
1  $R_n \leftarrow \text{ReadSet}()$ ; // Conjunto de dados dos nós sensores
2 para cada  $d \in R_n$  faça
3    $\text{DecisionMaking} \leftarrow \text{RedeNeural}(R_n)$ ; // toma a decisão
   // verifica tomada de decisão
4   se  $\text{DecisionMaking.Act} = \text{True}$  então
5      $\text{ToSend}(\text{DecisionMaking}, \text{TabelaRoteamento})$ ; // Envia a decisão para o nó atuador
6   fim
7 fim para
```

3.2. Mecanismo para a Tomada de Decisão do ResiDI

O modelo proposto para a tomada de decisão tem como objetivo o aprendizado das aplicações mediante uma rede neural do tipo *Multi-Layer Perceptron*. A escolha da rede neural é justificada por alguns motivos, sendo os principais: (i) capacidade de generalização na tomada de decisão; (ii) auto-aprendizado baseado apenas nos exemplos históricos; e (iii) imunidade a ruídos para dados reais. Além disso, ao contrário de outros métodos, a rede neural possibilita uma adaptação as condições que possam ocorrer e com uma maior estabilidade na tomada de decisão.

Para facilitar o entendimento da rede neural, a Figura 3 ilustra a topologia da rede neural e como os dados de entrada (isto é, dados provenientes dos nós sensores) são utilizados para a tomada de decisão. Para tanto, a topologia da rede foi modelada com as seguintes configurações: (i) camada de entrada com sete neurônios, os quais correspondem aos dados transmitidos pelos nós sensores; (ii) camada escondida com quinze neurônios, os quais representam a capacidade de aprendizagem para a tomada de decisão;

e (iii) camada de saída com três neurônios, representando a tomada de decisão a ser enviada para o nó atuador e sua aplicação, sendo esta composta por uma combinação de neurônios, uma vez que é possível ter mais de uma decisão para diferentes aplicações.




Figura 3. Topologia da rede neural modelada para a tomada de decisão.

Deve-se ressaltar, portanto, que com a rede treinada e transmitida para os nós decisores, é possível dar sentido mais amplo para a tomada de decisão por meio das grandezas físicas compartilhadas. Isto é, um único sensor de presença pode ser utilizado para o sistema de ar condicionado e iluminação. Desta forma, os dados coletados não são associados apenas a um evento. Por exemplo, quando o sensor de presença detecta ausência de moradores, o sistema de ar condicionado pode desligar ou aumentar a temperatura, enquanto, paralelamente, o sistema de iluminação pode ser desligado.

É fundamental destacar que para treinar a rede, optou-se por realizar no nó *sink*. Nesse caso, utilizou-se o Raspberry Pi por ser uma plataforma de prototipagem aberta e de baixo consumo de energia. No nó *sink*, encontra-se a base de dados utilizada para treinar a rede, descrita na Seção 3.2.1. Após o treinamento, deve-se ressaltar que o nó *sink* transmite a rede treinada para os nós decisores. Assim, não há *overhead* (isto é, processamento e/ou armazenamento em excesso) no ResiDI. Com isto, é possível re-treinar a rede, caso necessário, mediante o comportamento do(s) morador(es), sem prejuízos na eficiência energética do sistema. A seguir é apresentada a base de dados utilizada e como a rede foi treinada.

3.2.1. Base de Dados

Com o intuito de obter dados mais confiáveis para os experimentos, utilizou-se dados de um ambiente real para gerar os resultados, adquiridos em [Filho et al. 2014, Bache and Lichman 2013]. A coleta de dados foi realizada durante 3 meses em [Filho et al. 2014] e 40 dias em [Bache and Lichman 2013], ambos em um ambiente residencial. Com isso, uma base de dados foi modelada com base nos sensores de temperatura, presença, energia e um sensor lógico para captar o horário de utilização e o estado do equipamento (desligado, ligado e *standby*). As aplicações utilizadas na base de dados foram iluminação e eletrodoméstico (televisão, computador e geladeira). Deve-se ressaltar que as atividades de atuação estão relacionadas em ligar e desligar as aplicações mediante a preferência do morador.

Após a formação da base de dados, oito partições das amostras do conjunto de

dados foram feitas. Cada partição contém um conjunto de dados de 1 e 2 semanas. Em seguida, utilizou-se o algoritmo *back-propagation* para treinar a rede. Além disso, para evitar o problema de mínimo local, bem como estimar o quão correto o ResiDI será executado na prática, a técnica *k-fold cross-validation* com $k=4$ foi utilizada para separar o conjunto de treino e teste em cada partição de maneira disjunta. Desta forma, utilizou-se um subconjunto para teste e os outros três para treino. A seguir é apresentada uma avaliação de desempenho para validar o ResiDI.

4. Avaliação de Desempenho e Metodologia

Nesta seção, o desempenho do ResiDI é avaliado, comparando-o com o CONDE. A escolha do CONDE deve-se ao seu bom desempenho quando comparado com outra solução da literatura [Feng et al. 2008]. Além disso, é um dos trabalhos que mais se assemelha com a proposta deste artigo.

A validação do ResiDI foi dividida em dois estágios, a saber: (i) a avaliação de desempenho para determinar a sua capacidade de atuar no processo de tomada de decisão; e (ii) a avaliação de desempenho da infraestrutura da rede em termos de consumo de energia e tempo de resposta. Para o primeiro estágio, experimentos reais, utilizou-se o nó *sink* (Raspberry Pi) para treinar a topologia da rede neural que transmite a rede treinada para o nó decisor (MicaZ). Após o término do primeiro estágio, utilizou-se o Network Simulator 3³ para realizar a simulação da infraestrutura do ResiDI, tendo como parâmetros de simulação os nós da plataforma MicaZ. A seguir os resultados obtidos são apresentados.

4.1. Avaliação de desempenho do ResiDI na tomada de decisão

Esta subseção avalia o desempenho do ResiDI em determinar a sua capacidade na tomada de decisão. Para isso, considerou-se as seguintes medidas de desempenho: (i) sensibilidade; (ii) precisão; e (iii) especificidade. Tais medidas são obtidas mediante uma matriz de confusão, como ilustrada na Figura 4.

		Classe Predita		
		Positivo	Negativo	
Classe Verdadeira	Positivo	Verdadeiro Positivo (VP)	Falso Negativo (FN)	Sensibilidade: $VP/(VP + FN)$ Precisão: $VP/(VP + FP)$ Especificidade: $VN/(VN + FP)$
	Negativo	Falso Positivo (FP)	Verdadeiro Negativo (VN)	

Figura 4. Medidas de desempenho calculadas a partir da matriz de confusão.

Os conjuntos de parâmetros estabelecidos para realizar a avaliação de desempenho são sumarizados na Tabela 1. O sistema é avaliado com o uso dos métodos (ResiDI e CONDE), e com a mudança do *dataset* (1 semana e 2 semanas). Cada conjunto de parâmetros foi executado 12 vezes. Com o intuito de verificar a adequação a normalidade dos resultados apresentados na Figura 5, utilizou-se o *Shapiro-Wilk normality test*, o qual obteve os p-valores apresentados na Tabela 2. Com isso, notou-se que com exceção

³Network Simulator 3 - NS3, <http://www.nsnam.org/>

de um p-valor (E3 precisão, Tabela 2), os demais conjuntos tem a hipótese de adequação à normalidade aceita considerando 95% de confiança. Por isso, utilizou-se o *t-student* como método paramétrico de comparação entre os conjuntos. Os resultados são apresentados na Figura 5, com 95% de confiança.

Tabela 1. Conjunto de parâmetros escolhidos para serem avaliados.

Experimentos	Métodos	Dataset
E1	ResiDI	1 semana
E2	ResiDI	2 semanas
E3	CONDE	1 semana
E4	CONDE	2 semanas

Tabela 2. P-valores resultados do *Shapiro-Wilk normality test*.

Experimentos	Shapiro-Wilk normality test		
	Sensibilidade	Precisão	Especificidade
E1	0,472	0,8927	0,5031
E2	0,4322	0,2301	0,7154
E3	0,3433	0,01977	0,1622
E4	0,5224	0,754	0,5234

No gráfico da Figura 5, é apresentado a porcentagem dos resultados obtidos em função das medidas de desempenho para o *dataset* de 1 e 2 semanas. O resultado destaca que houve estatisticamente diferença significativa entre o ResiDI e o CONDE, independente do período monitorado (experimentos {(E1, E3), (E2, E4)} da Figura 5). Através desses resultados, notou-se que o ResiDI possui um desempenho superior em relação ao CONDE quando considerado o *dataset* de 1 semana. Além disso, tal aumento é mais acentuado quando considerado o *dataset* de 2 semanas. Esta situação é derivada do treinamento da rede, a qual possui mais exemplos para a sua auto-aprendizagem. Isto é, o ResiDI aprende a tomar decisões pela sua própria experiência, a qual pode ser obtida mediante os históricos comportamentais dos moradores (revise a Seção 3.2).

Outro aspecto importante, notado no resultado da Figura 5, está relacionado com a estabilidade do ResiDI quando comparado com o CONDE. Isto é identificado pela amplitude interquartil, a qual indica o grau de dispersão dos dados gerados. Isso faz sentido, posto que o ResiDI generaliza as suas decisões com base em exemplos históricos, separando as tomadas de decisões em hiperplanos. Portanto, é possível tomar decisões corretamente para instâncias nunca vistas na base de dados. Já o CONDE realiza a sua tomada de decisão mediante um espaço fixo para cada aplicação. Em virtude disso, há um alto grau de dispersão nos resultados obtidos.




Figura 5. Análise de desempenho do ResiDI de acordo com a Tabela 1.

4.2. Avaliação de desempenho da infraestrutura do ResiDI

Esta subseção avalia o desempenho da infraestrutura do ResiDI em um ambiente simulado. Para obter um cenário mais próximo de um ambiente real, utilizou-se como entrada para a simulação os conjuntos de dados reais de 1 e 2 semanas descritos na Seção 3.2.1. Em relação a topologia da rede, adotou-se uma topologia plana para depositar os nós. Com o intuito de evitar buracos na topologia, a densidade dos nós decisores e atuadores são de 0.007 nós/ m^2 . Já a densidade dos nós sensores é de 0.015 nós/ m^2 , uma vez que é realístico admitir que há mais nós sensoreando um ambiente. O raio de comunicação dos nós é de 15 m, e o seu consumo de energia para transmitir e receber um pacote são de $0,2088 \mu J/bit$ e $0,2256 \mu J/bit$, respectivamente, de acordo com a plataforma MicaZ. Além disso, adicionou-se 5% de imprecisão no RSSI. O tempo de simulação foi de uma hora, sendo o primeiro minuto para o *startup* da rede.

Os conjuntos de parâmetros estabelecidos para realizar a avaliação de desempenho são apresentados na Tabela 3. Os experimentos foram avaliados com a alteração da área monitorada ($100 m^2$, $225 m^2$, $400 m^2$ e $625 m^2$), e com a troca dos métodos (ResiDI e CONDE). Como o objetivo da avaliação é determinar a capacidade do ResiDI em obter soluções energeticamente eficiente, utilizou-se como variável de resposta as métricas: (i) atraso na tomada de decisão, o qual representa o tempo gasto desde o sensoreamento até a atuação para que uma decisão seja executada; e (ii) o consumo de energia dos nós, o qual indica a quantidade de energia consumida pela infraestrutura no processo de tomada de decisão. As configurações de cada conjunto de parâmetro foram executadas 33 vezes, com uma confiança de 95% de acordo com a distribuição *t-student*. A Tabela 4 apresenta os resultados da comparação entre os conjuntos de parâmetros {(E1,E5), (E2,E6), (E3,E7), (E4,E8)}. Como os resultados dos p-valores foram inferiores a 0,05, todos os resultados das comparações apresentados na Figura 6 são estatisticamente diferentes.

Tabela 3. Conjunto de parâmetros escolhidos para serem avaliados.

Experimento	Método	Área monitorada
E1	ResiDI	$100 m^2$
E2	ResiDI	$225 m^2$
E3	ResiDI	$400 m^2$
E4	ResiDI	$625 m^2$
E5	CONDE	$100 m^2$
E6	CONDE	$225 m^2$
E7	CONDE	$400 m^2$
E8	CONDE	$625 m^2$

Tabela 4. P-valores resultantes do *t-student*.

Comparação entre os conjuntos de parâmetros	t-student	
	Atraso	Energia
E1 E5	$\approx 0,000$	$\approx 0,000$
E2 E6	$\approx 0,000$	$\approx 0,000$
E3 E7	$\approx 0,000$	$\approx 0,000$
E4 E8	$\approx 0,000$	$\approx 0,000$

No gráfico da Figura 6a, são apresentados os resultados referentes ao atraso no processo de tomada de decisão em função da área, ilustrando uma análise comparativa entre o ResiDI e o CONDE. Nota-se, estatisticamente, que o ResiDI realiza o processo de tomada de decisão em um tempo menor quando comparado com o CONDE, em todos os experimentos. Nos experimentos E1 e E5 da Figura 6a, o processamento do ResiDI foi no mínimo 11,8% mais rápido que CONDE. Isso ocorre em virtude da formulação do hiperplano separador gerado pela rede neural, a qual não necessita consultar uma base de dados para chegar a um consenso no processo de tomada de decisão, ao contrário do CONDE. Desta forma, é possível obter respostas mais rápidas, o que influencia diretamente na redução do consumo de energia da rede. Além disso, quando há uma ampliação na área de interesse, observou-se que houve diferenças significativas de 35,04% e 44,35%

para os experimentos (E3, E7) e (E4, E8) entre o ResiDI e CONDE. Em outras palavras, no ResiDI, houve uma redução mais acentuada no tempo de entrega das mensagens para a tomada de decisão. Portanto, em relação a métrica atraso, o ResiDI possui um desempenho superior em relação ao CONDE, apresentando melhor robustez que a solução da literatura.




Figura 6. Análise de desempenho das métricas atraso e consumo de energia de acordo com a Tabela 3.

Com base no conjunto de parâmetros propostos, o gráfico da Figura 6b apresenta os resultados relativos à métrica consumo de energia para cenários com diferentes áreas monitoradas. Para o cenário com uma área de 100 m² e 225 m², observa-se que há uma redução de aproximadamente 14,11% e 13,79% do consumo de energia quando as soluções propostas pelo ResiDI é utilizada e, conseqüentemente, um aumento no tempo de vida útil da infraestrutura. Isso ocorre devido aos dados transmitidos serem correlacionados ao tempo. Em outras palavras, somente quando há uma diferença da leitura atual com as leituras reportadas, o dado sensorado é encaminhado para o nó desejado (revisite a Subseção 3.1.2). Além disso, deve-se salientar, portanto, que o aumento na área monitorada não afeta o desempenho do ResiDI, uma vez que o consumo de energia foi reduzido de forma significativa para 22,24% e 33,31% considerando as áreas de 400 m² e 625 m², respectivamente (experimentos {(E3, E7), (E4, E8)} da Figura 6b). Esta diferença significativa em relação ao consumo de energia faz sentido, posto que o trabalho da literatura penaliza o nó decisor por consumir mais energia, o qual é considerado um ponto de falha do sistema.

5. Conclusões e Trabalhos Futuros

Com o objetivo de atender os problemas encontrados na literatura, este artigo propôs o ResiDI, um sistema de decisão inteligente para uma infraestrutura residencial distribuída usando sensores e atuadores sem fio. O ResiDI além de manter uma precisão no processo de tomada de decisão, tem como objetivo minimizar o consumo de energia da infraestrutura. Com o intuito de comprovar a viabilidade do ResiDI, os resultados obtidos das avaliações de desempenho permitiu validar a sua eficiência. Nesse sentido, quando comparado com uma abordagem da literatura, os resultados apresentados são promissores,

sendo os principais: (i) aumento da precisão na tomada de decisão; (ii) redução no tempo de atraso para que uma decisão seja executada; e (iii) maximização do tempo de vida útil da rede. Como trabalhos futuros, planeja-se desenvolver soluções de agregação de dados para sistemas residências, investigando o seu impacto em termos de eficiência energética. Além disso, pretende-se investigar modelos de privacidade, uma vez que o sistema de automação residencial podem revelar informações detalhadas do dia-a-dia do morador.

6. Agradecimentos

Os autores gostariam de agradecer o apoio financeiro concedido da FAPESP (processo 2014/06330-5) para o bolsista de doutorado MSc. Geraldo P. R. Filho. Ainda, os autores também agradecem ao CNPq (processos 473493/2013-6 e 8486332/2013-6), CAPES (processo DS-6706658/D) e FAPESP (processos 2012/22550-0 e 2014/19076-0) por financiarem partes dos seus projetos de pesquisas. Por fim, Jó Ueyama agradece o *Office of Naval Research Global* pelo suporte financeiro em sua pesquisa.

Referências

- Akyildiz, I. F. and Kasimoglu, I. H. (2004). Wireless sensor and actor networks: research challenges. *Ad Hoc Networks*, 2(4):351 – 367.
- Akyildiz, I. F., Su, W., Sankarasubramaniam, Y., and Cayirci, E. (2002). A survey on sensor networks. *Communications magazine*, 40(8):102–114.
- Bache, K. and Lichman, M. (2013). UCI machine learning repository. Irvine, CA: University of California, School of Information and Computer Science [http://archive.ics.uci.edu/ml/machine-learning-databases/00235/] visited on March 22, 2015.
- Baraka, K., Ghobril, M., Malek, S., Kanj, R., and Kayssi, A. (2013). Low cost arduino/android-based energy-efficient home automation system with smart task scheduling. In *Comput. Intel., Communicat. Syst. and Networks*, pages 296–301. IEEE.
- de Farias, C., Soares, H., Pirmez, L., Delicato, F., Santos, I., Carmo, L. F., de Souza, J., Zomaya, A., and Dohler, M. (2014). A control and decision system for smart buildings using wireless sensor and actuator networks. *Transactions on Emerging Telecommunications Technologies*, 25(1):120 – 135.
- EPE (2013). Retrieved from: http://www.epe.gov.br/ResenhaMensal/20131030_1.pdf. visited on January 6, 2014.
- Feng, M.-W., Wen, S.-L., Tsai, K.-C., Liu, Y.-C., and Lai, H.-R. (2008). Wireless sensor network and sensor fusion technology for ubiquitous smart living space applications (invited paper). In *Universal Communication, 2008. ISUC '08. Second International Symposium on*, pages 295–302. IEEE.
- Filho, G. P. R., Ueyama, J., Villas, L. A., Pinto, A. R., Goncalves, V. P., Pessin, G., Pazzi, R. W., and Braun, T. (2014). Nodepm: A remote monitoring alert system for energy consumption using probabilistic techniques. *Sensors*, 14(1):848–867.
- Filho, G. P. R., Ueyama, J., Villas, L. A., Pinto, A. R., Goncalves, V. P., and Seraphini, S. (2013). An intelligent approach for improving energy efficiently in smart grids. In *International Conference on Wireless Networks (ICWN)*, volume 12, pages 227 – 233.

- Han, D.-M. and Lim, J.-H. (2010). Smart home energy management system using ieee 802.15.4 and zigbee. *Consumer Electronics, IEEE Transactions on*, 56(3):1403–1410.
- Lee, J. H., Lee, H., Kim, M. J., Wang, X., and Love, P. E. (2014). Context-aware inference in ubiquitous residential environments. *Computers in Industry*, 65(1):148 – 157.
- Lee, W. S. and Hong, S. H. (2009). Implementation of a knx-zigbee gateway for home automation. In *Consumer Electronics, 2009. ISCE '09. IEEE 13th International Symposium on*, pages 545–549. IEEE.
- Lima, M. M., de Oliveira, H. A. B. F., Nakamura, E. F., and Loureiro, A. A. F. (2013). Roteamento e agregacao de dados baseado no rssi em redes de sensores sem fio. In *XXXI Simposio Brasileiro de Redes de Computadores e Sistemas Distribuidos (SBRC)*, pages 555 – 568.
- Pessin, G., Osorio, F. S., Ueyama, J., Wolf, D. F., Moioli, R. C., and Vargas, P. A. (2014). Self-localisation in indoor environments combining learning and evolution with wireless networks. In *Proceedings of the 29th Annual ACM Symposium on Applied Computing, SAC '14*, pages 661 – 666. ACM.
- Ramlee, R., Othman, M., Leong, M., Ismail, M., and Ranjit, S. (2013). Smart home system using android application. In *Information and Communication Technology (ICoICT), 2013 International Conference of*, pages 277 – 280, Bandung. IEEE.
- Soares, H., Pirmez, L., Delicato, F., and de Farias, C. (2012). Conde: Um sistema de controle e decisao para edificios inteligentes usando redes de sensores e atuadores sem fio. In *XXX Simposio Brasileiro de Redes de Computadores e Sistemas Distribuidos (SBRC)*, pages 117 – 130.
- Souza, F. S. H. and Mateus, G. R. (2006). Um modelo de otimizacao para o problema de atribuicao de papeis em redes de sensores sem fio. In *XXXVIII Simposio Brasileiro de Pesquisa Operacional*, pages 1725 – 1736.
- Wang, M., Zhang, G., Zhang, C., Zhang, J., and Li, C. (2013). An iot-based appliance control system for smart homes. In *Intelligent Control and Information Processing (ICICIP), 2013 Fourth International Conference on*, pages 744 – 747. IEEE.