

Otimização do Posicionamento de Servidores Físicos em Centros de Dados Resilientes a Desastres

Rodrigo S. Couto¹, Stefano Secci²,
Miguel Elias M. Campista¹ e Luís Henrique M. K. Costa¹ *

¹Universidade Federal do Rio de Janeiro - PEE/COPPE/GTA - DEL/POLI

²Sorbonne Universités, UPMC Univ Paris 06, UMR 7606, LIP6, F-75005, Paris, France

{souza,miguel,luish}@gta.ufrj.br, stefano.secci@lip6.fr

Abstract. *The continuous and acknowledged replication of virtual machines in different data center sites is a feasible service today. This strategy guarantees that virtual machines will have no loss of disk and memory content if a disaster occurs, at a cost of strict bandwidth and latency requirements. Considering this kind of service, in this work we propose an optimization problem to place servers in a wide area network. The goal is to guarantee that backup machines do not fail at the same time as their primary counterparts and, by using virtualization, to reduce the amount of backup servers required. The optimal results, achieved in real topologies, reduce the number of backup servers by at least 40%. Moreover, this work highlights several characteristics of the backup service according to the employed network, such as the fulfillment of latency requirements.*

Resumo. *Atualmente, a replicação contínua e confirmada de máquinas virtuais em diferentes sítios de um centro de dados é um serviço viável. Essa estratégia permite garantir perda zero do disco e do conteúdo de memória das máquinas em caso de desastres, mas possui exigências severas de banda passante e latência. Considerando esse tipo de serviço, neste trabalho propõe-se um problema de otimização para posicionar servidores em uma rede de longa distância. O objetivo é garantir que máquinas de backup não falhem ao mesmo tempo que seus correspondentes primários e, através da virtualização, reduzir o número de servidores de backup necessários. Os resultados ótimos alcançados em topologias reais reduzem o número de servidores de backup em pelo menos 40%. Além disso, este trabalho aponta diversas características do serviço em relação às redes utilizadas, como o atendimento aos requisitos de latência.*

1. Introdução

No modelo de Infraestrutura como Serviço (IaaS - *Infrastructure as a Service*), os clientes da nuvem terceirizam suas infraestruturas computacionais, executando seus serviços dentro de máquinas virtuais (VMs - *Virtual Machines*) hospedadas em um provedor. Ao utilizar serviços IaaS, um cliente abandona o controle da sua infraestrutura computacional, e confiará nesses serviços de acordo com níveis de resiliência e desempenho garantidos pelos provedores. Assim, para atrair o uso de IaaS, provedores de nuvem geralmente buscam utilizar infraestruturas resilientes de servidores e de rede [Bauer e Adams, 2012].

*Este trabalho foi realizado com recursos da FAPERJ, CNPq e CAPES.

Para tal, os provedores empregam redundância na infraestrutura, de forma a superar diversos tipos de falhas, como de *hardware* (p.ex., discos rígidos ou sistemas de refrigeração), de *software* (p.ex., programação) e humanas (p.ex., procedimentos de manutenção). Essa estratégia, entretanto, não garante a disponibilidade do serviço em eventos de desastres, que estão fora do controle do provedor. Essas situações são causadas por catástrofes naturais ou por agentes humanos não relacionadas ao provedor, que podem atingir diversos enlaces da rede além de construções inteiras de um centro de dados (DC - *Data Center*). Como as corporações estão cada vez mais migrando suas infraestruturas para a nuvem pelo paradigma IaaS, os provedores precisam estar preparados para oferecer serviços resilientes a desastres. Para tal, a nuvem IaaS deve empregar um DC com sítios geodistribuídos, de forma a eliminar pontos únicos de falha e fornecer mecanismos para realizar cópias de segurança (backups) dos serviços em execução [Couto et al., 2014a].

Este trabalho foca o projeto de DCs resilientes a desastres com perda zero de dados ou de estado das VMs. Ou seja, as VMs possuem zero RPO (*Recovery Point Objective* - Objetivo do Ponto de Recuperação) [Couto et al., 2014b]. O RPO é a diferença de tempo entre o momento da última sincronização do backup e o momento do desastre, fornecendo uma ideia da perda de dados após o desastre. Alguns serviços necessitam de um RPO baixo ou até mesmo nulo (como transações bancárias), exigindo replicação contínua dos dados. Basicamente, um serviço IaaS com zero RPO consiste em VMs que enviam continuamente cópias de backup a um servidor. Nesse caso, uma determinada operação requisitada por um usuário final só será concluída após a VM receber uma confirmação do sítio de backup de que seu estado foi corretamente replicado [Rajagopalan et al., 2012]. Como exige replicação contínua de dados, esse serviço acarreta alta utilização da banda passante da rede. Além disso, como exige confirmação dos backups, demanda baixa latência entre o sítio primário e o de backup.

Este trabalho analisa o comportamento de serviços IaaS com zero RPO em redes de longa distância (WAN - *Wide Area Network*) reais. Para tal, é proposto um esquema de posicionamento de servidores físicos em centros de dados, que aloca cada servidor primário e seu respectivo backup na rede. O posicionamento leva em consideração um modelo de falhas, de forma que um desastre não destrua um servidor primário e seu backup ao mesmo tempo. Além disso, o posicionamento proposto tira proveito da virtualização para reduzir o número de servidores de backup necessários. A ideia básica é que um servidor de backup necessita instanciar uma VM apenas após um desastre. Assim, ao invés de adotar um esquema no qual cada servidor primário possui um servidor de backup dedicado, no posicionamento proposto um único servidor de backup poderá ser compartilhado, recebendo réplicas de diferentes servidores primários. Para tanto, esses servidores primários não podem falhar ao mesmo tempo. A partir da análise das topologias WAN, mostra-se que o compartilhamento de backups permite reduzir em pelo menos 40% o número de servidores necessários. Além disso, quantifica-se a capacidade de cada uma das WANs em número de servidores primários que podem ser instalados, o que impacta diretamente o número de VMs suportadas. Requisitos mais estritos de resiliência podem reduzir em pelo menos 50% o número de servidores primários suportados.

A literatura sobre posicionamento resiliente de servidores físicos em DCs considera uma distribuição tradicional do DC, como a utilizada para redes de distribuição de conteúdo (CDN - *Content Delivery Networks*) [Habib et al., 2012, Xiao et al., 2014].

Nesses trabalhos, os serviços de um DC são replicados através de uma infraestrutura geodistribuída. Para tal, utilizam o princípio *anycast*, no qual qualquer nó que execute o serviço desejado pode responder às requisições, fazendo com que tanto os servidores primários quanto seus backups encontrem-se ativos ao mesmo tempo. Entretanto, esses trabalhos não consideram a sincronização entre as réplicas do serviço, desconsiderando requisitos de RPO. Além disso, ao considerar que os backups encontram-se ativos, não economizam o número de servidores de backup. Este trabalho difere da literatura através da consideração das réplicas do serviço, que acarreta requisitos estritos de latência e banda passante, além de prover economia de servidores de backup. Para tal, foca-se no modelo IaaS, diferente das CDNs tradicionais. Em [Couto et al., 2014a] analisou-se o compromisso entre a resiliência e latência entre os nós de um DC geodistribuído. Esse trabalho mostrou que é possível projetar um DC resiliente com baixa latência entre seus sítios. Assim, o presente trabalho foca o caso de IaaS com zero RPO e considera os requisitos de banda passante e economia de servidores. Uma área correlata ao posicionamento de servidores em um DC é o mapeamento sobrevivente de redes virtuais em redes físicas. Em [Yu et al., 2011] propõe-se um problema de posicionamento da infraestrutura virtualizada na qual recursos de backup são compartilhados, reduzindo a quantidade de recursos necessária. Por fim, outro trabalho relacionado é o posicionamento de controladores em redes definidas por software (SDN - *Software Defined Networks*). Em SDNs os elementos de comutação são gerenciados por controladores. Assim, diferentes trabalhos propõem esquemas de posicionamento de um conjunto de controladores, de forma que os elementos de comutação consigam acesso a pelo menos um deles após falhas [Muller et al., 2014].

Este trabalho está organizado da seguinte forma. A Seção 2 apresenta o modelo do serviço considerado e as respectivas decisões de projeto. Com bases nessas decisões, a Seção 3 descreve o problema de otimização proposto. A Seção 4 apresenta os resultados da análise do problema proposto em redes WAN reais, enquanto a Seção 5 conclui o artigo e identifica direções futuras.

2. Modelagem e Decisões de Projeto

O problema proposto neste trabalho possui a função de distribuir servidores primários por uma WAN existente, que são utilizados para hospedar VMs de clientes IaaS. As VMs de um servidor primário são continuamente replicadas para um servidor de backup, instalado em algum outro sítio da rede. Para tal, o problema também escolhe a distribuição de servidores de backup, que hospedam as VMs dos servidores primários na ocorrência de um desastre. Para cada servidor primário, escolhe-se um servidor de backup correspondente. Note que este trabalho foca o posicionamento de servidores físicos, e não das VMs. A escolha dos servidores físicos primários que hospedam as VMs após requisições dos usuários é realizada por algoritmos de posicionamento *online* de VMs, e está fora do escopo deste trabalho [Couto et al., 2014b]. Esta seção detalha as decisões de projeto do DC, consideradas na formulação do problema de posicionamento, na Seção 3.

2.1. Replicação de VMs

O esquema de backup de VMs considerado neste trabalho é baseado na replicação contínua com reconhecimento. Um exemplo desse tipo de mecanismo é o Second-Site [Rajagopalan et al., 2012], utilizado como referência no restante deste trabalho. Para prover zero RPO, o SecondSite baseia-se em *checkpoints*. Um *checkpoint* é definido como




Figura 1. Exemplo de DC geodistribuído com replicação contínua de VMs.

o estado da VM (disco, memória, CPU) em determinado instante. Esse estado é enviado continuamente para o servidor de backup que, por sua vez, envia um reconhecimento ao seu servidor primário a cada *checkpoint* recebido. Antes do reconhecimento de um *checkpoint*, os pacotes enviados da VM ao mundo externo são acumulados em fila, não sendo enviados aos usuários finais. O envio só é permitido após o recebimento de reconhecimento positivo do *checkpoint*. O usuário final só receberá a resposta de alguma operação que realizou após essa ter sido replicada no servidor de backup. Assim, o mecanismo de replicação possui exigências severas de banda passante e latência. O alto uso de banda passante se deve à contínua replicação de dados, maior quanto mais a VM muda de estado (p.ex. quanto mais o conteúdo da memória RAM é alterado). As exigências estritas de latência se devem à necessidade de reconhecimento dos *checkpoints* antes de avançar na execução das operações. Assim, quanto menor a latência, maior será a vazão com que uma determinada VM consegue realizar suas operações.

Ao detectar uma falha no servidor primário, o SecondSite ativa a VM no servidor de backup. Para detectar a falha, emprega um terceiro tipo de servidor que realiza medições periódicas para arbitrar quando houve falhas e como o serviço deve ser recuperado. Obviamente, esses servidores também devem ser posicionados na rede de forma a detectar correta e rapidamente as falhas. Neste trabalho assume-se que esses servidores estão corretamente posicionados, conseguindo detectar todas as possíveis falhas. Esse tipo de posicionamento ainda não foi abordado na literatura, mas possui considerável semelhança com o posicionamento de controladores em SDNs [Muller et al., 2014].

2.2. Posicionamento dos Servidores

A Fig. 1(a) exemplifica o cenário considerado. Cada círculo representa um sítio posicionado em uma localidade geográfica, e os sítios são interconectados por uma WAN. Note que as VMs hospedadas em cada servidor não estão mostradas. As setas indicam que um sítio envia continuamente réplicas das VMs para seus vizinhos, e os números ao lado de cada seta indicam quantos servidores primários do sítio de origem enviam backups para o sítio de destino. O Sítio D possui três servidores primários. O backup das VMs de dois de seus servidores é enviado para o Sítio A e do terceiro servidor é enviado para o Sítio C. A figura mostra que um único sítio pode possuir servidores primários e de backup.

A Fig. 1(a) mostra que um sítio usado para backup pode atender mais backups de servidores primários do que o número de servidores de backup que possui instalados.

Por exemplo, o Sítio C possui dois servidores de backup instalados. Por outro lado, dois servidores primários do Sítio B e um do Sítio D enviam seus backups para ele, o que necessitaria de três servidores de backup no Sítio C. Entretanto, *considerando que o Sítio B e o Sítio D não estarão inacessíveis ao mesmo tempo*, o Sítio C não precisará hospedar as VMs dos três servidores primários ao mesmo tempo. Como o serviço é baseado em VMs, durante a operação normal (isto é, sem falhas) os sítios que recebem os backups não precisam manter as VMs em operação, armazenando apenas os dados referentes ao disco, conteúdo da memória e outras informações das VMs enviadas pelo servidor primário [Couto et al., 2014b, Wood et al., 2010]. Assim, em operação normal, o servidor de backup necessita apenas de capacidade de armazenamento para as VMs, fornecida por servidores de armazenamento não mostrados na figura. A capacidade de memória e processamento, fornecida pelos servidores de VMs de backup, só será necessária após o desastre, quando os procedimentos de recuperação são executados e as VMs de backup passam a operar. Assim, é possível economizar o número de servidores de VMs de backup necessários, visto que um sítio precisa ter apenas o número de servidores de backup para suportar a falha de pior caso. No exemplo do Sítio C, o pior caso constitui na falha do Sítio B, exigindo que dois de seus servidores de backup se tornem operacionais. Essa característica é considerada no problema de otimização proposto, permitindo economia significativa do número de servidores de VM necessários. É importante notar que, independente do uso desse esquema de economia, o número de servidores de armazenamento necessários para backup será sempre o mesmo. Consequentemente, desconsidera-se o posicionamento desse tipo de servidor.

Para posicionar os servidores, um requisito básico é instalar um servidor primário e seu respectivo backup em sítios diferentes e que não falhem ao mesmo tempo. Para tal, utiliza-se a Matriz de Independência de Falhas (matriz I). Cada elemento corresponde a um valor binário I_{ij} , valendo 1 se o sítio i pode se tornar inacessível ao mesmo tempo que o sítio j , 0 senão. Um sítio é considerado inacessível se, após uma falha, não possuir nenhum caminho para um *gateway* da rede ou se o próprio falhar. A matriz I é construída a partir do modelo de falhas. Neste trabalho, considera-se o modelo de grupos de risco compartilhado (SRGs - *Shared Risk Groups*) utilizado em [Couto et al., 2014a]. Um SRG é definido como um conjunto de elementos da infraestrutura suscetíveis à mesma situação de desastre. Considerando quedas de energia, um SRG pode ser o conjunto dos sítios servidos por uma mesma subestação elétrica. Assim, utilizando a noção de SRGs, o valor de I_{ij} é 1 se os sítios i e j possuírem algum SRG em comum, 0 caso contrário.

2.3. Enlace de Replicação e Caminho Secundário

Devido à severa restrição de latência imposta pela replicação de VMs, no problema formulado um determinado servidor realizará replicações de backup apenas aos vizinhos de um salto de seu sítio. Dessa forma, evita-se o aumento na latência causado por eventuais atrasos de processamento e de transmissão em roteadores intermediários. O enlace entre um sítio primário e seu respectivo backup, chamado de enlace de replicação, é utilizado para transportar as réplicas das VMs. Entretanto, caso esse enlace falhe e os dois sítios não consigam se comunicar, o processo de replicação é interrompido e as VMs do servidor primário começam a executar no modo desprotegido [Rajagopalan et al., 2012]. Nesse modo as VMs continuam operacionais, porém não realizam replicações devido à ausência de comunicação com os servidores de backup. Como em serviços com zero

RPO o tempo que a VM se encontra em modo desprotegido deve ser reduzido ao máximo, neste trabalho utiliza-se caminhos secundários entre o sítio primário e seu backup. Assim, quando for detectada uma queda no enlace de replicação, o servidor primário enviará suas replicações pelo caminho secundário. Obviamente, o caminho secundário escolhido não pode conter o enlace de replicação. A Fig. 1(b) mostra o caminho escolhido para dar continuidade ao envio de replicações entre os Sítios A e D, quando o enlace entre eles falha. Mais adiante serão analisados os compromissos de se utilizar esse caminho adicional, bem como a qualidade desse tipo de caminho em termos de latência.

3. Formulação do Problema de Otimização do Posicionamento de Servidores

Neste trabalho tenta-se maximizar o número de servidores primários e, ao mesmo tempo, minimizar a quantidade de servidores de backup adicionais necessários para abrigar as VMs após um desastre. O problema de otimização considera como parâmetros a latência e a capacidade (em Mbits/s) dos enlaces, a Matriz de Independência de Falhas, além da topologia da rede para cálculo dos caminhos secundários. A saída do problema fornece a quantidade de servidores primários e de backup a ser instalada em cada sítio, assim como o caminho secundário entre cada sítio primário e seu sítio de backup. O posicionamento proposto é realizado em duas etapas. Na primeira etapa calcula-se o caminho secundário entre cada par de sítios da rede. Na segunda etapa executa-se o problema de otimização do posicionamento de servidores físicos.

Na primeira etapa, modela-se a WAN como um grafo no NetworkX¹, no qual os nós são os sítios e cada aresta um enlace entre os sítios, com o peso correspondente à distância geográfica entre eles. Para cada par de nós vizinhos, retira-se do grafo o enlace entre esses nós e calcula-se o menor caminho entre eles utilizando o algoritmo de Dijkstra. Nessa estratégia são escolhidos os caminhos secundários com a menor latência possível, independentemente do problema de otimização subsequente. Optou-se por adotá-la de forma a forçar o menor valor de latência possível, devido às restritas exigências em relação a essa métrica. Vale lembrar que, ao fim do problema de otimização, caminhos secundários entre sítios que não replicam backup entre si não são configurados. O resultado dessa etapa consiste nos parâmetros s_{ij}^{km} , que definem os enlaces contidos no caminho secundário entre cada par de sítios k e m . Ou seja, para um enlace entre i e j , tem-se $s_{ij}^{km} = 1$ se esse enlace está no caminho secundário entre k e m , ou $s_{ij}^{km} = 0$ senão.

Na segunda etapa, utiliza-se a ferramenta IBM ILOG CPLEX 12.5.1 para executar o problema de programação linear inteira (ILP - *Integer Linear Programming*) formulado a seguir. Esse problema escolhe o posicionamento de cada servidor físico primário e seu respectivo backup, considerando os objetivos da otimização e restrições mencionados anteriormente. A Tabela 1 lista as notações utilizadas e seus tipos. Notações do tipo conjunto e parâmetro se referem aos dados do problema, enquanto as variáveis são ajustadas pelo algoritmo de otimização. A formulação ILP é a seguinte:

$$\text{maximizar } \sum_{i \in \mathcal{D}} (x_i - b_i) \quad (1)$$

$$\text{sujeito a } c_{ij} \cdot I_{ij} = 0 \quad \forall i, j \in \mathcal{D}. \quad (2)$$

¹ A ferramenta NetworkX está disponível em <http://networkx.github.io/>

Tabela 1. Notações utilizadas no problema.

Notação	Descrição	Tipo
$\mathcal{D}$	Sítios candidatos	Conjunto
I_{ij}	Valor binário indicando se o sítio i pode se tornar inacessível ao mesmo tempo que o sítio j	Parâmetro
Δ_{ij}	Atraso de propagação (latência) do enlace entre os sítios i e j	Parâmetro
W_{ij}	Capacidade do enlace entre os sítios i e j	Parâmetro
s_{ij}^{km}	Valor binário indicando se o enlace entre i e j pertence ao caminho secundário entre k e m	Parâmetro
α	Fração máxima da capacidade dos enlaces a ser utilizada pela replicação	Parâmetro
γ	Parâmetro binário indicando se existirá um caminho secundário entre sítios de backup e primários	Parâmetro
B	Consumo de banda, em Mbts/s, gerado pela transferência contínua do backup de um servidor primário	Parâmetro
L_{worst}	Máxima latência permitida entre um servidor primário e seu backup	Parâmetro
U_{max}	Máximo número de sítios utilizados	Parâmetro
x_i	Número de servidores primários na localização i	Variável
b_i	Número de servidores de backup na localização i	Variável
u_i	Valor binário indicando se o sítio i está ativo ($(x_i + b_i) > 0$)	Variável
r_{ij}	Quantidade de banda disponível para replicações do sítio i para o sítio j	Variável
c_{ij}	Número de backups do sítio i no sítio j	Variável
e_{ij}	Valor binário indicando se o sítio i possui backups no sítio j ($c_{ij} > 0$)	Variável
y_{kij}	Valor binário indicando se o sítio k abriga backups dos sítios i e j ($e_{ik} = 1$ e $e_{jk} = 1$)	Variável

$$\sum_{j \in \mathcal{D}} c_{ij} = x_i \quad \forall i \in \mathcal{D}. \quad (3)$$

$$M \cdot e_{ij} - c_{ij} \geq 0 \quad \forall i, j \in \mathcal{D}. \quad (4)$$

$$e_{ij} \leq c_{ij} \quad \forall i, j \in \mathcal{D}. \quad (5)$$

$$y_{kij} \geq e_{ik} + e_{jk} - 1 \quad \forall k, i, j \in \mathcal{D}, i < j. \quad (6)$$

$$y_{kij} \leq e_{ik} \quad \forall k, i, j \in \mathcal{D}, i < j. \quad (7)$$

$$y_{kij} \leq e_{jk} \quad \forall k, i, j \in \mathcal{D}, i < j. \quad (8)$$

$$\sum_{i, j \in \mathcal{D}, i < j} (I_{ij} \cdot y_{kij}) = 0 \quad \forall k \in \mathcal{D}. \quad (9)$$

$$b_j - c_{ij} \geq 0 \quad \forall i, j \in \mathcal{D}. \quad (10)$$

$$B \cdot c_{ij} \leq r_{ij} \quad \forall i, j \in \mathcal{D}. \quad (11)$$

$$r_{ij} \leq \alpha \cdot W_{ij} - \gamma \cdot B \cdot c_{km} \cdot s_{ij}^{km} \quad \forall i, j \in \mathcal{D} \quad \forall k, m \in \mathcal{D}. \quad (12)$$

$$e_{ij} \cdot \Delta_{ij} \leq L_{worst} \quad \forall i, j \in \mathcal{D}. \quad (13)$$

$$M \cdot u_i - (x_i + b_i) \geq 0 \quad \forall i \in \mathcal{D}. \quad (14)$$

$$u_i \leq (x_i + b_i) \quad \forall i \in \mathcal{D}. \quad (15)$$

$$\sum_{i \in \mathcal{D}} u_i \leq U_{max}. \quad (16)$$

$$x_i \geq 0, \quad b_i \geq 0, \quad \forall i \in \mathcal{D}; c_{ij} \geq 0 \quad \forall i, j \in \mathcal{D}. \quad (17)$$

$$x_i \in \mathbb{Z}, \quad b_i \in \mathbb{Z} \quad \forall i \in \mathcal{D}; \quad r_{ij} \in \mathbb{Z}, \quad c_{ij} \in \mathbb{Z} \quad \forall i, j \in \mathcal{D}; \quad u_i \in \{0, 1\}, \quad \forall i \in \mathcal{D}; \quad e_{ij} \in \{0, 1\} \quad \forall i, j \in \mathcal{D}; \quad y_{kij} \in \{0, 1\} \quad \forall k, i, j \in \mathcal{D}. \quad (18)$$

O objetivo do problema, dado pela Eq. (1), tenta encontrar o melhor compromisso entre o número de servidores primários ($\sum_{i \in \mathcal{D}} x_i$) e o número de servidores utilizados

para backup ($\sum_{i \in \mathcal{D}} b_i$). Para cada servidor instalado em um sítio, o problema tentará reduzir em uma unidade o número de servidores de backup. Dessa forma, a função objetivo pode ser vista como a economia, em número de servidores, dos servidores de backup necessários para instalar o serviço. No pior caso a função objetivo será zero, enquanto no melhor caso se aproximará do número de servidores primários instalados.

A Eq. (2) força os servidores primários de um sítio i a só possuírem backup em um sítio j (ou seja, $c_{ij} > 0$) se i e j não puderem se tornar inacessíveis ao mesmo tempo ($I_{ij} = 0$). A Eq. (3) define que o número de backups que um sítio i deverá espalhar pela rede seja igual ao número de servidores primários desse sítio.

As Eqs. (4) e (5) são utilizadas para calcular as variáveis binárias e_{ij} , que recebem valor 1 se $c_{ij} > 0$ e 0 caso contrário. O parâmetro M da Eq. (4) é apenas um valor grande o suficiente para ser sempre maior ou igual a qualquer possível valor das variáveis c_{ij} dessa equação e das somas $x_i + u_i$ da Eq. (14), mostrada adiante. Adota-se, de forma conservadora, $M = 1 \times 10^9$. As Eqs. (6), (7) e (8), utilizadas para calcular as variáveis binárias y_{kij} , são equivalentes à operação lógica E entre e_{ik} e e_{jk} .

A Eq. (9) é responsável pela economia de servidores de backup. Essa equação garante que se dois sítios i e j podem se tornar inacessíveis ao mesmo tempo (ou seja, $I_{ij} = 1$), eles não poderão hospedar seus backups em um mesmo sítio k . Em outras palavras, se $I_{ij} = 1$, i e j não poderão compartilhar servidores de backup. Note que a Eq. (9) influencia as variáveis y_{kij} e, conseqüentemente, as variáveis e_{ij} e c_{ij} , que definem o posicionamento dos backups. Como o problema garante que sítios que podem se tornar inacessíveis ao mesmo tempo não compartilham backups, o número de servidores de backup pode ser calculado utilizando a Eq. (10), que é equivalente a fazer $b_j = \max_{j \in \mathcal{D}}(c_{ij})$. Isto é, o número de servidores de backup a ser instalado em um sítio j é dado pelo máximo número de backups que qualquer outro sítio da rede envia para ele. Voltando à Fig. 1(a), o Sítio C recebe dois backups do Sítio B e um backup do Sítio D. Assim, o Sítio C possui dois servidores de backup para suportar a falha do Sítio B, que consiste no sítio que o envia o maior número de backups.

As Eqs. (11) e (12) tratam das restrições de banda passante. Na Eq. (11), $B \cdot c_{ij}$ representa a quantidade de banda necessária para a replicação de c_{ij} servidores primários de i em j . Note que, para cada backup, uma quantidade de banda de B Mbits/s é utilizada continuamente no enlace entre os dois sítios. Essa equação especifica que o consumo de banda em um determinado enlace não pode ultrapassar o valor definido pela variável r_{ij} , dada pela Eq. (12). Essa equação define a quantidade de banda disponível r_{ij} para realizar replicações entre os sítios i e j , considerando a banda reservada aos caminhos secundários que passam pelo enlace entre i e j . Nessa equação, $\alpha \cdot W_{ij}$ representa a quantidade de banda do enlace alocada para todo o serviço de IaaS com backup contínuo. O parâmetro W_{ij} representa a capacidade do enlace, zero caso os sítios i e j não possuam um enlace entre si. Dessa forma, apenas sítios vizinhos de um salto poderão replicar backups entre si. O termo $\gamma \cdot B \cdot c_{km} \cdot s_{ij}^{km}$ é a quantidade de banda utilizada por um determinado caminho secundário entre dois sítios k e m , que passa pelo enlace entre i e j . Note que, nesse problema, a Eq. (12) é equivalente a fazer $r_{ij} = \min_{k,m \in \mathcal{D}}(\alpha W_{ij} - B \cdot c_{km} \cdot s_{ij}^{km})$. Isto é, de todos os caminhos secundários que passam por um determinado enlace, contabiliza-se em r_{ij} apenas aquele que consome a maior quantidade de banda. Isso é possível assumindo que nenhum enlace da rede falhe ao mesmo tempo e, dessa forma, apenas um caminho

secundário poderá estar ativo em todo o DC. Assim, em um determinado enlace, é necessário apenas reservar banda necessária para o pior caso de caminho secundário. Em outras palavras, os caminhos secundários são provisionados no esquema de proteção compartilhada [Ramamurthy et al., 2003]. O parâmetro γ da Eq. (12) é utilizado para desabilitar a utilização de caminhos secundários, liberando recursos do enlace para replicações. Dessa forma, se $\gamma = 0$ tem-se simplesmente $r_{ij} = \alpha \cdot W_{ij}$.

A Eq. (13) define os requisitos de latência da replicação contínua. Um sítio i só poderá replicar backups para o sítio j (ou seja, $e_{ij} = 1$) se o enlace entre eles possuir latência Δ_{ij} inferior ou igual à máxima latência permitida (L_{worst}). As Eqs. (14), (15) e (16) limitam o número de sítios escolhidos para instalar servidores primários ou de backup, com base no número máximo de sítios, U_{max} . Finalmente, as Eqs. (17) e (18) definem, respectivamente, o limitante inferior e o domínio de cada variável.

Alguns requisitos comuns em serviços IaaS não são considerados no problema, como a proximidade dos servidores primários com os usuários finais. Desconsideram-se esses requisitos neste trabalho para permitir uma melhor análise de um serviço com zero RPO, cujos principais requisitos são a independência das falhas entre servidores primários e seus respectivos backups, além da baixa latência de replicação entre eles. Como visto anteriormente, a baixa latência é importante, pois influencia diretamente o tempo de resposta das aplicações executando nas VMs dos servidores primários.

4. Avaliação

O problema de otimização formulado na Seção 3 é utilizado neste trabalho para posicionar servidores em WANs reais de educação e pesquisa. Essas redes são formadas por diversos pontos de presença (PoP - *Point of Presence*), que são os possíveis sítios do DC no contexto deste trabalho. Assim, são adotadas as topologias da RNP (Fig. 2(a)) no Brasil, RENATER (Fig. 2(b)) na França, e GEANT (Fig. 2(c)) na Europa. Cada figura das redes utilizadas mostra seus sítios e *gateways* de acesso à Internet.

A partir das topologias mencionadas, calcula-se os parâmetros de entrada do problema de otimização. O valor de latência Δ_{ij} de cada enlace é dado pelo atraso de propagação entre os sítios i e j . Considera-se que a rede é bem provisionada e, assim, os atrasos de fila e de transmissão são desprezíveis. O atraso de propagação é diretamente proporcional à distância entre os dois sítios, que é estimada neste trabalho como o comprimento de uma linha reta entre os centros das duas cidades que hospedam os sítios. Para o cálculo desse atraso utiliza-se uma velocidade de propagação de 2×10^8 m/s, comumente adotada para análise de redes ópticas [Couto et al., 2014a]. A Matriz de Independência de Falhas (matriz I) é calculada a partir do modelo de SRGs de falha única, adotado também em [Couto et al., 2014a]. Nesse modelo, apenas um enlace ou sítio da rede falha por vez. Note que, apesar do modelo de falha única, dois sítios podem se tornar inacessíveis ao mesmo tempo. Por exemplo, na rede da Fig. 2(a), se o sítio de Goiânia falhar, o sítio de Palmas também ficará inacessível. A capacidade W_{ij} de cada enlace é mostrada na Fig. 2. Esses valores foram obtidos no *website* oficial de cada uma das redes. A rede é modelada por um grafo direcionado, ou seja, a capacidade mostrada na figura corresponde à banda passante disponível em cada sentido do enlace entre dois sítios. Apesar de o grafo ser direcionado, considera-se no modelo de falhas que a ruptura de um determinado enlace representa a falha nos dois sentidos desse enlace.




Figura 2. Topologias de redes de ensino e pesquisa consideradas na avaliação.

O consumo de banda gerado pela replicação contínua de cada servidor operacional, dado pelo parâmetro B , é fixado em 240 Mbits/s. Esse valor foi retirado do trabalho no qual o SecondSite foi proposto [Rajagopalan et al., 2012], e corresponde aproximadamente ao consumo de banda ao replicar um servidor primário que hospeda quatro VMs, sendo duas executando um *benchmark* de servidor web e duas executando um *benchmark* de banco de dados. O valor de B escolhido neste trabalho é usado apenas como referência, podendo variar consideravelmente dependendo da aplicação em execução nas VMs. Assim, no projeto de DCs, B deverá ser especificado em função de um Acordo de Nível de Serviço (SLA - *Service Level Agreement*), no qual o provedor garantirá uma certa banda dedicada ao backup contínuo. Além disso, cada conjunto de servidores primários pode possuir um requisito diferente de banda de replicação, o que tornaria necessária a utilização de diferentes valores de B . O problema proposto pode ser facilmente modificado para considerar diferentes valores de B . Entretanto, optou-se por utilizar apenas um único valor de B para simplificar a análise. Outro parâmetro que foi fixado para todas as avaliações desta seção é o máximo número de sítios utilizados, dado por U_{max} . Fixou-se U_{max} no número total de sítios existentes, para não limitar o número de sítios utilizados.

Finalmente, salvo indicação contrária, o parâmetro γ é fixado em 1 na análise a seguir. Isso significa que o problema considera a utilização de caminhos secundários.

4.1. Capacidade do Serviço e Economia

A partir do problema proposto e dos parâmetros escolhidos anteriormente, analisa-se a capacidade do serviço de IaaS resiliente nas três redes consideradas. A capacidade do serviço, medida em número de servidores primários suportados, é analisada para diferentes valores de banda disponível (α) e diferentes valores de latência máxima tolerada (L_{worst}). A Fig. 3 apresenta os resultados para cada rede, na qual cada gráfico agrupa no eixo X diferentes valores de α e cada barra representa um L_{worst} diferente. O L_{worst} mais baixo (isto é, 1,3 ms) foi escolhido com base nos experimentos realizados no artigo do SecondSite [Rajagopalan et al., 2012], nos quais replica-se um servidor em um enlace de 260 km entre as cidades canadenses de Vancouver e Kamloop. Essa distância acarreta uma latência de 1,3 ms, considerando a velocidade de propagação utilizada neste trabalho. Os demais valores utilizados são relaxamentos dos requisitos de latência, representando o dobro e o quádruplo desse valor de referência. Os resultados da Fig. 3 mostram, como esperado, que quanto maior a banda reservada e quanto mais relaxado o requisito de latência, maior o número de servidores primários suportados. Note que na rede RENATER o número de servidores instalados não se altera ao relaxar o requisito de latência de 2,6 ms para 5,2 ms. Isso ocorre pois essa rede abrange a França metropolitana, uma área significativamente menor que a área coberta pelas outras redes. Assim, a maioria de seus enlaces já atende aos requisitos de latência quando $L_{worst} = 2,6$ ms.




Figura 3. Número de Servidores Primários.

A Fig. 4 mostra o resultado da economia de servidores de backup alcançada pela otimização do posicionamento. A economia é quantificada pela métrica Aproveitamento de Servidores (AS), definida como a relação entre o número de servidores de backup que não foram necessários instalar e o número total de servidores primários, dada por:

$$AS = \frac{\sum_{i \in \mathcal{D}} (x_i - b_i)}{\sum_{i \in \mathcal{D}} (x_i)} = 1 - \frac{\sum_{i \in \mathcal{D}} (b_i)}{\sum_{i \in \mathcal{D}} (x_i)}. \quad (19)$$

Assim, AS varia no intervalo $[0, 1]$, e quanto maior seu valor, maior a economia. A Fig. 4 mostra que, para todas as redes e todos os valores de α e L_{worst} avaliados, o aproveitamento é igual ou maior que 40%. Isso mostra que o posicionamento proposto possibilita uma economia significativa de servidores de backup nas WANs consideradas. Além disso, os resultados mostram que relaxar o requisito de latência pode melhorar a economia de servidores, visto que mais opções de posicionamento estarão disponíveis.




Figura 4. Economia de servidores físicos.

4.2. Caminhos Secundários

Como já visto, o posicionamento deste trabalho restringe o valor máximo de latência no enlace entre dois sítios que replicam backups entre si. Entretanto, o problema não restringe esse valor para os caminhos secundários. Isto significa que, caso o enlace de replicação entre dois sítios falhe, esses realizarão suas replicações entre si utilizando um caminho que poderá não atender aos requisitos de latência definidos por L_{worst} . Dessa forma, o tempo de resposta das aplicações que as VMs executam poderá aumentar. A Fig. 5 mostra características dos caminhos secundários, considerando apenas os caminhos entre sítios que replicam backups entre si. Essas características são extraídas da saída do problema de otimização de cada rede. Os resultados são apresentados para $\alpha = 0,05$, mas os valores alcançados para os outros valores de α considerados são muito próximos aos da Fig. 5. As Figs. 5(a), 5(b) e 5(c) apresentam a Função de Distribuição Cumulativa (CDF - *Cumulative Distribution Function*) da latência dos caminhos secundários para cada uma das redes utilizadas. Note que em todas as redes existem diversos caminhos secundários com valores de latência bem mais altos do que os valores L_{worst} especificados. Na RNP, alguns caminhos possuem valores de latência próximos a 20 ms. Para uma melhor visualização dessa característica, a Fig. 5(d) apresenta a fração de caminhos secundários que atendem ao requisito de latência L_{worst} . O eixo X agrupa os resultados obtidos com diferentes valores de L_{worst} para cada rede analisada. Note que o requisito mais estrito, de 1,3 ms, é atendido apenas por 40% dos caminhos na RENATER e por nenhum caminho da RNP e GEANT. Esse melhor desempenho da RENATER ocorre pois essa rede abrange uma área significativamente menor que as outras, como mencionado anteriormente. Para o requisito mais relaxado, de 5,6 ms, a RENATER é capaz de atender ao requisito L_{worst} em aproximadamente 90% dos caminhos. Apesar desse resultado favorável, as demais redes, e mesmo a própria RENATER para requisitos mais estritos, apresentam caminhos secundários com altos valores de latência. Isso mostra que apenas o posicionamento proposto não é suficiente para garantir baixos valores de latência nos caminhos secundários, e que a topologia da WAN deve ser modificada para oferecer tal serviço. Esse projeto da WAN é importante, sobretudo em redes que abrangem grandes áreas geográficas. Este trabalho foca o posicionamento de servidores, considerando que a WAN já está instalada. O alinhamento do posicionamento de servidores ao projeto da WAN, recomendado em [Couto et al., 2014b], é um tema de trabalho futuro.

Como os possíveis caminhos secundários da rede podem apresentar alta latência, o projetista do DC pode escolher não configurar esses caminhos, fazendo $\gamma = 0$ no problema formulado na Seção 3. Dessa forma, mais banda passante estará disponível para a




Figura 5. Características dos caminhos secundários ($\alpha = 0,05$).

instalação de servidores primários e seus respectivos backups. Por outro lado, se houver falha do enlace entre dois sítios que replicam entre si, os servidores primários correspondentes deverão ser pausados para evitar a execução de operações não replicadas. Essa estratégia, entretanto, diminui a disponibilidade dos servidores primários (isto é, a fração de tempo que permanecem operacionais). Outra estratégia é deixar o servidor primário em modo desprotegido (isto é, operacional, mas sem realizar backup), afetando os valores de RPO em prol da disponibilidade.

Para analisar o quanto a utilização de caminhos secundários reduz a capacidade de instalação de servidores primários, executou-se o problema com os mesmos parâmetros das seções anteriores, mas fazendo $\gamma = 0$. Denotando por S e S' , respectivamente, o número de servidores primários suportados em uma rede quando utilizam-se caminhos secundários ($\gamma = 1$) e quando esses não são utilizados ($\gamma = 0$), calcula-se a redução da capacidade pela expressão $1 - \frac{S}{S'}$. A Fig. 5(e) mostra, para as diferentes redes e requisitos de latência, o valor da redução quando a fração máxima da banda utilizada nos enlaces (isto é, α) é de 0,05. Os resultados mostram que os caminhos secundários reduzem significativamente a capacidade do serviço, sendo a redução superior a 50% para todos os resultados da Fig. 5(e). Os resultados para os outros valores de α , omitidos por questões de espaço, apresentam o mesmo comportamento, sendo sempre superiores a 50%. Assim, essa análise mostra que o projetista do DC pode aumentar significativamente a capacidade do serviço se escolher não utilizar caminhos secundários nas topologias consideradas.

5. Conclusões e Trabalhos Futuros

Neste trabalho foi proposto o posicionamento de servidores físicos em DCs geodistribuídos, através da formulação de um problema de otimização com objetivo de suportar serviço IaaS com zero RPO. Utilizando essa proposta, mostrou-se ser possível reduzir significativamente o número de servidores necessários, através do compartilhamento de servidores de backups. Os resultados para todas as redes consideradas obtiveram no mínimo

40% de economia no número de servidores. Tal economia pode ser ainda maior se os requisitos de latência forem relaxados. Este trabalho também apresentou as características do DC geodistribuído se forem configurados caminhos secundários entre sítios que realizam réplicas entre si. Esses caminhos são utilizados caso o enlace entre dois sítios falhe. Os resultados mostraram que os caminhos secundários podem apresentar alta latência, desrespeitando os requisitos do serviço de replicação. Por fim, mostra-se que a existência de caminhos secundários adiciona alta sobrecarga à rede, devido à quantidade necessária de banda reservada. Os resultados mostraram que, em todas as redes consideradas, seria possível adicionar pelo menos o dobro do número de servidores primários caso os caminhos secundários não fossem configurados.

Como trabalhos futuros, pretende-se propor um algoritmo de projeto da WAN que atue em conjunto com o posicionamento de servidores para, por exemplo, oferecer caminhos secundários com melhor qualidade. Outra direção promissora é considerar o posicionamento dos servidores que detectam falhas de forma a otimizar o tempo de recuperação das VMs e permitir uma detecção mais acurada.

Referências

- Bauer, E. e Adams, R. (2012). *Reliability and availability of cloud computing*. John Wiley & Sons.
- Couto, R. S., Secci, S., Campista, M. E. M. e Costa, L. H. M. K. (2014a). Latência versus sobrevivência no projeto de centros de dados geograficamente distribuídos. Em *XXXII SBRC*, p. 809—822.
- Couto, R. S., Secci, S., Campista, M. E. M. e Costa, L. H. M. K. (2014b). Network design requirements for disaster resilience in IaaS clouds. *IEEE Communications Magazine*, 52(10):52–58.
- Habib, M. F., Tornatore, M., De Leenheer, M., Dikbiyik, F. e Mukherjee, B. (2012). Design of disaster-resilient optical datacenter networks. *Journal of Lightwave Technology*, 30(16):2563–2573.
- Muller, L. F., Oliveira, R. R., Luizelli, M. C., Gaspar, L. P. e Barcellos, M. P. (2014). Survivor: an enhanced controller placement strategy for improving SDN survivability. Em *IEEE GLOBECOM*, p. 1944—1950.
- Rajagopalan, S., Cully, B., O'Connor, R. e Warfield, A. (2012). SecondSite: disaster tolerance as a service. Em *ACM Virtual Execution Environments (VEE)*, p. 97–108.
- Ramamurthy, S., Sahasrabudhe, L. e Mukherjee, B. (2003). Survivable WDM mesh networks. *Journal of Lightwave Technology*, 21(4):870.
- Wood, T., Cecchet, E., Ramakrishnan, K., Shenoy, P., Van der Merwe, J. e Venkataramani, A. (2010). Disaster recovery as a cloud service: Economic benefits & deployment challenges. Em *2nd USENIX Workshop on Hot Topics in Cloud Computing*.
- Xiao, J., Wen, H., Wu, B., Jiang, X., Ho, P.-H. e Zhang, L. (2014). Joint design on DCN placement and survivable cloud service provision over all-optical mesh networks. *IEEE Transactions on Communications*, 62(1):235–245.
- Yu, H., Anand, V., Qiao, C. e Sun, G. (2011). Cost efficient design of survivable virtual infrastructure to recover from facility node failures. Em *IEEE ICC*, p. 1–6.